

第一讲：多元函数微分学

目录

1 多元微分学概念导引	3
1.1 从一元微分到二元微分到多元微分，几何视角	3
1.2 向量场，曲线的切向量场，微分方程的向量场	9
1.3 向量场的变化率及其微分	14
2 第一节内容的技术性完善、补充及拓展	23
2.1 多元函数的极限与连续性	23
2.2 偏导数及其几何意义、高阶偏导	36
2.3 方向导数与梯度	43
2.4 全微分概念	50
2.5 全微分与切平面逼近，线性化的映射机制	57
2.6 多元复合函数的微分法——链式法则	64
2.7 隐函数求导，隐函数存在定理	83
3 应用篇	110
3.1 偏导、微分、梯度及隐函数存在定理在几何上的简单应用	110
3.2 全微分与积分因子	124
3.3 变量替换和坐标变换问题	128
3.4 函数相关及其判定 (*)	142
3.5 多元泰勒公式及其计算	147
3.6 多元函数的极值问题、最小二乘法	160
3.7 条件极值与拉格朗日乘子法	173
3.8 多元凸函数及其刻画、凸规划 (*)	189
3.9 梯度下降法、库恩-塔克条件与广义拉格朗日乘子 (*)	197

4 附录篇	204
4.1 附录一：从边界无边界谈起：一般流形概念简介	204
4.2 附录二：从方向导数谈起：一般流形上如何定义切向量?	208
4.3 附录三：对行列式求导	212
4.4 附录四：拉格朗日乘子的分析力学起源	215

第一讲：多元函数微分学

1 多元微分学概念导引

1.1 从一元微分到二元微分到多元微分，几何视角

一元函数微分学的研究对象是单变量函数，它由解析式 $y = f(x)$ 显性地 (*explicitly*) 给出，或通过关系 $F(x, y) = 0$ 隐性地 (*implicitly*) 给出. 其图像是 x - y 坐标平面上的函数曲线，或以映射角视角观之，给出了从 $\mathbb{R}$ (中函数的定义域) 到 $\mathbb{R}$ 的一个映射.

自然也需考虑多元函数. 以二元函数为例，它可由 $z = f(x, y)$ 显性地给出 (其中 $(x, y) \in D \subseteq \mathbb{R}^2$)，也可由关系 $F(x, y, z) = 0$ 隐性地确定. 其图形是 x - y - z 空间中的一个曲面，或以映射视角观之，它给出了从 $D \subseteq \mathbb{R}^2$ 到 $\mathbb{R}$ 的一个映射.


回忆一元微分学的核心：将 $y = f(x)$ 在某点 $x = x_0$ 线性化，即用 $x = x_0$ 点函数图形的切线 $y - y_0 = f'(x_0)(x - x_0)$ 来近似该点的图像 (“以直代曲”). 如此一来，给 x 在 $x = x_0$ 处一个增量 $\Delta x := x - x_0$ ，则对应函数值的增量 $\Delta f = f(x_0 + \Delta x) - f(x_0)$ 可用切线上对应增量来近似，即函数 $f(x)$ 在 x_0 处的线性近似 (*linear approximation*)，即

$$\Delta f \approx f'(x_0)\Delta x, \text{ i.e., } \Delta f = f'(x_0)\Delta x + o(\Delta x)$$

换言之， $f'(x_0)\Delta x$ 是函数 $f(x)$ 在 x_0 处增量 Δx 下变化 Δf 的线性主部，并将其称为函数 f 在 x_0 处的微分，记为 $df|_{x_0} = f'(x_0)\Delta x$. 显然，对线性函数 $y = x$ 本身求微分，有 $dy|_{x_0} = \Delta x = x - x_0$ ，故微分可表示为 $df|_{x_0} = f'(x_0)dx$. 更准确点说，就是：函数在某点处的微分 $df|_{x_0}$ 给出了一个将函数在该点处线性化的映射机制，它将 x_0 处的增量 $\Delta x = x - x_0$ 映射为由 Δx 引起的函数值实际改变 Δf 的线性主部 (线性近似)，即作为映射，有

$$df|_{x_0} : \mathbb{R} \longrightarrow \mathbb{R} \quad \Delta x := x - x_0 \longmapsto df|_{x_0}(\Delta x) := f'(x_0)\Delta x$$

亦即， $df|_{x_0}$ 是一个从 $\mathbb{R}$ 到 $\mathbb{R}$ 的线性变换 (*linear transformation*)，它由数乘导数值 $f'(x_0)$ 给出. 该线性变换即为将函数 $f(x)$ 在点 $x = x_0$ 处线性化的映射机制.



若函数 $y = f(x)$ 由关系 $F(x, y) = 0$ 决定, 则线性化可由隐函数求导 (微分) 给出, 即上式两边同时对 x 求导, 然后从中解出 $\frac{dy}{dx}$ 即可; 或者, 上式两边同时求微分 d , 然后利用一阶微分的形式不变性操作即可. 若将 $F(x, y)$ 中的 y 看成常数, 即将 $F(x, y)$ 看成是 x 的函数, 并记 F_x 为此函数对 x 的导函数; 同理, 将 $F(x, y)$ 中的 x 看成常数, 即将 $F(x, y)$ 看成是 y 的函数, 并记 F_y 为此函数对 y 的导函数, 则隐函数求导的法则可归结为如下形式

$$F(x, y) = 0 \xrightarrow{\text{两边作用以 } d} F_x dx + F_y dy = 0 \implies \frac{dy}{dx} = -\frac{F_x}{F_y}$$

特别地, 将函数 $y = f(x)$ 看做 $F(x, y) = 0$, 即 $F(x, y) = y - f(x)$, 则按上说明, 得到 $F_x = -f'(x)$, $F_y = 1$. 故

$$\frac{dy}{dx} = -\frac{F_x}{F_y} = -\frac{-f'(x)}{1} = f'(x) \quad \text{符合预期}$$

在 x_0 处, 设 $y_0 = f(x_0)$, 则 $dx = \Delta x = x - x_0$. 在微分关系 $F_x dx + F_y dy = 0$ 中, 如将 dy 也看成是 $\Delta y = y - y_0$, 并代入上关系, 即得


$$F_x(x_0, y_0)(x - x_0) + F_y(x_0, y_0)(y - y_0) = 0$$

它是 x - y 平面上过点 (x_0, y_0) 的直线方程, 它不是别的, 正是函数曲线 $F(x, y) = 0$ 在 (x_0, y_0) 处的切线方程! 事实上, 若 $F(x, y) = y - f(x)$, 则直线方程为

$$-f'(x_0)(x - x_0) + 1(y - y_0) = 0 \iff y - y_0 = f'(x_0)(x - x_0)$$

分析: 我们知道, 当 y 是一函数关系里的自变量时, $dy = \Delta y = y - y_0$ 才是合理的, 这启发我们提升维度看问题: 即将 x - y 平面上的曲线 $F(x, y) = 0$ 看成是 x - y - z 空间中的曲面 $z = F(x, y)$ 同 x - y 坐标平面 $z = 0$ 的交线, 即

$$F(x, y) = 0 \iff \begin{cases} z = F(x, y) \\ z = 0 \end{cases}$$



则不难想见: x - y 平面上曲线 $F(x, y) = 0$ 在 (x_0, y_0) 处的切线就是曲面 $z = F(x, y)$ 在 $(x_0, y_0, 0)$ 处的切平面与坐标平面 $z = 0$ 的交线. 为验证这一说法, 我们先得知道如何对由 $z = F(x, y)$ 定义的二元函数的曲面求切面的方法.

同一元情形做类比, 很快可得答案, 同时也就知道如何对二元函数微分了.

曲面切平面计算: 首先, 曲面 $z = F(x, y)$ 在 (x_0, y_0, z_0) 处的切平面是在该点附近与曲面只交于 (x_0, y_0, z_0) 的平面, 设切平面方程为 $A(x - x_0) + B(y - y_0) + C(z - z_0) = 0$, 则切平面方程由下方程组

$$\begin{cases} A(x - x_0) + B(y - y_0) + C(z - z_0) = 0 \\ z = F(x, y); \quad z_0 = F(x_0, y_0) \end{cases} \quad \text{有唯一解 } (x_0, y_0, z_0)$$

来确定. 化简之, 得 $A(x - x_0) + B(y - y_0) + C(F(x, y) - F(x_0, y_0)) = 0$ (*).

上式两边对 x 求导 (将 y 看成常数) 后令 $(x, y) = (x_0, y_0)$, 得 $A + CF_x(x_0, y_0) = 0$; 再对 y 求导 (将 x 看成常数) 后令 $(x, y) = (x_0, y_0)$, 得 $B + CF_y(x_0, y_0) = 0$, 即

$$A = -CF_x(x_0, y_0); \quad B = -CF_y(x_0, y_0)$$

代入平面方程 (*), 得 $-CF_x(x_0, y_0)(x - x_0) - CF_y(x_0, y_0)(y - y_0) + C(z - z_0) = 0$, 约去 C (请读者思考为何 $C \neq 0$), 即得切平面的方程为

$$z - z_0 = F_x(x_0, y_0)(x - x_0) + F_y(x_0, y_0)(y - y_0) \quad (**)$$

该平面与 x - y 坐标面: $z = 0$ 的交线 (此时 $z_0 = 0$) 即直线 $F_x(x - x_0) + F_y(y - y_0) = 0$, 证实我们的预期!

注记 1.1.1 上面两边对 x 求导这个操作的“微观”机制: 式子 (*) 两边同除 $x - x_0$, 得

$$A + B \frac{y - y_0}{x - x_0} + C \frac{F(x, y) - F(x_0, y_0)}{x - x_0} = 0$$

不妨先令 $y = y_0$, 然后令 $x \rightarrow x_0$, 则得到

$$A = -C \lim_{x \rightarrow x_0} \frac{F(x, y_0) - F(x_0, y_0)}{x - x_0} = -CF_x(x_0, y_0) \left(-C \frac{\partial F}{\partial x} \Big|_{(x_0, y_0)} \right)$$

同理, 可写出两边同时对 y 求导这一操作的具体机制.

注记 1.1.2 也可按此思路求平面曲线 $y = f(x)$ 在 $x = x_0$ 处的切线. 设切线方程为

$y - y_0 = k(x - x_0)$, 则 $\begin{cases} y = f(x); y_0 = f(x_0) \\ y - y_0 = k(x - x_0) \end{cases}$ 有唯一解 (x_0, y_0) . 第二个方程两边同时除以 $x - x_0$, 然后令 $x \rightarrow x_0$, 得

$$k = \lim_{x \rightarrow x_0} k = \lim_{x \rightarrow x_0} \frac{f(x) - f(x_0)}{x - x_0} = f'(x_0) \quad \text{预期之中!}$$

本质上就是切线（平面）作为割线（割面）极限的代数表达.

二元函数微分：将类比继续下去. 知道了曲线 $y = f(x)$ 在 x_0 处的切线 $y - y_0 = f'(x_0)(x - x_0)$, 相当于知道了函数 $y = f(x)$ 在 x_0 处的微分: $dy = f'(x_0)dx$, 即 x_0 点切线方向上计算出的增量 $\Delta x = x - x_0$ 下的增量 dy .

同理, 知道了曲面 $z = f(x, y)$ 在 (x_0, y_0, z_0) 处的切平面

$$z - x_0 = f_x(x_0, y_0)(x - x_0) + f_y(x_0, y_0)(y - y_0)$$

相当于知道了二元函数 $z = f(x, y)$ 在 $(x_0, y_0) \in \mathbb{R}^2$ 处的微分! 类似于一元情形, 我们用符号 $df = df|_{(x_0, y_0)}$ 记之, 则应有

$$dz = df|_{(x_0, y_0)} = f_x(x_0, y_0)(x - x_0) + f_y(x_0, y_0)(y - y_0)$$

按照一元函数情形, 自变量 x 的增量 $\Delta x = x - x_0$ 等同于 dx , 自变量 y 的增量 $\Delta y = y - y_0$ 等同于 dy , 并记 $P_0 = (x_0, y_0)$, 则上微分关系可简记为

$$df = f_x(P_0)dx + f_y(P_0)dy$$

其形式结构与一元情形时一致, 只是从一个变量 x 的线性函数 $f_x dx$ 提升为两个变量 x, y 的线性函数 $f_x dx + f_y dy$.

二元（全）微分作为线性映射： $df|_{P_0}$ 可看成是个线性映射

$$df|_{P_0} : \mathbb{R}^2 \rightarrow \mathbb{R} \quad (\Delta x, \Delta y) \mapsto f_x(P_0)\Delta x + f_y(P_0)\Delta y$$

即将平面上点 $P_0(x_0, y_0)$ 处两个独立方向的增量 $(\Delta x, \Delta y)$ 映为函数 $f(x, y)$ 在该增量下实际增量的线性近似（线性主部），用矩阵表示就是 $df|_{P_0} = [f_x(P_0) \ f_y(P_0)]$, 而线性映射则实现为如下矩阵乘法

$$df_{P_0}(\Delta x, \Delta y) = [f_x(P_0) \ f_y(P_0)] \begin{bmatrix} \Delta x \\ \Delta y \end{bmatrix}$$

我们知道 $y = f(x_0) + f'(x_0)\Delta x$ 作为 $y = f(x)$ 在 x_0 处线性近似（一阶近似）的含义是： $\Delta f = f(x) - f(x_0) - f'(x_0)\Delta x = o(\Delta x)$ ，即

$$\lim_{\Delta x \rightarrow 0} \frac{\Delta f - f'(x_0)\Delta x}{\Delta x} = \lim_{\Delta x \rightarrow 0} \frac{f(x) - f(x_0) - f'(x_0)\Delta x}{\Delta x} = 0$$

这也是 $y = f(x)$ 在 x_0 处可微（differentiable）的刻画。我们希望知道 $z = f(x, y)$ 在 $P_0 = (x_0, y_0)$ 处可微的类似刻画。也即，函数的实际增量（称为**全增量**） $\Delta z = \Delta f = f(x_0 + \Delta x, y_0 + \Delta y) - f(x_0, y_0)$ 同在其切平面上对应之增量 $f_x(P_0)\Delta x + f_y(P_0)\Delta y$ 的差异 $\Delta f - f_x(P_0)\Delta x - f_y(P_0)\Delta y$ 相对于什么量（须是一元情形 Δx 在二元时的自然推广），是在它趋于零时的更高阶无穷小？

对一元函数 $y = f(x)$ 而言， Δx 是衡量自变量 x 在 x -轴上接近于 $x = x_0$ 的程度的量，它越小，则说明 x 越接近于 x_0 。而对二元函数 $z = f(x, y)$ ，平面上的点 $P(x, y)$ 与给定点 $P_0(x_0, y_0)$ 的接近程度自然可由该两点之间的距离（distance） $\rho := \sqrt{(\Delta x)^2 + (\Delta y)^2}$ 来衡量，且在一维时它就退化为 $|\Delta x|$ 。由此可推广一元函数可微性概念。

二元函数可微性的刻画： $\exists$ 常数 A, B ，使得在 x_0 处， $\Delta f - A\Delta x - B\Delta y = o(\rho)$ ，即

$$\lim_{\rho \rightarrow 0} \frac{\Delta f - A\Delta x - B\Delta y}{\rho} = \lim_{(\Delta x, \Delta y) \rightarrow (0, 0)} \frac{\Delta f - A\Delta x - B\Delta y}{\sqrt{(\Delta x)^2 + (\Delta y)^2}} = 0$$

上面用到： $\rho = \sqrt{(\Delta x)^2 + (\Delta y)^2} \rightarrow 0$ 当且仅当 $(\Delta x, \Delta y) \rightarrow (0, 0)$ ，证明留给读者。

显然，若 $z = f(x, y)$ 在 $P_0(x_0, y_0)$ 处可微，则 A, B 唯一确定，且 $A = f_x(x_0, y_0)$ ； $B = f_y(x_0, y_0)$ 。这是因为：令 $\Delta y = 0$ ，则上极限变为

$$\lim_{\Delta x \rightarrow 0} \frac{\Delta f - A\Delta x}{\Delta x} = \lim_{x \rightarrow x_0} \frac{f(x_0 + \Delta x, y_0) - f(x_0, y_0) - A(x - x_0)}{x - x_0} = 0$$

从而 $A = f_x(x_0, y_0)$ ；同理知 $B = f_y(x_0, y_0)$ 。我们将会证明：对 $z = f(x, y)$ ，若 f_x 和 f_y 在 (x_0, y_0) 处存在且**连续的**，则 z 在 (x_0, y_0) 处可微。

一般 n -元函数情形： 设 $y = f(x_1, \dots, x_n)$ 是定义在 $\mathbb{R}^n$ 内某区域上的 n 元函数，若偏导数 $f_{x_1}, \dots, f_{x_n}$ 在 $P_0(x_1^0, \dots, x_n^0)$ 处存在且连续，则 y 在 P_0 可微，且其（全）微分为

$$dy|_{P_0} = f_{x_1}(P_0)dx_1 + \dots + f_{x_n}(P_0)dx_n$$

即

$$\lim_{\Delta x_i \rightarrow 0, i=1, \dots, n} \frac{f(x_1^0 + \Delta x_1, \dots, x_n^0 + \Delta x_n) - f(x_1^0, \dots, x_n^0) - \sum_{k=1}^n f_{x_k}(P_0)\Delta x_k}{\sqrt{(\Delta x_1)^2 + \dots + (\Delta x_n)^2}} = 0$$

其中**偏导数** (partial derivative) 的极限定义为

$$f_{x_k}(P_0) := \lim_{\Delta x_k \rightarrow 0} \frac{f(x_1^0, \dots, x_k^0 + \Delta x_k, \dots, x_n^0) - f(x_1^0, \dots, x_k^0, \dots, x_n^0)}{\Delta x_k}$$

作为映射, df 为从 $\mathbb{R}^n \ni (\Delta x_1, \dots, \Delta x_n)$ 到 $\mathbb{R} \ni dy$ 的线性映射, 其矩阵表示为

$$df|_{P_0} : \mathbb{R}^n \longrightarrow \mathbb{R} \quad df|_{P_0} \left(\begin{bmatrix} \Delta x_1 \\ \vdots \\ \Delta x_n \end{bmatrix} \right) \mapsto [f_{x_1}(P_0) \cdots f_{x_n}(P_0)] \begin{bmatrix} \Delta x_1 \\ \vdots \\ \Delta x_n \end{bmatrix}$$

注: 多元函数 $z = f(x_1, x_2, \dots, x_n)$ 相当于将每一个变量 x_i 的改变 $x_i \rightarrow x_i + \Delta x_i$ 引起的函数变化的线性部分 $f_{x_i}(P_0)\Delta x_i$ “叠加”起来, 得到全微分 $df|_{P_0} = \sum_{i=1}^n f_{x_i}(P_0) \Delta x_i$. 也就是说, 经过线性化后, 即在线性近似的意义下时, 函数值的变化 (微分 df) 是其各变量引起变化 (微分 $f_{x_i} dx_i$) 之和 $\sum_i f_{x_i} dx_i$. 这种“**叠加原理**”对线性现象是普遍成立的 (有物理背景的读者可在此处多寻思). 事实上, 对讨论线性对象的线性空间而言, 其核心刻画就是其中的向量在任意线性组合下还是其中的向量.

隐函数情形: 若二元函数 $z = f(x, y)$ 由关系 $F(x, y, z) = 0$ 隐在地决定, 则按照一元时的章法, 求其微分或切平面方程, 可通过对方程两边同时微分确定, 即

$$dF|_{P_0} = F_x(P_0)dx + F_y(P_0)dy + F_z(P_0)dz = 0 \quad (***)$$

$$\Rightarrow \quad dz = -\frac{F_x(P_0)}{F_z(P_0)}dx - \frac{F_y(P_0)}{F_z(P_0)}dy$$

即知 $f_x = -\frac{F_x}{F_z}$, $f_y = -\frac{F_y}{F_z}$. 而曲面 $F(x, y, z) = 0$ 在 $P_0(x_0, y_0, z_0)$ 的切平面方程相当于在 (***) 中令 dx 为 $\Delta x = x - x_0$, dy 为 $\Delta y = y - y_0$, dz 为 $\Delta z = z - z_0$, 即

$$\boxed{F_x(P_0)(x - x_0) + F_y(P_0)(y - y_0) + F_z(P_0)(z - z_0) = 0}$$

以通常 $z = f(x, y)$ 为例, 它对应 $F(x, y, z) = z - f(x, y) = 0$, 显然 $F_x = -f_x$, $F_y = -f_y$, $F_z = 1$, 从而微分为


$$dz = -\frac{-f_x(x_0, y_0)}{1}dx - \frac{-f_y(x_0, y_0)}{1}dy = f_x(x_0, y_0)dx + f_y(x_0, y_0)dy$$

切线方程: $-f_x(x_0, y_0)(x - x_0) - f_y(x_0, y_0)(y - y_0) + 1(z - z_0) = 0$, 与先前按定义求解得到的完全一致.

1.2 向量场, 曲线的切向量场, 微分方程的向量场


向量场的概念: 向量是由方向有长度的量, 而空间中的向量场 (*vector field*) 是指空间每一点处都有一个向量与之对应. 特别地, 平面向量场是指对平面某区域 $D \subseteq \mathbb{R}^2$ 上的每点 $M(x, y, z)$, 都有一向量 $\mathbf{v} = (P(x, y), Q(x, y))$ 与之对应, 可将其形象化为以点 M 为顶点, 指向 $\mathbf{v}$, 模长为 $\sqrt{P^2 + Q^2}$ 的箭头.

例 1.2.1 考察平面向量场 $\mathbf{v} = (x, y)$, 也就是说点 $M(x, y)$ 处有向量 $(x, y) = x\mathbf{i} + y\mathbf{j}$, 其中 $\mathbf{i} = (1, 0)$, $\mathbf{j} = (0, 1)$. 该向量场的图示如下:



像从原点往各向发射的力场, 距中心越远, 场强 (向量模长) 越大.


例 1.2.2 考察平面向量场 $\mathbf{v} = (-y, x)$. 这个向量场的图示如下:



它像绕原点逆时针旋转的一“风场”, 且离开原点越远, “风力”越强. 而下例中的向量场描述的“风场”也是逆旋的, 只是当远离暴风中心时, 风力会变弱.

例 1.2.3 考察平面向量场 $\mathbf{v} = \left(\frac{-y}{x^2 + y^2}, \frac{x}{x^2 + y^2} \right)$, 其图示如下:

注意这个向量场在原点处是“奇异” (*singular*) 的, 或说原点是它的一个奇点 (*singularity*) .




以映射视角看之, 平面区域 D 上的向量场 $\mathbf{v} = (P(x, y), Q(x, y))$ 可看成是映射

$$\mathbf{v} : D \subseteq \mathbb{R}^2 \longrightarrow \mathbb{R}^2 \quad (x, y) \longmapsto (P(x, y), Q(x, y))$$


类似地, 任何从空间区域 $\Omega \subseteq \mathbb{R}^3$ 到 $\mathbb{R}^3$ 的下面映射都可以看成是定义了空间区域 Ω 上的一个向量场 $\mathbf{v}$.

$$\mathbf{v} : \Omega \subseteq \mathbb{R}^3 \longrightarrow \mathbb{R}^3 \quad (x, y, z) \longmapsto (P(x, y, z), Q(x, y, z), R(x, y, z))$$

例 1.2.1' 考察空间向量场 $\mathbf{v} = (x, y, z)$, 其图示如下:



例 1.2.2' 考察空间向量场 $\mathbf{v} = (-y, x, 1)$, 其图示如下:




为了更好地理解向量场及其生成机制, 我们定义并刻画曲线的切向量.

曲线的切线：给定一空间曲线的参数描述 $\Gamma: \begin{cases} x = x(t) \\ y = y(t) \\ z = z(t) \end{cases} \quad t \in I$. 假设 $x(t), y(t), z(t)$

对 t 是可微函数. 记 $P_0(x_0, y_0, z_0)$ 是曲线上对应参数 t_0 的点, 问题是如何确定曲线 Γ 在 P_0 处的切线?

法一：设切线 L 的方向向量为 $\mathbf{u} = (l, m, n)$, 则其参数式方程为 $L: \begin{cases} x = x_0 + ls \\ y = y_0 + ms \\ z = z_0 + ns \end{cases} \quad s \in \mathbb{R}$.

在 P_0 点的近旁, L 与 Γ 只交于点 P_0 , 故方程 $\begin{cases} x(t) - x(t_0) = ls \\ y(t) - y(t_0) = ms \\ z(t) - z(t_0) = ns \end{cases}$ 当参数 t, s 靠近 t_0 时的解只有 $s = 0, t = t_0$.



令直线参数 s 为 $s = t - t_0$, 则当 $t = t_0$ 时, $s = 0$. 将上方程两边同时除以 $s = t - t_0$, 然后令 $t \rightarrow t_0$, 得

$$l = \lim_{t \rightarrow t_0} \frac{x(t) - x(t_0)}{t - t_0} = x'(t_0); \quad m = \lim_{t \rightarrow t_0} \frac{y(t) - y(t_0)}{t - t_0} = y'(t_0); \quad n = \lim_{t \rightarrow t_0} \frac{z(t) - z(t_0)}{t - t_0} = z'(t_0)$$


即曲线 Γ 上 P_0 处的切线方向为 $\mathbf{u} = (x'(t_0), y'(t_0), z'(t_0))$, 称为曲线 Γ 在 P_0 处的切向量 (或切矢, *tangent vector*).

注记 1.2.1 对上曲线 Γ , 记其径矢为 $\mathbf{r}(t) = (x(t), y(t), z(t))$, 则曲线 Γ 可看出是一个向量场, 即其径矢场.

定义 1.2.1 曲线 Γ 上每点的切向量构成的向量场称为曲线的切向量场. 若曲线为 $\Gamma: \mathbf{r}(t) = (x(t), y(t), z(t))$, 则其切向量场为 $\mathbf{r}'(t) = (x'(t), y'(t), z'(t))$.

法二：将曲线 Γ 视作两平面 $\Sigma_i, i = 1, 2$ 的交曲线 $\Sigma_1 \cap \Sigma_2$. 其中 $\Sigma_1: \begin{cases} x = x(t) \\ y = y(t) \end{cases}$,

它描述了一个以 x - y 平面上曲线 $\Gamma_1: \begin{cases} x = x(t) \\ y = y(t) \end{cases}$ 为准线, 以 $\mathbf{k} = (0, 0, 1)$ 为母线方向的柱面; $\Sigma_2: \begin{cases} y = y(t) \\ z = z(t) \end{cases}$, 它描述了一个以 y - z 平面上曲线 $\Gamma_2: \begin{cases} y = y(t) \\ z = z(t) \end{cases}$ 为准线, 以 $\mathbf{i} = (1, 0, 0)$ 为母线方向的柱面.



那么曲线 Γ 在 $P_0(x_0, y_0, z_0)$ 处的切线 L 为曲面 $\Sigma_i, i = 1, 2$ 在 P_0 处切平面 $\pi_i, i = 1, 2$ 的交直线 (见上图所示) .

柱面 Σ_1 的方程由 $\begin{cases} x_1 = x(t_1), y_1 = x(t_1), z_1 = 0 \\ x = x_1, y = y_1, z = t \end{cases}$ 消去 x_1, y_1, z_1, t 后得到的方程决定, 即 $\Sigma_1: \begin{cases} x = x(t), y = y(t) \\ z \text{ 任意} \end{cases}$; 同理可知柱面 $\Sigma_2: \begin{cases} y = y(t), z = z(t) \\ x \text{ 任意} \end{cases}$

则 Σ_1 和 Σ_2 在其公共交点 $P_0(x_0, y_0, z_0)$ 处的法向量分别为

$$\mathbf{n}_1 = (-y'(t_0), x'(t_0), 0); \quad \mathbf{n}_2 = (0, -z'(t_0), y'(t_0))$$

知切平面的方程分别为: $\begin{aligned} \pi_1: -y'(t_0)(x - x_0) + x'(t_0)(y - y_0) &= 0 \\ \pi_2: -z'(t_0)(y - y_0) + y'(t_0)(z - z_0) &= 0 \end{aligned}$ 联立解得

$$\frac{x - x_0}{x'(t_0)} = \frac{y - y_0}{y'(t_0)} = \frac{z - z_0}{z'(t_0)}$$

故切线 L 的参数方程为 $\begin{cases} x = x_0 + x'(t_0)t \\ y = y_0 + y'(t_0)t \\ z = z_0 + z'(t_0)t \end{cases}$ 即知 Γ 在 t_0 对应点 P_0 处的切向量
为 $\mathbf{u} = (x'(t_0), y'(t_0), z'(t_0))$.


作为曲线切向量场的应用, 下面将前面几例向量场实现为曲线族的切向量场. 这些曲线族将作为对应微分方程的积分曲线给出, 故切向量场也称为微分方程的向量场.

考虑例 1.2.1 中的平面向量场 $\mathbf{v} = (x, y)$, 设它是平面曲线 $\begin{cases} x = x(t) \\ y = y(t) \end{cases}$ 的切矢场,

则有 $\begin{cases} \frac{dx}{dt} = x(t) \\ \frac{dy}{dt} = y(t) \end{cases}$, 即 $\frac{dy}{dx} = \frac{y}{x}$, 分离变量然后积分之, 得其通解为 $y = Cx$.

故积分曲线描述了平面上过原点的直线族, 其切向量场之全体显然是给定向量场 $\mathbf{v}$. 换言之, 向量场 $\mathbf{v}$ 是微分方程 $\frac{dy}{dx} = \frac{y}{x}$ 的向量场.

对例 1.2.2 中的平面向量场 $\mathbf{w} = (-y, x)$, 它对应的微分方程为 $\frac{dy}{dx} = -\frac{x}{y}$, 通解为: $x^2 + y^2 = C$. 该积分曲线族的切向量场即为给定旋转向量场 $\mathbf{v}$.



注记 1.2.2 上面两个例子中的向量场是正交的, 即任一点 (x, y) 处, 有

$$\mathbf{v} \bullet \mathbf{w} = (x, y) \bullet (-y, x) = 0$$

反应在对应积分曲线上, 可见两族积分曲线在交点处是**正交** (orthogonal) 的, 即对应切向量在交点处是正交的.

最后再看例 1.2.3 中的“奇异”向量场 $\mathbf{v} = \left(\frac{-y}{x^2 + y^2}, \frac{x}{x^2 + y^2} \right)$, 其积分曲线:

$\mathbf{r}(t) = (x(t), y(t))$ 须满足方程 $\begin{cases} \frac{dx}{dt} = \frac{-y}{x^2 + y^2} \\ \frac{dy}{dt} = \frac{x}{x^2 + y^2} \end{cases}$ 由于 $\mathbf{v}$ 在 $(0, 0)$ 处无定义, 故不能直接转化为 $dy/dx = -x/y$ 求解.

为顾及原点的“奇异性”, 我们转用极坐标 (ρ, θ) 来处理该微分方程. 它与直角坐标 (x, y) 的关系为 $\begin{cases} x = \rho \cos \theta \\ y = \rho \sin \theta \end{cases}$ 将 x, y 分别看成是 (ρ, θ) 的二元函数, 则由全微分公式, 知

$$\begin{cases} dx = x_\rho d\rho + x_\theta d\theta = \cos \theta d\rho - \rho \sin \theta d\theta \\ dy = y_\rho d\rho + y_\theta d\theta = \sin \theta d\rho + \rho \cos \theta d\theta \end{cases}$$

$$\text{从而} \quad \begin{cases} \frac{dx}{dt} = \cos \theta \frac{d\rho}{dt} - \rho \sin \theta \frac{d\theta}{dt} \\ \frac{dy}{dt} = \sin \theta \frac{d\rho}{dt} + \rho \cos \theta \frac{d\theta}{dt} \end{cases} \Rightarrow \begin{cases} \frac{d\rho}{dt} = 0 \\ \rho \frac{d\theta}{dt} = \frac{1}{\rho} \end{cases} \Rightarrow \begin{cases} \rho = C_1 (\neq 0) \\ \theta = \frac{t}{C_1^2} + C_2 \end{cases}$$

积分曲线为一族圆，只是不同半径（ C_1 ）圆上点运动的角速度 $\frac{d\theta}{dt} = \frac{1}{C_1^2}$ 与半径平方成反比，符合我们对对应向量场的直观感受。

1.3 向量场的变化率及其微分

给定空间某区域 $\Omega \subseteq \mathbb{R}^3$ 上的向量场 $\mathbf{v} = (P(x, y, z), Q(x, y, z), R(x, y, z))$. 下面考察当点在区域 Ω 内变动时，该向量场的变化速率问题，即对向量场如何求导或微分. 下面假设分量 P, Q, R 对 x, y, z 都是可微的.

固定一点 $M_0(x_0, y_0, z_0)$, 当从 M_0 移动到其近旁的点 $M(x, y, z) = M(x_0 + \Delta x, y_0 + \Delta y, z_0 + \Delta z)$ 时，向量场从 $\mathbf{v}(M_0)$ 变动到 $\mathbf{v}(M)$, 为计算其变差 $\Delta \mathbf{v} = \mathbf{v}(M) - \mathbf{v}(M_0)$, 不妨设点是沿着曲线 $\mathbf{r}(t) = (x(t), y(t), z(t))$ 从 M_0 移动到 M 点的，即可设 M_0 的坐标为 $(x(t_0), y(t_0), z(t_0))$, M 的坐标为 $(x(t_0 + \Delta t), y(t_0 + \Delta t), z(t_0 + \Delta t))$.

则向量场 $\mathbf{v}$ 沿着曲线 $\mathbf{r}(t)$ 从 M_0 变到 M 的改变量为 $\Delta \mathbf{v} = \mathbf{v}(M) - \mathbf{v}(M_0) =$

$$= (P(M), Q(M), R(M)) - (P(M_0), Q(M_0), R(M_0))$$

$$= (P(M) - P(M_0), Q(M) - Q(M_0), R(M) - R(M_0))$$

那么，向量场 $\mathbf{v}$ 沿着曲线 $\mathbf{r}(t)$ 在 M_0 点的（瞬时）变化速率向量为

$$\left. \frac{d\mathbf{v}}{dt} \right|_{t_0} := \lim_{\Delta t \rightarrow 0} \frac{\Delta \mathbf{v}}{\Delta t} = \lim_{\Delta t \rightarrow 0} \left(\frac{\Delta P}{\Delta t}, \frac{\Delta Q}{\Delta t}, \frac{\Delta R}{\Delta t} \right) = \left(\left. \frac{dP}{dt} \right|_{t_0}, \left. \frac{dQ}{dt} \right|_{t_0}, \left. \frac{dR}{dt} \right|_{t_0} \right)$$

$$\begin{aligned} \text{而 } \left. \frac{dP}{dt} \right|_{t_0} &= \lim_{\Delta t \rightarrow 0} \frac{P(x(t_0 + \Delta t), y(t_0 + \Delta t), z(t_0 + \Delta t)) - P(x(t_0), y(t_0), z(t_0))}{\Delta t} \\ &= \lim_{\Delta t \rightarrow 0} \frac{P(x(t_0 + \Delta t), y(t_0 + \Delta t), z(t_0 + \Delta t)) - P(x(t_0), y(t_0 + \Delta t), z(t_0 + \Delta t))}{\Delta t} \\ &\quad + \lim_{\Delta t \rightarrow 0} \frac{P(x(t_0), y(t_0 + \Delta t), z(t_0 + \Delta t)) - P(x(t_0), y(t_0), z(t_0 + \Delta t))}{\Delta t} \\ &\quad + \lim_{\Delta t \rightarrow 0} \frac{P(x(t_0), y(t_0), z(t_0 + \Delta t)) - P(x(t_0), y(t_0), z(t_0))}{\Delta t} \end{aligned}$$

$$\begin{aligned}
&= \lim_{\Delta t \rightarrow 0} \frac{P(x(t_0 + \Delta t), y(t_0 + \Delta t), z(t_0 + \Delta t)) - P(x(t_0), y(t_0 + \Delta t), z(t_0 + \Delta t))}{x(t_0 + \Delta t) - x(t_0)} \frac{\Delta x}{\Delta t} \\
&\quad + \lim_{\Delta t \rightarrow 0} \frac{P(x(t_0), y(t_0 + \Delta t), z(t_0 + \Delta t)) - P(x(t_0), y(t_0), z(t_0 + \Delta t))}{y(t_0 + \Delta t) - y(t_0)} \frac{\Delta y}{\Delta t} \\
&\quad + \lim_{\Delta t \rightarrow 0} \frac{P(x(t_0), y(t_0), z(t_0 + \Delta t)) - P(x(t_0), y(t_0), z(t_0))}{z(t_0 + \Delta t) - z(t_0)} \frac{\Delta z}{\Delta t} \\
&\Rightarrow \left. \frac{dP}{dt} \right|_{t_0} = P_x(x_0, y_0, z_0)x'(t_0) + P_y(x_0, y_0, z_0)y'(t_0) + P_z(x_0, y_0, z_0)z'(t_0) \\
&\text{同理 } \left. \frac{dQ}{dt} \right|_{t_0} = Q_x(x_0, y_0, z_0)x'(t_0) + Q_y(x_0, y_0, z_0)y'(t_0) + Q_z(x_0, y_0, z_0)z'(t_0) \\
&\text{且 } \left. \frac{dR}{dt} \right|_{t_0} = R_x(x_0, y_0, z_0)x'(t_0) + R_y(x_0, y_0, z_0)y'(t_0) + R_z(x_0, y_0, z_0)z'(t_0)
\end{aligned}$$

注意到： $\mathbf{u} = (x'(t_0), y'(t_0), z'(t_0))$ 是曲线 $\mathbf{r}(t)$ 在 M_0 处的切向量. 上计算表明：向量场沿着曲线在 M_0 处的变化率只依赖于曲线在该点的切向量 $\mathbf{u}$. 换言之，过 M_0 的不同曲线若在 M_0 的切向量一致，则向量场沿它们在 M_0 的变化率便相同，故有

定义 1.3.1 空间向量场 $\mathbf{v}$ 在点 M_0 处沿方向 $\mathbf{u}$ 的变化率（导函数）为它沿着任意在 M_0 的切方向为 $\mathbf{u}$ 的曲线变动时在 M_0 处的变化率.

定义 1.3.2 给定一函数 $w = f(x, y, z)$, 若偏导数 f_x, f_y, f_z 都存在, 则称向量场 (f_x, f_y, f_z) 为函数 w 的梯度场 (gradient field), 并记之为 ∇f , 即 $\nabla f = (f_x, f_y, f_z)$. 梯度场在某点处的取值 $\nabla f|_M$ 为函数在该点的梯度 (gradient).

注记 1.3.1 梯度场 ∇f 有时也记作 $\text{grad } f$. 在这些记号下，上面的计算结果简记为

$$\left. \frac{dP}{dt} \right|_{t_0} = \nabla P|_{M_0} \bullet \mathbf{u}; \quad \left. \frac{dQ}{dt} \right|_{t_0} = \nabla Q|_{M_0} \bullet \mathbf{u}; \quad \left. \frac{dR}{dt} \right|_{t_0} = \nabla R|_{M_0} \bullet \mathbf{u}$$

定理 1.3.1 空间向量场 $\mathbf{v} = (P(x, y, z), Q(x, y, z), R(x, y, z))$ 在点 $M_0 = (x_0, y_0, z_0)$ 处沿方向 $\mathbf{u}$ 的变化率由一个三维向量 $D\mathbf{v}$, 它由下给出

$$D\mathbf{v}|_{\mathbf{u}} = (\nabla P|_{M_0} \bullet \mathbf{u}, \nabla Q|_{M_0} \bullet \mathbf{u}, \nabla R|_{M_0} \bullet \mathbf{u})$$

特别地，对平面向量场 $\mathbf{v} = (P(x, y), Q(x, y))$, 它在 $M_0(x_0, y_0)$ 点沿方向 $\mathbf{u} = (u_x, u_y)$ 的变化率由向量 $D\mathbf{v}|_{\mathbf{u}} = (\nabla P|_{M_0} \bullet \mathbf{u}, \nabla Q|_{M_0} \bullet \mathbf{u})$ 衡量，其中 $\nabla P = (P_x, P_y)$, $\nabla Q = (Q_x, Q_y)$ 为二元函数的梯度场.

注记 1.3.2 向量场的“速率” $D\mathbf{v}|_{\mathbf{u}}$ 的每个分量衡量的是向量场 $\mathbf{v}$ 的对应分量沿着方向

$\mathbf{u}$ 在 M_0 点的变化率，它们整合为可完备描述向量场各分量变化的向量 $D\mathbf{v}$ 。这是自然的：向量场的变化是由其各分量变化而引起的，故衡量其沿某方向的变化速率自然要考虑其各分量沿该方向的变化速率之**线性叠加**，下面将讨论其矩阵表示。

映射视角：将向量场 $\mathbf{v} = (P(x, y, z), Q(x, y, z), R(x, y, z))$ 看成是映射，即

$$\mathbf{v} : \Omega \subseteq \mathbb{R}^3 \longrightarrow \mathbb{R}^3 \quad (x, y, z) \longmapsto (P(x, y, z), Q(x, y, z), R(x, y, z))$$

由定理 1.3.1 知其变化速率信息完全由以下九个偏导数决定：

$$P_x, P_y, P_z; Q_x, Q_y, Q_z; R_x, R_y, R_z$$

有了函数变化速率（导数）信息，也就知道函数的微分（当然前提条件是函数可微），如对 $y = f(x)$ ，知道 $f'(x_0)$ ，即知其微分 $dy = f'(x_0)dx$ ；对二元函数 $z = f(x, y)$ ，知道偏导数信息 f_x, f_y ，便知其（全微分） $dz = f_x dx + f_y dy$ 等等。

同样地，我们希望将上述九个偏导数信息整合为微分结构，然后推而广之。

我们从分析 $D\mathbf{v}|_{\mathbf{u}} = (\nabla P|_{M_0} \bullet \mathbf{u}, \nabla Q|_{M_0} \bullet \mathbf{u}, \nabla R|_{M_0} \bullet \mathbf{u})$ 的结构开始，注意到：梯

度向量 $\nabla P|_{M_0}$ 和方向 $\mathbf{u}$ 的点乘可用矩阵乘法表示为 $[P_x(M_0) \ P_y(M_0) \ P_z(M_0)] \begin{bmatrix} u_x \\ u_y \\ u_z \end{bmatrix}$,

受此启发， $D\mathbf{v}|_{\mathbf{u}}$ 可按矩阵乘法整理为如下格式

$$D\mathbf{v}|_{\mathbf{u}} = \begin{bmatrix} P_x(M_0) & P_y(M_0) & P_z(M_0) \\ Q_x(M_0) & Q_y(M_0) & Q_z(M_0) \\ R_x(M_0) & R_y(M_0) & R_z(M_0) \end{bmatrix} \begin{bmatrix} u_x \\ u_y \\ u_z \end{bmatrix}$$

记上矩阵为 $J_{\mathbf{v}}(M_0)$ ，可将其解释为对向量场 $\mathbf{v}$ 的**微分**（映射），或其线性化映射

$$D\mathbf{v}|_{M_0} : \mathbb{R}^3 \longrightarrow \mathbb{R}^3 \quad \mathbf{u} = \begin{bmatrix} u_x \\ u_y \\ u_z \end{bmatrix} \longmapsto J_{\mathbf{v}}(M_0) \cdot \mathbf{u}$$

通常称矩阵 $J_{\mathbf{v}}(M_0)$ 为向量场 $\mathbf{v}$ （作为映射，或向量值函数）在 M_0 点处的导数或雅可比矩阵（*Jacobi matrix*），它表示了对向量场的微分，即 $D\mathbf{v}|_{\mathbf{u}} = J_{\mathbf{v}}(M_0) \cdot \mathbf{u}$ 。也就是说， $D\mathbf{v}|_{M_0}$ 作为映射，它将 M_0 处（任意曲线的）任意切方向 $\mathbf{u}$ ，映射为向量场 $\mathbf{v}$ 在该点沿该方向 $\mathbf{u}$ 的变化率（向量）：

$$D\mathbf{v}|_{\mathbf{u}} = D\mathbf{v}|_{M_0}(\mathbf{u}) = J_{\mathbf{v}}(M_0) \cdot \mathbf{u}$$

注记 1.3.3 在上面的诠释背景下, 函数 $y = f(x)$ 在 x_0 点的微分 $df|_{x_0} = f'(x_0)dx$ 可理解为: 它将 x_0 点处的一增量 $dx = \Delta x = x - x_0$ 映射为对应切线上的增量 $f'(x_0)\Delta x$. 这一线性映射的 *Jacobi* 矩阵是 1×1 阶矩阵 $[f'(x_0)]$, 我们将 Δx 看成是 x -轴上 x_0 点处的一切向量. 二元函数 $z = f(x, y)$ 在 $M_0(x_0, y_0)$ 处的微分 $df|_{M_0} = f_x(M_0)dx + f_y(M_0)dy$ 可解释为以下线性映射

$$df|_{M_0} : \mathbb{R}^2 \longrightarrow \mathbb{R} \quad \begin{bmatrix} \Delta x \\ \Delta y \end{bmatrix} \longmapsto \underbrace{[f_x(M_0) \quad f_y(M_0)]}_{J_f(M_0)} \begin{bmatrix} \Delta x \\ \Delta y \end{bmatrix} = \nabla f|_{M_0} \bullet \begin{bmatrix} \Delta x \\ \Delta y \end{bmatrix}$$

该映射的 *Jacobi* 矩阵 $J_f(M_0)$ 是 1×2 阶矩阵, 它实现了从 $\mathbb{R}^2$ 到 $\mathbb{R}$ 的线性映射, 即二元函数在 M_0 点处的线性化机制, 它将 M_0 点处的自变量增(向)量: $(\Delta x, \Delta y)$ 映射为函数 f 相应增量的线性近似(主部). 可将增(向)量 $(\Delta x, \Delta y)$ 的一个 M_0 点处(某曲线)的切方向, 则将 $df|_{M_0} \left(\begin{bmatrix} \Delta x \\ \Delta y \end{bmatrix} \right) = \nabla f|_{M_0} \bullet \begin{bmatrix} \Delta x \\ \Delta y \end{bmatrix}$ 解释为 $f(x, y)$ 在 M_0 处沿 $(\Delta x, \Delta y)$ 的变化率.

更一般地, 将 n -元函数 $y = f(x_1, x_2, \dots, x_n) : D \subseteq \mathbb{R}^n \longrightarrow \mathbb{R}$ 在 $\mathbf{x}_0 = (x_1^0, x_2^0, \dots, x_n^0)$ 处的(全)微分 $df|_{\mathbf{x}_0} = f_{x_1}(\mathbf{x}_0)dx_1 + f_{x_2}(\mathbf{x}_0)dx_2 + \dots + f_{x_n}(\mathbf{x}_0)dx_n$ 理解为如下线性映射

$$df|_{\mathbf{x}_0} : \mathbb{R}^n \longrightarrow \mathbb{R} \quad \Delta \mathbf{x} := \begin{bmatrix} \Delta x_1 \\ \Delta x_2 \\ \vdots \\ \Delta x_n \end{bmatrix} \longmapsto \underbrace{[f_{x_1}(\mathbf{x}_0) \quad f_{x_2}(\mathbf{x}_0) \quad \dots \quad f_{x_n}(\mathbf{x}_0)]}_{\nabla f|_{\mathbf{x}_0} \bullet \Delta \mathbf{x}} \begin{bmatrix} \Delta x_1 \\ \Delta x_2 \\ \vdots \\ \Delta x_n \end{bmatrix}$$

此时, f 在 $\mathbf{x}_0$ 处的 *Jacobi* 矩阵 $J_f(\mathbf{x}_0) = [f_{x_1}(\mathbf{x}_0) \quad f_{x_2}(\mathbf{x}_0) \quad \dots \quad f_{x_n}(\mathbf{x}_0)]$ 等同于 f 在 $\mathbf{x}_0$ 处的梯度向量 $\nabla f|_{\mathbf{x}_0}$.

而 $df|_{\mathbf{x}_0}(\Delta \mathbf{x}) = J_f(\mathbf{x}_0) \cdot \Delta \mathbf{x} = \nabla f|_{\mathbf{x}_0} \bullet \Delta \mathbf{x}$, 它一方面表示 f 在 $\mathbf{x}_0$ 处给点增量 $\Delta \mathbf{x}$ 下的函数增量 Δf 的线性主部; 另一方面, $df|_{\mathbf{x}_0}(\Delta \mathbf{x})$ 也可理解为是衡量 f 在 $\mathbf{x}_0$ 处相对于 $\Delta \mathbf{x}$ 的变化率的量.

最一般地, 考虑 $D \subseteq \mathbb{R}^n$ 上取值于 $\mathbb{R}^m$ 的函数, 即一般向量值函数 (*vector-valued function*) 或一般映射

$$\mathbf{f} : D \subseteq \mathbb{R}^n \longrightarrow \mathbb{R}^m \quad \mathbf{x} = (x_1, x_2, \dots, x_n) \longmapsto \mathbf{y} = \mathbf{f}(\mathbf{x}) = (y_1, y_2, \dots, y_m)$$

$$\text{其坐标分量函数为: } \begin{cases} y_1 = f_1(x_1, x_2, \dots, x_n) \\ y_2 = f_2(x_1, x_2, \dots, x_n) \\ \dots \\ y_m = f_m(x_1, x_2, \dots, x_n) \end{cases} \quad \mathbf{x} = (x_1, x_2, \dots, x_n) \in D \subseteq \mathbb{R}^n.$$

定义 1.3.3 给定区域 D 内一点 $\mathbf{x}_0 = (x_1^0, x_2^0, \dots, x_n^0)$, 称 $\mathbf{f}$ 在 $\mathbf{x}_0$ 点处可微, 如 $\exists$ 只与 $\mathbf{x}_0$ 有关, 而与 $\Delta \mathbf{x}$ 无关的 $m \times n$ 阶矩阵 $\mathbf{A}$, 使得在 $\mathbf{x}_0$ 点附近, 成立

$$\Delta \mathbf{y} = \mathbf{f}(\mathbf{x}_0 + \Delta \mathbf{x}) - \mathbf{f}(\mathbf{x}_0) = \mathbf{A} \Delta \mathbf{x} + o(\Delta \mathbf{x})$$

其中 $o(\Delta \mathbf{x})$ 为列向量, 其模长是 $|\Delta \mathbf{x}| := \sqrt{(\Delta x_1)^2 + \dots + (\Delta x_n)^2}$ 的高阶无穷小. 此时, 称 $\mathbf{A} \cdot \Delta \mathbf{x}$ 为 $\mathbf{f}$ 在 $\mathbf{x}_0$ 处的微分, 记之为 $d\mathbf{y}$, 即有 $d\mathbf{f} = \mathbf{A} \cdot d\mathbf{x} = \mathbf{A} \cdot \Delta \mathbf{x}$

定理 1.3.2 向量值函数 $\mathbf{f}$ 在 $\mathbf{x}_0$ 点可微的充要条件是其坐标分量函数 $y_i = f_i(x_1, x_2, \dots, x_n)$ ($i = 1, 2, \dots, m$) 都在 $\mathbf{x}_0$ 点可微. 此时 $d\mathbf{y} = \mathbf{f}'(\mathbf{x}_0) d\mathbf{x}$, 其中 $\mathbf{f}'(\mathbf{x}_0) = J_{\mathbf{f}}(\mathbf{x}_0)$ 为 $\mathbf{f}$ 在 $\mathbf{x}_0$ 点的 *Jacobi* 矩阵, 即

$$J_{\mathbf{f}}(\mathbf{x}_0) = \left[\frac{\partial f_i}{\partial x_j}(\mathbf{x}_0) \right]_{m \times n} := \begin{bmatrix} \frac{\partial f_1}{\partial x_1}(\mathbf{x}_0) & \dots & \frac{\partial f_1}{\partial x_n}(\mathbf{x}_0) \\ \vdots & & \vdots \\ \frac{\partial f_m}{\partial x_1}(\mathbf{x}_0) & \dots & \frac{\partial f_m}{\partial x_n}(\mathbf{x}_0) \end{bmatrix}$$

故向量值函数 $\mathbf{f}$ 连续、可导和可微等价于其每一坐标分量函数 f_i 连续、可导和可微. 注意, 我们用偏导数常用的符号 $\frac{\partial f_i}{\partial x_j}$ 来替代之前记偏导数的方式 $(f_i)_{x_j}$.

证明: (必要性) 若 $\mathbf{f}$ 在 $\mathbf{x}_0$ 可微, 即存在 $\mathbf{A} = [a_{ij}]_{m \times n}$, 使得

$$\Delta f_i = \Delta y_i = \sum_{k=1}^n a_{ik} \Delta x_k + o(\Delta \mathbf{x})_i, \quad i = 1, 2, \dots, m,$$

且满足 $\lim_{|\Delta \mathbf{x}| \rightarrow 0} \frac{o(\Delta \mathbf{x})_i}{|\Delta \mathbf{x}|} = 0$, $i = 1, 2, \dots, m$. 而这正是坐标分量函数 f_i 在 $\mathbf{x}_0$ 处可微的条件, 从而知道 $a_{ij} = \frac{\partial f_i}{\partial x_j}$, 故 $\mathbf{A} = J_{\mathbf{f}}(\mathbf{x}_0)$.

(充分性) 若 $f_i(x_1, x_2, \dots, x_n)$ 在 $\mathbf{x}_0$ 处可微, 则

$$\Delta y_i = \Delta f_i = \sum_{k=1}^n \frac{\partial f_i}{\partial x_k}(\mathbf{x}_0) \Delta x_k + o(|\Delta \mathbf{x}|) \quad i = 1, 2, \dots, m$$

记以矩阵形式 $d\mathbf{f} = \mathbf{A} \cdot d\mathbf{x}$, 其中 $\mathbf{A} = \left(\frac{\partial f_i}{\partial x_j}(\mathbf{x}_0) \right)_{m \times n}$, 从而 $\mathbf{f}$ 在 $\mathbf{x}_0$ 可微. $\square$

例 1.3.1 我们再次考察 例 1.2.1 中的平面向量场 $\mathbf{v} = (x, y)$. 作为映射, 它表示

$$\mathbf{v}: \begin{cases} u = u(x, y) = x \\ v = v(x, y) = y \end{cases} \quad \mathbb{R}^2 \longrightarrow \mathbb{R}^2 \quad (x, y) \longmapsto (u(x, y), v(x, y))$$

其 *Jacobi* 矩阵为 $J_{\mathbf{v}}(\mathbf{x}) = \begin{bmatrix} u_x & u_y \\ v_x & v_y \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$, 为单位方阵. 这表明对任意点 $M(x, y)$ 处的方向 $\mathbf{u} = (u_x, u_y)$, 向量场沿着 $\mathbf{u}$ 的变化率由下向量衡量

$$D\mathbf{v}|_{\mathbf{u}} = J_{\mathbf{v}}(M) \cdot \mathbf{u} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} u_x \\ u_y \end{bmatrix} = \begin{bmatrix} u_x \\ u_y \end{bmatrix} = \mathbf{u}$$

现给上结论以物理解释. 我们知道 $\mathbf{v} = (x, y)$ 是微分方程 $\frac{dy}{dx} = \frac{y}{x}$ 的向量场, 故它是方程的积分曲线 $y = Cx$ 每点处的切向量, 即按下运动方程运动粒子的速度 (t 看出是时间参数)

$$\begin{cases} \frac{dx(t)}{dt} = x(t) \\ \frac{dy(t)}{dt} = y(t) \end{cases}$$

即速度 $\mathbf{v} = (x'(t), y'(t)) = (x(t), y(t))$. 而 $J_{\mathbf{v}}(M)$ 描述沿径向的无穷小移动.

例 1.3.2 对 例 1.2.2 中的向量场 $\mathbf{v} = (-y, x)$, 其 *Jacobi* 矩阵为 $J_{\mathbf{v}}(\mathbf{x}) = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}$, 它将点 $M(x, y)$ 处的方向 $\mathbf{u}$ 映射为

$$D\mathbf{v}|_{\mathbf{u}} = J_{\mathbf{v}}(M) \cdot \mathbf{u} = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} u_x \\ u_y \end{bmatrix} = \begin{bmatrix} -u_y \\ u_x \end{bmatrix}$$

即轨迹 $\begin{cases} x = C \cos t \\ y = C \sin t \end{cases}$ 上粒子在 $M(x, y)$ 点的速度为 $\mathbf{v} = (-y, x)$. 而 $J_{\mathbf{v}}(M)$ 描述了平面上的无穷小旋转.

注记 1.3.4 我们解释上例中提到的无穷小旋转的含义. 记 $\mathbf{r}(t) = \begin{bmatrix} x(t) \\ y(t) \end{bmatrix}$, 则向量场

$\mathbf{v} = (-y, x)$ 是满足方程 $\frac{d\mathbf{r}(t)}{dt} = \underbrace{\begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}}_{J_{\mathbf{v}}} \mathbf{r}(t)$ 运动的例子的速度场. 形式地

$$\begin{aligned} \mathbf{r}(t) &= e^{J_{\mathbf{v}}t} \mathbf{C} \stackrel{\text{形式地}}{=} \left(\mathbb{I} + J_{\mathbf{v}}t + \frac{J_{\mathbf{v}}^2}{2!}t^2 + \frac{J_{\mathbf{v}}^3}{3!}t^3 + \dots \right) \mathbf{C} \\ &= \left(\begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} + \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}t + \frac{1}{2!} \begin{bmatrix} -1 & 0 \\ 0 & -1 \end{bmatrix}t^2 + \frac{1}{3!} \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix}t^3 + \dots \right) \mathbf{C} \\ &= \left(\begin{bmatrix} 1 - \frac{t^2}{2!} + \frac{t^4}{4!} - \dots & -t + \frac{t^3}{3!} - \frac{t^5}{5!} + \dots \\ t - \frac{t^3}{3!} + \frac{t^5}{5!} - \dots & 1 - \frac{t^2}{2!} + \frac{t^4}{4!} - \dots \end{bmatrix} \right) \mathbf{C} = \begin{bmatrix} \cos t & -\sin t \\ \sin t & \cos t \end{bmatrix} \mathbf{C} \\ &\stackrel{\mathbf{C} = \begin{bmatrix} C_1 \\ C_2 \end{bmatrix}}{\Longrightarrow} \mathbf{r}(t) = \begin{bmatrix} x(t) \\ y(t) \end{bmatrix} = \begin{bmatrix} C_1 \cos t - C_2 \sin t \\ C_1 \sin t + C_2 \cos t \end{bmatrix} \end{aligned}$$

例 1.3.3 对映射 $\mathbf{f}(u, v) = (u \cos v, u \sin v, v)$, 其 *Jacobi* 矩阵为 $J_{\mathbf{f}} = \begin{bmatrix} \cos v & -u \sin v \\ \sin v & u \cos v \\ 0 & 1 \end{bmatrix}$,

故在点 $M(u, v)$ 处的微分为

$$d\mathbf{f}|_M : \mathbb{R}^2 \longrightarrow \mathbb{R}^3 \quad \begin{bmatrix} \Delta u \\ \Delta v \end{bmatrix} \mapsto \begin{bmatrix} \cos v & -u \sin v \\ \sin v & u \cos v \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \Delta u \\ \Delta v \end{bmatrix} = \begin{bmatrix} \cos v \Delta u - u \sin v \Delta v \\ \sin v \Delta u + u \cos v \Delta v \\ \Delta v \end{bmatrix}$$

特别地, 在点 $M_0(1, \pi)$ 处, $\mathbf{f}$ 的线性化的矩阵表示为 $J_{\mathbf{f}}(M_0) = \begin{bmatrix} -1 & 0 \\ 0 & -1 \\ 0 & 1 \end{bmatrix}$, 即

在 M_0 点近旁用下面的线性映射来一阶逼近 $\mathbf{f}$

$$d\mathbf{f}|_{M_0} : \mathbb{R}^2 \longrightarrow \mathbb{R}^3 \quad (u, v) \mapsto (-u, -v, v)$$

例 1.3.4 对空间曲线 $\gamma : I \subseteq \mathbb{R} \longrightarrow \mathbb{R}^3 \quad t \in I \mapsto \begin{bmatrix} x(t) \\ y(t) \\ z(t) \end{bmatrix}$, 作为向量值函数, 其微分

由 *Jacobi* 矩阵 $J_\gamma(t) := \begin{bmatrix} x'(t) \\ y'(t) \\ z'(t) \end{bmatrix}$ 来决定, 此即曲线的切向量场. 将曲线看成是一粒子的运动轨迹, 则 $J_\gamma(t)$ 给出了粒子运动的速度, 故它也可看成是粒子在其上运动的速度场; 而时刻 t_0 处的微分

$$d\gamma|_{t_0}(\Delta t) = J_\gamma(t_0) \cdot \Delta t = \begin{bmatrix} x'(t_0) \\ y'(t_0) \\ z'(t_0) \end{bmatrix} \cdot \Delta t = \begin{bmatrix} x'(t_0)\Delta t \\ y'(t_0)\Delta t \\ z'(t_0)\Delta t \end{bmatrix}$$

给出了粒子位移的微分信息, 即

$$ds = d \begin{bmatrix} \int_{t_0}^t x'(t) dt \\ \int_{t_0}^t y'(t) dt \\ \int_{t_0}^t z'(t) dt \end{bmatrix} = \frac{d}{dt} \begin{bmatrix} \int_{t_0}^t x'(t) dt \\ \int_{t_0}^t y'(t) dt \\ \int_{t_0}^t z'(t) dt \end{bmatrix} dt = \begin{bmatrix} x'(t_0)\Delta t \\ y'(t_0)\Delta t \\ z'(t_0)\Delta t \end{bmatrix}$$

注记 1.3.5 我们知道一元复合函数的求导法则: $\frac{dy}{dx} = \frac{dy}{du} \frac{du}{dx}$. 现在对任意两个映射的复合, 对应的复合映射的求导法则自然是其推广.

形式上, 不难猜测应该是对应 *Jacobi* 矩阵的乘积.

设 $\mathbf{y}(\mathbf{u}) = (y_1(\mathbf{u}), \dots, y_m(\mathbf{u}))$; $\mathbf{u}(\mathbf{x}) = (u_1(\mathbf{x}), \dots, u_n(\mathbf{x}))$, $\mathbf{x} \in \mathbb{R}^p$, 即

$$\mathbf{u} : \mathbb{R}^p \longrightarrow \mathbb{R}^n; \quad \mathbf{y} : \mathbb{R}^n \longrightarrow \mathbb{R}^m$$

则复合映射 $\mathbf{y} \circ \mathbf{u} : \mathbb{R}^p \longrightarrow \mathbb{R}^m$ 的求导法则 (假设映射可复合, 即 $\mathbf{u}$ 的象包含于 $\mathbf{y}$ 的定于与内) 应为 $J_{\mathbf{y} \circ \mathbf{u}}(\mathbf{x}) = J_{\mathbf{y}}(\mathbf{u}(\mathbf{x})) \cdot J_{\mathbf{u}}(\mathbf{x}) =$

$$= \begin{bmatrix} \frac{\partial y_1}{\partial u_1}(\mathbf{u}(\mathbf{x})) & \cdots & \frac{\partial y_1}{\partial u_n}(\mathbf{u}(\mathbf{x})) \\ \vdots & & \vdots \\ \frac{\partial y_m}{\partial u_1}(\mathbf{u}(\mathbf{x})) & \cdots & \frac{\partial y_m}{\partial u_n}(\mathbf{u}(\mathbf{x})) \end{bmatrix} \begin{bmatrix} \frac{\partial u_1}{\partial x_1}(\mathbf{x}) & \cdots & \frac{\partial u_1}{\partial x_p}(\mathbf{x}) \\ \vdots & & \vdots \\ \frac{\partial u_n}{\partial x_1}(\mathbf{x}) & \cdots & \frac{\partial u_n}{\partial x_p}(\mathbf{x}) \end{bmatrix}.$$

按矩阵乘法展开来, 便是链式法则的高维版本 $\frac{\partial y_i}{\partial x_j} = \sum_{k=1}^n \frac{\partial y_i}{\partial u_k} \frac{\partial u_k}{\partial x_j}$, $\forall i, j$. 当 $m = n = p$ 时则退化为我们熟悉的一元符合函数求导的链式法则.

当然，形式上何以如此简洁漂亮，且与矩阵代数衔接地这般天衣无缝的原因也很简单：求微分即将映射 $\mathbf{y} = \mathbf{y}(\mathbf{u})$ 局部线性化，即以线性映射 $d\mathbf{y} = \mathbf{J}_{\mathbf{y}}d\mathbf{u}$ 在局部替代原映射；同理，用线性映射 $d\mathbf{u} = \mathbf{J}_{\mathbf{u}}d\mathbf{x}$ 在局部替代映射 $\mathbf{u} = \mathbf{u}(\mathbf{x})$ ，如此，映射的复合 $\mathbf{y} \circ \mathbf{u}$ 在局部线性化的层面则就变成两个线性映射（即微分）的复合了，而两线性映射分别由 *Jacobi* 矩阵 $\mathbf{J}_{\mathbf{y}}$ 和 $\mathbf{J}_{\mathbf{u}}$ 来表示，我们知道，线性映射的复合在其矩阵表示层面就是矩阵的乘积！具体写出来就是

$$\begin{aligned}
 d\mathbf{y} = \mathbf{J}_{\mathbf{y}}d\mathbf{u} : \quad & \begin{bmatrix} dy_1 \\ \vdots \\ dy_m \end{bmatrix} = \begin{bmatrix} \frac{\partial y_1}{\partial u_1} & \cdots & \frac{\partial y_1}{\partial u_n} \\ \vdots & & \vdots \\ \frac{\partial y_m}{\partial u_1} & \cdots & \frac{\partial y_m}{\partial u_n} \end{bmatrix} \begin{bmatrix} du_1 \\ \vdots \\ du_n \end{bmatrix} \\
 d\mathbf{u} = \mathbf{J}_{\mathbf{u}}d\mathbf{x} : \quad & \begin{bmatrix} du_1 \\ \vdots \\ du_n \end{bmatrix} = \begin{bmatrix} \frac{\partial u_1}{\partial x_1} & \cdots & \frac{\partial u_1}{\partial x_p} \\ \vdots & & \vdots \\ \frac{\partial u_n}{\partial x_1} & \cdots & \frac{\partial u_n}{\partial x_p} \end{bmatrix} \begin{bmatrix} dx_1 \\ \vdots \\ dx_p \end{bmatrix} \\
 \text{进而可知} \quad & \underbrace{\begin{bmatrix} dy_1 \\ \vdots \\ dy_m \end{bmatrix}}_{d\mathbf{y}} = \underbrace{\begin{bmatrix} \frac{\partial y_1}{\partial u_1} & \cdots & \frac{\partial y_1}{\partial u_n} \\ \vdots & & \vdots \\ \frac{\partial y_m}{\partial u_1} & \cdots & \frac{\partial y_m}{\partial u_n} \end{bmatrix}}_{\mathbf{J}_{\mathbf{y}}} \underbrace{\begin{bmatrix} \frac{\partial u_1}{\partial x_1} & \cdots & \frac{\partial u_1}{\partial x_p} \\ \vdots & & \vdots \\ \frac{\partial u_n}{\partial x_1} & \cdots & \frac{\partial u_n}{\partial x_p} \end{bmatrix}}_{\mathbf{J}_{\mathbf{u}}} \underbrace{\begin{bmatrix} dx_1 \\ \vdots \\ dx_p \end{bmatrix}}_{d\mathbf{x}}
 \end{aligned}$$

相当于将线性代数中的相关内容在微积分背景下重做一遍。与其这样重复造轮子，不如锤炼抽象思维能力，将线性代数中的抽象框架灵活使用。

2 第一节内容的技术性完善、补充及拓展

2.1 多元函数的极限与连续性

我们研究的对象是二元或多元函数（或向量值函数——向量场乃其特例），即从 $\mathbb{R}^n$ ($n \geq 2$) 中区域 D 到 $\mathbb{R}^m$ 中的映射： $\mathbf{f}: D \subseteq \mathbb{R}^n \rightarrow \mathbb{R}^m$ $\mathbf{x} = (x_1, x_2, \dots, x_n) \mapsto (y_1, y_2, \dots, y_m)$ ，其中坐标分量函数为

$$\begin{cases} y_1 = f_1(x_1, x_2, \dots, x_n) \\ y_2 = f_2(x_1, x_2, \dots, x_n) \\ \dots \\ y_m = f_m(x_1, x_2, \dots, x_n) \end{cases}$$

而每个坐标分量函数 $f_i: \mathbb{R}^n \rightarrow \mathbb{R}$ 是 D 上的多元函数. 故对一般函数的研究归根结底需先对多元函数的方方面面有所了解才行，本小节我们以最简单但却最基本的二元函数为例来说明，一般情形由此明朗.

我们熟悉一元函数 $y = f(x)$ 的定义域 D 可写成是直线 $\mathbb{R}$ 上开区间何闭区间的并何交. 问题是：在高维欧几里得空间 $\mathbb{R}^n$ ($n \geq 2$) 里，该如何推广开（闭）区间？特别地，为描述极限现象，我们需知道直线上点 $x_0 \in \mathbb{R}$ 的 δ 领域 $U(x_0, \delta) = \{x: |x - x_0| < \delta\}$ 的自然推广. 为此，需对一维情形中的开、闭区间做出便于推广的内在刻画.

比如对 $\mathbb{R}$ 中的基本开区间 $I = (a, b)$ ($a < b, a, b$ 可为 $\pm\infty$)，它满足如下刻画条件：

$$\forall x \in I, \exists \delta > 0, \text{ 使得 } U(x, \delta) \subseteq I$$

进一步，如上形式的开区间的任意并集显然也满足以上刻画条件. 另一方面，可以证明： $\mathbb{R}$ 中满足上条件的集合 I 一定具有形式：

$$\bigcup_i I_i \quad \text{其中 } I_i = (a_i, b_i) (a_i < b_i, a_i, b_i \text{ 可为 } \pm\infty)$$

由此我们可抽象出如下定义，将作为直线上开区间概念的一般形式，它是自然适用与高维情形的推广的.

定义 2.1.1 设 $E \subseteq \mathbb{R}$ ，若 $\exists \delta > 0$ ，使得 $U(x_0, \delta) \subseteq E$ ，则称 x_0 是 E 的内点 (*interior point*)；若 $\exists \delta > 0$ ，使得 $U(x_0, \delta) \cap E = \emptyset$ ，则称 x_0 是 E 的外点 (*exterior point*)；若 $\forall \delta > 0$ ， $U(x_0, \delta)$ 内既有属于 E 的点又有不属于 E 的点，则称 x_0 是 E 的边界点 (*boundary point*) .

比如 $(2, 4]$ 中，2 是其内点，5 是其外点，2 和 4 都是其边界点.

为推广到高维, 核心是将 $U(x_0, \delta)$ 从一维推广到高维, 而这只需注意到在一般 $\mathbb{R}^n$ 中, 两点 $P(x_1, x_2, \dots, x_n)$ 和 $Q(y_1, y_2, \dots, y_n)$ 的**距离** (欧几里得距离) 定义如下

$$d(P, Q) := \sqrt{(y_1 - x_1)^2 + (y_2 - x_2)^2 + \dots + (y_n - x_n)^2}$$

当 $n = 1$ 是, 它就是绝对值 $|\cdot|$ 概念. 由此, 我们有高维中 δ -领域的概念.

设 $P_0 \in \mathbb{R}^n$, $\delta > 0$, 则称 $U(P_0, \delta) := \{P \in \mathbb{R}^n \mid d(P, P_0) < \delta\}$ 为点 P_0 的 δ -领域; 而称 $\dot{U}(P_0, \delta) := \{P \in \mathbb{R}^n \mid 0 < d(P, P_0) < \delta\}$ 为点 P_0 的去心 δ -领域.


知道了 δ -领域的高维推广, 则定义 2.1.1 自然可推广到一般情形.

定义 2.1.1' 设 $E \subseteq \mathbb{R}^n$, 若 $\exists \delta > 0$, 使得 $U(P_0, \delta) \subseteq E$, 则称 P_0 是 E 的内点 (*interior point*); 若 $\exists \delta > 0$, 使得 $U(P_0, \delta) \cap E = \emptyset$, 则称 P_0 是 E 的外点 (*exterior point*); 若 $\forall \delta > 0$, $U(P_0, \delta)$ 内既有属于 E 的点又有不属于 E 的点, 则称 P_0 是 E 的边界点 (*boundary point*).

定义 2.1.2 设 $E \subseteq \mathbb{R}^n$, 若 E 中的点全是 E 的内点, 则称 E 是 $\mathbb{R}^n$ 的开集 (*open set*); 若补集 $\mathbb{R}^n \setminus E$ 为开集, 则称 E 为 $\mathbb{R}^n$ 的闭集 (*closed set*).

定义 2.1.3 设 $E \subseteq \mathbb{R}^n$, 则由 E 的所有边界点组成的集合称为 E 的边界 (*boundary*), 记之为 ∂E .

可以证明: $\partial E \subseteq E \iff E$ 是闭集.



$\mathbb{R}^2$ 中的基本开集是 $U(P_0, \delta) = \{(x, y) \mid \sqrt{(x - x_0)^2 + (y - y_0)^2} < \delta\}$, 它表示平面上一个开圆盘 (*open disk*);


$\mathbb{R}^3$ 中的基本开集是 $U(P_0, \delta) = \{(x, y, z) \mid \sqrt{(x - x_0)^2 + (y - y_0)^2 + (z - z_0)^2} < \delta\}$, 它表示空间中一个开球 (*open ball*).

例 2.1.1 对 $I = (0, 3] \cup (4, 5)$, 它即非开也非闭, 其边界 $\partial I = \{0, 3, 4, 5\}$.

例 2.1.2 对 $E = \{(x, y) \mid 1 < x^2 + y^2 \leq 4\}$, 满足条件 $1 < x_0^2 + y_0^2 < 4$ 的所有点 (x_0, y_0) 都是其内点, 而其边界为

$$\partial E = \{(x, y) \mid x^2 + y^2 = 1\} \cup \{(x, y) \mid x^2 + y^2 = 4\}$$


定义 2.1.4 设 $D \subseteq \mathbb{R}^n$, 若 D 中任意两点都能用完全属于 D 内的折线相联, 则称 D 是连通的 (*connected*). 其中折线是形如 $\overline{P_1 P_2} := \{P \mid P = tP_1 + (1-t)P_2, t \in [0, 1]\}$ 这样的直线段依次首位相联而成的.



定义 2.1.5 连通的开集称为开区域, 简称区域 (*domain*); 区域连同其边界称为闭区域 (*closed domain*).


定义 2.1.6 设 $E \subseteq \mathbb{R}^n$, O 是 $\mathbb{R}^n$ 的原点, 若 $\exists M > 0$, 使得 $E \subseteq U(0, M)$, 则称 E 是有界集 (*bounded set*), 否则称为无界集 (*unbounded set*).

例 2.1.3 $E = \{(x, y) \mid 0 < x^2 + y^2 < 1\}$ 是有界开区域, 它是 $E_\epsilon = \{(x, y) \mid \epsilon < x^2 + y^2 < 1\}$ 的 $\epsilon \rightarrow 0$ 极限, 而 $\partial E_\epsilon = \{(x, y) \mid x^2 + y^2 = 1\} \cup \{(x, y) \mid x^2 + y^2 = \epsilon\}$



$\partial E = \lim_{\epsilon \rightarrow 0} \partial E_\epsilon = \{0\} \cup \{(x, y) \mid x^2 + y^2 = 1\}$, 故 $E \cup \partial E = \{(x, y) \mid x^2 + y^2 \leq 1\}$ 是有界闭区域.

例 2.1.4 $E = \{(x, y) \mid xy > 0\} \subseteq \mathbb{R}^2$ 是开集, 但不连通, 故不是区域. 它是无界点集.



显然 $E \cup \{0\}$ 是开区域. $\partial E = \{x\text{-轴}\} \cup \{y\text{-轴}\} \cup \{\text{三象限中的无穷远}\}$.

$\mathbb{R}^n$ 中点列的极限概念：先回忆一维 $\mathbb{R}$ 上的点列 $\{x_n\}$ 具有极限 x_0 的刻画：

$$\lim_{n \rightarrow \infty} x_n = x_0 \iff \forall \epsilon > 0, \exists N > 0, \text{使得当 } n > N \text{ 时, 有 } |x_n - x_0| < \epsilon$$

直观上, 当 n 越大时, x_n 中有无穷多点同 x_0 在直线上的距离越来越小——可以小到实现给定的任何正数 ϵ .

那么, 对高维 $\mathbb{R}_m (m \geq 2)$ 中的点列 $\{\mathbf{x}_n\}$, 其中 $\mathbf{x}_n = (x_n^1, \dots, x_n^m)$, 我们认为它收敛于点 $\mathbf{x}_0 = (x_0^1, \dots, x_0^m)$, 即 $\lim_{n \rightarrow \infty} \mathbf{x}_n = \mathbf{x}_0$ 当且仅当

$$\forall \epsilon > 0, \exists N > 0, \text{使得当 } n > N \text{ 时, 有 } d(\mathbf{x}_n, \mathbf{x}_0) < \epsilon \text{ (或 } \mathbf{x}_n \in U(\mathbf{x}_0, \epsilon))$$

$$\text{由于 } |x_n^i - x_0^i| \leq d(\mathbf{x}_n, \mathbf{x}_0) = \sqrt{(x_n^1 - x_0^1)^2 + \dots + (x_n^m - x_0^m)^2} \leq \sum_{i=1}^m |x_n^i - x_0^i|$$

从而, 若 $d(\mathbf{x}_n, \mathbf{x}_0) < \epsilon$, 则 $\forall i$, 有 $|x_n^i - x_0^i| < \epsilon$; 反之, 若 $\forall i$, 当 $|x_n^i - x_0^i| < \epsilon$, 必有 $d(\mathbf{x}_n, \mathbf{x}_0) < m\epsilon$. 故有

定理 2.1.1 $\lim_{n \rightarrow \infty} \mathbf{x}_n = \mathbf{x}_0$ 当且仅当 $\lim_{n \rightarrow \infty} x_n^i = x_0^i, (\forall i = 1, 2, \dots, m.)$

$\mathbb{R}^n$ 上函数的极限概念：先回忆 $y = f(x), x \in D \subseteq \mathbb{R}$ 有极限 $\lim_{x \rightarrow x_0} f(x) = A$ 的刻画：

$$\forall \epsilon > 0, \exists \delta > 0, \text{使得 } \forall x : 0 < |x - x_0| < \delta, \text{有 } |f(x) - A| < \epsilon$$

换言之, $\forall \epsilon > 0, \exists \delta > 0$, 使得当 $x \in \mathring{U}(x_0, \delta)$ 时, 有 $f(x) \in U(A, \epsilon)$. 这是很容易推广到高维的, 即有

定义 2.1.7 (多元函数的 (多重) 极限) 设 $y = f(\mathbf{x})$ 是定义于 $\mathring{U}(P_0)$ 上的 n -元函数, 若 $\exists A$, 对 $\forall \epsilon > 0$, 都 $\exists \delta > 0$, 使得只要 $0 < d(P, P_0) < \delta$ (即 $P \in \mathring{U}(P_0, \delta)$), 有

$$|f(P) - A| < \epsilon, \text{ (即 } f(P) \in U(A, \epsilon))$$

则称当 $P(x_1, \dots, x_n) \rightarrow P_0(x_1^0, \dots, x_n^0)$ 时, $f(P) = f(x_1, \dots, x_n)$ 的 (n -重) 极限为 A , 或称 $f(x_1, \dots, x_n)$ 收敛于 A , 记为

$$\lim_{P \rightarrow P_0} f(P) = \lim_{(x_1, \dots, x_n) \rightarrow (x_1^0, \dots, x_n^0)} f(x_1, \dots, x_n) = \lim_{x_1 \rightarrow x_1^0, \dots, x_n \rightarrow x_n^0} f(x_1, \dots, x_n) = A$$

注记 2.1.1 更一般地, 对 $\mathbb{R}^n$ 上的向量值函数 (取值于 $\mathbb{R}^m$) $\mathbf{f}: D \setminus \{\mathbf{x}_0\} \subseteq \mathbb{R}^n \rightarrow \mathbb{R}^m$

$$\mathbf{x} = (x_1, \dots, x_n) \mapsto \mathbf{y} = \mathbf{f}(\mathbf{x}) = (y_1, \dots, y_m) \text{ 其中 } \begin{cases} y_1 = f_1(\mathbf{x}) = f_1(x_1, \dots, x_n) \\ \dots \\ y_m = f_m(\mathbf{x}) = f_m(x_1, \dots, x_n) \end{cases}$$

也记 $\mathbf{f} = (f_1, \dots, f_m)$. 则如存在 m -维向量 $\mathbf{A}$, 使得 $\forall \epsilon > 0, \exists \delta > 0$, 只要当 $x \in \dot{U}(\mathbf{x}_0, \delta)$ 时, 都有 $\mathbf{f} \in U(\mathbf{A}, \epsilon)$, 则称 $\mathbf{A}$ 为当 $\mathbf{x} \rightarrow \mathbf{x}_0$ 时 $\mathbf{f}$ 的**极限**, 或称 $\mathbf{f}$ 当 $\mathbf{x} \rightarrow \mathbf{x}_0$ 时**收敛**, 记为 $\lim_{\mathbf{x} \rightarrow \mathbf{x}_0} \mathbf{f}(\mathbf{x}) = \mathbf{A}$.

我们在本节中主要探讨二元函数的 (二重) 极限问题, 下面看一些例子.

例 2.1.5 对极限 $\lim_{x,y \rightarrow 0} \frac{x^2 y}{x^2 + y^2}$. 显然在原点 O 附近, 有 $0 \leq \left| \frac{x^2 y}{x^2 + y^2} \right| \leq |y|$, 则由夹逼定理, 知其极限为 0. 或按照极限的定义, 可按如下格式论证

$\forall \epsilon > 0$, 取 $\delta = \epsilon$, 则当 $x \in U(0, \delta)$ 时, 即 $\sqrt{x^2 + y^2} < \delta = \epsilon$, 时, 有

$$|f(x, y) - 0| = \left| \frac{x^2 y}{x^2 + y^2} \right| \leq |y| \leq \sqrt{x^2 + y^2} < \delta = \epsilon$$

例 2.1.6 设 $f(x, y) = \begin{cases} \frac{\sin xy}{x}, & x \neq 0, \\ y, & x = 0, y \neq 0. \end{cases}$, 计算 $\lim_{(x,y) \rightarrow (0,0)} f(x, y)$. 由于

$$|f(x, y)| = \begin{cases} \left| \frac{\sin xy}{x} \right| \leq |y|, & x \neq 0, \\ |y| & x = 0, y \neq 0. \end{cases}$$

由夹逼定理知所求极限为 0.

例 2.1.7 对极限 $\lim_{(x,y) \rightarrow (0,0)} (x^2 + y^2)^{x^2 y^2}$, 先对函数取对数:

$$\ln(x^2 + y^2)^{x^2 y^2} = (x^2 y^2) \ln(x^2 + y^2) = \frac{x^2 y^2}{x^2 + y^2} \frac{\ln(x^2 + y^2)}{x^2 + y^2}$$

$$\text{而 } 0 \leq \frac{x^2 y^2}{x^2 + y^2} \leq \frac{(x^2 + y^2)^2}{x^2 + y^2} = x^2 + y^2 \implies \lim_{(x,y) \rightarrow (0,0)} \frac{x^2 y^2}{x^2 + y^2} = 0$$

$$\lim_{(x,y) \rightarrow (0,0)} \frac{\ln(x^2 + y^2)}{x^2 + y^2} \stackrel{x=r \cos \theta, y=r \sin \theta}{=} \lim_{r \rightarrow 0} \frac{\ln r^2}{r^2} = 0$$


从而 $\lim_{(x,y) \rightarrow (0,0)} (x^2 + y^2)^{x^2 y^2} = e^0 = 1$.

解: 利用极坐标 (r, θ) , 由于 $\begin{cases} x = r \cos \theta \\ y = r \sin \theta \end{cases}$, 故

$$(x^2 + y^2)x^2y^2 = (r^2)r^4 \cos^2 \theta \sin^2 \theta = e^{(\cos^2 \theta \sin^2 \theta)r^4 \ln r^2}$$

$$\text{则 } \lim_{(x,y) \rightarrow (0,0)} (x^2 + y^2)x^2y^2 = \lim_{r \rightarrow 0} e^{(\cos^2 \theta \sin^2 \theta)r^4 \ln r^2} = e^0 = 1.$$

注记 2.1.2 平面极坐标 (r, θ) 中的 r 是径向长度, 故 $r \rightarrow 0$ 指沿任意直线方向趋于坐标原点. 即沿直线 $y = kx$ ($k = \tan \theta$) 趋于原点时 ($\forall \theta$), 极限都为 1.



事实上, $\lim_{P \rightarrow P_0} f(P) = A$ 当且仅当 P (在其定义域内) 不论以何种方式趋近 P_0 (即只要 $d(P_0, P) \rightarrow 0$) 时, 都有 $f(P) \rightarrow A$. 当然, 变量所处空间的维度越高, 则趋于的方式也更加多样.

比如对例 2.1.5 中的函数 $f(x, y) = \frac{x^2y}{x^2 + y^2}$, 当沿直线 $y = kx$ 趋于原点时

$$\lim_{(x,y) \rightarrow (0,0); y=kx} f(x, y) = \lim_{x \rightarrow 0} \frac{kx^3}{(1 + k^2)x^2} = \lim_{x \rightarrow 0} \frac{kx}{(1 + k^2)} = 0$$

一般地, 若沿着 $y = x^m$ ($m \geq 2$) 趋于原点, 则

$$\lim_{(x,y) \rightarrow (0,0), y=x^m} f(x, y) = \lim_{x \rightarrow 0} \frac{x^{m+2}}{x^2(1 + x^{2m-2})} = \lim_{x \rightarrow 0} \frac{x^m}{1 + x^{2m-2}} = 0$$

或沿 $y = \sin x$ 趋于原点, 则

$$\lim_{(x,y) \rightarrow (0,0), y=\sin x} f(x, y) = \lim_{x \rightarrow 0} \frac{x^2 \sin x}{x^2 + \sin^2 x} = \lim_{x \rightarrow 0} \frac{\sin x}{1 + \left(\frac{\sin x}{x}\right)^2} = 0$$

等等. 我们无法穷尽所有的可能, 但由于我们已证极限为零, 故知不论沿和途径趋于原点, 函数极限都为零.


当然, 这也表明: 只要存在两种不同的趋于 P_0 的方式, 使得对应极限有不存在者, 或都存在但不相等, 则说明 $\lim_{P \rightarrow P_0} f(P)$ 是不存在的.

例 2.1.8 考察函数 $z = f(x, y) = \frac{(y^2 - x)^2}{y^4 + x^2}$, $(x, y) \neq (0, 0)$ 在原点处的极限情况.


分析: 沿任意直线方向 $y = kx$ 趋于原点时, 有

$$\lim_{y=kx, x \rightarrow 0} \frac{(y^2 - x)^2}{y^4 + x^2} = \lim_{x \rightarrow 0} \frac{(k^2x - 1)^2 x^2}{x^2(k^4x^2 + 1)} = \lim_{x \rightarrow 0} \frac{(k^2x - 1)^2}{k^4x^2 + 1} = 1$$


但当沿着抛物线 $x = y^2$ 趋于 $(0, 0)$ 时, 极限显然为 0, 从而知函数在原点处不存在极限. 下图是函数 z 的图像.




再看曲面和平面 $y = x$ 的相交情况



再看曲面和柱面 $y^2 = x$ 的相交情况




对 $f(x, y)$, 若 $\lim_{(x,y) \rightarrow (x_0, y_0)} f(x, y)$ 存在, 则计算时, 可选如下两种路径




对应 $\lim_{y \rightarrow y_0} \lim_{x \rightarrow x_0} f(x, y)$ 和 $\lim_{x \rightarrow x_0} \lim_{y \rightarrow y_0} f(x, y)$, 称为累次极限. 一般而言, 累次极限不一定都存在; 且即便两者都存在, 也可能不等.

例 2.1.9 对 $f(x, y) = \frac{x^2 - y^2}{x^2 + y^2}$, 由于 $\lim_{x \rightarrow 0} \lim_{y \rightarrow 0} f(x, y) = \lim_{x \rightarrow 0} 1 = 1$ 且 $\lim_{y \rightarrow 0} \lim_{x \rightarrow 0} f(x, y) = \lim_{y \rightarrow 0} (-1) = -1$, 从而二重极限 $\lim_{(x,y) \rightarrow (0,0)} f(x, y)$ 不存在. 其图象如下:



例 2.1.10 (二重极限存在, 但累次极限不存在) $f(x, y) = \begin{cases} (x^2 + y^2) \sin \frac{1}{x} \cos \frac{1}{y}, & x \neq 0 \text{ 且 } y \neq 0 \\ 0, & x = 0 \text{ 或 } y = 0. \end{cases}$


因 $|f(x, y)| \leq x^2 + y^2$, 故 $\lim_{(x,y) \rightarrow (0,0)} f(x, y) = 0$. 但累次极限显然都不存在. 其图象如下:



例 2.1.11 (二重极限存在, 一个累次极限不存在) $f(x, y) = \begin{cases} y \sin \frac{1}{x}, & x \neq 0 \text{ 且 } y \neq 0, \\ 0 & x = 0 \text{ 或 } y = 0. \end{cases}$

显然 $\lim_{(x,y) \rightarrow (0,0)} f(x, y) = 0$; $\lim_{x \rightarrow 0} \lim_{y \rightarrow 0} y \sin \frac{1}{x} = 0$, 但

$$\lim_{y \rightarrow 0} \lim_{x \rightarrow 0} y \sin \frac{1}{x} = \lim_{y \rightarrow 0} y \left(\lim_{x \rightarrow 0} \sin \frac{1}{x} \right) \text{ 不存在!}$$



这个例子也说明: 一般地, $\lim_{x \rightarrow x_0} \lim_{y \rightarrow y_0} f(x, y) \neq \lim_{y \rightarrow y_0} \lim_{x \rightarrow x_0} f(x, y)$. 自然要问: 什么条件下, 可保证累次极限相等, 即先对 x 后对 y 等同于先对 y 后对 x 求极限?

期望: 只要 $\lim_{(x,y) \rightarrow (x_0, y_0)} f(x, y)$ 存在, 并累次极限都存在, 即 $\varphi(x) = \lim_{y \rightarrow y_0} f(x, y)$ 对 $x \neq x_0$ 有意义, 且 $\psi(y) = \lim_{x \rightarrow x_0} f(x, y)$ 对 $y \neq y_0$ 有意义, 则必有

$$\lim_{(x,y) \rightarrow (x_0, y_0)} f(x, y) = \underbrace{\lim_{x \rightarrow x_0} \lim_{y \rightarrow y_0} f(x, y)}_{\lim_{x \rightarrow x_0} \varphi(x)} = \underbrace{\lim_{y \rightarrow y_0} \lim_{x \rightarrow x_0} f(x, y)}_{\lim_{y \rightarrow y_0} \psi(y)}$$

证明: 设 $\lim_{(x,y) \rightarrow (x_0, y_0)} f(x, y) = A$, 则 $\forall \epsilon > 0, \exists \delta > 0$, 使得当

$$0 < \sqrt{(x - x_0)^2 + (y - y_0)^2} < \delta \text{ 时, 有 } |f(x, y) - A| < \frac{\epsilon}{2}$$

则对每个满足 $0 < |x - x_0| < \delta$ 的 x , 令 $y \rightarrow y_0$, 便有 $|\varphi(x) - A| =$

$$= \lim_{y \rightarrow y_0} |f(x, y) - A| \leq \frac{\epsilon}{2} < \epsilon \implies \lim_{x \rightarrow x_0} \varphi(x) = \lim_{x \rightarrow x_0} \lim_{y \rightarrow y_0} f(x, y) = A$$

同理可证 $\lim_{y \rightarrow y_0} \psi(y) = \lim_{y \rightarrow y_0} \lim_{x \rightarrow x_0} f(x, y) = A$. 期望由此得验证. $\square$

多元函数的连续性：与一元情形完全类似，我们有如下定义：

定义 2.1.8 设 $D \subseteq \mathbb{R}^n$ 是区域（或闭区域）， $\mathbf{y} = \mathbf{f}(\mathbf{x}) : \mathbb{R}^n \rightarrow \mathbb{R}^m$ 是定义在 D 上的向量值函数. 给定 $\mathbf{x}_0 \in D$ ，如 $\lim_{\mathbf{x} \rightarrow \mathbf{x}_0} \mathbf{f}(\mathbf{x}) = \mathbf{f}(\mathbf{x}_0)$ ，则称 $\mathbf{f}$ 在 $\mathbf{x}_0$ 处连续，即 $\forall \epsilon > 0, \exists \delta > 0$ ，使得只要 $\mathbf{x} \in U(\mathbf{x}_0, \delta)$ ，便有 $\mathbf{f}(\mathbf{x}) \in U(\mathbf{f}(\mathbf{x}_0), \epsilon)$. 如果 $\mathbf{f}$ 在 D 上每一点都连续，则称 $\mathbf{f}$ 在 D 上连续，或 $\mathbf{f}$ 是 D 上的连续函数，记为 $\mathbf{f} \in C(D)$. 不连续的点统称为间断点.

特别地，若 $m = 1$ ，则我们得到 $D \subseteq \mathbb{R}^n$ 上 n 元函数在点 $\mathbf{x}_0 \in D$ 处连续的定义. 特别地，对二元函数 $z = f(x, y)$ ， $(x, y) \in D \subseteq \mathbb{R}^2$ ，它在 (x_0, y_0) 处连续，即

$$\forall \epsilon > 0, \exists \delta > 0, \text{ 使得, 当 } \sqrt{(x - x_0)^2 + (y - y_0)^2} < \delta \text{ 有 } |f(x, y) - f(x_0, y_0)| < \epsilon$$

定理 2.1.2 设 $\mathbf{y} = \mathbf{f}(\mathbf{x}) : D \subseteq \mathbb{R}^n \rightarrow \mathbb{R}^m$ 的分量函数为
$$\begin{cases} y_1 = y_1(x_1, \dots, x_n) \\ \dots \\ y_m = y_m(x_1, \dots, x_n) \end{cases} \quad \text{则 } \mathbf{f}$$

在 $\mathbf{x}_0 \in D$ 连续当且仅当函数 $f_1, \dots, f_m$ 都在 $\mathbf{x}_0$ 处连续.


证明：（请对照 pg 24 定理 2.1.1 的证明）定理成立的原因是： $\forall i = 1, 2, \dots, m$ ，都有

$$|f_i(\mathbf{x}) - f_i(\mathbf{x}_0)| \leq |\mathbf{f}(\mathbf{x}) - \mathbf{f}(\mathbf{x}_0)| = \sqrt{\sum_{i=1}^m (f_i(\mathbf{x}) - f_i(\mathbf{x}_0))^2} \leq \sum_{i=1}^m |f_i(\mathbf{x}) - f_i(\mathbf{x}_0)| \quad \square$$

注记 2.1.3 当 $n = 1, m = 3$ 时，函数 $\mathbf{f} = (f_1(t), f_2(t), f_3(t))$ 描绘 $\mathbb{R}^3$ 中的一条曲线，如 $\mathbf{f}(t)$ 连续，即三个分量 $f_i(t)$ 函数都连续，则我们说这条曲线是连续的.

注记 2.1.4 当 $n = 2, m = 3$ 时，函数 $\mathbf{f} : \begin{cases} x = x(u, v) \\ y = y(u, v) \\ z = z(u, v) \end{cases} \quad (u, v) \in D \subseteq \mathbb{R}^2$ 描绘出 $\mathbb{R}^3$

中的一个曲面， $\mathbf{f}$ 即为其参数方程（其中 u, v 为参数）. 如 $\mathbf{f}$ 连续，即其三个坐标分量函数 x, y, z 都连续时，我们说改曲面是连续的.



下面的性质和一元情形完全类似，其证明也类似，读者可比照一元情形自行证明.

1. 多元连续函数的和、差、积、商（分母不为零）仍连续；
2. 多元连续函数的复合函数也连续；
3. 多元初等函数再起定义域内连续.

例 2.1.12 对函数 $f(x, y) = \begin{cases} \frac{xy}{x^2 + y^2}, & (x, y) \neq (0, 0), \\ 0, & (x, y) = (0, 0). \end{cases}$ 由于 $\lim_{(x, y) \rightarrow (0, 0)} f(x, y)$ 不存在, 故 $f(x, y)$ 在 $(0, 0)$ 不连续.

但将它看成只是 x 或 y 的函数, 则它关于 x 在 $(0, 0)$ 处连续, 或关于 y 在 $(0, 0)$ 处连续.

例 2.1.13 对极限 $\lim_{(x, y) \rightarrow (0, 1)} \frac{1 - xy}{x^2 + y^2}$. 由于 $(0, 1)$ 在函数的定义域内, 而函数本身是初等函数, 故

$$\lim_{(x, y) \rightarrow (0, 1)} \frac{1 - xy}{x^2 + y^2} = f(0, 1) = 1$$

例 2.1.14 $\lim_{(x, y) \rightarrow (0, 0)} \frac{\sqrt{x^2 + y^2 + 1} - 1}{x^2 + y^2} = \lim_{(x, y) \rightarrow (0, 0)} \frac{x^2 + y^2 + 1 - 1}{(x^2 + y^2)(\sqrt{x^2 + y^2 + 1} + 1)}$

$$= \lim_{(x, y) \rightarrow (0, 0)} \frac{1}{\sqrt{x^2 + y^2 + 1} + 1} \xrightarrow{\text{利用连续性}} \frac{1}{2}$$

例 2.1.15 对函数 $f(x, y) = \begin{cases} \frac{x^2 y}{x^2 + y^2}, & x^2 + y^2 \neq 0 \\ 0, & x^2 + y^2 = 0 \end{cases}$ 根据例 2.1.5 中的讨论, 知 $f(x, y)$ 在 $(0, 0)$ 处连续. 当 $(x, y) \neq 0$ 时, 即 $x^2 + y^2 \neq 0$ 时, 函数为初等函数, 故连续. 从而 $f(x, y)$ 在 $\mathbb{R}^2$ 上连续.

连续函数的性质: 类似于一元连续函数的情形, 下面性质对多元函数也成立.

1. **有界性定理:** 若 $f(\mathbf{x})$ 在有界闭区域 $D \subseteq \mathbb{R}^n$ 上连续, 则 $f(\mathbf{x})$ 在 D 上有界, 即 $\exists M > 0$, 当 $\mathbf{x} \in D$ 时, 恒有 $|f(\mathbf{x})| \leq M$.
2. **最值定理:** 若 $f(\mathbf{x})$ 在有界闭区域 $D \subseteq \mathbb{R}^n$ 上连续, 则 $f(\mathbf{x})$ 在 D 上必取得最大值和最小值, 即 $\exists \mathbf{x}_{\min}, \mathbf{x}_{\max} \in D$, 使得 $f(\mathbf{x}_{\max}) = \max_D f(\mathbf{x})$; $f(\mathbf{x}_{\min}) = \min_D f(\mathbf{x})$.
3. **零点存在定理:** 若 $f(\mathbf{x})$ 在有界闭区域 $D \subseteq \mathbb{R}^n$ 上连续, 且 $f(\mathbf{x}_1)f(\mathbf{x}_2) < 0$ (其中 $\mathbf{x}_1, \mathbf{x}_2 \in D$), 则 $\exists \mathbf{x}^* \in D$, 使得 $f(\mathbf{x}^*) = 0$.
4. **介值定理:** 若 $f(\mathbf{x})$ 在有界闭区域 $D \subseteq \mathbb{R}^n$ 上连续, 记 M, m 分别是 f 在 D 上的最大值和最小值, 则 $\forall \mu \in (m, M)$, $\exists \mathbf{x}^* \in D$, 使得 $f(\mathbf{x}^*) = \mu$.


例 2.1.16 证明不存在从闭区间 $[a, b]$ 到圆周上的一对一的连续映射.

证明: 设圆周为 $S^1 := \{re^{i\theta} \mid \theta \in [0, 2\pi)\}$ (注意 $\theta = 2\pi$ 和 $\theta = 0$ 对应圆周上同一点, 故将 2π 排除). 假设存在从 $[a, b]$ 到圆周的一对一连续映射, 即存在从 $[a, b]$ 到 $[0, 2\pi)$ 的一对一连续映射 $\phi : [a, b] \rightarrow [0, 2\pi)$. 则 a, b 两点不能同时对应于 0 (否则违背一对一条件), 不妨设 $\phi(a) \in (0, 2\pi)$, 即 $0 < \phi(a) < 2\pi$. 那么 $\exists \theta_1, \theta_2 \in [0, 2\pi)$, 使得 $0 < \theta_1 < \phi(a) < \theta_2 < 2\pi$. 记 $x_i = \phi^{-1}(\theta_i)$ ($i = 1, 2$), 则 $x_i \in (a, b]$, 且满足

$$0 < \phi(x_1) < \phi(a) < \phi(x_2) < 2\pi$$

由连续函数的介值定理, 知 $\exists \xi$ 介于 x_1, x_2 之间, 使得 $\phi(\xi) = \phi(a)$, 这与 ϕ 是一对一相矛盾. $\square$


注记 2.1.5 两个空间之间如果存在连续的一一映射, 则称两个空间是同胚 (*homeomorphism*) 的. 同胚的两个空间在拓扑 (*topology*) 上可看成是相同的空间, 即两空间在不割裂或黏连 (一一) 的情形下可连续变形而合一. 比如, 一个三角形和一个圆是同胚的, 故拓扑上两者是相同的; 而上面的例子表明, 闭区间和开区间在拓扑上有本质的不同. 空间的某个性质如果在同胚映射下保持不变, 则称该性质是空间的拓扑性质 (*topological property*). 比如一个空间有几个“洞”是个拓扑性质, 由此, 球面和环面在拓扑上是本质不同的.



点集的连通性也是一个拓扑性质, 即有

定理 2.1.3 设 $D \subseteq \mathbb{R}^n$ 连通, 如果 $f : D \rightarrow \mathbb{R}^m$ 是连续的, 则 D 在 f 下的像集 $f(D) := \{y \in \mathbb{R}^m \mid y = f(x), x \in D\}$ 也是连通的.

证明: 需表明, 对 $f(D)$ 内任两点 $f(x), f(y)$, 都有 $f(D)$ 内一折线道路将两者连结.



由 D 的连通性, 知存在连续映射 $\gamma: [0, 1] \rightarrow D \subseteq \mathbb{R}^n$, 使得 $\gamma(0) = \mathbf{x}$, $\gamma(1) = \mathbf{y}$, 它表示连结 $\mathbf{x}$ 和 $\mathbf{y}$ 的折线道路. 考虑复合映射 $\mathbf{f} \circ \gamma: [0, 1] \rightarrow \mathbf{f}(D) \subseteq \mathbb{R}^m$, 因两者皆连续, 故其复合也连续, 从而 $\mathbf{f} \circ \gamma$ 表示 $\mathbf{f}(D)$ 内的一连续路径, 它连结 $\mathbf{f}(\mathbf{x})$ 和 $\mathbf{f}(\mathbf{y})$. $\square$

定理 2.1.4 设 $\mathbf{f}: D \rightarrow \mathbf{f}(D)$ 连续, 当且仅当对 $\mathbf{f}(D)$ 内的任何开集 U , 其逆象 $\mathbf{f}^{-1}(U)$ 是 D 中的开集.

证明: " $\Rightarrow$ " 对任意 $\mathbf{f}(D)$ 中开集 V , 如 $\mathbf{f}^{-1}(V)$ 为空, 则结论成立 (请思考为何空集是开集), 故设 $\mathbf{f}^{-1}(V)$ 非空, 则 $\forall \mathbf{x}_0 \in \mathbf{f}^{-1}(V)$, 有 $\mathbf{f}(\mathbf{x}_0) \in V$, 而由于 V 是开集, 故 $\exists \epsilon > 0$, 使得 $U(\mathbf{f}(\mathbf{x}_0), \epsilon) \subseteq V$, 又因 $\mathbf{f}$ 在 $\mathbf{x}_0$ 连续, $\exists \delta > 0$, 当 $\mathbf{x} \in U(\mathbf{x}_0, \delta)$ 时, 有 $\mathbf{f}(\mathbf{x}) \in U(\mathbf{f}(\mathbf{x}_0), \epsilon)$, 从而 $U(\mathbf{x}_0, \delta) \subseteq \mathbf{f}^{-1}(V)$, 故 $\mathbf{f}^{-1}(V)$ 为开集.

" $\Leftarrow$ " $\forall \mathbf{x}_0 \in D$, $\mathbf{f}(\mathbf{x}_0) \in \mathbf{f}(D)$, 对任意小的 ϵ , 只要 $U(\mathbf{f}(\mathbf{x}_0), \epsilon) \subseteq \mathbf{f}(U)$, 则因 $\mathbf{f}^{-1}(U(\mathbf{f}(\mathbf{x}_0), \epsilon)) =: V \ni \mathbf{x}_0$ 是 D 中开集, $\exists \delta > 0$, 使得 $U(\mathbf{x}_0, \delta) \subseteq V$, 这表明: 只要 $\mathbf{x} \in U(\mathbf{x}_0, \delta)$, 必有 $\mathbf{f}(\mathbf{x}) \in U(\mathbf{f}(\mathbf{x}_0), \epsilon)$, 即 $\mathbf{f}(\mathbf{x})$ 在 $\mathbf{x}_0$ 处连续. $\square$

注记 2.1.6 上定理给出映射的连续性通过开集的等价刻画. 我们知道, 空间的拓扑性质有关空间的连续形变. 由此可见, 只要能给空间指定其开集结构, 自然也就能有了空间的连续形变, 或空间之间连续映射的概念等. 所以, 一个空间 X 的拓扑结构 (或简称拓扑), 指其中满足以下条件的子集族 (family of subsets) $\mathcal{F}$:

1. $X, \emptyset \in \mathcal{F}$;
2. 若 $U, V \in \mathcal{F}$, 则 $U \cap V \in \mathcal{F}$;
3. $\mathcal{F}$ 中任意多个子集的并仍属于 $\mathcal{F}$.

我们说 $\mathcal{F}$ 赋 X 以拓扑结构, $\mathcal{F}$ 中的元素称为 X 的开集.

显然, 若 X 上有距离函数 d , 则由其确定的 δ 领域 ($\forall \delta > 0, \forall$ 中心) 的全体是 X 上的一个拓扑, 称为由度量 d 诱导的拓扑.

设空间 X 上有拓扑 $\mathcal{F}_X$, 空间 Y 上有拓扑 $\mathcal{F}_Y$, 则 $\varphi: X \rightarrow Y$ 连续 当且仅当 $\forall U \in \mathcal{F}_Y$, 有 $\varphi^{-1}(U) \in \mathcal{F}_X$; 若 φ 同时是一一的, 则称 φ 建立了从 X 到 Y 的同胚, 即可连续形变而合一.

2.2 偏导数及其几何意义、高阶偏导

对一个多元函数 $z = f(x_1, x_2, \dots, x_n)$, 其值的变化是由其定义域 D 内 $\mathbf{x} = (x_1, x_2, \dots, x_n)$ 的变动引起的, 多元微分学的一个核心问题是: 如何衡量 z 相对于 $\mathbf{x}$ 变化的速率?

我们化繁就简, 先将问题化归为一元模式, 分而治之, 以不变应万变, 进可洞悉其中的统一模式, 从而不再一元、多元之二分.

定义 2.2.1 设 $z = f(x_1, x_2, \dots, x_n)$ 在 $P_0(x_1^0, x_2^0, \dots, x_n^0)$ 的某个领域 $U(P_0)$ 内有定义, 现仅给 x_i^0 以增量 Δx_i , 则 z 有相应的对 x_i 的 (偏) 增量

$$\Delta_{x_i} z = f(x_1^0, \dots, x_i^0 + \Delta x_i, x_{i+1}^0, \dots, x_n^0) - f(x_1^0, \dots, x_i^0, \dots, x_n^0)$$

若极限

$$\lim_{\Delta x_i \rightarrow 0} \frac{\Delta_{x_i} z}{\Delta x_i} = \lim_{\Delta x_i \rightarrow 0} \frac{f(x_1^0, \dots, x_i^0 + \Delta x_i, x_{i+1}^0, \dots, x_n^0) - f(x_1^0, \dots, x_i^0, \dots, x_n^0)}{\Delta x_i}$$

存在, 则称其为 n -元函数 $z = f(x_1, \dots, x_n)$ 在 P_0 处对 x_i 的偏导数 (*partial derivative*), 记为

$$f_{x_i}(P_0), \left. \frac{\partial f}{\partial x_i} \right|_{P_0}, z_{x_i}(P_0) \text{ 或 } \left. \frac{\partial z}{\partial x} \right|_{P_0}$$

即偏导数 $\left. \frac{\partial f}{\partial x_i} \right|_{P_0}$ 衡量的是函数 f 在 P_0 处只关于自变量 x_i 的变化率. 若函数对每个 x_i 处的偏导数都存在, 则称其在 P_0 处是可偏导的.

注记 2.2.1 特别地, 对二元函数 $z = f(x, y)$, 它在 $P_0(x_0, y_0)$ 处有两个偏导数, 分别定义为

$$z_x(x_0, y_0) = \left. \frac{\partial f}{\partial x} \right|_{(x_0, y_0)} = \lim_{\Delta x \rightarrow 0} \frac{f(x_0 + \Delta x, y_0) - f(x_0, y_0)}{\Delta x}$$

$$z_y(x_0, y_0) = \left. \frac{\partial f}{\partial y} \right|_{(x_0, y_0)} = \lim_{\Delta y \rightarrow 0} \frac{f(x_0, y_0 + \Delta y) - f(x_0, y_0)}{\Delta y}$$

定义 2.2.2 若 $z = f(x_1, \dots, x_n)$ 在区域 D 上任意一点 $\mathbf{x} = (x_1, \dots, x_n)$ 都可偏导, 则称 f 在 D 上可偏导, 此时便得到函数关于各变量的偏导函数 $\frac{\partial f}{\partial x_i}(\mathbf{x})$, 简称为偏导数, 通常将其简记为 $\frac{\partial f}{\partial x_i}$.

注记 2.2.2 多元函数的偏导数在本质上还是一元导数, 即令 $\varphi(x) := f(x, y_0)$, 则 $f_x(x_0, y_0) = \varphi'(x_0)$. 所以在求对某个变量的偏导数时, 只需将其它变量看成常数, 然后按一元函数的求导规则进行即可.

例 2.2.1 $z = x^2 - y^2$ 在 $(1, 0)$ 处的偏导数为

$$\frac{\partial z}{\partial x}(1, 0) = 2x|_{(1,0)} = 2; \quad \frac{\partial z}{\partial y}(1, 0) = -2y|_{(1,0)} = 0$$

同理可知 $z_x(0, 1) = 0; z_y = -1$. 而在 $(0, 0)$ 处, $z_x = z_y = 0$ (请结合“马鞍面”的形思考其几何意义) .

例 2.2.2 设 $u = x^{\frac{z}{y}} (x > 0, x \neq 1, y \neq 0)$, 其各偏导计算如下

$$\begin{aligned} \frac{\partial u}{\partial x} & \stackrel{y, z \text{ 视为常数}}{=} \frac{z}{x} x^{\frac{z}{y}-1} \\ \frac{\partial u}{\partial y} & \stackrel{x, z \text{ 视为常数}}{=} \frac{x^{\frac{z}{y}} \ln x \left(\frac{z}{y}\right)}{\text{利用 } (a^x)' = a^x \ln a} = z^{\frac{x}{y}} \ln x \left(-\frac{z}{y^2}\right) = -\frac{z \ln x}{y^2} x^{\frac{z}{y}} \\ \frac{\partial u}{\partial z} & \stackrel{x, y \text{ 视为常数}}{=} \frac{x^{\frac{z}{y}} \ln x \left(\frac{z}{y}\right)}{\text{利用 } (a^x)' = a^x \ln a} = \frac{\ln x}{y} x^{\frac{z}{y}} \end{aligned}$$

例 2.2.3 若 $w = \ln(x + y^2 + z^3)$, 求其各偏导数.

$$\frac{\partial u}{\partial x} = \frac{1}{x + y^2 + z^3}; \quad \frac{\partial u}{\partial y} = \frac{2y}{x + y^2 + z^3}; \quad \frac{\partial u}{\partial z} = \frac{3z^2}{x + y^2 + z^3}$$

例 2.2.4 验证 $z = x^y (x > 0, x \neq 1)$ 满足偏微分方程 $\frac{x}{y} \frac{\partial z}{\partial x} + \frac{1}{\ln x} \frac{\partial z}{\partial y} = 2z$.

$$\begin{aligned} \frac{\partial z}{\partial x} &= yx^{y-1}; \quad \frac{\partial z}{\partial y} = x^y \ln x \\ \Rightarrow \quad \frac{x}{y} \frac{\partial z}{\partial x} + \frac{1}{\ln x} \frac{\partial z}{\partial y} &= \frac{x}{y} yx^{y-1} + \frac{1}{\ln x} x^y \ln x = 2x^y = 2z \end{aligned}$$

例 2.2.5 (偏导数不存在) 求 $f(x, y) = \begin{cases} y \ln(x^2 + y^2), & (x, y) \neq (0, 0) \\ 0, & (x, y) = (0, 0) \end{cases}$ 在 $(0, 0)$ 处的偏导数.

此时最好按原始定义处理

$$\begin{aligned} f_x(0, 0) &= \lim_{\Delta x \rightarrow 0} \frac{f(\Delta x, 0) - f(0, 0)}{\Delta x} = \lim_{\Delta x \rightarrow 0} \frac{0 - 0}{\Delta x} = 0 \\ f_y(0, 0) &= \lim_{\Delta y \rightarrow 0} \frac{f(0, \Delta y) - f(0, 0)}{\Delta y} = \lim_{\Delta y \rightarrow 0} \frac{\Delta y \ln(\Delta x)^2}{\Delta y} = \lim_{\Delta y \rightarrow 0} \ln(\Delta y)^2 \end{aligned}$$

极限不存在, 故 $f_y(0, 0)$ 不存在, 所以 f 在 origin 处不可偏导.


偏导数的几何意义：以二元函数 $z = f(x, y)$ 为例， $z_x(x_0, y_0)$ 衡量的是在 $P_0(x_0, y_0)$ 函数只对于 x 的变化率，而这相当于空间曲线 $\begin{cases} z = f(x, y) \\ y = y_0 \end{cases}$ （其实是位于 $y = y_0$ 平面上的由 $z = f(x, y_0)$ 描绘的平面曲线）在点 (x_0, y_0) 处切线的斜率，显然就是 $f_x(x_0, y_0)$ 。由此可知，所截曲线在点 (x_0, y_0) 处的切线的一个方向向量（direction vector）即是

$$\mathbf{T} = (1, 0, f_x(x_0, y_0))$$

这是因为切线也在 $y = y_0$ 平面上，故 $\mathbf{T}$ 的 y -分量为零，而其 z -分量和 x -分量的比值 $z : x$ 应等于所截曲线的斜率 $f_x(x_0, y_0)$ ，即 $z : x = f_x(x_0, y_0) : 1$ 。换言之，曲线在 (x_0, y_0) 切向量（即切线的方向向量） $\mathbf{T}$ 相对于三个坐标轴的方向余弦满足

$$\cos(\mathbf{T}, x) : \cos(\mathbf{T}, y) : \cos(\mathbf{T}, z) = 1 : 0 : f_x(x_0, y_0)$$

注记 2.2.3 事实上， $\cos(\mathbf{T}, x) = \frac{\mathbf{T} \cdot \mathbf{i}}{|\mathbf{T}|} = \frac{1}{\sqrt{1 + f_x^2(x_0, y_0)}}$ ； $\cos(\mathbf{T}, y) = \frac{\mathbf{T} \cdot \mathbf{j}}{|\mathbf{T}|} = 0$ ； $\cos(\mathbf{T}, z) = \frac{\mathbf{T} \cdot \mathbf{k}}{|\mathbf{T}|} = \frac{f_x(x_0, y_0)}{\sqrt{1 + f_x^2(x_0, y_0)}}$ 。



同理， $f_y(x_0, y_0)$ 的几何意义是曲面 $z = f(x, y)$ 与平面 $x = x_0$ 所截曲线在 (x_0, y_0) 处切线的斜率，即切向量可取为 $\mathbf{T} = (0, 1, f_y(x_0, y_0))$ 。

注记 2.2.4 由第一节中的导引，可知曲面 $z = f(x, y)$ 在 $(x_0, y_0, f(x_0, y_0))$ 处的切平面方程为： $z - f(x_0, y_0) = f_x(x_0, y_0)(x - x_0) + f_y(x_0, y_0)(y - y_0)$ ，直观上，所截曲线的切线就是该切平面和截平面的交线，事实上，考虑切平面与截平面 $y = y_0$ 的交线

$$\begin{cases} z - f(x_0, y_0) = f_x(x_0, y_0)(x - x_0) + f_y(x_0, y_0)(y - y_0) \\ y = y_0 \end{cases}$$

$$\text{即 } z - f(x_0, y_0) = f_x(x_0, y_0)(x - x_0) \iff \frac{x - x_0}{1} = \frac{y - y_0}{0} = \frac{z - f(x_0, y_0)}{f_x(x_0, y_0)}$$

此即为曲线 $\begin{cases} z = f(x, y) \\ y = y_0 \end{cases}$ 在 $(x_0, y_0, f(x_0, y_0))$ 处的切线方程, 由此看出曲线在

该点处的切向量是 $\mathbf{T} = (1, 0, f_x(x_0, y_0))$, 与先前讨论结果完全一致.

可偏导与连续性的关系: 在一元函数情形, 我们知道, 可导必然连续, 连续未必可导. 但在多元情形下, 由于自变量所处空间的维度增加, 导致自变量趋于某点的方式更多样, 所以可偏导和连续性的关系不易厘清. 我们通过例子加以说明.

例 2.2.6 考察函数 $f(x, y) = \begin{cases} \frac{xy}{x^2 + y^2}, & (x, y) \neq (0, 0) \\ 0 & (x, y) = (0, 0) \end{cases}$ 我们知道它在 $(0, 0)$ 处的极限不存在, 故在该点不连续, 但

$$f_x(0, 0) = \lim_{x \rightarrow 0} \frac{f(x, 0) - f(0, 0)}{x} = 0; \quad \text{同理 } f_y(0, 0) = 0$$

即函数 $f(x, y)$ 在 $(0, 0)$ 处可偏导. 故**可偏导未必连续**.

例 2.2.7 对函数 $z = x + |y|$, 由于 $\sqrt{x^2 + y^2} \rightarrow 0$ 等价于 $x, y \rightarrow 0$, 即知 z 在原点是连续的, 但 $z(0, y) = |y|$ 当 $y = 0$ 时不可导, 故 $z_y(0, 0)$ 不存在, 所以 z 在原点不可偏导. 这是即不连续也不可导的例子.

注记 2.2.5 通过分析定义的结构, 即知 $f_x(x_0, y_0)$ 和 $f_y(x_0, y_0)$ 存在, 只能说明在 (x_0, y_0) 处, 沿着平行于 x -轴和平行于 y -轴的方向时, 函数是连续的, 但 $z = f(x, y)$ 作为二元函数在 (x_0, y_0) 处连续, 指的是在该点附近沿着任意方式接近时极限都存在且等于该点处的函数值. 仅凭两个方向极限的存在性当然不足以保证极限的存在, 遑论其他.

但如果对偏导数做一些严格限制, 则“可偏导”也能推出“连续”来, 比如

命题 2.2.1 设 $z = f(x, y)$ 的两个偏导数 f_x, f_y 在 (x_0, y_0) 点的某个领域内存在且有界, 则 f 在 (x_0, y_0) 点连续.

证明: 考虑函数 f 在 (x_0, y_0) 处的增量 $\Delta f = f(x_0 + \Delta x, y_0 + \Delta y) - f(x_0, y_0) =$


$$= f(x_0 + \Delta x, y_0 + \Delta y) - f(x_0, y_0 + \Delta y) + f(x_0, y_0 + \Delta y) - f(x_0, y_0)$$

$$\stackrel{\text{一元函数中值定理}}{\exists \xi_x, \xi_y \in (0, 1)} f_x(x_0 + \xi_x \Delta x, y_0 + \Delta y) \Delta x + f_y(x_0, y_0 + \xi_y \Delta y) \Delta y$$

由于两偏导数都在 (x_0, y_0) 邻近处存在且有界, 故当 $\Delta x, \Delta y \rightarrow 0$ 时, $\Delta f \rightarrow 0$, 即知 f 在 (x_0, y_0) 处连续. $\square$

注记 2.2.6 上命题成立的直观原因是: f_x, f_y 在 (x_0, y_0) 的近旁存在且有界, 这意味着

它在 (x_0, y_0) 近旁沿着任何方向靠近 (x_0, y_0) 的速率都是有限的, 比如按下图中从 P 沿着斜线方向趋于 P_0 , 可看成是沿平行于 x -轴和 y -轴的各微小路径 (即沿图中的微小折线) 趋近的极限. 显然, 当折线堆叠非常密集, 以致于非常接近于直线 $\overline{P_0P}$ 时, 由于在每条折线上函数的变化都是连续的 (因 P_0 近旁偏导数存在且有界), 故其净效应为函数沿 $\overline{P_0P}$ 的变化也连续. 同理, 对曲线路径, 也可利用这种折现逼近策略.



高阶偏导数: 设函数 $z = f(x, y)$ 在区域 D 内具有偏导 (函) 数 $\frac{\partial f}{\partial x} = f_x(x, y)$ 和 $\frac{\partial f}{\partial y} = f_y(x, y)$, 偏导数仍然是二元函数, 如果它们在 D 内依然可偏导, 则称其各偏导数为 $z = f(x, y)$ 在 D 内的二阶偏导数, 即

$$f_{xx} = \frac{\partial^2 f}{\partial x^2} := \frac{\partial}{\partial x} \left(\frac{\partial f}{\partial x} \right); \quad f_{xy} = \frac{\partial^2 f}{\partial x \partial y} := \frac{\partial}{\partial y} \left(\frac{\partial f}{\partial x} \right)$$

$$f_{yx} = \frac{\partial^2 f}{\partial y \partial x} := \frac{\partial}{\partial x} \left(\frac{\partial f}{\partial y} \right); \quad f_{yy} = \frac{\partial^2 f}{\partial y^2} := \frac{\partial}{\partial y} \left(\frac{\partial f}{\partial y} \right)$$

其中 f_{xy} 和 f_{yx} 称为二阶混合偏导数 (*mixed partial derivatives of 2nd order*), 下面的例子将表明: 一般情况下, $f_{xy} \neq f_{yx}$. 所以在计算高阶混合偏导时, 求导顺序很重要, 不确定时, 勿轻易调序.

可以将上面四个二阶偏导数整合为矩阵 $\mathbf{Q} := \begin{bmatrix} f_{xx} & f_{xy} \\ f_{yx} & f_{yy} \end{bmatrix}$, 称为 f 的 *Hesse* 矩阵, 后面会知道, 它包含函数在一点处的二阶展开信息, 且与函数在一点处是否有极值及极值的类型有密切关系. 特别地, 若 $f_{xy} = f_{yx}$, 则 *Hesse* 矩阵对称, 则它对应一个二次型, 该二次型是函数泰勒展开二阶信息的携带者.

注记 2.2.7 可沿两个方向推广上定义, 其一, 对一般 n 原函数 $z = f(x_1, \dots, x_n)$, 可有 n^2 个二阶偏导数 $\frac{\partial^2 z}{\partial x_i \partial x_j}$ ($1 \leq i, j \leq n$); 另一方面, 如果二阶偏导仍然可偏导, 则可继续求其三阶偏导, 等等. 比如对二元函数 $z = f(x, y)$, 若其可三阶偏导, 则三阶偏导共有 8 个: $f_{xxx}, f_{xxy}, f_{xyx}, f_{xyy}, f_{yxx}, f_{yxy}, f_{yyx}, f_{yyy}$.

例 2.2.8 对 $z = \arctan \frac{y}{x}$, 有 $z_x = \frac{-\frac{y}{x^2}}{1 + (\frac{y}{x})^2} = \frac{-y}{x^2 + y^2}$; $z_y = \frac{\frac{1}{x}}{1 + (\frac{y}{x})^2} = \frac{x}{x^2 + y^2}$.

$$z_{xx} = \frac{\partial}{\partial x} \left(\frac{-y}{x^2 + y^2} \right) = \frac{2xy}{(x^2 + y^2)^2}; \quad z_{xy} = \frac{\partial}{\partial y} \left(\frac{-y}{x^2 + y^2} \right) = \frac{-x^2 + y^2}{(x^2 + y^2)^2}$$

$$z_{yx} = \frac{\partial}{\partial x} \left(\frac{x}{x^2 + y^2} \right) = \frac{-x^2 + y^2}{(x^2 + y^2)^2}; \quad z_{yy} = \frac{\partial}{\partial y} \left(\frac{x}{x^2 + y^2} \right) = \frac{-2xy}{(x^2 + y^2)^2}$$

注意此时 $z_{xy} = z_{yx}$.

例 2.2.9 对函数 $z = x^2 + y^2$ (其图形为旋转抛物面), 有 $z_x = 2x$, $z_y = 2y$, $z_{xx} = z_y = 2$, $z_{xy} = z_{yx} = 0$. 故其 Hesse 矩阵为 $\mathbf{Q}_1 = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$, 对应二次型为 $2x^2 + 2y^2$. (请读者与一元时 $y = x^2$, $y'' = 2$ 对比之: y 在 $x = 0$ 处的泰勒展开为 $y = 0 + 0x + \frac{1}{2!}2x^2 = x^2$) 矩阵 $\mathbf{Q}_1$ 是正定的.

而对于函数 $z = x^2 - y^2$ (其图形为“马鞍面”), 此时有 $z_x = 2x$, $z_y = -2y$; $z_{xx} = 2$; $z_{yy} = -2$; $z_{xy} = z_{yx} = 0$. 故其 Hesse 矩阵为 $\mathbf{Q}_2 = \begin{bmatrix} 2 & 0 \\ 0 & -2 \end{bmatrix}$. 注意 $\mathbf{Q}_2$ 是不定的.

例 2.2.10 考察函数 $f(x, y) = \begin{cases} xy \frac{x^2 - y^2}{x^2 + y^2}, & x^2 + y^2 \neq 0 \\ 0, & x^2 + y^2 = 0 \end{cases}$ 则其一阶偏导数为

$$f_x(x, y) = \begin{cases} y \frac{x^4 + 4x^2y^2 - y^4}{(x^2 + y^2)^2}, & x^2 + y^2 \neq 0 \\ 0, & x^2 + y^2 = 0 \end{cases}$$

$$f_y(x, y) = \begin{cases} x \frac{x^4 - 4x^2y^2 - y^4}{(x^2 + y^2)^2}, & x^2 + y^2 \neq 0 \\ 0, & x^2 + y^2 = 0 \end{cases}$$

$$\frac{\partial^2 z}{\partial y \partial x}(0, 0) = f_{xy}(0, 0) = \lim_{\Delta y \rightarrow 0} \frac{f_x(0, 0 + \Delta y) - f_x(0, 0)}{\Delta y} = \lim_{\Delta y \rightarrow 0} \frac{\frac{-\Delta y^5}{\Delta y^4} - 0}{\Delta y} = -1$$

$$\frac{\partial^2 z}{\partial x \partial y}(0, 0) = f_{yx}(0, 0) = \lim_{\Delta y \rightarrow 0} \frac{f_y(0 + \Delta y, 0) - f_y(0, 0)}{\Delta x} = \lim_{\Delta y \rightarrow 0} \frac{\frac{\Delta x^5}{\Delta x^4} - 0}{\Delta x} = 1$$

注意, 该例中函数在 $(0, 0)$ 处的两混合偏导数存在但不相等. 但如果混合偏导数满足连续性条件, 则两者相等.

命题 2.2.2 如函数 $z = f(x, y)$ 的两个混合偏导数 f_{xy} 和 f_{yx} 在点 (x_0, y_0) 连续, 则成立 $f_{xy}(x_0, y_0) = f_{yx}(x_0, y_0)$.

证明: 记 $\varphi(x) := f(x, y_0 + \Delta y) - f(x, y_0)$, 则它可导 (因 f_x 存在), 由拉格朗日中值定理, 知 $\exists \xi_1 \in (0, 1)$, 使得 $\varphi(x + \Delta x) - \varphi(x_0) = \varphi'(x_0 + \xi_1 \Delta x) \Delta x =$

$$= (f_x(x_0 + \xi_1 \Delta x, y_0 + \Delta y) - f_x(x_0 + \xi_1 \Delta x, y_0)) \Delta x$$

$$\frac{\text{再对 } y \text{ 运用中值定理}}{\exists \xi_2 \in (0,1)} f_{xy}(x_0 + \xi_1 \Delta x, y_0 + \xi_2 \Delta y) \Delta x \Delta y$$

$$\begin{aligned} \text{即 } f(x_0 + \Delta x, y_0 + \Delta y) - f(x_0 + \Delta x, y_0) - f(x_0, y_0 + \Delta y) + f(x_0, y_0) &= \\ &= f_{xy}(x_0 + \xi_1 \Delta x, y_0 + \xi_2 \Delta y) \Delta x \Delta y \end{aligned}$$

上式两边同时除 Δy 后令 $\Delta y \rightarrow 0$, 并结合 f_{xy} 的连续性, 有

$$f_y(x_0 + \Delta x, y_0) - f_y(x_0, y_0) = f_{xy}(x_0 + \xi_1 \Delta x, y_0) \Delta x$$

两边除 Δx 后令 $\Delta x \rightarrow 0$, 由 f_{xy} 和 f_{yx} 的连续性得 $f_{yx}(x_0, y_0) = f_{xy}(x_0, y_0)$ $\square$.

下面的例子给出了数学物理中重要一些偏微分方程解的形式.

例 2.2.11 验证 $u = \frac{1}{\sqrt{x^2 + y^2 + z^2}}$ 满足 Laplace 方程: $\Delta u = 0$, 其中

$$\Delta := \frac{\partial^2}{\partial x^2} + \frac{\partial^2}{\partial y^2} + \frac{\partial^2}{\partial z^2}$$

是作用在函数空间上的微分算子 (differential operators), 称为 Laplace 算子.

解: 由于 $\frac{\partial u}{\partial x} = -x(x^2 + y^2 + z^2)^{-\frac{3}{2}}$, 所以

$$\frac{\partial^2 u}{\partial x^2} = -(x^2 + y^2 + z^2)^{-\frac{3}{2}} + 3x^2(x^2 + y^2 + z^2)^{-\frac{5}{2}} = (2x^2 - y^2 - z^2)(x^2 + y^2 + z^2)^{-\frac{5}{2}}$$

由于变量 x, y, z 在 u 中和算子 Δ 中的出现是对称的, 从而

$$\frac{\partial^2 u}{\partial y^2} = (2y^2 - z^2 - x^2)(x^2 + y^2 + z^2)^{-\frac{5}{2}}; \quad \frac{\partial^2 u}{\partial z^2} = (2z^2 - x^2 - y^2)(x^2 + y^2 + z^2)^{-\frac{5}{2}}$$

$$\text{从而可知 } \Delta u = \frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2} + \frac{\partial^2 u}{\partial z^2} = 0.$$

例 2.2.12 验证 $z = e^{-kn^2 t} \sin(nx)$ (其中 n 是任意整数) 满足热传导方程: $\frac{\partial z}{\partial t} = k \frac{\partial^2 z}{\partial x^2}$.

解: $\frac{\partial z}{\partial t} = -kn^2 e^{-kn^2 t} \sin(nx)$; $\frac{\partial^2 z}{\partial x^2} = e^{-kn^2 t} n \cos(nx)$, 故

$$\frac{\partial z}{\partial t} - k \frac{\partial^2 z}{\partial x^2} = -kn^2 e^{-kn^2 t} \sin(nx) - k e^{-kn^2 t} n \cos(nx) = 0 \quad \square$$

例 2.2.13 验证函数 $u(x, t) = \frac{1}{2k\sqrt{\pi t}} e^{-\frac{x^2}{4k^2 t}}$ 在上半平面 $\mathbb{R}_+^2 = \{(x, t) \in \mathbb{R}^2 \mid t > 0\}$ 上满

足热传导方程 $\frac{\partial u}{\partial t} = k^2 \frac{\partial^2 u}{\partial x^2}$ 其中 k 为正常数.

解: $\forall (x, t) \in \mathbb{R}_+^2$, 有 $\frac{\partial u}{\partial t}(x, t) = \frac{1}{2k\sqrt{\pi}} \left(-\frac{1}{2} \frac{1}{t^{3/2}} e^{-\frac{x^2}{4k^2t}} + \frac{1}{t^{1/2}} e^{-\frac{x^2}{4k^2t}} \frac{x^2}{4k^2t^2} \right)$

$$= \frac{1}{4k\sqrt{\pi}t^{3/2}} e^{-\frac{x^2}{4k^2t}} \left(-1 + \frac{x^2}{2k^2t} \right)$$

$$\frac{\partial u}{\partial x}(x, t) = \frac{1}{2k\sqrt{\pi t}} e^{-\frac{x^2}{4k^2t}} \left(-\frac{x}{2k^2t} \right) \Rightarrow \frac{\partial^2 u}{\partial x^2}(x, t) = \frac{1}{2a\sqrt{\pi t}} \left(e^{-\frac{x^2}{4k^2t}} \frac{x^2}{4k^4t^2} - \right.$$

$$\left. - \frac{1}{2k^2t} e^{-\frac{x^2}{4k^2t}} \right) = \frac{1}{4k^3\sqrt{\pi}t^{3/2}} e^{-\frac{x^2}{4k^2t}} \left(\frac{x^2}{2k^2t} - 1 \right) \quad \square$$

注记 2.2.8 做坐标变换 $t' = k^2t$, 则 $\frac{\partial u}{\partial t} = \frac{\partial u}{\partial t'} \frac{dt'}{dt} = k^2 \frac{\partial u}{\partial t'}$, 故在变量 (x, t') 下, 方程变为 $\frac{\partial u}{\partial t'} = \frac{\partial^2 u}{\partial x^2}$. 上面的解变为 $u(x, t') = \frac{1}{2\sqrt{\pi t'}} e^{-\frac{x^2}{4t'}}$. 对更一般的 (空间中的三维) 热传导方程:


$$\frac{\partial u}{\partial t} = \Delta u = \frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2} + \frac{\partial^2 u}{\partial z^2}$$

则 $u(x, t) = \frac{1}{2\sqrt{\pi}} t^{-\frac{3}{2}} e^{-\frac{x^2+y^2+z^2}{4t}}$ 满足上方程. 令 $r = \sqrt{x^2 + y^2 + z^2}$, 可验证 $f(r, t) = \frac{1}{2\sqrt{\pi}} t^{-\frac{3}{2}} e^{-r^2/4t}$ 满足方程 $\frac{\partial f}{\partial t} = \frac{1}{r^2} \frac{\partial}{\partial r} \left(r^2 \frac{\partial f}{\partial r} \right)$.

2.3 方向导数与梯度

对多元函数 $z = f(\mathbf{x})$, $\mathbf{x} = (x_1, \dots, x_n) \in \mathbb{R}^n$, 其偏导数 $\frac{\partial z}{\partial x_i}$ 只衡量函数在自变量分量 x_i 方向上的变化速率, 为全面衡量函数在某一点 $\mathbf{x}_0$ 的变化速率, 需考虑函数以任何方式趋于点 $\mathbf{x}_0$ 时的变化率问题.

比如要考虑函数在 $\mathbf{x}_0$ 处沿着向量 $\mathbf{u} = (u_1, \dots, u_n)$ 的变化率, 为此, 我们取任一 (因计算结果将不依赖于曲线的选择) 曲线 $\gamma(t) = (x_1(t), \dots, x_n(t))$ 使得 $\gamma(t_0) = \mathbf{x}_0$ 且 $\gamma'(t_0) = \mathbf{u}$, 即 $x'_i(t_0) = u_i, i = 1, \dots, n$.



则 $f(\mathbf{x})$ 在 $\mathbf{x}_0$ 点沿向量 $\mathbf{u}$ 的变化率可按下计算

$$\left. \frac{df(\mathbf{x}(t))}{dt} \right|_{t=t_0} = \lim_{\Delta t \rightarrow 0} \frac{f(\mathbf{x}(t_0 + \Delta t)) - f(\mathbf{x}(t_0))}{\Delta t} = \lim_{\Delta t \rightarrow 0} \frac{f(\mathbf{x}(t_0 + \Delta t)) - f(\mathbf{x}_0)}{\Delta t}$$

$$\begin{aligned}
&= \lim_{\Delta t \rightarrow 0} \frac{f(x_1(t_0 + \Delta t), \dots, x_n(t_0 + \Delta t)) - f(x_0^1, \dots, x_0^n)}{\Delta t} \\
&= \lim_{\Delta t \rightarrow 0} \frac{f(x_1(t_0 + \Delta t), \dots, x_n(t_0 + \Delta t)) - f(x_1(t_0), x_2(t_0 + \Delta t), \dots, x_n(t_0 + \Delta t))}{\Delta t} \\
&\quad + \frac{f(x_1(t_0), x_2(t_0 + \Delta t), \dots, x_n(t_0 + \Delta t)) - f(x_0^1, \dots, x_0^n)}{\Delta t} \\
&= \lim_{\Delta t \rightarrow 0} \frac{f(x_1(t_0 + \Delta t), \dots, x_n(t_0 + \Delta t)) - f(x_1(t_0), x_2(t_0 + \Delta t), \dots, x_n(t_0 + \Delta t))}{\Delta t} \\
&\quad + \lim_{\Delta t \rightarrow 0} \frac{f(x_1(t_0), x_2(t_0 + \Delta t), \dots, x_n(t_0 + \Delta t)) - f(x_1(t_0), x_2(t_0), \dots, x_n(t_0 + \Delta t))}{\Delta t} \\
&\quad + \lim_{\Delta t \rightarrow 0} \frac{f(x_1(t_0), x_2(t_0), \dots, x_n(t_0 + \Delta t)) - f(x_0^1, \dots, x_0^n)}{\Delta t} \\
&= \lim_{\Delta t \rightarrow 0} \frac{f(x_1(t_0 + \Delta t), \dots, x_n(t_0 + \Delta t)) - f(x_1(t_0), x_2(t_0 + \Delta t), \dots, x_n(t_0 + \Delta t))}{x_1(t_0 + \Delta t) - x_1(t_0)} \frac{x_1(t_0 + \Delta t) - x_1(t_0)}{\Delta t} \\
&\quad + \lim_{\Delta t \rightarrow 0} \frac{f(x_1(t_0), x_2(t_0 + \Delta t), \dots, x_n(t_0 + \Delta t)) - f(x_1(t_0), x_2(t_0), \dots, x_n(t_0 + \Delta t))}{x_2(t_0 + \Delta t) - x_2(t_0)} \frac{x_2(t_0 + \Delta t) - x_2(t_0)}{\Delta t} \\
&\quad + \lim_{\Delta t \rightarrow 0} \frac{f(x_1(t_0), x_2(t_0), \dots, x_n(t_0 + \Delta t)) - f(x_0^1, \dots, x_0^n)}{\Delta t} \\
&= \frac{\partial f}{\partial x_1} \Big|_{\mathbf{x}_0} x_1'(t_0) + \frac{\partial f}{\partial x_2} \Big|_{\mathbf{x}_0} x_2'(t_0) + \lim_{\Delta t \rightarrow 0} \frac{f(x_1(t_0), x_2(t_0), \dots, x_n(t_0 + \Delta t)) - f(x_0^1, \dots, x_0^n)}{\Delta t} \\
&= \frac{\partial f}{\partial x_1} \Big|_{\mathbf{x}_0} u_1 + \frac{\partial f}{\partial x_2} \Big|_{\mathbf{x}_0} u_2 + \lim_{\Delta t \rightarrow 0} \frac{f(x_1(t_0), x_2(t_0), \dots, x_n(t_0 + \Delta t)) - f(x_0^1, \dots, x_0^n)}{\Delta t} \\
&\quad \dots \\
&= \frac{\partial f}{\partial x_1} \Big|_{\mathbf{x}_0} u_1 + \frac{\partial f}{\partial x_2} \Big|_{\mathbf{x}_0} u_2 + \dots + \frac{\partial f}{\partial x_n} \Big|_{\mathbf{x}_0} u_n = \nabla f|_{\mathbf{x}_0} \bullet \mathbf{u}
\end{aligned}$$

其中 $\nabla f|_{\mathbf{x}_0} := \left(\frac{\partial f}{\partial x_1} \Big|_{\mathbf{x}_0}, \dots, \frac{\partial f}{\partial x_n} \Big|_{\mathbf{x}_0} \right)$ 为 f 在 $\mathbf{x}_0$ 点处的梯度 (gradient) 向量, 简称梯度.

求梯度可看成是对函数 f 作用以微分算子 $\nabla = \left(\frac{\partial}{\partial x_1}, \dots, \frac{\partial}{\partial x_n} \right)$, 它将函数变为一向量场 $\nabla f = \left(\frac{\partial f}{\partial x_1}, \dots, \frac{\partial f}{\partial x_n} \right)$, 称为函数 f 的梯度场 (gradient field), 梯度场在某点的取值即为函数在该点处的梯度. 注意, 上面计算结果只依赖于 $\mathbf{x}_0$ 处的方向 $\mathbf{u}$, 而并不依赖于曲线的选择 (只要其在 $\mathbf{x}_0$ 处的切向量为 $\mathbf{u}$ 即可).

由于算子 ∇ 将函数变为一向量场, 故它是一向量微分算子 (vector valued differential operator), 常也称其为哈密顿算子 (Hamilton operator).

定义 2.3.1 设 $\mathbf{u}$ 为 $\mathbf{x}_0$ 处的单位向量, 则 f 在 $\mathbf{x}_0$ 处沿方向 $\mathbf{u}$ 的方向导数 (*directional derivative*) 定义为如下极限

$$\left. \frac{\partial f}{\partial \mathbf{u}} \right|_{\mathbf{x}_0} := \lim_{t \rightarrow 0} \frac{f(\mathbf{x}_0 + t\mathbf{u}) - f(\mathbf{x}_0)}{t}$$

方向导数常也记为 $\nabla_{\mathbf{u}} f(\mathbf{x}_0) = \nabla_{\mathbf{u}} f|_{\mathbf{x}_0}$. 注意, 上面的定义相当于计算函数沿着过 $\mathbf{x}_0$ 的直线 $\mathbf{x}(t) = \mathbf{x}_0 + t\mathbf{u}$ 趋近于 $\mathbf{x}_0$ 的变化率, 而我们知道, 该变化率只依赖于 $\mathbf{x}_0$ 处的梯度和方向 $\mathbf{u}$, 即

$$\nabla_{\mathbf{u}} f(\mathbf{x}_0) = \left. \frac{\partial f}{\partial \mathbf{u}} \right|_{\mathbf{x}_0} = \sum_{i=1}^n f_{x_i}(\mathbf{x}_0) u_i = \nabla f|_{\mathbf{x}_0} \bullet \mathbf{u}$$

对二元函数 $z = f(x, y)$, 设它在 $P_0(x_0, y_0)$ 领域内有定义, $\mathbf{l}$ 是给点非零向量, 其方向余弦为 $\cos \alpha, \cos \beta$, 即 $\mathbf{l}$ 方向的单位向量可取为 $\mathbf{l}^0 = (\cos \alpha, \cos \beta)$, 则 f 在 P_0 处沿 $\mathbf{l}$ 的方向导数可计算为

$$\begin{aligned} \nabla_{\mathbf{l}} f(P_0) &= \left. \frac{\partial f}{\partial \mathbf{l}} \right|_{(x_0, y_0)} = \lim_{t \rightarrow 0} \frac{f(x_0 + t \cos \alpha, y_0 + t \cos \beta) - f(x_0, y_0)}{t} \\ &= \lim_{t \rightarrow 0} \frac{f(x_0 + t \cos \alpha, y_0 + t \cos \beta) - f(x_0, y_0 + t \cos \beta)}{t} + \\ &\quad + \lim_{t \rightarrow 0} \frac{f(x_0, y_0 + t \cos \beta) - f(x_0, y_0)}{t} \\ &= \lim_{t \rightarrow 0} \frac{f(x_0 + t \cos \alpha, y_0 + t \cos \beta) - f(x_0, y_0 + t \cos \beta)}{x_0 + t \cos \alpha - x_0} \cdot \frac{x_0 + t \cos \alpha - x_0}{t} \\ &\quad + \lim_{t \rightarrow 0} \frac{f(x_0, y_0 + t \cos \beta) - f(x_0, y_0)}{y_0 + t \cos \beta - y_0} \cdot \frac{y_0 + t \cos \beta - y_0}{t} \\ &= \left. \frac{\partial f}{\partial x} \right|_{(x_0, y_0)} \cos \alpha + \left. \frac{\partial f}{\partial y} \right|_{(x_0, y_0)} \cos \beta = \nabla f|_{(x_0, y_0)} \bullet \mathbf{l}^0 \end{aligned}$$

方向导数作为映射: 对 x 和 y 方向上的单位向量 $\mathbf{i} = (1, 0)$ 和 $\mathbf{j} = (0, 1)$ 有

$$\nabla_{\mathbf{i}} f = \nabla f \bullet \mathbf{i} = \frac{\partial f}{\partial x}; \quad \nabla_{\mathbf{j}} f = \nabla f \bullet \mathbf{j} = \frac{\partial f}{\partial y}$$

即偏导数可看成是方向导数, 亦即 x - y 平面上两个标准独立方向 ($\mathbb{R}^2$ 的标准基) 上

的方向导数. 那么对方向

$$\boldsymbol{l} = (\cos \alpha, \cos \beta) = \cos \alpha \mathbf{i} + \cos \beta \mathbf{j}$$

其方向导数 $\nabla_{\boldsymbol{l}} f$ 亦是 $\nabla_{\mathbf{i}} f$ 和 $\nabla_{\mathbf{j}} f$ 的线性组合, 即

$$\nabla_{\boldsymbol{l}} f = \cos \alpha \frac{\partial f}{\partial x} + \cos \beta \frac{\partial f}{\partial y} = \cos \alpha \nabla_{\mathbf{i}} f + \cos \beta \nabla_{\mathbf{j}} f$$

由于 f 的任意性, 作为 (作用于函数上的) 微分算子, 我们有

$$\nabla_{\boldsymbol{l}} = \cos \alpha \nabla_{\mathbf{i}} + \cos \beta \nabla_{\mathbf{j}} = \nabla \bullet \boldsymbol{l}^0 = \cos \alpha \frac{\partial}{\partial x} + \cos \beta \frac{\partial}{\partial y}$$

$$\nabla_{\boldsymbol{l}}|_{P_0} = \cos \alpha \nabla_{\mathbf{i}}|_{P_0} + \cos \beta \nabla_{\mathbf{j}}|_{P_0} = \nabla|_{P_0} \bullet \boldsymbol{l}^0 = \cos \alpha \frac{\partial}{\partial x}\bigg|_{P_0} + \cos \beta \frac{\partial}{\partial y}\bigg|_{P_0}$$

由此可见, 在 P_0 点处, 沿单位方向 $\boldsymbol{l}$ 的方向导数可看成是一个映射 $\nabla_{\boldsymbol{l}}|_{P_0}$, 它将函数 f 映为其在 P_0 处 $\boldsymbol{l}$ 方向的方向导数 $\nabla_{\boldsymbol{l}} f(P_0)$. 该映射显然是线性的, 即

$$\nabla_{\boldsymbol{l}}|_{P_0} (c_1 f + c_2 g) = c_1 \nabla_{\boldsymbol{l}}|_{P_0} f + c_2 \nabla_{\boldsymbol{l}}|_{P_0} g \quad \forall c_1, c_2 \in \mathbb{R}$$

且它也满足求导的莱布尼茨法则 (请读者自证之)

$$\nabla_{\boldsymbol{l}}|_{P_0} (fg) = f \nabla_{\boldsymbol{l}}|_{P_0} g + g \nabla_{\boldsymbol{l}}|_{P_0} f$$

这些性质从某种意义上来说是显然的, 因为 $\nabla_{\boldsymbol{l}}$ 本质上是偏导算子 $\frac{\partial}{\partial x}$ 和 $\frac{\partial}{\partial y}$ 的线性组合, 所以偏导算子所满足的性质可“迁移”为 $\nabla_{\boldsymbol{l}}$ 的对应性质.

注记 2.3.1 $\mathbb{R}^2$ 上的方向可由单位圆参数 $\{(\cos \theta, \sin \theta)\}$ 表示为 $(\cos \theta, \sin \theta)$, 则方向导数表示为: $\nabla_{\boldsymbol{\theta}} := \cos \theta \frac{\partial}{\partial x} + \sin \theta \frac{\partial}{\partial y}$.

梯度的几何意义 (以二元为例): 由方向导数的计算公式知, 方向导数为

$$\nabla_{\boldsymbol{l}} f(P_0) = \frac{\partial f}{\partial \boldsymbol{l}}\bigg|_{(x_0, y_0)} = \nabla f|_{(x_0, y_0)} \bullet \boldsymbol{l}^0 = |\nabla f|_{(x_0, y_0)} \cos \varphi$$

其中 φ 为梯度向量和方向向量 $\boldsymbol{l}$ 之间的夹角. 由此可见, 当 $\varphi = 0$ 时, 方向导数取其最大值 $|\nabla f|$; 而当 $\varphi = \pi$ 时, 方向导数取其最小值 $-|\nabla f|$. 故梯度方向是方向导数取最大值的方向, 也即函数变化最快的方向, 其模长是方向导数的最大值, 而与梯度

方向相反的方向则是方向导数取最小值的方向.


对二元函数 $z = f(x, y)$, 对给定常数 C , 曲线 $f(x, y) = C$ 称为函数 f 的等高线 (level curve). 当 C 按一定速率变化时, 等高线族在平面 $\mathbb{R}^2$ 上不同区域的疏密程度反映出函数在不同区域变化速率的快慢.

例 2.3.1 考察函数 $f(x, y) = x^2 + y^2$, 其梯度为 $\nabla f = \left(\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y} \right) = (2x, 2y)$, $|\nabla f| = 2\sqrt{x^2 + y^2}$. 也就是说, 函数沿径向 $\mathbf{r} = (x, y)$ 的变化速度最快, 且在圆 $x^2 + y^2 = C$ 上各点处的变化速度都相同, 半径越大 (即点越远离原点), 函数的变化速度越快.


当 C 按一定速度增长时, 比如取 $C = 1, 2, 3, \dots$, 函数的等高线为: $x^2 + y^2 = n$, 切在其上 $|\nabla f| = 2\sqrt{C} = 2\sqrt{n}$. 等高线族于 x 轴的交点分别为 $\sqrt{n}$, 当 n 越大时, 其间距

$$\sqrt{n} - \sqrt{n-1} = \frac{1}{\sqrt{n} + \sqrt{n-1}}$$


越来越小, 即等高线族越来越密集, 和梯度计算结果一致.



例 2.3.2 考察函数 $f(x, y) = x^2 - y^2$, 其梯度为 $\nabla f = (2x, -2y)$, $|\nabla f| = 2\sqrt{x^2 + y^2}$. 如同前例, 离原点距离越远, 函数值的变化越快; 在 (x, y) 处, 函数变化最快的方向是 $(x, -y)$. 我们考察其等高曲线族.



例 2.3.3 考察函数 $f = 3x^2 + 2y^2 - z^2$ ，其等高面 (level surface) 如下



其梯度场为 $\nabla f = (6x, 4y, -2z)$. 在 $M_0(1, 2, -1)$ 处, $\nabla f|_{M_0} = (6, 8, 2)$, 即在 M_0 点处, 函数沿 $\mathbf{u} = (6, 8, 2)$ 方向变化最快, 且其变化速度的最大值和最小值分别为 $|\nabla f|_{M_0}| = \sqrt{6^2 + 8^2 + 2^2} = 2\sqrt{26}$, $-|\nabla f|_{M_0}| = -2\sqrt{26}$. 它在 M_0 点处沿 $\mathbf{u} = (8, -1, 4)$ 的方向导数为

$$\nabla_{\mathbf{u}} f|_{M_0} = \frac{\partial f}{\partial \mathbf{u}} \Big|_{M_0} = \nabla f|_{M_0} \bullet \mathbf{u}^0 = (6, 8, 2) \bullet \frac{(8, -1, 4)}{9} = \frac{48}{9}$$

注记 2.3.2 通过上面几个例子, 不难观察得到: 某点处梯度向量总与过该点的等高线 (或等高面) 相互正交 (orthogonal).



这是不难理解的, 梯度方向是函数变化速度最快的方向, 也就是说, 在该方向上, 等高线的变化也最快, 如下图, 取两非常接近的等高线 ($\Delta t \rightarrow 0$), 则在 P_0 点的无穷小领域, 两条无限靠近的等高线近似于两平行直线 (或用对应切线近似之), 而两平行直线间的最短距离是垂直于两者的线段的长度, 由此可知, 为使得函数值从 P_0 点的 C 起, 以最快的速度 (即 P_0 到等高线 $f = C + \Delta C$ 的距离最短) 取到函数值 $C + \Delta t$, 必得沿着 P_0 处与等高线垂直的方向走起, 即梯度方向. 其严格证明如下:

对等高线方程 $f(x, y) = C$ 两边对 x 求导, 得到等高线上 P_0 处的切线斜率为

$$y'(x_0) = -\frac{f_x}{f_y} \Big|_{(x_0, y_0)}$$

即 P_0 处等高线的切向量是 $\mathbf{v} = (f_y(x_0, y_0), -f_x(x_0, y_0))$, 而我们知道在 P_0 处的梯度为 $\nabla f|_{P_0} = (f_x(x_0, y_0), f_y(x_0, y_0))$, 从而

$$\nabla f|_{P_0} \bullet \mathbf{v} = f_x \cdot f_y + f_y \cdot (-f_x) \equiv 0$$

更直接的证明方法是对 $f(x, y) = C$ 两边微分, 得到曲线的切线方向

$$f_x dx + f_y dy = 0 \implies f_x(x_0, y_0)(x - x_0) + f_y(x_0, y_0)(y - y_0) = 0$$

可看出等高线 $f(x, y) = C$ 在 P_0 处切线的法向量 (即等高线在该点的法向量) 为 $(f_x(x_0, y_0), f_y(x_0, y_0))$, 此即为梯度向量.

注记 2.3.3 梯度概念也是物理等自然科学中的基本概念, 比如电场强度 $\mathbf{E}$ 就是对应电势 V 的梯度, 而由上条注记中的说明可知, 场强指向电势下降最快的方向, 即有基本方程: $\mathbf{E} = -\nabla V$. 对原点处的电量为 q 的点电荷, 其势由 $V = \frac{q}{4\pi\epsilon r}$ 给出, 其中 $r = |\mathbf{r}|$, $\mathbf{r} = (x, y, z)$, ϵ 为介电常数, 则

$$\nabla V = \frac{dV}{dr} \nabla r = -\frac{q}{4\pi\epsilon r^2} \frac{1}{r} (x, y, z) = -\frac{q}{4\pi\epsilon} \cdot \frac{\mathbf{r}}{r^3}$$

$$\text{故对应场强为 } \mathbf{E} = \frac{q}{4\pi\epsilon} \cdot \frac{\mathbf{r}}{r^3}.$$

注记 2.3.4 梯度算子 ∇ 可看成是广义的导算子, 因其运算性质同通常求导完全一致, 即有

1. $\nabla(c_1 u + c_2 v) = c_1 \nabla u + c_2 \nabla v$ (其中 c_1, c_2 为常数.)
2. $\nabla(uv) = v \nabla u + u \nabla v$;
3. $\nabla\left(\frac{u}{v}\right) = \frac{v \nabla u - u \nabla v}{v^2}$ ($v \neq 0$);
4. $\nabla(f(u)) = f'(u) \nabla u$ (其中 f 为一元函数);
5. $\nabla(g(u, v)) = g_u \nabla u + g_v \nabla v$ (其中 g 为二元函数).

上面的性质 4 和性质 5 的沿着需要知道多元复合函数求导 (微分) 的规则, 我们将放在第 5 小节探讨.

2.4 全微分概念

我们以二元函数 $z = f(x, y)$ 为例来说明（推广到一般 n 元情形是直截了当的——纯形式上的推广）.

在 $P_0(x_0, y_0)$ 附近, 将 z 只看成 x 的函数, 然后线性化, 有 $dz = \frac{\partial f}{\partial x}(x_0, y_0)dx$; 同理, 将 z 只看成 y 的函数, 然后线性化, 有 $dz = \frac{\partial f}{\partial y}(x_0, y_0)dy$.

而求微分, 即线性化的本质就是在局部将函数关系转变为线性关系, 又根据线性叠加原则, 我们预期: 当 $P(x, y)$ 在 $P_0(x_0, y_0)$ 近旁变动时, $z = f(x, y)$ 的线性化为两个独立方向线性化的如下“叠加”, 称为是 z 在 P_0 处的全微分 (*total differential*), 通常简称为微分

$$dz|_{P_0} = df|_{P_0} = \frac{\partial f}{\partial x}(x_0, y_0)dx + \frac{\partial f}{\partial y}(x_0, y_0)dy$$

即在 P_0 处, 给 x, y 分别以增量 $\Delta x, \Delta y$, 则函数值所获增量 (称为全增量)

$$\Delta z = f(x_0 + \Delta x, y_0 + \Delta y) - f(x_0, y_0)$$

有线性近似 $\Delta z \approx f_x(x_0, y_0)(x - x_0) + f_y(x_0, y_0)(y - y_0)$, 即用下面的二元线性函数 $L_f|_{P_0}(x, y)$ 来近似二元函数 $z = f(x, y)$ 在 P_0 点近旁的行为

$$L_f|_{P_0}(x, y) := f(x_0, y_0) + f_x(x_0, y_0)(x - x_0) + f_y(x_0, y_0)(y - y_0)$$

如果这个由偏导信息 f_x, f_y 给出的线性近似是合理的, 则它逼近 f 的精度须得复合我们的基本预期. 首先得明确这里所说的“基本预期”, 我们从分析一元情形入手. 对 $y = f(x)$, 它在 $x = x_0$ 处可微 (此时等价于可导), 即 $f'(x_0)$ 是使下式成立的唯一数

$$f(x) - f(x_0) = f'(x_0)(x - x_0) + o((x - x_0)) \quad \Delta x = x - x_0 \rightarrow 0 \text{ 时}$$

亦即实际增量 $\Delta y = f(x) - f(x_0)$ 同线性近似给出的实际增量的线性主部 $f'(x_0)\Delta x$ 相比而言, 其差是关于 Δx 的高阶无穷小, 即

$$\lim_{\Delta x \rightarrow 0} \frac{\Delta y - f'(x_0)\Delta x}{\Delta x} = 0$$

在一元情形, 这就是可导的定义, 故一元情形, 可导即可微, 可微即可导.

在二元情形, 不同于一元情形时只能“单向度”靠近 P_0 , 我们须考虑到点 P 在平面 $\mathbb{R}^2$ 上以任意方式靠近 P_0 时 ($d(P, P_0) \rightarrow 0$), 函数全增量同其线性近似给出的线性主部之差是关于距离 $d(P, P_0)$ 的高阶无穷小. 即有关于二元函数可微的如下定义.

定义 2.4.1 设函数 $z = f(x, y)$ 在 $P_0(x_0, y_0)$ 的某领域内定义, 若它在 P_0 处的全增量 $\Delta z = f(x_0 + \Delta x, y_0 + \Delta y) - f(x_0, y_0)$ 可表示为

$$\Delta z = A \cdot \Delta x + B \cdot \Delta y + o(\rho)$$

其中 A, B 是与 Δx 和 Δy 无关的常数, $\rho = \sqrt{(\Delta x)^2 + (\Delta y)^2}$. 这里 $o(\rho)$ 表示在 $\rho \rightarrow 0$ (等价于 $(\Delta x, \Delta y) \rightarrow (0, 0)$) 时的高阶无穷小.

则称 f 在 P_0 处可微, 而称 $A\Delta x + B\Delta y$ 为函数在 P_0 处的全微分, 记为 $dz|_{(x_0, y_0)}$ 或 $df|_{(x_0, y_0)}$, 即

$$dz|_{(x_0, y_0)} = df|_{(x_0, y_0)} = A\Delta x + B\Delta y$$

注记 2.4.1 对二元函数 $f(x, y) = x$, 其全增量 $\Delta f = \Delta x$, 故其全微分 $dx = \Delta x$; 同理, 对自变量 y , 有 $dy = \Delta y$. 从而全微分也写作 $dz|_{(x_0, y_0)} = df|_{(x_0, y_0)} = A\Delta x + B\Delta y$

可微必连续: 设 $z = f(x, y)$ 在 $P_0(x_0, y_0)$ 处可微, 则 $\exists A, B$ 使得 $\Delta z = A\Delta x + B\Delta y + o(\rho)$ 当 $P(x, y) \rightarrow P_0(x_0, y_0)$, 即 $d(P, P_0) = \sqrt{(\Delta x)^2 + (\Delta y)^2} \rightarrow 0$ 时, 由于

$$|\Delta x|, |\Delta y| \leq \sqrt{(\Delta x)^2 + (\Delta y)^2} \leq |\Delta x| + |\Delta y|$$

即 $\rho \rightarrow 0$ 当且仅当 $(\Delta x, \Delta y) \rightarrow (0, 0)$, 故 $\lim_{\rho \rightarrow 0} \Delta x = \lim_{\rho \rightarrow 0} \Delta y = 0$, 从而

$$\lim_{\rho=d(P_0, P) \rightarrow 0} \Delta z = \lim_{\rho \rightarrow 0} (A\Delta x + B\Delta y + o(\rho)) = 0 \quad \square$$

注记 2.4.2 或可将 $A\Delta x + B\Delta y$ 按如下改写

$$\begin{aligned} A\Delta x + B\Delta y &= \left(A \frac{\Delta x}{\sqrt{(\Delta x)^2 + (\Delta y)^2}} + B \frac{\Delta y}{\sqrt{(\Delta x)^2 + (\Delta y)^2}} \right) \sqrt{(\Delta x)^2 + (\Delta y)^2} \\ &= \left(A \frac{\Delta x}{\rho} + B \frac{\Delta y}{\rho} \right) \rho \end{aligned}$$

但 $\left| \frac{\Delta x}{\rho} \right|, \left| \frac{\Delta y}{\rho} \right| \leq 1$, 从而括弧内是有界量, 从而直接可得 $\lim_{\rho \rightarrow 0} \Delta z = 0$.

同样的考量可致 $o(\rho)$ 的另一种写法, 从而将 $\rho \rightarrow 0 \iff (\Delta x, \Delta y) \rightarrow (0, 0)$ 这一主题凸显出来.

记 $m = o(\rho)$, 令 $\epsilon := \frac{m}{\rho}$, 则当 $\rho \rightarrow 0$ 时, $\epsilon \rightarrow 0$. 又, m 可按两种方式表示

$$m = \rho\epsilon = \epsilon \frac{\rho}{\Delta x} \Delta x; \quad m = \rho\epsilon = \epsilon \frac{\rho}{\Delta y} \Delta y$$

$$\Rightarrow 2m = \epsilon \frac{\rho}{\Delta x} \Delta x + \epsilon \frac{\rho}{\Delta y} \Delta y \Rightarrow m = \underbrace{\frac{\epsilon}{2} \frac{\rho}{\Delta x} \Delta x}_{\epsilon_1} + \underbrace{\frac{\epsilon}{2} \frac{\rho}{\Delta y} \Delta y}_{\epsilon_2}$$

从而 $o(\rho) = \epsilon_1 \Delta x + \epsilon_2 \Delta y$, 其中 ϵ_1, ϵ_2 是 $(\Delta x, \Delta y) \rightarrow (0, 0)$ 时的无穷小. 从而可微条件也可写成

$$\Delta z = A\Delta x + B\Delta y + \epsilon_1 \Delta x + \epsilon_2 \Delta y = \underbrace{A\Delta x + \epsilon_1 \Delta x}_{\Delta x \text{ 导致的线性化}} + \underbrace{B\Delta y + \epsilon_2 \Delta y}_{\Delta y \text{ 导致的线性化}}$$

由此便将“线性叠加”的原理明白无误地表现出来了!

可微 $\Rightarrow$ 方向导数存在: 设 $z = f(x, y)$ 在 $P_0(x_0, y_0)$ 处可微, 则 f 在 P_0 处沿任意方向 $\mathbf{u} = (\cos \theta, \sin \theta)$ 的方向导数存在且等于

$$\nabla_{\mathbf{u}} f(P_0) = \left. \frac{\partial f}{\partial \mathbf{u}} \right|_{(x_0, y_0)} = \frac{\partial f}{\partial x}(x_0, y_0) \cos \theta + \frac{\partial f}{\partial y}(x_0, y_0) \sin \theta = \nabla f(P_0) \bullet \mathbf{u}$$

证明: 由方向导数的定义, 知 $\nabla_{\mathbf{v}} f(P_0) =$

$$\begin{aligned} &= \lim_{t \rightarrow 0} \frac{f(x_0 + t \cos \theta, y_0 + t \sin \theta) - f(x_0, y_0)}{t} \quad \underline{\underline{\text{利用全微分公式}}} \\ &= \lim_{t \rightarrow 0} \frac{f_x(x_0, y_0)t \cos \theta + f_y(x_0, y_0)t \sin \theta + o(t)}{t} \\ &= f_x(x_0, y_0) \cos \theta + f_y(x_0, y_0) \sin \theta \quad \square \end{aligned}$$

可微 $\Rightarrow$ 可偏导: 设 $z = f(x, y)$ 在 $P_0(x_0, y_0)$ 处可微, 则 $\Delta z = A\Delta x + B\Delta y + o(\rho)$. 令 $\Delta y = 0$, 则 Δz 只由 Δx 引起, 此时 $\Delta z = A\Delta x + o(|\Delta x|)$, 从而

$$A = \lim_{\Delta x \rightarrow 0} \left(\frac{\Delta z}{\Delta x} - \frac{o(|\Delta x|)}{\Delta x} \right) = z_x(x_0, y_0) = f_x(x_0, y_0)$$

同理可得 $B = f_y(x_0, y_0)$. 故可微即可导, 且微分由下给出

$$dz|_{(x_0, y_0)} = f_x(x_0, y_0)dx + f_y(x_0, y_0)dy$$

若 $z = f(x, y)$ 在一区域 D 内的每点都可微, 则 f 在 D 内可偏导, 此时 f 在 $(x, y) \in D$ 的微分如下

$$dz = df = \frac{\partial f}{\partial x} dx + \frac{\partial f}{\partial y} dy$$

可偏导未必可微：比如对函数 $f(x, y) = \begin{cases} \frac{xy}{x^2 + y^2}, & (x, y) \neq (0, 0) \\ 0, & (x, y) = (0, 0) \end{cases}$ 我们知道它在 $(0, 0)$ 处的极限不存在，故不连续，从而在 $(0, 0)$ 处也不可微，但它在 $(0, 0)$ 处是可偏导的（见例 2.2.6）。当然，我们可以用定义直接证明其不可微性。

$$\lim_{\rho=\sqrt{x^2+y^2}\rightarrow 0} \frac{f(x, y) - f(0, 0) - 0x - 0y}{\sqrt{x^2 + y^2}} = \lim_{\rho\rightarrow 0} \frac{xy}{(x^2 + y^2)^{\frac{3}{2}}} = \lim_{(x, y)\rightarrow(0, 0)} \frac{xy}{(x^2 + y^2)^{\frac{3}{2}}}$$

考察当 (x, y) 在直线 $y = kx$ 上趋于原点时函数的表现，即

$$\lim_{x\rightarrow 0} \frac{kx^2}{x^3(1+k^2)^{\frac{3}{2}}} = \lim_{x\rightarrow 0} \frac{k}{x(1+k^2)^{\frac{3}{2}}}$$

即知极限不存在，故函数在 $(0, 0)$ 处不可微。

例 2.4.1 考察函数 $f(x, y) = \begin{cases} \frac{2xy^3}{x^2 + y^4}, & x^2 + y^2 \neq 0 \\ 0, & x^2 + y^2 = 0 \end{cases}$ 由于

$$|f(x, y)| = \left| \frac{2xy^2}{x^2 + y^4} y \right| \leq \left| \frac{x^2 + y^4}{x^2 + y^2} y \right| = |y|$$

由此可见 $f(x, y)$ 在 $(0, 0)$ 处连续，且它在 $(0, 0)$ 处沿任意方向 $\mathbf{u} = (\cos \theta, \sin \theta)$ 的方向导数为

$$\begin{aligned} \frac{\partial f}{\partial \mathbf{u}}(0, 0) &= \lim_{t\rightarrow 0} \frac{f(0 + t \cos \theta, 0 + t \sin \theta) - f(0, 0)}{t} = \\ &= \lim_{t\rightarrow 0} \frac{\frac{2t^4 \cos \theta \sin^3 \theta}{t^2 \cos^2 \theta + t^4 \sin^4 \theta}}{t} = \lim_{t\rightarrow 0} \frac{2t \cos \theta \sin^3 \theta}{\cos^2 \theta + t^2 \sin^4 \theta} = 0 \end{aligned}$$

所以 f 在 $(0, 0)$ 处不仅可偏导，且其方向导数都存在，但下面将表明它在 $(0, 0)$ 处是不可微的。为此，先计算 $f_x(0, 0)$ 和 $f_y(0, 0)$ 。在上公式中，令 $\theta = 0$ ，即考虑沿 $\mathbf{i} = (1, 0)$ 的方向导数，得

$$\frac{\partial f}{\partial x}(0, 0) = \frac{\partial f}{\partial \mathbf{i}}(0, 0) = 0; \quad \text{同理} \quad \frac{\partial f}{\partial y}(0, 0) = 0$$

故若 f 在 $(0, 0)$ 处可微，则其微分只能是 $f_x(0, 0)dx + f_y(0, 0)dy = 0$ ，且

$$\lim_{(x, y)\rightarrow(0, 0)} \frac{f(x, y) - f(0, 0) - f_x(0, 0)x - f_y(0, 0)y}{\sqrt{x^2 + y^2}} = \lim_{(x, y)\rightarrow(0, 0)} \frac{\frac{2xy^3}{x^2 + y^4}}{\sqrt{x^2 + y^2}}$$

$$= \lim_{(x,y) \rightarrow (0,0)} \frac{2xy^3}{(x^2 + y^4)\sqrt{x^2 + y^2}}$$

如可微, 则该极限存在且必须为 0, 但我们将表明极限其实不存在, 从而推得函数在 (0,0) 处不可微. 考察点沿直线 $y = kx$ 上趋于 (0,0) 时的情形, 有

$$\lim_{x \rightarrow 0} \frac{2k^3 x^4}{x^2(1 + k^4 x^2)x\sqrt{1 + k^2}} = \lim_{x \rightarrow 0} \frac{2k^3 x}{\sqrt{1 + k^2}(1 + k^4 x^2)} = 0$$

故沿所有直线方向趋于原点时极限是存在的, 且都是 0; 但若考虑沿着抛物线 $x = y^2$ 的路径趋于原点时, 我们发现

$$\lim_{y \rightarrow 0} \frac{2y^5}{2y^4 y \sqrt{1 + y^2}} = \lim_{y \rightarrow 0} \frac{1}{\sqrt{1 + y^2}} = 1$$


故极限不存在, 从而函数在原点处不可微.

下面的例子更直观地表现出了不可微的典型表象.

例 2.4.2 函数 $z = f(x, y) = \sqrt{x^2 + y^2}$, 其图形是顶点在 (0,0), 以 $z = x$ 为母线的锥面, 由于顶点处的“尖锐性”, 导致在该点局部无法找到一线性函数 (即用平面取代) 来合理逼近其表现, 故我们预期函数在 (0,0) 处是不可微的. 事实上

$$z_x(0,0) = \lim_{x \rightarrow 0} \frac{z(x,0) - z(0,0)}{x} = \lim_{x \rightarrow 0} \frac{|x|}{x} \text{ 不存在!}$$

同理 $z_y(0,0)$ 也不存在, 故函数在原点处不可微, 这是因为, 如果函数可微, 则其微分必是 $dz = z_x(0,0)dx + z_y(0,0)dy$, 但我们已表明偏导数是不存在的.



给一函数, 比如 $z = xye^{xy}$, 求得

$$z_x = ye^{xy} + xy^2e^{xy} = ye^{xy}(1 + xy); \quad z_y = xe^{xy}(1 + xy)$$

则如其可微, 则可直接写出其微分为

$$dz = \frac{\partial z}{\partial x}dx + \frac{\partial z}{\partial y}dy = ye^{xy}(1 + xy)dx + xe^{xy}(1 + xy)dy$$

当然, 能这么写的前提条件是我们已知函数可微, 但我们也不想每次都从原始定义先证明可微性然后再写微分. 故我们非常期望能有一些易于验证的条件可保证函数在某点是可微的, 下面定理表明: **只要偏导数在某点存在且连续的话**, 即可保证函数在该点可微. 该定理给出的可微的充分条件也说明我们上面写出的微分是合法的.

定理 2.4.1 若函数 $z = f(x, y)$ 的两个一阶偏导数在某点连续, 则它在该点可微.

证明: 设 $z = f(x, y)$ 在 (x_0, y_0) 点可偏导, 且两个偏导数在该点连续. 给点增量 $\Delta x, \Delta y$, 函数的全增量 Δz 可写成

$$\begin{aligned} \Delta z &= f(x_0 + \Delta x, y_0 + \Delta y) - f(x_0, y_0) \xrightarrow{\text{对不同变量分而治之}} \\ &= \underbrace{f(x_0 + \Delta x, y_0 + \Delta y) - f(x_0, y_0 + \Delta y)}_{\text{对 } x \text{ 用拉格朗日中值定理}} + \underbrace{f(x_0, y_0 + \Delta y) - f(x_0, y_0)}_{\text{对 } y \text{ 用拉格朗日中值定理}} \\ &\xrightarrow{\exists \xi_1, \xi_2 \in (0, 1)} f_x(x_0 + \xi_1 \Delta x, y_0 + \Delta y) \Delta x + f_y(x_0, y_0 + \xi_2 \Delta y) \Delta y \\ \text{则 } \Delta z - f_x(x_0, y_0) \Delta x - f_y(x_0, y_0) \Delta y &= \\ &= \underbrace{(f_x(x_0 + \xi_1 \Delta x, y_0 + \Delta y) - f_x(x_0, y_0)) \Delta x}_{\epsilon_1} + \underbrace{(f_y(x_0, y_0 + \xi_2 \Delta y) - f_y(x_0, y_0)) \Delta y}_{\epsilon_2} \end{aligned}$$

由于 f_x, f_y 在 (x_0, y_0) 处连续, 故 $\lim_{(\Delta x, \Delta y) \rightarrow (0, 0)} \epsilon_1 = \lim_{(\Delta x, \Delta y) \rightarrow (0, 0)} \epsilon_2 = 0$. 从而

$$\Delta z = f_x(x_0, y_0) \Delta x + f_y(x_0, y_0) \Delta y + \epsilon_1 \Delta x + \epsilon_2 \Delta y$$

其中 ϵ_1 和 ϵ_2 是 $\rho = \sqrt{(\Delta x)^2 + (\Delta y)^2} \rightarrow 0$ 时的无穷小量. 故知 $f(x, y)$ 在 (x_0, y_0) 处可微. $\square$

注记 2.4.3 对一般 n 元函数 $z = f(x_1, \dots, x_n)$, 其中 $(x_1, \dots, x_n) \in D \subseteq \mathbb{R}^n$, 其在某点

$P_0 = (x_1^0, \dots, x_n^0)$ 可微, 指存在与 Δx_i 无关的数 A_i (其中 $i = 1, \dots, n$) 使得

$$\Delta z = f(x_1^0 + \Delta x_1, \dots, x_n^0 + \Delta x_n) - f(x_1^0, \dots, x_n^0) = \sum_{i=1}^n A_i \Delta x_i + o(\rho)$$

其中 $\rho = \sqrt{\sum_{i=1}^n (\Delta x_i)^2}$. 此时 $\forall i = 1, \dots, n$, 有 $A_i = f_{x_i}(P_0) = \frac{\partial f}{\partial x_i}(P_0)$

同理, 若 f 在 P_0 处可偏导, 且每个偏导在 P_0 点连续, 则 f 必在 P_0 点可微.

注意定理 2.4.1 只给出了可微的一个充分条件, 即可偏导且偏导连续必可微, 但反过来不一定成立, **即可微必偏导, 但偏导数未必连续**. 下面是这方面的一个例子.

例 2.4.3 考察 $f(x, y) = \begin{cases} x^3 \sin \frac{1}{x^2} + y^3 \sin \frac{1}{y^2}, & xy \neq 0 \\ 0, & xy = 0 \end{cases}$ 其偏导数为

$$f_x(x, y) = \begin{cases} 3x^2 \sin \frac{1}{x^2} - 2 \cos \frac{1}{x^2}, & xy \neq 0 \\ 0, & xy = 0 \end{cases}$$

$$f_y(x, y) = \begin{cases} 3y^2 \sin \frac{1}{y^2} - 2 \cos \frac{1}{y^2}, & xy \neq 0 \\ 0, & xy = 0 \end{cases}$$

显然, f_x, f_y 在 $(0, 0)$ 处都不连续, 但我们可证明函数在 $(0, 0)$ 处是可微的. 如可微, 则微分为 $df = 0dx + 0dy = 0$, 且 Δf 可写成 $\rho := \sqrt{x^2 + y^2}$ 当 $(x, y) \rightarrow (0, 0)$ 时的高阶无穷小 (或可写成 $\epsilon_1 x + \epsilon_2 y$, 其中 ϵ_1, ϵ_2 是 $(x, y) \rightarrow (0, 0)$ 时的无穷小)

$$\underbrace{f(x, y) - f(0, 0)}_{\Delta f} = x^3 \sin \frac{1}{x^2} + y^3 \sin \frac{1}{y^2} = \underbrace{x^2 \sin \frac{1}{x^2}}_{\epsilon_1} + \underbrace{y^2 \sin \frac{1}{y^2}}_{\epsilon_2}$$

$$\text{且 } \lim_{(x, y) \rightarrow (0, 0)} \epsilon_1 = \lim_{(x, y) \rightarrow (0, 0)} \epsilon_2 = 0; \text{ 或 } \lim_{(x, y) \rightarrow (0, 0)} \frac{\Delta f - 0x - 0y}{\sqrt{x^2 + y^2}} =$$

$$\lim_{(x, y) \rightarrow (0, 0)} \frac{x^3 \sin \frac{1}{x^2} + y^3 \sin \frac{1}{y^2}}{\sqrt{x^2 + y^2}} = \lim_{(x, y) \rightarrow (0, 0)} \frac{x^3 \sin \frac{1}{x^2}}{\sqrt{x^2 + y^2}} + \lim_{(x, y) \rightarrow (0, 0)} \frac{y^3 \sin \frac{1}{y^2}}{\sqrt{x^2 + y^2}} = 0$$

这是因为

$$\left| \frac{x^3 \sin \frac{1}{x^2}}{\sqrt{x^2 + y^2}} \right| \leq \left| \frac{x^3}{\sqrt{x^2 + y^2}} \right| \leq \left| \frac{x^3}{x^2} \right| = |x|. \quad \text{同理可放缩另一边.}$$

2.5 全微分与切平面逼近, 线性化的映射机制

对一元函数 $y = f(x)$, 其在 x_0 可微, 即 $f'(x_0)$ 存在, 此时微分 $df = f'(x_0)dx$ 给出了 $f(x)$ 在 x_0 处的线性近似, 即对 x 在 x_0 处的增量 Δx (注意不一定要要求该增量很小), 函数的实际增量 $\Delta y = f(x_0 + \Delta x) - f(x_0)$ 可由其线性主部 $f'(x_0)\Delta x$ 来 (一阶) 逼近. 也就是说, 微分 $df|_{x_0}$ 可看成是个线性映射, 它将 Δx 映为 $f'(x_0)\Delta x$. 即

$$df|_{x_0} : \mathbb{R} \longrightarrow \mathbb{R} \quad \Delta x \longmapsto f'(x_0)\Delta x$$

也就是说, 函数 $y = f(x)$ 在 x_0 附近的表现可由下线性函数来近似

$$L_f|_{x_0}(x) = f(x_0) + f'(x_0)(x - x_0)$$

此即函数图形在点 $(x_0, f(x_0))$ 处的切线方程, 其法向量是 $\mathbf{n} = (f'(x_0), -1) = f'(x_0)\mathbf{i} - \mathbf{j}$, 其中 $\mathbf{i} = (1, 0)$, $\mathbf{j} = (0, 1)$ 是 $\mathbb{R}^2$ 的标准基 (standard basis).

对二元函数 $z = f(x, y)$, 其在 $P_0(x_0, y_0)$ 可微时, $f_x(P_0), f_y(P_0)$ 存在, 且其 (全) 微分 $df|_{P_0} = f_x(P_0)dx + f_y(P_0)dy$ 给出了 f 在 P_0 处的线性近似, 即对 (x, y) 在 P_0 处的增量 $(\Delta x, \Delta y)$, 函数的实际增量 $\Delta z = f(x_0 + \Delta x, y_0 + \Delta y) - f(x_0, y_0)$ 可由其线性主部:

$$\frac{\partial f}{\partial x}(P_0)\Delta x + \frac{\partial f}{\partial y}(P_0)\Delta y$$

来逼近. 也就是说 $df|_{P_0}$ 可看成是一个线性映射, 它表述了上面对函数在一点附近“线性化”的映射机制 $df|_{P_0} : \mathbb{R}^2 \longrightarrow \mathbb{R}$

$$(\mathbb{R}^2 \ni) \begin{bmatrix} \Delta x \\ \Delta y \end{bmatrix} \longmapsto \underbrace{\begin{bmatrix} f_x(P_0) & f_y(P_0) \end{bmatrix}}_{\mathbf{J}_f(P_0)} \begin{bmatrix} \Delta x \\ \Delta y \end{bmatrix} = f_x(P_0)\Delta x + f_y(P_0)\Delta y (\in \mathbb{R})$$

其中 1×2 阶矩阵 $\mathbf{J}_f(P_0)$ 称为 f 在 P_0 处的雅克比 (Jacobi) 矩阵, 它是线性映射 $df|_{P_0}$ (在标准基下) 的矩阵表示, 简称为映射 f 在 P_0 处的微分.

换言之, 若 $z = f(x, y)$ 在 P_0 可微, 则意味着函数 f 在该点近旁的可用如下 (二元) 线性函数来 (一阶) 近似

$$L_f|_{P_0}(x, y) = f(P_0) + f_x(P_0)(x - x_0) + f_y(P_0)(y - y_0)$$


全微分的近似计算公式: $f(x, y) \approx L_f|_{P_0}(x, y)$ 当 (x, y) 接近 (x_0, y_0) 时.

$L_f(P_0)$ 的图形是 $\mathbb{R}^3$ 中过点 $(x_0, y_0, f(x_0, y_0))$ 的一个平面方程, 其法向量是

$$\mathbf{n} = (f_x(P_0), f_y(P_0), -1) = f_x(P_0)\mathbf{i} + f_y(P_0)\mathbf{j} - \mathbf{k}$$

其中 $\mathbf{i} = (1, 0, 0)$, $\mathbf{j} = (0, 1, 0)$, $\mathbf{k} = (0, 0, 1)$ 是 $\mathbb{R}^3$ 的标准基 (standard basis) .

在第一节的概念导引部分已经说明: 该平面不是别的, 就是函数曲面 $z = f(x, y)$ 在点 $(x_0, y_0, f(x_0, y_0))$ 处的切平面 (tangent plane), 即在 $(x_0, y_0, f(x_0, y_0))$ 近旁过该点且与曲面只有一个交点的唯一平面. 下面是纯几何视角的论证.



如上图所示, 记曲面 $z = f(x, y)$ 被平面 $x = x_0$ 所截曲线在 $P_0(x_0, y_0, z_0)$ 的切线为 l_1 ; 被平面 $y = y_0$ 所截曲线在 P_0 的切线为 l_2 , 其方程分别为

$$l_1: \begin{cases} z - z_0 = f_y(P_0)(y - y_0) \\ x = x_0 \end{cases}; \quad l_2: \begin{cases} z - z_0 = f_x(P_0)(x - x_0) \\ y = y_0 \end{cases}$$

其方向向量分别为: $\mathbf{l}_1 = (0, 1, f_y(P_0))$; $\mathbf{l}_2 = (1, 0, f_x(P_0))$. 显然, 曲面 $z = f(x, y)$ 在 P_0 处的切平面 π 是过两切线 l_1, l_2 的唯一平面, 其法向量可取为

$$\mathbf{n} = \mathbf{l}_1 \times \mathbf{l}_2 = \begin{vmatrix} \mathbf{i} & \mathbf{j} & \mathbf{k} \\ 0 & 1 & f_y(P_0) \\ 1 & 0 & f_x(P_0) \end{vmatrix} = (f_x(P_0), f_y(P_0), -1)$$

从而知 $P_0(x_0, y_0)$ 处切平面的方程为

$$\pi: f_x(P_0)(x - x_0) + f_y(P_0)(y - y_0) - (z - f(P_0)) = 0$$

注记 2.5.1 微分关系 $dz = f_x(P_0)dx + f_y(P_0)dy$ 表示函数关系 $z = f(x, y)$ 在 P_0 点的“线性化”, 即局部用平面逼近函数曲面: 在 P_0 附近, $f(P)$ 和 $L_f|_{P_0}(P) = f(P_0) +$

$f_x(P_0)(x-x_0) + f_y(P_0)(y-y_0)$ 的值 (其差记为 $\lambda(P) := f(P) - L_f|_{P_0}(P)$) 要比较接近, 且其接近程度应对距 P_0 距离相同的点 P “大体相当” 才行, 不能对某些点有偏好. 从概率的视角来看, 就是若 P 在某 δ -领域内均匀分布, 则随机变量 $\lambda(P)$ 的期望 $\frac{1}{\pi\delta^2} \iint_{U(P_0, \delta)} \lambda(P) dx dy$ 为零, 且其方差 $\frac{1}{\pi\delta^2} \iint_{U(P_0, \delta)} \lambda(P)^2 dx dy$ 取最小. 从几何上来看, 只有切平面满足需求 (割平面显然对某些点太“偏好”了); 从代数上来讲, 由全微分定义的平面即为所求. 从而, 求切平面方程, 只需在微分关系 $dz = f_x(P_0)dx + f_y(P_0)dy$ 中令 $dx = x - x_0, dy = y - y_0, dz = z - f(P_0)$, 即

$$\pi: \quad z - f(x_0, y_0) = f_x(x_0, y_0)(x - x_0) + f_y(x_0, y_0)(y - y_0)$$

微分 df 作为映射再论: $df|_{P_0}: \mathbb{R}^2 \rightarrow \mathbb{R}$

$$\begin{bmatrix} \Delta x \\ \Delta y \end{bmatrix} \mapsto \underbrace{\begin{bmatrix} f_x(P_0) & f_y(P_0) \end{bmatrix}}_{\mathbf{J}_f(P_0)} \begin{bmatrix} \Delta x \\ \Delta y \end{bmatrix} = f_x(P_0)\Delta x + f_y(P_0)\Delta y$$

即微分 $df|_{P_0}$ 将 $P_0 \in \mathbb{R}^2$ 处的自变量独立增量 $(\Delta x, \Delta y)$ 映为对应函数增量的线性主部 $f_x(P_0)\Delta x + f_y(P_0)\Delta y$. 这个解释当然是重要的, 它是用微分做近似计算的基础.

然而, 线性主部的形式让我们联想到了方向导数, 即将增量 $(\Delta x, \Delta y)$ 解释为一向量方向 $\mathbf{u}$, 则 $df|_{P_0} \left(\begin{bmatrix} \Delta x \\ \Delta y \end{bmatrix} \right) = f_x(P_0)\Delta x + f_y(P_0)\Delta y$

$$\begin{aligned} &= \left(f_x(P_0) \frac{\Delta x}{\sqrt{(\Delta x)^2 + (\Delta y)^2}} + f_y(P_0) \frac{\Delta y}{\sqrt{(\Delta x)^2 + (\Delta y)^2}} \right) \sqrt{(\Delta x)^2 + (\Delta y)^2} \\ &= (\nabla f|_{P_0} \bullet \mathbf{u}^0) |\mathbf{u}| = \nabla_{\mathbf{u}} f|_{P_0} |\mathbf{u}| = \left. \frac{\partial f}{\partial \mathbf{u}} \right|_{P_0} |\mathbf{u}| \end{aligned}$$

亦即, 微分 $df|_{P_0} \left(\begin{bmatrix} \Delta x \\ \Delta y \end{bmatrix} \right)$ 计算出函数在 P_0 点处沿方向 $\mathbf{u} = (\Delta x, \Delta y)$ 的方向导数 (即变化率) 和增量向量之长 $|\mathbf{u}|$ 的乘积.

特别地, 对增量 $(\Delta x, 0) = \Delta x \mathbf{i}$, 我们有 $df_{P_0} \left(\begin{bmatrix} \Delta x \\ 0 \end{bmatrix} \right) = \frac{\partial f}{\partial x}(P_0)\Delta x$, 即函数在 P_0 处沿 x 轴方向的变化速率与 x 增量之积, 给出了当 $(x_0, y_0) \rightarrow (x_0 + \Delta x, y_0)$ 时, 函数增长的线性主部 (对其积分则给出实际增长); 同理, 对增量 $(0, \Delta y) = \Delta y \mathbf{j}$, 我们有 $df_{P_0} \left(\begin{bmatrix} 0 \\ \Delta y \end{bmatrix} \right) = \frac{\partial f}{\partial y}(P_0)\Delta y$, 即函数在 P_0 处沿 y 轴方向的变化速率与 y 增量之

积, 给出了当 $(x_0, y_0) \rightarrow (x_0, y_0 + \Delta y)$ 时, 函数增长的线性主部.

一般地, 对增量 $(\Delta x, \Delta y)$, 我们有

$$df|_{P_0} \left(\begin{bmatrix} \Delta x \\ \Delta y \end{bmatrix} \right) = \frac{\partial f}{\partial x}(P_0)\Delta x + \frac{\partial f}{\partial y}\Delta y = \frac{\partial f}{\partial \mathbf{u}} \Big|_{P_0} |\mathbf{u}|$$

即函数在 P_0 处沿方向 $\mathbf{u} := \Delta x \mathbf{i} + \Delta y \mathbf{j}$ 的变化率 (方向导数) 与在该方向上自变量增量带来的距离增量 $|\mathbf{u}| = \sqrt{(\Delta x)^2 + (\Delta y)^2}$ 的乘积. 其共同模式为:

函数在某方向上增量的线性主部 = 该方向上函数变化率 (方向导数) $\times$ 该方向的增量向量的长度.

特别地, 对方向 $\mathbf{u} = (1, 0) = \mathbf{i}$, 即 $(\Delta x, \Delta y) = (1, 0)$ 时, $df|_{P_0} \left(\begin{bmatrix} 1 \\ 0 \end{bmatrix} \right) = \frac{\partial f}{\partial x}(P_0)$;

对方向 $\mathbf{u} = (0, 1) = \mathbf{j}$, 即 $(\Delta x, \Delta y) = (0, 1)$ 时, $df|_{P_0} \left(\begin{bmatrix} 0 \\ 1 \end{bmatrix} \right) = \frac{\partial f}{\partial y}(P_0)$. 对一般的方向 $\mathbf{u} = \Delta x \mathbf{i} + \Delta y \mathbf{j}$, 有

$$df|_{P_0} \left(\begin{bmatrix} \Delta x \\ \Delta y \end{bmatrix} \right) = df|_{P_0} \left(\begin{bmatrix} 1 \\ 0 \end{bmatrix} \right) \Delta x + df|_{P_0} \left(\begin{bmatrix} 0 \\ 1 \end{bmatrix} \right) \Delta y$$

故增量的线性主部 $df|_{P_0} \left(\begin{bmatrix} \Delta x \\ \Delta y \end{bmatrix} \right)$ 可写成 $df|_{P_0} \left(\begin{bmatrix} 1 \\ 0 \end{bmatrix} \right)$ 和 $df|_{P_0} \left(\begin{bmatrix} 0 \\ 1 \end{bmatrix} \right)$ 的线性组合.

当然, 本质原因在于 $\{\mathbf{i}, \mathbf{j}\}$ 是 $\mathbb{R}^2$ 的一组基.

注记 2.5.2 由于沿 $\mathbf{i}$ 方向的方向导数就是作用以偏导算子 $\frac{\partial}{\partial x}$, 沿 $\mathbf{j}$ 方向的方向导数就是作用以偏导算子 $\frac{\partial}{\partial y}$, 故也记方向 $\mathbf{i}$ 为 $\frac{\partial}{\partial x}$, 记方向 $\mathbf{j}$ 为 $\frac{\partial}{\partial y}$. 也可从方向在所讨论背景中的功能属性来加以解释: 方向 $\mathbf{i}$ 的功能是考察函数沿其的变化速率, 即对函数求偏导 $\frac{\partial}{\partial x}$, 故将其等同于 $\frac{\partial}{\partial x}$; 同理可将 $\mathbf{j}$ 等同于 $\frac{\partial}{\partial y}$. 这两个独立方向对应的微分算子共同构成了所谓梯度算子: $\nabla = \left(\frac{\partial}{\partial x}, \frac{\partial}{\partial y} \right)$, 它在函数 f 上的作用给出了函数的梯度 ∇f , 即给出了函数沿着两个基本独立方向 $\frac{\partial}{\partial x}$ 和 $\frac{\partial}{\partial y}$ 的变化率信息, 通过“线性叠加”, 可由此探测函数沿任何方向的变化率信息.

下面用古朴的析取线性主部的方法求得微分. 返璞归真看问题, 不为形式所拘.

例 2.5.1 考虑函数 $z = x^2 + y^2$, 它在 $(1, 1)$ 处的微分为 $dz|_{(1,1)} = 2dx + 2dy$.

$$\begin{aligned} z(1 + \Delta x, 1 + \Delta y) - z(1, 1) &= (1 + \Delta x)^2 + (1 + \Delta y)^2 - 2 \\ &= 1 + 2\Delta x + (\Delta x)^2 + 1 + 2\Delta y + (\Delta y)^2 - 2 = 2\Delta x + (\Delta x)^2 + 2\Delta y + (\Delta y)^2 \end{aligned}$$

略去关于 Δx 和 Δy 的二阶项, 只保留一阶项, 即得到函数 z 在 $(1, 1)$ 处增量的线性主部 $2\Delta x + 2\Delta y$, 故函数的微分为 $dz|_{(1,1)} = 2dx + 2dy$.

例 2.5.2 对 $z = \sqrt{x^2 + y^2}$, 我们知道它在锥面的顶点 $(0, 0)$ 处不可微. 从近似计算的角度入手, 有 $z(x, y) - z(0, 0) = \sqrt{x^2 + y^2}$, 故它不可能写成 $Ax + By + o(\sqrt{x^2 + y^2})$ 的形式, 即知函数在 $(0, 0)$ 处不可微.

例 2.5.3 对函数 $f(x, y) = 3x^2y - xy^2$, 为求其在 $(1, 2)$ 处的微分, 我们分析其增量

$$\begin{aligned} \Delta f &= f(1 + \Delta x, 2 + \Delta y) - f(1, 2) = 3(1 + \Delta x)^2(2 + \Delta y) - (1 + \Delta x)(2 + \Delta y)^2 - 2 \\ &= 3(1 + 2\Delta x + (\Delta x)^2)(2 + \Delta y) - (1 + \Delta x)(4 + 2\Delta y + (\Delta y)^2) - 2 \\ &= 8\Delta x - \Delta y + 4\Delta x\Delta y + 6(\Delta x)^2 + 3(\Delta x)^2\Delta y - \Delta x(\Delta y)^2 - (\Delta y)^2 \\ &\stackrel{\text{略去所有高阶项}}{=} 8\Delta x - \Delta y + \underbrace{(4\Delta y + 6\Delta x + 3\Delta x\Delta y)}_{\epsilon_1}\Delta x + \underbrace{(-\Delta x\Delta y - \Delta y)}_{\epsilon_2}\Delta y \end{aligned}$$

其中 ϵ_1, ϵ_2 为 $(\Delta x, \Delta y) \rightarrow (0, 0)$ 时的无穷小量. 故函数在 $(1, 2)$ 处可微, 且其微分 (线性主部) 等于 $df|_{(1,2)} = 8\Delta x - \Delta y$. 或直接验证

$$\lim_{(\Delta x, \Delta y) \rightarrow (0, 0)} \frac{4\Delta x\Delta y + 6(\Delta x)^2 + 3(\Delta x)^2\Delta y - \Delta x(\Delta y)^2 - (\Delta y)^2}{\sqrt{(\Delta x)^2 + (\Delta y)^2}} = 0$$

例 2.5.4 对函数 $z = y^x$, 求它在 $(1, 1)$ 处的微分, 为此考察 $\Delta z = z(1+x, 1+y) - z(1, 1) = (1+y)^{1+x} - 1 = (1+y)(1+y)^x - 1 = (1+y)e^{x \ln(1+y)} - 1 =$

$$\begin{aligned} &= (1+y)e^{x\left(y - \frac{y^2}{2} + \frac{y^3}{3} + o(y^3)\right)} - 1 = (1+y) \left(1 + x \left(y - \frac{y^2}{2} + \frac{y^3}{3} + o(y^3)\right) + \text{高阶项}\right) - 1 \\ &= x \left(y - \frac{y^2}{2} + \frac{y^3}{3} + o(y^3)\right) + y + yx \left(y - \frac{y^2}{2} + \frac{y^3}{3} + o(y^3)\right) + \text{高阶项} \\ &= y + o(\sqrt{x^2 + y^2}) \end{aligned}$$

即 $dz|_{(1,1)} = dy$. 事实上, $z_x|_{(1,1)} = (\ln y)y^x|_{(1,1)} = 0$, $z_y|_{(1,1)} = xy^{x-1}|_{(1,1)} = 1y^0 = 1$, 故上面的计算结果与全微分公式给出的结果一致.

注记 2.5.3 一般地, 对函数 $z = f(x, y)$, 在 (x, y) 处增量 $x \rightarrow x + \Delta x$, $y \rightarrow y + \Delta y$, 对应函数的实际增量 (全增量) 为 $\Delta z = f(x + \Delta x, y + \Delta y) - f(x, y)$, 类似于推到方向导数公式的思路, 我们沿用“分而治之”的策略对该增量进行变形处理, 以便从中析取“线性主部”, 即微分来.

$$\begin{aligned}\Delta z &= f(x + \Delta x, y + \Delta y) - f(x, y + \Delta y) + f(x, y + \Delta y) - f(x, y) \\&= f(x, y + \Delta y) + f_x(x, y + \Delta y)\Delta x - f(x, y + \Delta y) + \\&\quad + f(x, y) + f_y(x, y)\Delta y - f(x, y) + \text{高阶项} \\&= f_x(x, y + \Delta y)\Delta x + f_y(x, y)\Delta y + \text{高阶项} \\&= \underbrace{f_x(x, y)\Delta x + f_y(x, y)\Delta y}_{\text{微分}} + \text{高阶项}\end{aligned}$$

如同方向导数, 全微分 d 也满足如下类导数性质

1. $d(f \pm g) = df \pm dg$;
2. $d(fg) = \frac{\partial(fg)}{\partial x}dx + \frac{\partial(fg)}{\partial y}dy = \left(f\frac{\partial g}{\partial x} + \frac{\partial f}{\partial x}g\right)dx + \left(f\frac{\partial g}{\partial y} + \frac{\partial f}{\partial y}g\right)dy$
 $= f\left(\frac{\partial g}{\partial x}dx + \frac{\partial g}{\partial y}dy\right) + \left(\frac{\partial f}{\partial x}dx + \frac{\partial f}{\partial y}dy\right)g = f dg + g df$
3. $d\left(\frac{f}{g}\right) = \frac{\partial}{\partial x}\left(\frac{f}{g}\right)dx + \frac{\partial}{\partial y}\left(\frac{f}{g}\right)dy =$
 $= \frac{(f_x g - f g_x)dx + (f_y g - f g_y)dy}{g^2} = \frac{g df - f dg}{g^2}$

例 2.5.5 求 $(1.04)^{1.98}$ 的近似值.

解: 1.04 和 1 比较接近; 1.98 和 2 比较接近, 故为逼近 $1.04^{1.98}$, 须考察函数 $z = x^y$ 在 $(1, 2)$ 处的线性近似.

$$z_x(1, 2) = yx^{y-1}|_{(1,2)} = 2 \cdot 1^1 = 2; \quad z_y(1, 2) = (\ln x)x^y|_{(1,2)} = 0$$

从而 $dz|_{(1,2)} = 2dx$, 代入 $dx = \Delta x = 1.04 - 1 = 0.04$, 得

$$\Delta z = z(1.04, 1.98) - z(1, 2) \stackrel{\text{线性近似}}{\approx} dz|_{(1,2)}(\Delta x) = 2\Delta x = 0.08$$

从而 $(1.04)^{1.98} \approx 1^2 + 0.08 = 1.08$. 注意 $dz|_{(1,2)}$ 只有 dx 的部分, 没有 dy 部分, 这说明在线性化“滤镜”下, 函数 $z = x^y$ 在 $(1, 2)$ 近旁对 y 的变化不敏感. 当然这是因为基准点处 $x = 1$ 的缘故.

例 2.5.6 求 $\sqrt{1 - (1.004)^2 + (1.994)^2}$ 的近似值.

解: 函数 $z = \sqrt{1 - x^2 + y^2}$ 在 $(1, 2)$ 处的全微分为

$$dz|_{(1,2)} = z_x(1,2)dx + z_y(1,2)dy = -\frac{1}{2}dx + dy$$

当 $(x, y) = (1.004, 1.994)$ 时, $dx = \Delta x = 0.004$, $dy = \Delta y = -0.006$. 从而

$$\Delta z = z(1.004, 1.994) - z(1, 2) \stackrel{\text{线性近似}}{\approx} -\frac{1}{2} \times 0.004 + 1 \times (-0.006)$$

$$\Rightarrow z(1.004, 1.994) \approx 2 - \frac{1}{2} \times 0.004 + 1 \times (-0.006) = 1.992.$$

例 2.5.7 利用单摆测定重力加速度 g 的公式为 $g = \frac{4\pi^2 l}{T^2}$, 现测得单摆摆长与摆动周期分别为 $l = (100 \pm 0.1) \text{ cm}$, $T = (2 \pm 0.004) \text{ s}$, 问测定 l 和 T 的误差引起 g 的最大绝对误差和最大相对误差各为多少?

解: 记摆长和周期的最大绝对误差分别为 δ_l 和 δ_T . 利用全微分公式, 我们有

$$|\Delta g| \approx |dg| = \left| \frac{\partial g}{\partial l} \Delta l + \frac{\partial g}{\partial T} \Delta T \right| \leq \left| \frac{\partial g}{\partial l} \right| |\Delta l| + \left| \frac{\partial g}{\partial T} \right| |\Delta T|$$

$$\leq \left| \frac{\partial g}{\partial l} \right| \delta_l + \left| \frac{\partial g}{\partial T} \right| \delta_T = \frac{4\pi^2}{T^2} \left(\delta_l + \frac{2l}{T} \delta_T \right) \stackrel{l=100, T=2}{\delta_l=0.1, \delta_T=0.004} 0.5\pi^2 = 4.93 \text{ (cm/s}^2\text{)}$$


$$\text{相对误差: } \left| \frac{\Delta g}{g} \right| \leq \frac{0.5\pi^2}{4\pi^2} \frac{2^2}{100} = 0.5\%$$

注记 2.5.4 对 n 元函数 $z = f(x_1, \dots, x_n)$, 其可微性可类似定义 (见 1.1 小节), 若其可微, 则可偏导, 且微分由各分量微分“线性叠加”而成: $dz = \sum_{i=1}^n \frac{\partial f}{\partial x_i} dx_i$. 对一般的映射 (或向量值函数) $\mathbf{f}: \mathbb{R}^n \rightarrow \mathbb{R}^m$ ($x_1, \dots, x_n \rightarrow y_1, \dots, y_m$), 其中 $y_i = f_i(x_1, \dots, x_n)$, 它的微分 $d\mathbf{f}$ 由各分量函数微分 $df_i = \sum_{j=1}^n \frac{\partial f_i}{\partial x_j} dx_j$ 合和而成 (详见 1.3 节). 即

$$\underbrace{\begin{bmatrix} dy_1 \\ \vdots \\ dy_m \end{bmatrix}}_{d\mathbf{y}} = \underbrace{\begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \cdots & \frac{\partial f_1}{\partial x_n} \\ \vdots & & \vdots \\ \frac{\partial f_m}{\partial x_1} & \cdots & \frac{\partial f_m}{\partial x_n} \end{bmatrix}}_{\mathbf{J}_{\mathbf{f}}} \underbrace{\begin{bmatrix} dx_1 \\ \vdots \\ dx_n \end{bmatrix}}_{d\mathbf{x}} \quad d\mathbf{y} = \mathbf{J}_{\mathbf{f}} \cdot d\mathbf{x}$$

2.6 多元复合函数的微分法——链式法则

回忆在引入二元函数 $z = f(x, y)$ 方向导数时 $\left. \frac{\partial f}{\partial \mathbf{l}} \right|_P = \nabla f|_P \bullet \mathbf{l}^0$ 时, 我们表明了它本质上就是: 求函数当 (x, y) 沿过点 $P(x, y)$ 且在 P 的切线方向 (切向量) 为 $\mathbf{l}$ 的任意曲线 $\begin{cases} x = x(t) \\ y = y(t) \end{cases}$ 时, 函数 $z = f(x, y)$ 在 P 点的变化率.




$$\begin{aligned}
 & \text{即当 } \mathbf{l} = (x'(t), y'(t)) \text{ 时, 求 } \left. \frac{dz(t)}{dt} \right|_P = \left. \frac{df(x(t), y(t))}{dt} \right|_P = \\
 &= \lim_{\Delta t \rightarrow 0} \frac{f(x(t + \Delta t), y(t + \Delta t)) - f(x(t), y(t))}{\Delta t} \quad \begin{array}{l} \text{加项减项} \\ \text{损益相抵, 分而治之} \end{array} \\
 &= \lim_{\Delta t \rightarrow 0} \frac{f(x(t + \Delta t), y(t + \Delta t)) - f(x(t), y(t + \Delta t)) + f(x(t), y(t + \Delta t)) - f(x(t), y(t))}{\Delta t} \\
 &= \lim_{\Delta t \rightarrow 0} \frac{f(x(t + \Delta t), y(t + \Delta t)) - f(x(t), y(t + \Delta t))}{\Delta t} + \lim_{\Delta t \rightarrow 0} \frac{f(x(t), y(t + \Delta t)) - f(x(t), y(t))}{\Delta t} \\
 &\quad \begin{array}{l} \text{模式重整} \end{array} \lim_{\Delta t \rightarrow 0} \frac{f(x(t + \Delta t), y(t + \Delta t)) - f(x(t), y(t + \Delta t))}{x(t + \Delta t) - x(t)} \cdot \frac{x(t + \Delta t) - x(t)}{\Delta t} + \\
 &\quad + \lim_{\Delta t \rightarrow 0} \frac{f(x(t), y(t + \Delta t)) - f(x(t), y(t))}{y(t + \Delta t) - y(t)} \cdot \frac{y(t + \Delta t) - y(t)}{\Delta t} \\
 &= \frac{\partial f}{\partial x} x'(t) + \frac{\partial f}{\partial y} y'(t) = \nabla f|_P \bullet \mathbf{l} = \nabla f|_P \bullet \mathbf{l}^0 |\mathbf{l}| = \underbrace{\nabla_{\mathbf{l}^0} f|_P}_{\text{方向导数}} |\mathbf{l}| = \underbrace{\left. \frac{\partial f}{\partial \mathbf{l}} \right|_P}_{\text{方向导数}} |\mathbf{l}| \\
 &\quad \begin{array}{l} \text{全微分作为映射} \\ \text{的诠释框架} \end{array} df|_P(\mathbf{l}) = \mathbf{J}_f|_P \begin{bmatrix} x'(t) \\ y'(t) \end{bmatrix} = \underbrace{\begin{bmatrix} \frac{\partial f}{\partial x} & \frac{\partial f}{\partial y} \end{bmatrix}}_{\text{映射的微分}} \begin{bmatrix} x'(t) \\ y'(t) \end{bmatrix}
 \end{aligned}$$

从纯求导的形式上来看上页的说明和计算，我们便得到

$$\frac{dz}{dt} = \frac{df(x(t), y(t))}{dt} = \frac{\partial f}{\partial x} \frac{dx}{dt} + \frac{\partial f}{\partial y} \frac{dy}{dt}$$

即考虑函数 $z = f(x, y)$ 和 $\begin{cases} x = x(t) \\ y = y(t) \end{cases}$ 的复合 $z(t) = f(x(t), y(t))$ ，上面的公式即为对该复合函数求导的链式法则 (*chain rule*) .



显然，它是一元情形链式法则 $\frac{dz}{dt} = \frac{dz}{dx} \frac{dx}{dt}$ 的自然推广（以“线性叠加”模式）.

完全类似地，对三元函数 $u = f(x, y, z)$ ，及 $x = x(t)$, $y = y(t)$, $z = z(t)$ ，若它们阶可微，则 u 对 t 的导数的计算公式为

$$\frac{du}{dt} = \frac{\partial f}{\partial x} \frac{dx}{dt} + \frac{\partial f}{\partial y} \frac{dy}{dt} + \frac{\partial f}{\partial z} \frac{dz}{dt}$$

称为函数 u 对变量 t 的全导数 (*total derivative*) 公式.

毫无困难地，对可微的 n 元函数 $z = f(x_1, \dots, x_n)$ ，若 $x_i = x_i(t)$ 又可微地依赖于变量 t ，则 f 对 t 的全导数计算公式是

$$\frac{dz}{dt} = \sum_{i=1}^n \frac{\partial f}{\partial x_i} \frac{dx_i}{dt}$$

形式上，可简记之为： $\frac{d(f \circ \mathbf{g})}{dt} = \frac{df}{d\mathbf{x}} \cdot \frac{d\mathbf{x}}{dt}$ ，只是这里 $\frac{df}{d\mathbf{x}}$ 和 $\frac{d\mathbf{x}}{dt}$ 需理解为矩阵，而

式子右边也需理解为矩阵乘法.

$$\frac{df}{d\mathbf{x}} = \begin{bmatrix} \frac{\partial f}{\partial x_1} & \cdots & \frac{\partial f}{\partial x_n} \end{bmatrix}; \quad \frac{d\mathbf{x}}{dt} = \frac{d}{dt} \begin{bmatrix} x_1(t) \\ \vdots \\ x_n(t) \end{bmatrix} = \begin{bmatrix} \frac{dx_1}{dt} \\ \vdots \\ \frac{dx_n}{dt} \end{bmatrix}$$

$$\frac{df}{d\mathbf{x}} \cdot \frac{d\mathbf{x}}{dt} = \begin{bmatrix} \frac{\partial f}{\partial x_1} & \cdots & \frac{\partial f}{\partial x_n} \end{bmatrix} \begin{bmatrix} \frac{dx_1}{dt} \\ \vdots \\ \frac{dx_n}{dt} \end{bmatrix} = \sum_{i=1}^n \frac{\partial f}{\partial x_i} \frac{dx_i}{dt}$$

形式符号诠释: 向量值函数 $\mathbf{g}$ 是从 $\mathbb{R}$ 到 $\mathbb{R}^n$ 的一个映射, 记之为 $\mathbf{g}: t \mapsto \begin{bmatrix} x_1(t) \\ \vdots \\ x_n(t) \end{bmatrix}$; f 是从 $\mathbb{R}^n$ 到 $\mathbb{R}$ 的映射 $f: (x_1, \dots, x_n) \mapsto f(x_1, \dots, x_n)$. 复合函数 $f(x_1(t), \dots, x_n(t))$ 即映射的复合 $f \circ \mathbf{g}$.

$$\begin{array}{c} \mathbb{R} \xrightarrow{\quad \mathbf{g} \quad} \mathbb{R}^n \xrightarrow{\quad f \quad} \mathbb{R} \\ \text{f} \circ \mathbf{g} \end{array}$$

$$t \longmapsto (x_1(t), \dots, x_n(t))^T \longmapsto f(x_1(t), \dots, x_n(t))$$

微分 $df: \mathbb{R}^n \rightarrow \mathbb{R}$ 作为 $\mathbf{f}$ 的线性化, 由其 *Jacobi* 矩阵 $\mathbf{J}_f = \begin{bmatrix} \frac{\partial f}{\partial x_1} & \cdots & \frac{\partial f}{\partial x_n} \end{bmatrix}$ 给出; 注意若将 $1 \times n$ 矩阵等同于向量, 则 $\mathbf{J}_f = \nabla f$. 同理, 对映射 $\mathbf{g}$, 其微分 $d\mathbf{g}$ 作为从 $\mathbb{R}$ 到 $\mathbb{R}^n$ 的线性映射, 由其 *Jacobi* 矩阵 $\mathbf{J}_g = \begin{bmatrix} \frac{dx_1}{dt} & \cdots & \frac{dx_n}{dt} \end{bmatrix}^T$ 表示 (“ T ” 为矩阵转置).

$$df: \mathbb{R}^n \rightarrow \mathbb{R} \quad (\Delta x_1, \dots, \Delta x_n) \mapsto \sum_{i=1}^n \frac{\partial f}{\partial x_i} \Delta x_i = \underbrace{\begin{bmatrix} \frac{\partial f}{\partial x_1} & \cdots & \frac{\partial f}{\partial x_n} \end{bmatrix}}_{\mathbf{J}_f \cdot \Delta \mathbf{x}} \begin{bmatrix} \Delta x_1 \\ \vdots \\ \Delta x_n \end{bmatrix}$$

$$d\mathbf{g}: \mathbb{R} \rightarrow \mathbb{R}^n \quad \Delta t \mapsto d\mathbf{g}(\Delta t) = \begin{bmatrix} x'_1(t)\Delta t \\ \vdots \\ x'_n(t)\Delta t \end{bmatrix} = \underbrace{\begin{bmatrix} \frac{dx_1}{dt} \\ \vdots \\ \frac{dx_n}{dt} \end{bmatrix}}_{\mathbf{J}_g \cdot \Delta t} \Delta t$$

则线性映射 df 和 $d\mathbf{g}$ 的复合即是线性映射 $df \circ d\mathbf{g} : \mathbb{R} \rightarrow \mathbb{R}^n$, 其矩阵表示就是对应 *Jacobi* 矩阵的乘积 $\mathbf{J}_f \circ \mathbf{J}_g$, 见下图所示

$$\begin{array}{c}
 \begin{array}{ccccc}
 & & df \circ dg & & \\
 & & \mathbf{J}_f \cdot \mathbf{J}_g & & \\
 \mathbb{R} & \xrightarrow[\mathbf{J}_g]{dg} & \mathbb{R}^n & \xrightarrow[\mathbf{J}_f]{df} & \mathbb{R}
 \end{array} \\
 \\
 \Delta t \mapsto \underbrace{\begin{bmatrix} \frac{dx_1}{dt} \\ \vdots \\ \frac{dx_n}{dt} \end{bmatrix}}_{\mathbf{J}_g \Delta t} \xrightarrow{\Delta t} \underbrace{\begin{bmatrix} \frac{\partial f}{\partial x_1} & \cdots & \frac{\partial f}{\partial x_n} \end{bmatrix}}_{\mathbf{J}_f} \underbrace{\begin{bmatrix} \frac{dx_1}{dt} \\ \vdots \\ \frac{dx_n}{dt} \end{bmatrix}}_{\mathbf{J}_g \Delta t} \Delta t
 \end{array}$$

而 $\mathbf{J}_f \circ \mathbf{J}_g = \sum_{i=1}^n \frac{\partial f}{\partial x_i} \frac{dx_i}{dt}$. 这不是别的, 正是复合函数 $f(\mathbf{g}(t))$ 的导数, 或复合映射 $f \circ \mathbf{g}$ 的微分, 其 *Jacobi* 矩阵 $\mathbf{J}_{f \circ \mathbf{g}}$ 不是别的, 正是各映射 *Jacobi* 矩阵的乘积, 即

$$d(f \circ \mathbf{g}) = df \circ d\mathbf{g} \quad \longleftrightarrow \quad \mathbf{J}_{f \circ \mathbf{g}} = \mathbf{J}_f \cdot \mathbf{J}_g$$

我们不应止步于此, 而应审视其结构、琢磨其机理, 以窥测出背后的一般模式, 不仅有助于我们在复杂的知识体系中摸清主脉, 也能让我们在处理具体问题时做到化繁为简, 知一而知其余.

对一般的映射 (向量值函数) $\mathbf{f} : \mathbb{R}^n \rightarrow \mathbb{R}^m$ ($x_1, \dots, x_n \mapsto (y_1, \dots, y_m)$), 其中

$$\mathbf{f} : \begin{cases} y_1 = f_1(x_1, \dots, x_n) \\ \vdots \\ y_m = f_m(x_1, \dots, x_n) \end{cases}$$

知道了其微分 $d\mathbf{f}$, 即其 *Jacobi* 矩阵 $\mathbf{J}_f = \left[\frac{\partial f_i}{\partial x_j} \right]_{m \times n}$, 就知道了其各偏导 $\frac{\partial f_i}{\partial x_j}$. 另给一映射 $\mathbf{g} : \mathbb{R}^m \rightarrow \mathbb{R}^p$ ($y_1, \dots, y_m \mapsto (z_1, \dots, z_p)$), 其分量函数为

$$\mathbf{g} : \begin{cases} z_1 = g_1(y_1, \dots, y_m) \\ \vdots \\ z_p = g_p(y_1, \dots, y_m) \end{cases}$$

设 $\mathbf{f}$ 和 $\mathbf{g}$ 可复合, 即 $\text{Ran}(\mathbf{f}) \subseteq \text{Dom}(\mathbf{g})$, 则其复合映射 $\mathbf{g} \circ \mathbf{f} : \mathbb{R}^n \rightarrow \mathbb{R}^p$ 的分量

函数由 $\mathbf{g} \circ \mathbf{f}$: $\begin{cases} z_1 = g_1(f_1(x_1, \dots, x_n), \dots, f_m(x_1, \dots, x_n)) \\ \vdots \\ z_p = g_p(f_1(x_1, \dots, x_n), \dots, f_m(x_1, \dots, x_n)) \end{cases}$ 给出. 其线性化, 即其微分由下给出

$$d(\mathbf{g} \circ \mathbf{f}) : \mathbb{R}^n \longrightarrow \mathbb{R}^p \quad \begin{bmatrix} \Delta x_1 \\ \vdots \\ \Delta x_n \end{bmatrix} \mapsto \underbrace{\begin{bmatrix} \frac{\partial z_1}{\partial x_1} & \dots & \frac{\partial z_1}{\partial x_n} \\ \vdots & & \vdots \\ \frac{\partial z_p}{\partial x_1} & \dots & \frac{\partial z_p}{\partial x_n} \end{bmatrix}}_{\mathbf{J}_{\mathbf{g} \circ \mathbf{f}}} \begin{bmatrix} \Delta x_1 \\ \vdots \\ \Delta x_n \end{bmatrix}$$

一般模式: 复合之线性化 = 线性化之复合

$$\underbrace{d(\mathbf{g} \circ \mathbf{f}) = d\mathbf{g} \circ d\mathbf{f}}_{\text{映射之复合}} \quad \longleftrightarrow \quad \underbrace{\mathbf{J}_{\mathbf{g} \circ \mathbf{f}} = \mathbf{J}_{\mathbf{g}} \cdot \mathbf{J}_{\mathbf{f}}}_{\text{矩阵之乘积}}$$

演示: $\mathbb{R}^n \xrightarrow{\mathbf{f}} \mathbb{R}^m \xrightarrow{\mathbf{g}} \mathbb{R}^p \quad (x_1, \dots, x_n) \xmapsto{\mathbf{f}} (y_1, \dots, y_m) \xmapsto{\mathbf{g}} (z_1, \dots, z_p)$

$$(x_1, \dots, x_n) \xmapsto{\mathbf{f}} (f_1(\mathbf{x}), \dots, f_m(\mathbf{x})) \xmapsto{\mathbf{g}} (g_1(f_1(\mathbf{x}), \dots, f_m(\mathbf{x})), \dots, g_p(f_1(\mathbf{x}), \dots, f_m(\mathbf{x})))$$

其微分 (线性化) 层面的表示如下

$$\begin{array}{c} \begin{array}{c} \xrightarrow{\quad d(\mathbf{g} \circ \mathbf{f}) \quad} \\ \quad \mathbf{J}_{\mathbf{g} \circ \mathbf{f}} \end{array} \\ \mathbb{R}^n \xrightarrow[\mathbf{J}_{\mathbf{f}}]{d\mathbf{f}} \mathbb{R}^m \xrightarrow[\mathbf{J}_{\mathbf{g}}]{d\mathbf{g}} \mathbb{R}^p \end{array}$$

$$\begin{bmatrix} \Delta x_1 \\ \vdots \\ \Delta x_n \end{bmatrix} \mapsto \underbrace{\begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \dots & \frac{\partial f_1}{\partial x_n} \\ \vdots & & \vdots \\ \frac{\partial f_m}{\partial x_1} & \dots & \frac{\partial f_m}{\partial x_n} \end{bmatrix}}_{\mathbf{J}_{\mathbf{f}}} \begin{bmatrix} \Delta x_1 \\ \vdots \\ \Delta x_n \end{bmatrix} \mapsto \underbrace{\begin{bmatrix} \frac{\partial g_1}{\partial y_1} & \dots & \frac{\partial g_1}{\partial y_m} \\ \vdots & & \vdots \\ \frac{\partial g_p}{\partial y_1} & \dots & \frac{\partial g_p}{\partial y_m} \end{bmatrix}}_{\mathbf{J}_{\mathbf{g}}} \underbrace{\begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \dots & \frac{\partial f_1}{\partial x_n} \\ \vdots & & \vdots \\ \frac{\partial f_m}{\partial x_1} & \dots & \frac{\partial f_m}{\partial x_n} \end{bmatrix}}_{\mathbf{J}_{\mathbf{f}}} \begin{bmatrix} \Delta x_1 \\ \vdots \\ \Delta x_n \end{bmatrix}$$

对比

$$\begin{bmatrix} \Delta x_1 \\ \vdots \\ \Delta x_n \end{bmatrix} \mapsto \underbrace{\begin{bmatrix} \frac{\partial(\mathbf{g} \circ \mathbf{f})_1}{\partial x_1} & \dots & \frac{\partial(\mathbf{g} \circ \mathbf{f})_1}{\partial x_n} \\ \vdots & & \vdots \\ \frac{\partial(\mathbf{g} \circ \mathbf{f})_p}{\partial x_1} & \dots & \frac{\partial(\mathbf{g} \circ \mathbf{f})_p}{\partial x_n} \end{bmatrix}}_{\mathbf{J}_{\mathbf{g} \circ \mathbf{f}}} \begin{bmatrix} \Delta x_1 \\ \vdots \\ \Delta x_n \end{bmatrix}$$

其中 $z_i = (\mathbf{g} \circ \mathbf{f})_i$, $i = 1, \dots, p$. 由此即得 $\mathbf{J}_{\mathbf{g} \circ \mathbf{f}} = \mathbf{J}_{\mathbf{g}} \cdot \mathbf{J}_{\mathbf{f}}$, 具体就是

$$\underbrace{\begin{bmatrix} \frac{\partial z_1}{\partial x_1} & \dots & \frac{\partial z_1}{\partial x_n} \\ \vdots & & \vdots \\ \frac{\partial z_p}{\partial x_1} & \dots & \frac{\partial z_p}{\partial x_n} \end{bmatrix}}_{\mathbf{J}_{\mathbf{g} \circ \mathbf{f}}} = \underbrace{\begin{bmatrix} \frac{\partial z_1}{\partial y_1} & \dots & \frac{\partial z_1}{\partial y_m} \\ \vdots & & \vdots \\ \frac{\partial z_p}{\partial y_1} & \dots & \frac{\partial z_p}{\partial y_m} \end{bmatrix}}_{\mathbf{J}_{\mathbf{g}}} \underbrace{\begin{bmatrix} \frac{\partial y_1}{\partial x_1} & \dots & \frac{\partial y_1}{\partial x_n} \\ \vdots & & \vdots \\ \frac{\partial y_m}{\partial x_1} & \dots & \frac{\partial y_m}{\partial x_n} \end{bmatrix}}_{\mathbf{J}_{\mathbf{f}}}$$

利用矩阵乘法运算法则, 展开即得对一般复合映射求导的链式法则:

$$\boxed{\frac{\partial z_i}{\partial x_j} = \sum_{k=1}^m \frac{\partial z_i}{\partial y_k} \frac{\partial y_k}{\partial x_j}} \quad \forall i = 1, \dots, p; \quad \forall j = 1, \dots, n.$$

比如, 对三元函数 $u = f(x, y, z)$ 同向量值函数 $\begin{cases} x = x(t) \\ y = y(t) \\ z = z(t) \end{cases}$ 之复合 $z = f(x(t), y(t), z(t))$

的全导数公式

$$\frac{dz}{dt} = \frac{\partial f}{\partial x} \frac{dx}{dt} + \frac{\partial f}{\partial y} \frac{dy}{dt} + \frac{\partial f}{\partial z} \frac{dz}{dt}$$

它对应上面一般公式当 $n = 1, m = 3, p = 1$ 时的情形. 由上即知, 所谓复合函数(映射)的链式求导法则本质上是符合映射微分法则之矩阵乘法表示的产物. 为进一步熟悉其形式, 并活化其应用, 须再讨论一些低维情形.

当 $n = m = 2, p = 1$ 时: 即考察(向量值)函数 $\mathbf{g} : \begin{cases} u = u(x, y) \\ v = v(x, y) \end{cases}$ 同二元函数 $z = f(u, v)$ 的复合. 设 $\mathbf{g}$ 在点 (x, y) 处可一阶偏导(即其两个分量函数都可偏导); z 在相应于 (x, y) 的点 (u, v) 处可微, 则其复合函数 $z = f(u(x, y), v(x, y))$ 在 (x, y) 处可导, 其导数由下给出

$$\underbrace{\begin{bmatrix} \frac{\partial z}{\partial x} & \frac{\partial z}{\partial y} \end{bmatrix}}_{\mathbf{J}_{f \circ \mathbf{g}}} = \underbrace{\begin{bmatrix} \frac{\partial z}{\partial u} & \frac{\partial z}{\partial v} \end{bmatrix}}_{\mathbf{J}_f} \underbrace{\begin{bmatrix} \frac{\partial u}{\partial x} & \frac{\partial u}{\partial y} \\ \frac{\partial v}{\partial x} & \frac{\partial v}{\partial y} \end{bmatrix}}_{\mathbf{J}_{\mathbf{g}}} = \begin{bmatrix} \frac{\partial z}{\partial u} \frac{\partial u}{\partial x} + \frac{\partial z}{\partial v} \frac{\partial v}{\partial x} & \frac{\partial z}{\partial u} \frac{\partial u}{\partial y} + \frac{\partial z}{\partial v} \frac{\partial v}{\partial y} \end{bmatrix}$$

$$\text{即得到 } \frac{\partial z}{\partial x} = \frac{\partial z}{\partial u} \frac{\partial u}{\partial x} + \frac{\partial z}{\partial v} \frac{\partial v}{\partial x}; \quad \frac{\partial z}{\partial y} = \frac{\partial z}{\partial u} \frac{\partial u}{\partial y} + \frac{\partial z}{\partial v} \frac{\partial v}{\partial y}$$

下面给出它的几种诠释, 以凸显其背后的共性考量, 并用图示将其形式结图示化, 以方便其形式规则的记忆.

微分角度诠释：函数 $z = f(u, v)$ 和 $\mathbf{g} : \begin{cases} u = u(x, y) \\ v = v(x, y) \end{cases}$ 的微分分别为

$$dz = \frac{\partial z}{\partial u} du + \frac{\partial z}{\partial v} dv = \underbrace{\begin{bmatrix} \frac{\partial z}{\partial u} & \frac{\partial z}{\partial v} \end{bmatrix}}_{\mathbf{J}_f} \begin{bmatrix} du \\ dv \end{bmatrix}$$

$$d\mathbf{g} = \begin{bmatrix} du \\ dv \end{bmatrix} = \underbrace{\begin{bmatrix} \frac{\partial u}{\partial x} & \frac{\partial u}{\partial y} \\ \frac{\partial v}{\partial x} & \frac{\partial v}{\partial y} \end{bmatrix}}_{\mathbf{J}_g} \begin{bmatrix} dx \\ dy \end{bmatrix}$$

将第二式代入第一式后得到

$$\begin{aligned} dz &= \underbrace{\begin{bmatrix} \frac{\partial z}{\partial u} & \frac{\partial z}{\partial v} \end{bmatrix}}_{\mathbf{J}_f} \underbrace{\begin{bmatrix} \frac{\partial u}{\partial x} & \frac{\partial u}{\partial y} \\ \frac{\partial v}{\partial x} & \frac{\partial v}{\partial y} \end{bmatrix}}_{\mathbf{J}_g} \begin{bmatrix} dx \\ dy \end{bmatrix} = \underbrace{\begin{bmatrix} \frac{\partial z}{\partial u} \frac{\partial u}{\partial x} + \frac{\partial z}{\partial v} \frac{\partial v}{\partial x} & \frac{\partial z}{\partial u} \frac{\partial u}{\partial y} + \frac{\partial z}{\partial v} \frac{\partial v}{\partial y} \end{bmatrix}}_{\mathbf{J}_{f \circ g}} \begin{bmatrix} dx \\ dy \end{bmatrix} \\ &= \underbrace{\left(\frac{\partial z}{\partial u} \frac{\partial u}{\partial x} + \frac{\partial z}{\partial v} \frac{\partial v}{\partial x} \right)}_{\frac{\partial z}{\partial x}} dx + \underbrace{\left(\frac{\partial z}{\partial u} \frac{\partial u}{\partial y} + \frac{\partial z}{\partial v} \frac{\partial v}{\partial y} \right)}_{\frac{\partial z}{\partial y}} dy \end{aligned}$$

即 $dz = \frac{\partial z}{\partial x} dx + \frac{\partial z}{\partial y} dy$, 这是将 z 看成 x, y 的函数时对其微分的公式, 其形式上完全与将 z 看成是 u, v 的函数时求全微分的公式 $dz = \frac{\partial z}{\partial u} du + \frac{\partial z}{\partial v} dv$, 此即为一阶微分的形式不变性:

即对二元函数 $z = f(u, v)$ 而言, 不论 u, v 是中间变量还是自变量, 其 (一阶) 微分在形式上是一样的. 其计算验证如下

$$\begin{aligned} \begin{cases} du = \frac{\partial u}{\partial x} dx + \frac{\partial u}{\partial y} dy \\ dv = \frac{\partial v}{\partial x} dx + \frac{\partial v}{\partial y} dy \end{cases} &\Rightarrow dz = \frac{\partial z}{\partial u} du + \frac{\partial z}{\partial v} dv = \frac{\partial z}{\partial u} \left(\frac{\partial u}{\partial x} dx + \frac{\partial u}{\partial y} dy \right) + \\ &+ \frac{\partial z}{\partial v} \left(\frac{\partial v}{\partial x} dx + \frac{\partial v}{\partial y} dy \right) = \left(\frac{\partial z}{\partial u} \frac{\partial u}{\partial x} + \frac{\partial z}{\partial v} \frac{\partial v}{\partial x} \right) dx + \left(\frac{\partial z}{\partial u} \frac{\partial u}{\partial y} + \frac{\partial z}{\partial v} \frac{\partial v}{\partial y} \right) dy \\ &= \underbrace{\frac{\partial z}{\partial x} dx + \frac{\partial z}{\partial y} dy} \end{aligned}$$

注记 2.6.1 由一阶微分形式的不变量知在求微分时我们可以采取化整为零的策略，即可以灵活地将中间变量当做自变量处理，这是不是和计算矩阵乘法时的分块策略非常相似？了解到求微分（导数）规则与矩阵乘法的关系后，读者不难认识到这不仅仅是表面的相似，更是线性化复合运算（矩阵乘法）的本性特征。

例 2.6.1 设 $z = e^{xy} \arctan \frac{y}{x}$ ，求 $\frac{\partial z}{\partial x}$ 和 $\frac{\partial z}{\partial y}$ 。

解：利用一阶微分的形式不变性 $dz \xrightarrow{\text{将 } u = e^{xy} \text{ 和 } v = \arctan \frac{y}{x} \text{ 作为自变量}} u dv + v du$

$$= e^{xy} d \arctan \frac{y}{x} + \arctan \frac{y}{x} d(e^{xy}) \xrightarrow{\text{将 } xy, \frac{y}{x} \text{ 看成自变量}} e^{xy} \frac{d\left(\frac{y}{x}\right)}{1 + \left(\frac{y}{x}\right)^2} + \arctan \frac{y}{x} e^{xy} d(xy)$$

$$\begin{aligned} & \xrightarrow{\text{将 } x, y \text{ 看成自变量}} e^{xy} \frac{\frac{xdy - ydx}{x^2}}{1 + \left(\frac{y}{x}\right)^2} + \arctan \frac{y}{x} e^{xy} (xdy + ydx) \\ &= e^{xy} \left(\left(y \arctan \frac{y}{x} - \frac{y}{x^2 + y^2} \right) dx + \left(x \arctan \frac{y}{x} + \frac{x}{x^2 + y^2} \right) dy \right) \\ \Rightarrow \quad & \frac{\partial z}{\partial x} = ye^{xy} \left(\arctan \frac{y}{x} - \frac{1}{x^2 + y^2} \right); \quad \frac{\partial z}{\partial y} = xe^{xy} \left(\arctan \frac{y}{x} + \frac{1}{x^2 + y^2} \right) \end{aligned}$$

明显迅捷了不少，且每一步都是简单的运算，不易出错，当然代价是步骤变多了。也就是说，将一次运算的复杂性“匀”到了多步骤里头了。

求导作为极限的视角：为考察复合函数 $z = f(u(x, y), v(x, y))$ 在 (x, y) 点处的（偏）导数，我们利用“导数作为微商”这一极限机制来处理。同前，我们假设 z 在相应于 (x, y) 的点 (u, v) 处可微，且 u, v 在 (x, y) 处可一阶偏导。首先由可微性，知

$$\Delta z = f(u + \Delta u, v + \Delta v) - f(u, v) = \frac{\partial f}{\partial u} \Delta u + \frac{\partial f}{\partial v} \Delta v + o\left(\sqrt{(\Delta u)^2 + (\Delta v)^2}\right)$$

记 $\Delta_x u = u(x + \Delta x, y) - u(x, y)$ ； $\Delta_y v = v(x + \Delta x, y) - v(x, y)$ 为 Δx 引起的 u, v 之增量，由假设知

$$\lim_{\Delta x \rightarrow 0} \frac{\Delta_x u}{\Delta x} = \frac{\partial u}{\partial x} \text{ 和 } \lim_{\Delta x \rightarrow 0} \frac{\Delta_x v}{\Delta x} = \frac{\partial v}{\partial x} \text{ 在 } (x, y) \text{ 处存在}$$

故

$$\frac{\Delta z}{\Delta x} = \frac{\partial f}{\partial u} \frac{\Delta u}{\Delta x} + \frac{\partial f}{\partial v} \frac{\Delta v}{\Delta x} + \frac{o\left(\sqrt{(\Delta_x u)^2 + (\Delta_x v)^2}\right)}{\Delta x} \xrightarrow{\text{因只考虑 } \Delta x \text{ 的效应}}$$

$$= \frac{\partial f}{\partial u} \frac{\Delta_x u}{\Delta x} + \frac{\partial f}{\partial v} \frac{\Delta_x v}{\Delta x} + \frac{o\left(\sqrt{(\Delta_x u)^2 + (\Delta_x v)^2}\right)}{\Delta x} \xrightarrow{\Delta x \rightarrow 0} \frac{\partial f}{\partial u} \frac{\partial u}{\partial x} + \frac{\partial f}{\partial v} \frac{\partial v}{\partial x}$$

上面用到了

$$\begin{aligned} \frac{o\left(\sqrt{(\Delta_x u)^2 + (\Delta_x v)^2}\right)}{\Delta x} &= \frac{o\left(\sqrt{(\Delta_x u)^2 + (\Delta_x v)^2}\right)}{\sqrt{(\Delta_x u)^2 + (\Delta_x v)^2}} \frac{\sqrt{(\Delta_x u)^2 + (\Delta_x v)^2}}{\Delta x} \\ &= \frac{o\left(\sqrt{(\Delta_x u)^2 + (\Delta_x v)^2}\right)}{\sqrt{(\Delta_x u)^2 + (\Delta_x v)^2}} \underbrace{\sqrt{\left(\frac{\Delta_x u}{\Delta x}\right)^2 + \left(\frac{\Delta_x v}{\Delta x}\right)^2} \frac{|\Delta x|}{\Delta x}}_{\Delta x \rightarrow 0 \text{ 时有界}} \xrightarrow{\Delta x \rightarrow 0} 0 \end{aligned}$$

从而证得了 $\frac{\partial z}{\partial x} = \frac{\partial f}{\partial u} \frac{\partial u}{\partial x} + \frac{\partial f}{\partial v} \frac{\partial v}{\partial x}$; 同理可证 $\frac{\partial z}{\partial y} = \frac{\partial f}{\partial u} \frac{\partial u}{\partial y} + \frac{\partial f}{\partial v} \frac{\partial v}{\partial y}$. $\square$

注记 2.6.2 注意, 在链式法则应用中, 外层函数的“可微性”这一假设条件是不可弱化为“可偏导”. 我们再以例 2.4.1 中的函数 $z = f(x, y) = \begin{cases} \frac{2xy^3}{x^2 + y^4}, & x^2 + y^2 \neq 0, \\ 0, & x^2 + y^2 = 0 \end{cases}$ 为说明, 已知它在 $(0, 0)$ 处可偏导, 且 $f_x(0, 0) = f_y(0, 0) = 0$, 但它在 $(0, 0)$ 处不可微.

又设 x, y 以方式 $\begin{cases} x = t^2 \\ y = t \end{cases}$ 依赖于 t . 复合后给出 $z(t) = t$, 故 $\left.\frac{dz}{dt}\right|_{t=0} = 1$, 但若贸然套用链式法则, 则会得到 $\left.\frac{dz}{dt}\right|_{t=0} = \left.\frac{\partial f}{\partial x}\right|_{(0,0)} \left.\frac{dx}{dt}\right|_{t=0} + \left.\frac{\partial f}{\partial y}\right|_{(0,0)} \left.\frac{dy}{dt}\right|_{t=0} = 0$ 的错误结论.

例 2.6.2 设 $z = (2x + y)^{x+2y}$, 计算 $\frac{\partial z}{\partial x}$ 和 $\frac{\partial z}{\partial y}$.

解法一 (直接求导)

$$\begin{aligned} \frac{\partial z}{\partial x} &= \frac{\partial}{\partial x} e^{(x+2y)\ln(2x+y)} \xrightarrow{\text{视 } y \text{ 为常数}} (2x+y)^{x+2y} \left(\ln(2x+y) + (x+2y) \frac{2}{2x+y} \right) \\ \frac{\partial z}{\partial y} &= \frac{\partial}{\partial y} e^{(x+2y)\ln(2x+y)} \xrightarrow{\text{视 } x \text{ 为常数}} (2x+y)^{x+2y} \left(2\ln(2x+y) + (x+2y) \frac{1}{2x+y} \right) \end{aligned}$$

解法二 (链式法则) 设 $u = 2x + y$, $v = x + 2y$, 则 $z = u^v$, 从而


$$\begin{aligned} \frac{\partial z}{\partial x} &= \frac{\partial z}{\partial u} \frac{\partial u}{\partial x} + \frac{\partial z}{\partial v} \frac{\partial v}{\partial x} = vu^{v-1} \times 2 + (\ln u)u^v \times 1 \\ &= 2(x+2y)(2x+y)^{x+2y-1} + \ln(2x+y)(2x+y)^{x+2y} \\ \frac{\partial z}{\partial y} &= \frac{\partial z}{\partial u} \frac{\partial u}{\partial y} + \frac{\partial z}{\partial v} \frac{\partial v}{\partial y} = vu^{v-1} \times 1 + (\ln u)u^v \times 2 \end{aligned}$$

$$= (x+2y)(2x+y)^{x+2y-1} + 2\ln(2x+y)(2x+y)^{x+2y}$$

解法三（利用一阶微分的形式不变性） $dz = d(u^v) = d(e^{v\ln u}) = e^{v\ln u}d(v\ln u)$

$$\begin{aligned} &= u^v(v d\ln u + \ln u dv) = u^v \left(\frac{vdu}{u} + \ln u dv \right) \\ &= (2x+y)^{x+2y} \left(\frac{(x+2y)d(2x+y)}{2x+y} + \ln(2x+y)d(x+2y) \right) \\ &= (2x+y)^{x+2y} \left(2\frac{x+2y}{2x+y} + \ln(2x+y) \right) dx + \\ &\quad + (2x+y)^{x+2y} \left(\frac{x+2y}{2x+y} + \ln(2x+y) + 2\ln(2x+y) \right) dy \\ \Rightarrow &\begin{cases} \frac{\partial z}{\partial x} = (2x+y)^{x+2y} \left(2\frac{x+2y}{2x+y} + \ln(2x+y) \right) \\ \frac{\partial z}{\partial y} = (2x+y)^{x+2y} \left(\frac{x+2y}{2x+y} + \ln(2x+y) + 2\ln(2x+y) \right) \end{cases} \end{aligned}$$

链式法则的“图学”：对之前 $w = f(x, y, z)$ 和 $\begin{cases} x = x(t) \\ y = y(t) \\ z = z(t) \end{cases}$ 的复合，其变量依赖关系可由下图表示：




则复合的全导数公式 $\frac{dz}{dt} = \frac{\partial z}{\partial x} \frac{dx}{dt} + \frac{\partial z}{\partial y} \frac{dy}{dt} + \frac{\partial z}{\partial z} \frac{dz}{dt}$ 可诠释为：

1. 为寻求 z 对 t 的导数，我们先在上变量依赖图中寻求所有从变量 w 到 t 的路径，比如在上图中有三条相关路径： $w \rightarrow x \rightarrow t$; $w \rightarrow y \rightarrow t$; $w \rightarrow z \rightarrow t$;
2. 对取定路径中的每个箭头关联一导数：箭尾处变量对箭头处变量的导数；
3. 同一条路径中个箭头处关联的导数相乘；
4. 不同路径对应的导数之积相加。

以下诸例表明上图示计算 (*diagrammatic computation*) 其实是个“通用法则”.

例 2.6.3 对 $z = f(u, v)$ 和 $\mathbf{g}: \begin{cases} u = u(x, y) \\ v = v(x, y) \end{cases}$ 的复合, 先画出变量依赖图如下



为求 $\frac{\partial z}{\partial x}$, 我们操作如下

$$\begin{cases} z \rightarrow u \rightarrow x \rightsquigarrow \frac{\partial z}{\partial u} \frac{\partial u}{\partial x} \\ z \rightarrow v \rightarrow x \rightsquigarrow \frac{\partial z}{\partial v} \frac{\partial v}{\partial x} \end{cases} \Rightarrow \frac{\partial z}{\partial x} = \frac{\partial z}{\partial u} \frac{\partial u}{\partial x} + \frac{\partial z}{\partial v} \frac{\partial v}{\partial x}$$


例 2.6.4 设向量值函数 $\mathbf{f}: \mathbb{R}^2 \rightarrow \mathbb{R}^3$ 的坐标分量函数为 $\begin{cases} x = u^2 + v^2 \\ y = u^2 - v^2 \\ z = uv \end{cases}$; 向量值函数

$\mathbf{g}: \mathbb{R}^2 \rightarrow \mathbb{R}^2$ 的坐标分量函数为 $\begin{cases} u = r \cos \theta \\ v = r \sin \theta \end{cases}$, 则其复合 $\mathbf{f} \circ \mathbf{g}: \mathbb{R}^2 \rightarrow \mathbb{R}^3$ 的坐标分

量函数为 $\begin{cases} x = r^2 \\ y = r^2 \cos 2\theta \\ z = \frac{r^2}{2} \sin 2\theta \end{cases}$ 求复合函数的各一阶偏导: $\frac{\partial x}{\partial r}, \frac{\partial x}{\partial \theta}, \frac{\partial y}{\partial r}, \frac{\partial y}{\partial \theta}, \frac{\partial z}{\partial r}, \frac{\partial z}{\partial \theta}$.

解法一 (直接求导): $\frac{\partial x}{\partial r} = 2r; \frac{\partial x}{\partial \theta} = 0; \frac{\partial y}{\partial r} = 2r \cos 2\theta; \frac{\partial y}{\partial \theta} = -2r^2 \sin 2\theta; \frac{\partial z}{\partial r} = r \sin 2\theta; \frac{\partial z}{\partial \theta} = r^2 \cos 2\theta$.

解法二 (图式算法) 各变量依赖关系图如下



$$\begin{aligned}
\left\{ \begin{array}{l} x \rightarrow u \rightarrow r \quad \rightsquigarrow \quad \frac{\partial x}{\partial u} \frac{\partial u}{\partial r} \\ x \rightarrow v \rightarrow r \quad \rightsquigarrow \quad \frac{\partial x}{\partial v} \frac{\partial v}{\partial r} \end{array} \right. & \Rightarrow \quad \frac{\partial x}{\partial r} = \frac{\partial x}{\partial u} \frac{\partial u}{\partial r} + \frac{\partial x}{\partial v} \frac{\partial v}{\partial r} = 2u \cos \theta + 2v \sin \theta = 2r \\
\left\{ \begin{array}{l} x \rightarrow u \rightarrow \theta \quad \rightsquigarrow \quad \frac{\partial x}{\partial u} \frac{\partial u}{\partial \theta} \\ x \rightarrow v \rightarrow \theta \quad \rightsquigarrow \quad \frac{\partial x}{\partial v} \frac{\partial v}{\partial \theta} \end{array} \right. & \Rightarrow \quad \frac{\partial x}{\partial \theta} = \frac{\partial x}{\partial u} \frac{\partial u}{\partial \theta} + \frac{\partial x}{\partial v} \frac{\partial v}{\partial \theta} = 2u(-r \sin \theta) + 2v(r \cos \theta) = 0 \\
\left\{ \begin{array}{l} y \rightarrow u \rightarrow r \quad \rightsquigarrow \quad \frac{\partial y}{\partial u} \frac{\partial u}{\partial r} \\ y \rightarrow v \rightarrow r \quad \rightsquigarrow \quad \frac{\partial y}{\partial v} \frac{\partial v}{\partial r} \end{array} \right. & \Rightarrow \quad \frac{\partial y}{\partial r} = \frac{\partial y}{\partial u} \frac{\partial u}{\partial r} + \frac{\partial y}{\partial v} \frac{\partial v}{\partial r} = 2u \cos \theta - 2v \sin \theta = 2r \cos 2\theta \\
\left\{ \begin{array}{l} y \rightarrow u \rightarrow \theta \quad \rightsquigarrow \quad \frac{\partial y}{\partial u} \frac{\partial u}{\partial \theta} \\ y \rightarrow v \rightarrow \theta \quad \rightsquigarrow \quad \frac{\partial y}{\partial v} \frac{\partial v}{\partial \theta} \end{array} \right. & \Rightarrow \quad \frac{\partial y}{\partial \theta} = \frac{\partial y}{\partial u} \frac{\partial u}{\partial \theta} + \frac{\partial y}{\partial v} \frac{\partial v}{\partial \theta} = 2u(-r \sin \theta) - 2v(r \cos \theta) = -2r^2 \sin 2\theta \\
\left\{ \begin{array}{l} z \rightarrow u \rightarrow r \quad \rightsquigarrow \quad \frac{\partial z}{\partial u} \frac{\partial u}{\partial r} \\ z \rightarrow v \rightarrow r \quad \rightsquigarrow \quad \frac{\partial z}{\partial v} \frac{\partial v}{\partial r} \end{array} \right. & \Rightarrow \quad \frac{\partial z}{\partial r} = \frac{\partial z}{\partial u} \frac{\partial u}{\partial r} + \frac{\partial z}{\partial v} \frac{\partial v}{\partial r} = v \cos \theta + u \sin \theta = r \sin 2\theta \\
\left\{ \begin{array}{l} z \rightarrow u \rightarrow \theta \quad \rightsquigarrow \quad \frac{\partial z}{\partial u} \frac{\partial u}{\partial \theta} \\ z \rightarrow v \rightarrow \theta \quad \rightsquigarrow \quad \frac{\partial z}{\partial v} \frac{\partial v}{\partial \theta} \end{array} \right. & \Rightarrow \quad \frac{\partial z}{\partial \theta} = \frac{\partial z}{\partial u} \frac{\partial u}{\partial \theta} + \frac{\partial z}{\partial v} \frac{\partial v}{\partial \theta} = v(-r \sin \theta) + u(r \cos \theta) = r^2 \cos 2\theta
\end{aligned}$$

解法三（映射微分法）映射 $\mathbf{f}$ 和 $\mathbf{g}$ 的 *Jacobi* 矩阵分别为

$$\mathbf{J}_{\mathbf{f}} = \begin{bmatrix} \frac{\partial x}{\partial u} & \frac{\partial x}{\partial v} \\ \frac{\partial y}{\partial u} & \frac{\partial y}{\partial v} \\ \frac{\partial z}{\partial u} & \frac{\partial z}{\partial v} \end{bmatrix} = \begin{bmatrix} 2u & 2v \\ 2u & -2v \\ v & u \end{bmatrix}; \quad \mathbf{J}_{\mathbf{g}} = \begin{bmatrix} \frac{\partial u}{\partial r} & \frac{\partial u}{\partial \theta} \\ \frac{\partial v}{\partial r} & \frac{\partial v}{\partial \theta} \end{bmatrix} = \begin{bmatrix} \cos \theta & -r \sin \theta \\ \sin \theta & r \cos \theta \end{bmatrix}$$

则复合映射 $\mathbf{f} \circ \mathbf{g}$ 的微分为 $d(\mathbf{f} \circ \mathbf{g}) = d(\mathbf{f}) \cdot d(\mathbf{g})$ 的 *Jacobi* 矩阵 $\mathbf{J}_{\mathbf{f} \circ \mathbf{g}}$ 由下给出

$$\begin{aligned} \begin{bmatrix} x_r & x_\theta \\ y_r & y_\theta \\ z_r & z_\theta \end{bmatrix} &= \mathbf{J}_{\mathbf{f} \circ \mathbf{g}} = \mathbf{J}_{\mathbf{f}} \cdot \mathbf{J}_{\mathbf{g}} = \begin{bmatrix} 2u & 2v \\ 2u & -2v \\ v & u \end{bmatrix} \begin{bmatrix} \cos \theta & -r \sin \theta \\ \sin \theta & r \cos \theta \end{bmatrix} \\ &= \begin{bmatrix} 2u \cos \theta + 2v \sin \theta & -2ur \sin \theta + 2vr \cos \theta \\ 2u \cos \theta - 2v \sin \theta & -2ur \sin \theta + 2vr \cos \theta \\ v \cos \theta + u \sin \theta & -vr \sin \theta + ur \cos \theta \end{bmatrix} = \begin{bmatrix} 2r & 0 \\ 2r \cos 2\theta & -2r^2 \sin 2\theta \\ r \sin \theta & r^2 \cos 2\theta \end{bmatrix} \end{aligned}$$

解法四 (利用一阶微分的形式不变性)

$$\bullet \quad dx = \frac{\partial x}{\partial u} du + \frac{\partial x}{\partial v} dv = 2u du + 2v dv = 2u \left(\frac{\partial u}{\partial r} dr + \frac{\partial u}{\partial \theta} d\theta \right) + 2v \left(\frac{\partial v}{\partial r} dr + \frac{\partial v}{\partial \theta} d\theta \right)$$

$$= \left(2u \frac{\partial u}{\partial r} + 2v \frac{\partial v}{\partial r} \right) dr + \left(2u \frac{\partial u}{\partial \theta} + 2v \frac{\partial v}{\partial \theta} \right) d\theta \implies \begin{cases} \frac{\partial x}{\partial r} = 2u \frac{\partial u}{\partial r} + 2v \frac{\partial v}{\partial r} \\ \frac{\partial x}{\partial \theta} = 2u \frac{\partial u}{\partial \theta} + 2v \frac{\partial v}{\partial \theta} \end{cases}$$

$$\bullet \quad dy = \frac{\partial y}{\partial u} du + \frac{\partial y}{\partial v} dv = 2u du - 2v dv = 2u \left(\frac{\partial u}{\partial r} dr + \frac{\partial u}{\partial \theta} d\theta \right) - 2v \left(\frac{\partial v}{\partial r} dr + \frac{\partial v}{\partial \theta} d\theta \right)$$

$$= \left(2u \frac{\partial u}{\partial r} - 2v \frac{\partial v}{\partial r} \right) dr + \left(2u \frac{\partial u}{\partial \theta} - 2v \frac{\partial v}{\partial \theta} \right) d\theta \implies \begin{cases} \frac{\partial y}{\partial r} = 2u \frac{\partial u}{\partial r} - 2v \frac{\partial v}{\partial r} \\ \frac{\partial y}{\partial \theta} = 2u \frac{\partial u}{\partial \theta} - 2v \frac{\partial v}{\partial \theta} \end{cases}$$

$$\bullet \quad dz = \frac{\partial z}{\partial u} du + \frac{\partial z}{\partial v} dv = u dv + v du = u \left(\frac{\partial v}{\partial r} dr + \frac{\partial v}{\partial \theta} d\theta \right) + v \left(\frac{\partial u}{\partial r} dr + \frac{\partial u}{\partial \theta} d\theta \right)$$

$$= \left(u \frac{\partial v}{\partial r} + v \frac{\partial u}{\partial r} \right) dr + \left(u \frac{\partial v}{\partial \theta} + v \frac{\partial u}{\partial \theta} \right) d\theta \implies \begin{cases} \frac{\partial z}{\partial r} = u \frac{\partial v}{\partial r} + v \frac{\partial u}{\partial r} \\ \frac{\partial z}{\partial \theta} = u \frac{\partial v}{\partial \theta} + v \frac{\partial u}{\partial \theta} \end{cases}$$

注记 2.6.3 上例中的 $\mathbf{f}: \mathbb{R}^2 \rightarrow \mathbb{R}^3$ 描绘了三维空间中的一张二维曲面 (因其描述依赖于两个独立的参数 u, v); 而映射 $\mathbf{g}: \mathbb{R}^2 \rightarrow \mathbb{R}^2$ 相当于改变了描述曲面的参数, 即从原参数 (u, v) 变为新参数 (r, θ) . 显然, 由于在参数 (r, θ) 之下, 从曲面参数方程

$$\begin{cases} x = r^2 \\ y = r^2 \cos 2\theta \\ z = \frac{r^2}{2} \sin 2\theta \end{cases} \text{ 中更易消参而得到曲面的在 } x\text{-}y\text{-}z \text{ 坐标下的方程: } y^2 + 4z^2 = x^2.$$

这是一个齐次多项式 $F = -x^2 + y^2 + 4z^2$ 的零点集合, 故其描述出一张以原点为其顶点的锥面. 它的一种形成机制为: 将 $x\text{-}y$ 平面上的直线 $y = x$ 沿着 x -轴旋转一周, 得到旋转面 (锥面): $\pm\sqrt{y^2 + z^2} = x \iff y^2 + z^2 = x^2$, 然后再 z -方向做尺度变换 (*scaling*) $z \rightarrow 2z$, 即得所讨论锥面的方程.

另一方面, 将锥面方程写成: $(2z)(2z) = (x+y)(x-y)$, 由此可见该曲面是直纹面, 它由直线族 $\begin{cases} x+y=2\lambda z \\ \lambda(x-y)=2z \end{cases}$ 生成, 其中 λ 为参数. 显然, 它是过原点的直线族, 且其方向向量为

$$\begin{aligned} l_\lambda &= \begin{vmatrix} \mathbf{i} & \mathbf{j} & \mathbf{k} \\ 1 & 1 & -2\lambda \\ \lambda & -\lambda & -2 \end{vmatrix} = \left(\begin{vmatrix} 1 & -2\lambda \\ -\lambda & -2 \end{vmatrix}, -\begin{vmatrix} 1 & -2\lambda \\ \lambda & -2 \end{vmatrix}, \begin{vmatrix} 1 & 1 \\ \lambda & -\lambda \end{vmatrix} \right) \\ &= (2\lambda^2 - 2, 2 - 2\lambda^2, -2\lambda) \end{aligned}$$

锥面也由直线族 $\begin{cases} \mu(x+y)=2z \\ x-y=2\mu z \end{cases}$ 生成, 其中 μ 为参数. 该族直线的方向向量为

$$\begin{aligned} l_\mu &= \begin{vmatrix} \mathbf{i} & \mathbf{j} & \mathbf{k} \\ 1 & -1 & -2\mu \\ \mu & \mu & -2 \end{vmatrix} = \left(\begin{vmatrix} -1 & -2\mu \\ \mu & -2 \end{vmatrix}, -\begin{vmatrix} 1 & -2\mu \\ \mu & -2 \end{vmatrix}, \begin{vmatrix} 1 & -1 \\ \mu & \mu \end{vmatrix} \right) \\ &= (2\mu^2 + 2, -2\mu^2 + 2, 2\mu) \end{aligned}$$

这两族直线可统一描述为 $\begin{cases} \mu(x+y)=2\lambda z \\ \lambda(x-y)=2\mu z \end{cases}$ 直线族只依赖于比值 $\mu : \lambda$. 在此参数下, 直线族的方向向量为

$$\begin{aligned} l_{\mu,\lambda} &= \begin{vmatrix} \mathbf{i} & \mathbf{j} & \mathbf{k} \\ \lambda & -\lambda & -2\mu \\ \mu & \mu & -2\lambda \end{vmatrix} = \left(\begin{vmatrix} -\lambda & -2\mu \\ \mu & -2\lambda \end{vmatrix}, -\begin{vmatrix} \lambda & -2\mu \\ \mu & -2\lambda \end{vmatrix}, \begin{vmatrix} \lambda & -\lambda \\ \mu & \mu \end{vmatrix} \right) \\ &= (2\lambda^2 + 2\mu^2, 2\lambda^2 - 2\mu^2, 2\lambda\mu) \end{aligned}$$

而对锥面上任一点 (x, y, z) , 其与顶点 (原点) 的连线即为一条母线 (直线族中之

一条), 其方向向量为 (x, y, z) , 对比上面可得该锥面以 (u, v) 为参数的参数方程.

我们知道顶点为原点的锥面由齐次函数的零点来描述. 比如上例中的多项式 $F(x, y, z) = -x^2 + y^2 + 4z^2$ 即是各 (二次) 齐次多项式. 一般地, 我们有

定义 2.6.1 函数 $z = f(x_1, \dots, x_n)$ 称为 k 次齐次函数 (homogeneous function) 如果

$$f(tx_1, \dots, tx_n) = t^k f(x_1, \dots, x_n) \quad \forall t \in \mathbb{R}$$

特别地, $k = 0$ 时的零次齐次函数即在自变量尺度变化 (scaling) 下不变的函数.

注记 2.6.4 如果 $z = f(x_1, \dots, x_n)$ 是一个 k 次齐次函数, 则 $\{(x_1, \dots, x_n) \mid f(x_1, \dots, x_n) = 0\}$ 描绘了 $\mathbb{R}^n$ 中以原点为顶点的一个锥体. 这是因为, 过原点的所有直线都位于其上. 反之, 任何以原点为顶点的锥面的描述方程都是齐次函数.

设 $\{(x_1, \dots, x_n) \in \mathbb{R}^n \mid g(x_1, \dots, x_n) = 0\}$ 是 $\mathbb{R}^n$ 中的一超曲面, 则以它为准, 顶点为原点的锥体方程可按下求解: 如 $(x_1, \dots, x_n)$ 位于该锥体, 则连接该点与原点的直线必与上超曲面相交, 即 $\exists x_1^0, \dots, x_n^0$, 使得

$$\begin{cases} g(x_1^0, \dots, x_n^0) = 0 \\ tx_i = x_i^0 \quad \forall i = 1, \dots, n \end{cases} \implies g(tx_1, \dots, tx_n) = 0$$

如 g 是齐次函数, 则消去参数 t 后得到锥体方程.

我们考察位于超平面 $x_n = x_n^0$ 上的超曲面: $h(x_1, \dots, x_{n-1}) = 0$, 则在 $\mathbb{R}^n$ 中以该超曲面为准, 以原点为顶点的锥体方程的求解如下

$$\begin{cases} h(x_1^0, \dots, x_{n-1}^0) = 0 \\ tx_1 = x_1^0, \dots, tx_{n-1} = x_{n-1}^0; tx_n = x_n^0 \end{cases} \xrightarrow{t = \frac{x_n^0}{x_n}} h\left(\frac{x_n^0 x_1}{x_n}, \dots, \frac{x_n^0 x_{n-1}}{x_n}\right) = 0$$

考虑标度变换: $x_n \rightarrow x_n^0 x_n$, 则锥体方程为 $h\left(\frac{x_1}{x_n}, \dots, \frac{x_{n-1}}{x_n}\right) = 0$. 由此可知 (当

$x_n \neq 0$ 时) 做变量变换 $\begin{cases} x_1 \rightarrow \frac{x_1}{x_n} \\ \dots \\ x_{n-1} \rightarrow \frac{x_{n-1}}{x_n} \\ x_n \rightarrow x_n \end{cases}$ 可将方程齐次化, 从而得到锥体描述, 即获

得了以原点为投射中心, 在超平面 $x_n = 1$ 上投影的视角, 这也是射影几何 (projective) 齐次坐标 $\left[\frac{x_1}{x_n} : \dots : \frac{x_{n-1}}{x_n}\right]$ 和非齐次坐标 $(x_1, \dots, x_n)$ 转换背后的几何图景.

设 $z = f(x_1, \dots, x_n)$ 是 k 次齐次函数, 即 $f(tx_1, \dots, tx_n) = t^k f(x_1, \dots, x_n)$. 也就是说, 函数 f 在任一点 $P(x_1, \dots, x_n)$ 处沿着 $\overrightarrow{OP} = \mathbf{x} = (x_1, \dots, x_n)$ 方向的增量与 $f(P)$ 本身成比例, 则不难推测其变化率也与 $f(P)$ 成比例, 事实上, 我们有

$$\begin{aligned}\nabla f|_P \bullet \mathbf{x} &= \nabla_{\mathbf{x}} f|_P \cdot |\mathbf{x}| = \lim_{t \rightarrow 0} \frac{f(x_1 + tx_1, \dots, x_n + tx_n) - f(x_1, \dots, x_n)}{t} \\&= \lim_{t \rightarrow 0} \frac{f((1+t)x_1, \dots, (1+t)x_n) - f(x_1, \dots, x_n)}{t} = \lim_{t \rightarrow 0} \frac{f(x_1, \dots, x_n)((1+t)^k - 1)}{t} \\&= f(x_1, \dots, x_n) \lim_{t \rightarrow 0} \frac{(1+t)^k - 1}{t} = kf(x_1, \dots, x_n)\end{aligned}$$

即方向导数为 $\nabla_{\mathbf{x}} f|_P = \frac{\partial f}{\partial \mathbf{x}} \Big|_P = \frac{kf}{\sqrt{x_1^2 + \dots + x_n^2}}$. 上面的计算表明, 对 k 次齐次函数 f , 我们得到了如下重要微分关系

$$\boxed{\sum_{i=1}^n x_i \frac{\partial f}{\partial x_i} = kf} \quad (*)$$

当然, 这一关系也可通过对方程 $f(tx_1, \dots, tx_n) = t^k f(x_1, \dots, x_n)$ 对 t 求导得来


$$\frac{\partial f(tx_1, \dots, tx_n)}{\partial(tx_1)} \frac{d(tx_1)}{dt} + \dots + \frac{\partial f(tx_1, \dots, tx_n)}{\partial(tx_n)} \frac{d(tx_n)}{dt} = kt^{k-1} f(x_1, \dots, x_n)$$

令 $t = 1$ 即得公式 (*). 下命题表明: 关系 (*) 是齐次可微函数的刻画性质.

命题 2.6.1 若 $f(x_1, \dots, x_n)$ 满足关系 (*), 且有连续的偏导数, 则它必是 k 次齐次函数.

证明: 欲证关系 (*), 即证函数 $\varphi(t) := \frac{f(tx_1, \dots, tx_n)}{t^k}$ 关于 t 是恒定的, 即证 $\varphi'(t) \equiv 0$.

$$\begin{aligned}\varphi'(t) &= \frac{\frac{df(tx_1, \dots, tx_n)}{dt} t^k - kt^{k-1} f(tx_1, \dots, tx_n)}{t^{2k}} \quad \underline{\underline{\text{链式法则}}} \\&= \frac{t^k \sum_{i=1}^n x_i \frac{\partial f(tx_1, \dots, tx_n)}{\partial(tx_i)} - kt^{k-1} f(tx_1, \dots, tx_n)}{t^{2k}} \\&= \frac{t^{k-1} \sum_{i=1}^n (tx_i) \frac{\partial f(tx_1, \dots, tx_n)}{\partial(tx_i)} - kt^{k-1} f(tx_1, \dots, tx_n)}{t^{2k}} \quad \underline{\underline{\begin{matrix} (*) \\ tx_i \text{ 看成独立变量} \end{matrix}}} \\&= \frac{t^{k-1} kf(tx_1, \dots, tx_n) - kt^{k-1} f(tx_1, \dots, tx_n)}{t^{2k}} \equiv 0 \quad \square\end{aligned}$$



一般的链式法则总结如下:

定理 2.6.1 对映射 (向量值函数) $\mathbf{f}: \mathbb{R}^n \rightarrow \mathbb{R}^m$ $(x_1, \dots, x_n) \mapsto (y_1, \dots, y_m)$, 其中

$$\mathbf{f}: \begin{cases} y_1 = f_1(x_1, \dots, x_n) \\ \vdots \\ y_m = f_m(x_1, \dots, x_n) \end{cases}$$


及映射 $\mathbf{g}: \mathbb{R}^m \rightarrow \mathbb{R}^p$ $(y_1, \dots, y_m) \mapsto (z_1, \dots, z_p)$, 其分量函数为

$$\mathbf{g}: \begin{cases} z_1 = g_1(y_1, \dots, y_m) \\ \vdots \\ z_p = g_p(y_1, \dots, y_m) \end{cases}$$

设 $\mathbf{f}$ 和 $\mathbf{g}$ 可复合, 即 $Ran(\mathbf{f}) \subseteq Dom(\mathbf{g})$, 则其复合映射 $\mathbf{g} \circ \mathbf{f}: \mathbb{R}^n \rightarrow \mathbb{R}^p$ 的分量函数由 $\mathbf{g} \circ \mathbf{f}: \begin{cases} z_1 = g_1(f_1(x_1, \dots, x_n), \dots, f_m(x_1, \dots, x_n)) \\ \vdots \\ z_p = g_p(f_1(x_1, \dots, x_n), \dots, f_m(x_1, \dots, x_n)) \end{cases}$ 给出.

现假设内层函数 $\mathbf{f}$ 在 $(x_1, \dots, x_n)$ 处可导, 外层函数 $\mathbf{g}$ 在对应的点 $(y_1, \dots, y_m)$ 处可微, 则复合映射 $\mathbf{g} \circ \mathbf{f}$ 在 $(x_1, \dots, x_n)$ 处亦可导, 且其导数由下链式法则给出

$$\frac{\partial z_i}{\partial x_j} = \sum_{k=1}^m \frac{\partial z_i}{\partial y_k} \frac{\partial y_k}{\partial x_j} \quad \forall i = 1, \dots, p; \quad \forall j = 1, \dots, n.$$




例 2.6.5 设 $z = \arctan xy$, 且 $y = e^x$, 计算 $\left. \frac{dz}{dx} \right|_{x=0}$

解: 利用一阶微分的形式不变性, 得

$$dz = \frac{d(xy)}{1 + (xy)^2} = \frac{xdy + ydx}{1 + (xy)^2} = \frac{xe^x dx + e^x dx}{1 + (xy)^2} = \frac{e^x(1+x)}{1 + x^2 e^{2x}} dx$$

故 $\left. \frac{dz}{dx} \right|_{x=0} = \left. \frac{e^x(1+x)}{1 + x^2 e^{2x}} \right|_{x=0} = \frac{e^0(1+0)}{1+0} = 1$. 或对如下变量依赖关系运用链式法
则




$$\begin{aligned} \frac{dz}{dx} &\stackrel{u=xy}{=} \frac{\partial z}{\partial u} \frac{\partial u}{\partial x} + \frac{\partial z}{\partial u} \frac{\partial u}{\partial y} \frac{dy}{dx} = \frac{1}{1+u^2} \cdot y + \frac{1}{1+u^2} \cdot xe^x \\ &= \frac{y + xe^x}{1+u^2} = \frac{e^x + xe^x}{1+x^2 e^{2x}} = \frac{e^x(1+x)}{1+x^2 e^{2x}} \end{aligned}$$

链式法则对求高阶偏导时依然成立, 只要一阶偏导可偏导, 可先理清一阶偏导作为函数对变量的依赖关系, 然后用链式法则对之求导即可.

例 2.6.7 设 $z = f(x+y, xy, x^2-y^2)$ 有连续二阶偏导数, 求 $z_x, z_y, z_{xx}, z_{xy}, z_{yy}$.

解: 引入中间变量 $u = x+y, v = xy, w = x^2-y^2$, 则变量依赖关系为



从而

$$\begin{aligned} z_x &= \frac{\partial z}{\partial x} = \frac{\partial z}{\partial u} \frac{\partial u}{\partial x} + \frac{\partial z}{\partial v} \frac{\partial v}{\partial x} + \frac{\partial z}{\partial w} \frac{\partial w}{\partial x} = f_u + yf_v + 2xf_w \\ z_y &= \frac{\partial z}{\partial y} = \frac{\partial z}{\partial u} \frac{\partial u}{\partial y} + \frac{\partial z}{\partial v} \frac{\partial v}{\partial y} + \frac{\partial z}{\partial w} \frac{\partial w}{\partial y} = f_u + xf_v - 2yf_w \\ z_{xx} &= \frac{\partial}{\partial x} (f_u + yf_v + 2xf_w) = \frac{\partial f_u}{\partial x} + \frac{\partial(yf_v)}{\partial x} + \frac{\partial(2xf_w)}{\partial x} \end{aligned}$$

$$\begin{aligned}
&= f_{uu} \frac{\partial u}{\partial x} + f_{uv} \frac{\partial v}{\partial x} + f_{uw} \frac{\partial w}{\partial x} + y \left(f_{vu} \frac{\partial u}{\partial x} + f_{vv} \frac{\partial v}{\partial x} + f_{vw} \frac{\partial w}{\partial x} \right) + \underbrace{\frac{dy}{dx}}_{=0: x, y \text{ 相互独立}} f_v \\
&\quad + 2f_w + 2x \left(f_{wu} \frac{\partial u}{\partial x} + f_{wv} \frac{\partial v}{\partial x} + f_{ww} \frac{\partial w}{\partial x} \right) \\
&= f_{uu} + yf_{uv} + 2xf_{uw} + y(f_{vu} + yf_{uv} + 2xf_{vw}) + 2f_w + 2x(f_{wu} + yf_{wv} + wf_{ww})
\end{aligned}$$


为减轻符号书写的负担, 并减少笔误, 可将函数 f 对第 i 个分量的偏导数用 f_i 表示, 而将函数 f 先对第 i 个分量, 再对第 j 个分量的二阶偏导数用 f_{ij} 表示, 如此类推. 下面我们用这种符号表示来计算 z_{xy} .

$$\begin{aligned}
z_{xy} &= \frac{\partial(f_1 + yf_2 + 2xf_3)}{\partial y} = f_{11} \cdot (x+y)'_y + f_{12} \cdot (xy)'_y + f_{13} \cdot (x^2 - y^2)'_y \\
&\quad + f_2 + y(f_{21} \cdot (x+y)'_y + f_{22} \cdot (xy)'_y + f_{23} \cdot (x^2 - y^2)'_y) + \\
&\quad + 2x(f_{31} \cdot (x+y)'_y + f_{32} \cdot (xy)'_y + f_{33} \cdot (x^2 - y^2)'_y) \\
&= f_{11} + xf_{12} = 2yf_{13} + f_2 + y(f_{21} + xf_{22} - 2yf_{23}) + 2x(f_{31} + xf_{32} - 2yf_{33})
\end{aligned}$$

同理可计算 z_{yy} , 此处省去, 请读者自行完成.

最后举一例说明在求复合函数的偏导时一定要厘清变量依赖关系的相对层次, 否则可能导致错误.

例 2.6.8 若 $z = f(x, y, t)$, 而 $x = u(s, t)$, $y = v(s, t)$, 其变量依赖关系图如下



$$\frac{\partial z}{\partial s} = \frac{\partial f}{\partial x} \frac{\partial u}{\partial s} + \frac{\partial f}{\partial y} \frac{\partial v}{\partial s}; \quad \frac{\partial z}{\partial t} = \frac{\partial f}{\partial x} \frac{\partial u}{\partial t} + \frac{\partial f}{\partial y} \frac{\partial v}{\partial t} + \frac{\partial f}{\partial t}$$

需强调的时, 上式坐标的 $\frac{\partial z}{\partial t}$ 和右边的 $\frac{\partial f}{\partial t}$ 含义是不同的. 左边 $\frac{\partial z}{\partial t}$ 表示函数 $z = f(u(s, t), v(s, t), t)$ 对 t 的变化率 (将 s 看成常数, 从而将 z 只看成 t 的函数时的导数); 而右边的 $\frac{\partial f}{\partial t}$ 表示 z 在关系 $z = f(x, y, t)$ 中直接依赖 t 时的变化率. 为避免符号歧义, 按上面的记号, 则可写为

$$\frac{\partial z}{\partial t} = f_1 \frac{\partial u}{\partial t} + f_2 \frac{\partial v}{\partial t} + f_3 \frac{\partial t}{\partial t} = f_1 \frac{\partial u}{\partial t} + f_2 \frac{\partial v}{\partial t} + f_3$$

2.7 隐函数求导, 隐函数存在定理

我们知道一元函数 $y = f(x)$ 有时是通过函数关系 $F(x, y) = 0$ 隐性地确定的. 更准确地, 我们说 $F(x, y) = 0$ 在 $P_0(x_0, y_0)$ ($F(x_0, y_0) = 0$) 附近确定一个函数关系 $y = f(x)$, 如果: $\forall x \in U(x_0, \delta), \exists! y \in U(y_0, \delta')$ 使得 $F(x, y) = 0$, 此时定义函数关系 $U(x_0, \delta) \ni x \mapsto f(x) := y$, 即关系 $F(x, y)$ 在 (x_0, y_0) 附近能确定一个局部存在的函数关系 $y = f(x)$, 这个关系有时可以延拓到整体确定的关系, 但经常只能局部存在, 不能整体延拓.

比如方程 $x^2 + y^2 = 1$, 考虑它位于上半平面 $\{(x, y) \in \mathbb{R}^2 \mid -1 < x < 1, y > 0\}$ 内的任意点 (x_0, y_0) , 显然, 由于 $y_0 > 0$, 故必存在 δ , 使得 $\forall x \in U(x_0, \delta)$, 总有唯一的正的 $y = \sqrt{1 - x^2}$, 从而函数关系在 $P_0(x_0, y_0)$ 附近决定了唯一的一个函数关系, 且该关系可以延拓到对任意上半平面圆上的点, 故得到了一个具有显式表达的如下函数

$$y = \sqrt{1 - x^2} \quad -1 < x < 1$$

同理, 下半平面内半圆上的确定了函数的另一支 $y = -\sqrt{1 - x^2}$, $-1 < x < 1$.

但在圆周上的点 $(\pm 1, 0)$ 处附近, 关系 $x^2 + y^2 = 1$ 是不能确定 y 关于 x 的函数关系的. 这是因为 $\forall \delta > 0$, 及 $\forall x \in U(1, \delta)$, 由于 $y_0 = 0$, 故必有两个 y 值与 x 相对于, 即无法确定出 y 对于 x 的一个函数关系 (问: 那么 x 是否可为 y 的函数呢?).

对 $y = \sqrt{1 - x^2}$, 其导数为 $y' = \frac{-x}{\sqrt{1 - x^2}}$; 对 $y = -\sqrt{1 - x^2}$, 其导数为 $y' = \frac{x}{\sqrt{1 - x^2}}$. 当然, 它们是可以不同过显示表达而直接得到的. 方法是对关系 $x^2 + y^2 = 1$ 两边同时对 x 求导, 并将 y 看成 x 的函数, 则有

$$2x + 2y \frac{dy}{dx} = 0 \implies \frac{dy}{dx} = -\frac{x}{y}$$

导数表达式对 $y \neq 0$ 的点都成立, 反映出在这些点附近, 由关系 $x^2 + y^2 = 1$ 确定的点, 当 y 的变化相对于 x 的改变是单调的, 即对给点的 x , 能选取一 y 值与之对应, 从而得到一个函数关系 $y = f(x)$; 而在 $(\pm 1, 0)$ 处, 由于导数不存在 (或为 ∞), 即曲线在该点具有铅直切线, 这说明在该点附近的无穷小领域内, 曲线不能是一个函数关系的局部图像.

我们也可以用更具启发性的视角重新审视这个问题: 对关系 $x^2 + y^2 = 1$ 两边微分, 得到曲线在每点附近的线性近似图景: $x dx + y dy = 0$. 如果我们能从中解出 dy 关于 dx 的微商, 即导数 $\frac{dy}{dx} = -\frac{x}{y}$, 则说明在这些点附近曲线的切线表示了一线性函数, 即 $Y = y + \frac{dy}{dx}(X - x)$, 也就是说在线性化的层面, 这点附近是的切线是某线性函数的图

像. 那么, 我们自然要问: 该线性化图景中能确立的线性函数关系是否也忠实地反映出了原曲线上的点 (x, y) 的坐标分量之间具有的某种函数关系, 使得该函数关系在这点附近的图形的切线是由这些线性函数所描绘的?

在上面例子中, 对该问题显然有肯定的回答, 即线性化后的切线代表的函数关系忠实地反映了切点附近由曲线方程决定的函数关系. 那么我们要问, 一般地, 这种以线性的关系 (只需微分) 是否为函数关系来探测曲线本身是否能够确定函数关系的关联机制是否具有普遍性呢? 下面我们将表明, 对这个问题我们也有肯定的回答! 这也是“线性化”的微分手段的强大威力的再次显现.

假设关系 $F(x, y) = 0$ 确定了某点 (x, y) 附近的 y 关于 x 的一个函数关系 $y = f(x)$, 即在这点附近 $F(x, f(x)) = 0$, 则可用复合函数求导的链式法则计算出导数 $\frac{dy}{dx}$ (假设 F 可偏导, 且偏导连续), 则在上方程两边同时对 x 求导, 得


$$F_x + F_y \frac{dy}{dx} = 0 \implies \frac{dy}{dx} = -\frac{F_x}{F_y}$$

即知函数关系存在的必要条件是 $F_y \neq 0$, 且 $F_y \neq 0$ 局部保号 (偏导连续性条件即可保证); 或可对关系 $F(x, y) = 0$ 直接微分 (线性化), 得到线性化图景如下:

$$F_x dx + F_y dy = 0 \xrightarrow{\text{当 } F_y \neq 0 \text{ 时}} dy = -\frac{F_x}{F_y} dx \implies y' = -\frac{F_x}{F_y}$$

即该点附近的线性化确定了线性函数关系 $Y - y = -\frac{F_x}{F_y}(X - x)$, 自然的预期是: 它其实就是曲线在该点附近所确定的 (隐) 函数的图像的切线方程.

当然, 上例中的隐函数关系是可以显式求解的, 但很多时候隐函数是无法显式求解的. 比如行星运动的开普勒 (Kepler) 方程 $F(x, y) = y - x - \epsilon \sin y = 0$, $0 < \epsilon < 1$. 其中 x 是时间, y 是行星与太阳的连线扫过的扇形的弧度, ϵ 是行星运行椭圆轨迹的离心率. 显然, y 必是 x 的函数, 但却无法显式求解出来.



由于 $F_y = 1 - \epsilon \cos y \neq 0$ 且连续, 故在曲线上任意点附近, dy/dx 存在且局部保号, 即有局部的 y 和 x 之间的函数关系, 它们可“黏”为整体隐函数关系.

定理 2.7.1 (一元隐函数存在定理) 若二元函数 $F(x, y)$ 满足条件:

1. $F(x_0, y_0) = 0$;
2. 在 $P_0(x_0, y_0)$ 的某个 (二维) 领域 $U(P_0, \delta)$ 内 $F(x, y)$ 连续, 且具有连续偏导数;
3. $F_y(x_0, y_0) \neq 0$.

则在 P_0 点附近可从函数关系 $F(x, y) = 0$ 惟一确定一隐函数 $y = f(x)$, $x \in U(x_0, \rho)$, 它满足 $F(x, f(x)) = 0$, 以及 $f(x_0) = y_0$, 且具如下性质:

a) 隐函数 $y = f(x)$ 在 $x \in O(x_0, \rho)$ 上连续;

b) 隐函数 $y = f(x)$ 在 $x \in O(x_0, \rho)$ 上具有连续导数, 且 $\frac{dy}{dx} = -\frac{F_x(x, y)}{F_y(x, y)}$.


证明: 隐函数的存在性不妨设 $F_y(x_0, y_0) > 0$, 由 F_y 的连续性, 知在 $P_0(x_0, y_0)$ 的某个 δ 领域内, $F_y > 0$. 于是, 对 $\forall x \in (x_0 - \delta, x_0 + \delta)$ 固定, $F(x, y)$ 在该领域内关于 y 是严格单调增加的, 从而

$$F(x, y_0 - \delta) < F(x, y_0) < F(x, y_0 + \delta)$$

特别地 $F(x_0, y_0 - \delta) < F(x_0, y_0) = 0$, $F(x_0, y_0 + \delta) > F(x_0, y_0) = 0$.

由 $F(x, y)$ 本身的连续性, 及连续函数的局部保号性质, 知 $\exists \rho > 0$, 使得当 $x \in (x_0 - \rho, x_0 + \rho)$ 时, 有 $F(x, y_0 + \delta) > 0$, 且 $F(x, y_0 - \delta) < 0$.

换言之, 对 $(x_0 - \rho, x_0 + \rho)$ 内的任意点 x , 关于 y 的函数 $\varphi_x(y) := F(x, y)$ 在 $[y_0 - \delta, y_0 + \delta]$ 内连续, 且 $\varphi_x(y_0 - \delta) < 0$, $\varphi_x(y_0 + \delta) > 0$, 则根据闭区间上连续函数的介质 (或零点) 定理, 并结合 $\varphi_x(y)$ 的单调性, 知存在唯一的 $y \in (y_0 - \delta, y_0 + \delta)$, 使得 $\varphi_x(y) = F(x, y) = 0$. 由此便确定了函数关系 $y = f(x)$, $\forall x \in (x_0 - \rho, x_0 + \rho)$. 它显然满足 $F(x, f(x)) = 0$, 且 $y_0 = f(x_0)$.



隐函数的连续性 即需证 $\forall \epsilon > 0, \exists \delta' > 0, \forall x_1, x_2 \in (x_0 - \rho, x_0 + \rho)$, 只要 $|x_1 - x_2| < \delta'$, 就有 $|y_1 - y_2| = |f(x_1) - f(x_2)| < \epsilon$. 而这可以转为 $F(x, y)$ 的连续性而加以证明.

将 $\epsilon > 0$ 选得小于 δ , 则由 $F(x, y)$ 的连续性及上面的讨论, 知 $\exists \delta' > 0$, 使得当 $|x_1 - x_2| < \delta'$ 时, 成立 $F(x_i, y_i - \epsilon) < 0, F(x_i, y_i + \epsilon) > 0$, 而 $F(x_i, y_i) = 0$. 由此可见 $|y_1 - y_2| < \epsilon$.

隐函数的可导性 $\forall x \in (x_0 - \rho, x_0 + \rho)$, 取 Δx 足够小, 以使 $x + \Delta x \in (x_0 - \rho, x_0 + \rho)$, 记 $y = f(x), y + \Delta y = f(x + \Delta x)$, 则有 $0 = F(x + \Delta x, y + \Delta y) - F(x, y) =$

$$= F(x + \Delta x, y + \Delta y) - F(x, y + \Delta y) + F(x, y + \Delta y) - F(x, y)$$

$$\xrightarrow[\exists \theta_i \in (0,1)]{\text{拉格朗日中值定理}} F_x(x + \theta_1 \Delta x, y + \Delta y) \Delta x + F_y(x, y + \theta_2 \Delta y) \Delta y$$

$$\xrightarrow{F_y(x,y) \neq 0, \text{且局部保号}} \frac{\Delta y}{\Delta x} = - \frac{F_x(x + \theta_1 \Delta x, y + \Delta y)}{F_y(x, y + \theta_2 \Delta y)} \implies$$

$$\frac{dy}{dx} = - \lim_{\Delta x \rightarrow 0} \frac{F_x(x + \theta_1 \Delta x, y + \Delta y)}{F_y(x, y + \theta_2 \Delta y)} \xrightarrow{\lim_{\Delta x \rightarrow 0} \Delta y = 0} - \frac{F_x(x, y)}{F_y(x, y)} \quad \square$$

显然, 一元函数的隐函数存在定理可直接推广为下面的二元函数的隐函数存在定理.

定理 2.7.1 (二元隐函数存在定理) 若三元函数 $F(x, y, z)$ 在点 $P_0(x_0, y_0, z_0)$ 的领域内具有连续的偏导数, 且 $F(x_0, y_0, z_0) = 0, F_z(x_0, y_0, z_0) \neq 0$, 则函数关系 $F(x, y, z) = 0$ 在 P_0 附近可确定唯一的函数 $z = f(x, y)$, 满足 $F(x, y, z(x, y)) = 0, z_0 = f(x_0, y_0)$. 函数 $z = f(x, y)$ 具有连续偏导数

$$\frac{\partial z}{\partial x} = - \frac{F_x(x, y, z)}{F_z(x, y, z)}; \quad \frac{\partial z}{\partial y} = - \frac{F_y(x, y, z)}{F_z(x, y, z)}$$

注记 2.7.1 如果其它条件相同, 但 $F_x(x_0, y_0, z_0) \neq 0$, 则在 P_0 附近将确定唯一的隐函数关系 $x = g(y, z)$, 且 $\frac{\partial x}{\partial y} = - \frac{F_y}{F_x}; \frac{\partial x}{\partial z} = - \frac{F_z}{F_x}$. 当然这些偏导数公式无需强记, 只需将关系 $F(x, y, z) = 0$ 微分 (线性化) $F_x dx + F_y dy + F_z dz = 0$, 然后将其看成关于 dx, dy, dz 的线性方程, 从中求解 (如 $F_z \neq 0$) 出 dz 关于 dx, dy 的表达. 由一阶微分的形式不变性, 即知 dx, dy 前的系数便是 z_x 和 z_y .

例 2.7.1 设 $z = f(x, y)$ 由关系 $e^x - xyz = 0$ 确定, 计算 $\frac{\partial z}{\partial x}, \frac{\partial z}{\partial y}, \frac{\partial^2 z}{\partial x^2}, \frac{\partial^2 z}{\partial x \partial y}$.

解：将 $e^x - xyz = 0$ 两边微分，得

$$e^x dx - yz dx - xz dy - xy dz = 0 \quad \Leftrightarrow \quad (e^x - yz) dx - xz dy - xy dz = 0$$

在 $xy \neq 0$ 的点处， $dz = \frac{e^x - yz}{xy} dx - \frac{z}{y} dy = 0$ ，从而在这些点的附近，方程确定了唯一的隐函数关系 $z = z(x, y)$ ，且其微分由上公式给出，由此直接看出

$$\frac{\partial z}{\partial x} = \frac{e^x - yz}{xy}; \quad \frac{\partial z}{\partial y} = -\frac{z}{y}$$

$$\begin{aligned} \frac{\partial^2 z}{\partial x^2} &= \frac{\partial}{\partial x} \left(\frac{e^x}{xy} - \frac{z}{x} \right) = \frac{xye^x - ye^x}{(xy)^2} - \frac{x \frac{\partial z}{\partial x} - z}{x^2} = \frac{e^x(x-1)}{x^2y} - \frac{\frac{e^x - yz}{y} - z}{x^2} \\ &= \frac{e^x(x-1) - e^x + 2yz}{x^2y} = \frac{e^x(x-2) + 2yz}{x^2y} \end{aligned}$$

$$\frac{\partial^2 z}{\partial x \partial y} = \frac{\partial^2 z}{\partial y \partial x} = \frac{\partial}{\partial x} \left(\frac{\partial z}{\partial y} \right) = \frac{\partial}{\partial x} \left(-\frac{z}{y} \right) = -\frac{1}{y} \frac{\partial z}{\partial x} = \frac{yz - e^x}{xy^2}$$

例 2.7.2 设函数 $z = z(x, y)$ 由方程 $\varphi(cx - az, cy - bz) = 0$ 所确定，其中 φ 具有连续偏导数，且 $a\varphi_1 + b\varphi_2 \neq 0$ ，证明： $a \frac{\partial z}{\partial x} + b \frac{\partial z}{\partial y} = c$ 。

证明：将关系 $\varphi(cx - az, cy - bz) = 0$ 微分，得 $\varphi_1 \cdot (cdx - adz) + \varphi_2 \cdot (cdy - b dz) = 0$

$$c\varphi_1 dx + c\varphi_2 dy - (a\varphi_1 + b\varphi_2) dz = 0 \quad \xrightarrow{a\varphi_1 + b\varphi_2 \neq 0} \quad dz = \frac{c\varphi_1}{a\varphi_1 + b\varphi_2} dx + \frac{c\varphi_2}{a\varphi_1 + b\varphi_2} dy$$

$$\Rightarrow \quad a \frac{\partial z}{\partial x} + b \frac{\partial z}{\partial y} = \frac{ac\varphi_1 + bc\varphi_2}{a\varphi_1 + b\varphi_2} = c. \quad \square$$

例 2.7.3 设函数 $u = u(x, y, z)$ 由方程 $\frac{x^2}{a^2 + u} + \frac{y^2}{b^2 + u} + \frac{z^2}{c^2 + u} = 1$ 所确定，证明

$$\left(\frac{\partial u}{\partial x} \right)^2 + \left(\frac{\partial u}{\partial y} \right)^2 + \left(\frac{\partial u}{\partial z} \right)^2 = 2 \left(x \frac{\partial u}{\partial x} + y \frac{\partial u}{\partial y} + z \frac{\partial u}{\partial z} \right)$$

证明：将方程微分，得

$$\frac{2x(a^2 + u)dx - x^2 du}{(a^2 + u)^2} + \frac{2y(b^2 + u)dy - y^2 du}{(b^2 + u)^2} + \frac{2z(c^2 + u)dz - z^2 du}{(c^2 + u)^2} = 0$$

$$\Rightarrow \underbrace{\left(\frac{x^2}{(a^2+u)^2} + \frac{y^2}{(b^2+u)^2} + \frac{z^2}{(c^2+u)^2} \right)}_{\kappa} du = \frac{2x}{a^2+u} dx + \frac{2y}{b^2+u} dy + \frac{2z}{c^2+u} dz$$

$$\text{即 } du = \frac{2x}{\kappa(a^2+u)} dx + \frac{2y}{\kappa(b^2+u)} dy + \frac{2z}{\kappa(c^2+u)} dz \Rightarrow \begin{cases} \frac{\partial u}{\partial x} = \frac{2x}{\kappa(a^2+u)} \\ \frac{\partial u}{\partial y} = \frac{2y}{\kappa(b^2+u)} \\ \frac{\partial u}{\partial z} = \frac{2z}{\kappa(c^2+u)} \end{cases}$$

$$\text{从而 } \left(\frac{\partial u}{\partial x} \right)^2 + \left(\frac{\partial u}{\partial y} \right)^2 + \left(\frac{\partial u}{\partial z} \right)^2 = \frac{4}{\kappa^2} \left(\frac{x^2}{(a^2+u)^2} + \frac{y^2}{(b^2+u)^2} + \frac{z^2}{(c^2+u)^2} \right)$$

$$\text{另一方面 } 2 \left(x \frac{\partial u}{\partial x} + y \frac{\partial u}{\partial y} + z \frac{\partial u}{\partial z} \right) = \frac{4}{\kappa} \left(\frac{x^2}{a^2+u} + \frac{y^2}{b^2+u} + \frac{z^2}{c^2+u} \right) = \frac{4}{\kappa}$$

由此可见, 所证等式由 κ 的定义给出. $\square$

函数关系组所确定的向量值函数的存在性及其微分法则:

$F(x, y) = 0$ 相当于给两个自由变量 x, y 一个 (函数) 约束关系, 而隐函数 $y = f(x)$ 的存在表明这个约束是“有效”的, 即 x, y 只有 x 是自由的, 而 y 是由 x 表出的. 同理 $F(x, y, z)$ 是三个变量 x, y, z 间的一个约束条件, 它的“有效性”表明这三个变量只有两个是自由的, 而另一个需通过两个自由变量来表达, 由此确定一个二元函数关系.

自然地, 尚需考虑多个变量间的多个约束方程, 并会确定其中有效约束的个数, 以及如何消去无效约束 (冗余约束) 从而确定变量间的函数关系? 当然, 还得确定由此决定的隐函数关系的微分法则. 它将是之前讨论的一个约束情形的一般推广. 虽然形式上会更复杂些, 但其本质是统一的.

注记 2.7.2 在正式讨论之前, 我们先介绍这个问题的最基本情形, 即如何约化变量间的线性关系, 而这就是线性代数中一般线性方程组的理论. 考虑 n 个自由变量 $x_1, \dots, x_n$ 间的 m 个线性约束:

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \dots + a_{1n}x_n = 0 \\ a_{21}x_1 + a_{22}x_2 + \dots + a_{2n}x_n = 0 \\ \dots \\ a_{m1}x_1 + a_{m2}x_2 + \dots + a_{mn}x_n = 0 \end{cases}$$

令 $A = [a_{ij}]_{1 \leq i, j \leq n}$, $\mathbf{x} = [x_1 \ \dots \ x_n]^T$, 则上述线性约束用矩阵来表示就是 $A\mathbf{x} = \mathbf{0}$.

由线性方程组的一般理论知,有效约束的个数取决于系数矩阵 A 的秩 (*rank*) $r(A)$. 当 $r(k) = r \leq n$ 时, m 个约束中本质上只有 r 个是有效的, 故有 $n-r$ 个自由变量, 不妨记为 $x_1, \dots, x_{n-r}$, 则剩余的 r 个变量 $x_{n-r+1}, \dots, x_n$ 便可用这 $n-r$ 个自由变量线性表达, 即存在数 b_{ij} , 使得

$$\begin{cases} x_{n-r+1} = b_{n-r+1,1}x_1 + \dots + b_{n-r+1,n-r}x_{n-r} \\ \dots \\ x_n = b_{n,1}x_1 + \dots + b_{n,n-r}x_{n-r} \end{cases}$$

即将 $x_{n-r+1}, \dots, x_n$ 写成了 $x_1, \dots, x_{n-r}$ 的线性函数的形式. 由此便确定了一个向量值函数 $L_A: \mathbb{R}^{n-r} \rightarrow \mathbb{R}^r$, 它由矩阵 $B = [b_{ji}]$ 表示. 这里的 B 是对系数矩阵 A 做初等行变换而得到的阶梯型矩阵中非零行部分 (即将代表冗余约束的零行省去后的 $r \times n$ 阶矩阵) 的有 “主元 (*pivotal variable*)” 的列构成的 $r \times (n-r)$ 阶矩阵.

变量间的函数约束关系微分后得到的是诸变量微分间的齐次线性关系, 在局部将完全雷同于上线性方程组的情形, 便可利用线性代数工具来判断变量微分间的依赖关系, 即确定处微分间的线性函数关系. 一般的隐函数存在定理将表明: **微分间的线性函数关系反映的是变量间的局部函数关系——局部函数关系的微分给出微分间的线性函数关系.**

对约束 $F(x, y) = 0$, 其微分 $F_x dx + F_y dy = 0$ 在点 $P_0(x_0, y_0)$ 处给出变量微分 dx, dy 之间的一个线性约束, 其对应矩阵为函数 F 的 *Jacobi* 矩阵 $\mathbf{J}_F = \begin{bmatrix} F_x & F_y \end{bmatrix}$ 在 P_0 处的值, 它的秩只能是 0 或 1.

1. 当秩 $r(\mathbf{J}_F) = 0$ 时, 即 $F_x(x_0, y_0) = F_y(x_0, y_0) = 0$, 此时 $\mathbf{J}_F$ 对 dx, dy 不是有效约束, 即在 P_0 点附近, dx, dy 是独立的, 从而 $F(x, y) = 0$ 不能确定变量 x, y 在 P_0 间的函数关系.
2. 当秩 $r(\mathbf{J}_F) = 1$ 时, $F_x(x_0, y_0), F_y(x_0, y_0)$ 中至少有一个非零, 不妨设 $F_y(x_0, y_0) \neq 0$, 则能解出 dx, dy 之间的线性函数关系 $dy = -\frac{F_x}{F_y} \Big|_{(x_0, y_0)} dx$, 而一元函数隐函数存在定理说明该微分关系是 x, y 之间在 P_0 附近的唯一隐函数关系 $y = f(x)$ 在 P_0 处的线性近似!

比如对 $F(x, y) = x^2 + y^2 - 1$, 其 *Jacobi* 矩阵为 $\mathbf{J}_F = \begin{bmatrix} 2x & 2y \end{bmatrix}$. 则当单位圆上任意点, $\mathbf{J}_F$ 是满秩的, 即 $r(\mathbf{J}_F) \equiv 1$. 若 F_x, F_y 同时不为零, 则 dx 和 dy 互为线性函数关系, 从而在这些点附近, y 可为 x 的函数, x 亦可为 y 的函数; 若 $F_x = 0, F_y \neq 0$, 则 dy 是 dx 的线性函数, 故由隐函数存在定理知 y 在局部是 x 的函数; 若 $F_y = 0, F_x \neq 0$, 则 dx 是 dy 的线性函数, 故由隐函数存在定理知 x 在局部是 y 的函数.

同理, 对约束 $F(x, y, z) = 0$, 其微分 $F_x dx + F_y dy + F_z dz = 0$ 在点 $P_0(x_0, y_0, z_0)$ 处给出变量微分 dx, dy, dz 之间的一个线性约束, 其对应矩阵为函数 F 的 *Jacobi* 矩阵 $\mathbf{J}_F = \begin{bmatrix} F_x & F_y & F_z \end{bmatrix}$ 在 P_0 处的值, 它的秩只能是 0 或 1.

1. 当秩 $r(\mathbf{J}_F) = 0$ 时, 即 $F_x(x_0, y_0) = F_y(x_0, y_0) = F_z(x_0, y_0) = 0$, 此时 $\mathbf{J}_F$ 对 dx, dy, dz 不是有效约束, 即在 P_0 点附近, dx, dy, dz 是独立的, 从而 $F(x, y, z) = 0$ 不能确定变量 x, y, z 在 P_0 间的函数关系.
2. 当秩 $r(\mathbf{J}_F) = 1$ 时, $F_x(x_0, y_0, z_0), F_y(x_0, y_0, z_0), F_z(x_0, y_0, z_0)$ 中至少有一个非零, 不妨设 $F_z(x_0, y_0, z_0) \neq 0$, 则能解出 dx, dy, dz 之间的线性函数关系

$$dz = -\frac{F_x}{F_z} \Big|_{(x_0, y_0, z_0)} dx - \frac{F_y}{F_z} \Big|_{(x_0, y_0, z_0)} dy$$

而二元函数隐函数存在定理说明该微分关系是 x, y, z 之间在 P_0 附近的唯一隐函数关系 $z = f(x, y)$ 在 P_0 处的线性近似!

有了上面的启发性说明及对一元和二元情形的再诠释 (“新瓶装旧酒”), 一般的模式可以呼之欲出了. 但还是先解析一个例子, 便于熟悉其形式结构及背后的简易思路.

例 2.7.4 考虑四个变量之间的两个函数约束 $\begin{cases} F(x, y, u, v) = x^2 + y^2 - uv = 0 \\ G(x, y, u, v) = xy - u^2 + v^2 = 0 \end{cases}$ 先将变量间的约束关系线性化, 及将两方程微分, 得

$$\begin{cases} 2xdx + 2ydy - vdu - u dv = 0 \\ ydx + xdy - 2udu + 2v dv = 0 \end{cases} \iff \underbrace{\begin{bmatrix} 2x & 2y & -v & -u \\ y & x & -2u & 2v \end{bmatrix}}_{\mathbf{J}_{F,G}} \begin{bmatrix} dx \\ dy \\ du \\ dv \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

即在每一点附近, 得到了四个微分 dx, dy, du, dv 之间的两个线性约束. 其 *Jacobi* 矩阵 $\mathbf{J}_{F,G}$ 的秩只能是 0, 1, 2. 当 $x = y = u = v = 0$ 时秩为零, 此时无有效线性约束, 进而也无函数关系可确立; 若秩为 1, 则两方程的系数成比例 (即本质上两个约束是相同的), 但这是不可能的, 故 $r(\mathbf{J}_{F,G}) \neq 1$; 若 $\mathbf{J}_{F,G}$ 满秩, 即秩为 2, 则存在二阶子矩阵的行列式不为零, 即有如下六种可能:

1. $\frac{\partial(F, G)}{\partial(x, y)} = \begin{vmatrix} F_x & F_y \\ G_x & G_y \end{vmatrix} = \begin{vmatrix} 2x & 2y \\ y & x \end{vmatrix} = 2(x^2 - y^2) \neq 0$. 即当 $x \neq \pm y$ 时, 此时可将微分满足的线性方程组写成

$$\begin{cases} 2xdx + 2ydy = vdu + u dv \\ ydx + xdy = 2udu + 2v dv \end{cases}$$

从中可将 dx, dy 解出, 即将 dx, dy 表示为 du, dv 的线性函数. 利用求解线性方程组的克拉默法则 (Cramer's rule), 得

$$dx = \frac{\begin{vmatrix} vdu + udv & 2y \\ 2udu + 2vdv & x \end{vmatrix}}{\begin{vmatrix} 2x & 2y \\ y & x \end{vmatrix}} = \frac{(xv - 4yu)du + (xu - 4yv)dv}{2(x^2 - y^2)}$$

$$dy = \frac{\begin{vmatrix} 2x & vdu + udv \\ y & 2udu + 2vdv \end{vmatrix}}{\begin{vmatrix} 2x & 2y \\ y & x \end{vmatrix}} = \frac{(4xu - yv)du + (4xv - yu)dv}{2(x^2 - y^2)}$$

推广形式的隐函数存在定理保证了在 $x^2 \neq y^2$ 的点附近, x, y 分别可写成 u, v 的函数 $\begin{cases} x = x(u, v) \\ y = y(u, v) \end{cases}$ (即得到一个映射 $\mathbb{R}^2 \rightarrow \mathbb{R}^2$) 且其微分由上给出, 由此可写出诸偏导数——微分关系中 du, dv 的系数也.

2. $\frac{\partial(F, G)}{\partial(x, u)} = \begin{vmatrix} F_x & F_u \\ G_x & G_u \end{vmatrix} = \begin{vmatrix} 2x & -v \\ y & -2u \end{vmatrix} = -4xu + yv \neq 0$. 即当 $yv \neq 4xu$ 时, 此时可将微分满足的线性方程组写成

$$\begin{cases} 2xdx - vdu = udv - 2ydy \\ ydx - 2udu = -2vdv - xdy \end{cases}$$

从中可将 dx, du 解出, 即将 dx, du 表示为 dy, dv 的线性函数. 利用求解线性方程组的克拉默法则 (Cramer's rule), 得

$$dx = \frac{\begin{vmatrix} udv - 2ydy & -v \\ -2vdv - xdy & -2u \end{vmatrix}}{\begin{vmatrix} 2x & -v \\ y & -2u \end{vmatrix}} = \frac{(4yu - xv)dy - 2(u^2 + v^2)dv}{yv - 4xu}$$

$$du = \frac{\begin{vmatrix} 2x & udv - 2ydy \\ y & -2vdv - xdy \end{vmatrix}}{\begin{vmatrix} 2x & -v \\ y & -2u \end{vmatrix}} = \frac{2(y^2 - x^2)dy - (yu + 4xv)dv}{yv - 4xu}$$

推广形式的隐函数存在定理保证了在 $yv \neq 4xu$ 的点附近, x, u 分别可写成 y, v 的函数 $\begin{cases} x = x(y, v) \\ u = u(y, v) \end{cases}$ (即得到一个映射 $\mathbb{R}^2 \rightarrow \mathbb{R}^2$) 且其微分由上给出, 由此可写出诸偏导数——微分关系中 dy, dv 的系数也.

$$3. \frac{\partial(F, G)}{\partial(x, v)} = \begin{vmatrix} F_x & F_v \\ G_x & G_v \end{vmatrix} = \begin{vmatrix} 2x & -u \\ y & 2v \end{vmatrix} = 4xv + yu \neq 0. \text{ 即当 } yu \neq -4xv \text{ 时, 此时}$$

可将微分满足的线性方程组写成

$$\begin{cases} 2xdx - udu = vdu - 2ydy \\ ydx + 2vdu = 2udu - xdy \end{cases}$$

从中可将 dx, dv 解出, 即将 dx, dv 表示为 dy, du 的线性函数. 利用求解线性方程组的克拉默法则 (Cramer's rule), 得

$$dx = \frac{\begin{vmatrix} vdu - 2ydy & -u \\ 2udu - xdy & 2v \end{vmatrix}}{\begin{vmatrix} 2x & -u \\ y & 2v \end{vmatrix}} = \frac{-(xu + 2yv)dy + 2(u^2 + v^2)du}{yv + 4xv}$$

$$dv = \frac{\begin{vmatrix} 2x & vdu - 2ydy \\ y & 2udu - xdy \end{vmatrix}}{\begin{vmatrix} 2x & -u \\ y & 2v \end{vmatrix}} = \frac{2(y^2 - x^2)dy + (4xu - yv)du}{yu + 4xv}$$

推广形式的隐函数存在定理保证了在 $yu \neq -4xv$ 的点附近, x, v 分别可写成 y, u 的函数 $\begin{cases} x = x(y, u) \\ v = u(y, u) \end{cases}$ (即得到一个映射 $\mathbb{R}^2 \rightarrow \mathbb{R}^2$) 且其微分由上给出, 由此可写出诸偏导数——微分关系中 dy, dv 的系数也.

$$4. \frac{\partial(F, G)}{\partial(y, u)} = \begin{vmatrix} F_y & F_u \\ G_y & G_u \end{vmatrix} = \begin{vmatrix} 2y & -v \\ x & -2u \end{vmatrix} = -4yu + xv \neq 0. \text{ 即当 } xv \neq 4yu \text{ 时, 此时}$$

可将微分满足的线性方程组写成

$$\begin{cases} 2ydy - vdu = udu - 2xdx \\ xdy - 2udu = -2vdu - ydx \end{cases}$$

从中可将 dy, du 解出, 即将 dy, du 表示为 dx, dv 的线性函数. 利用求解线性方程

组的克拉默法则 (Cramer's rule), 得

$$dy = \frac{\begin{vmatrix} u dv - 2x dx & -v \\ -2v dv - y dx & -2u \end{vmatrix}}{\begin{vmatrix} 2y & -v \\ x & -2u \end{vmatrix}} = \frac{(4xu - yv)dx - 2(u^2 + v^2)dv}{xv - 4yu}$$

$$du = \frac{\begin{vmatrix} 2y & u dv - 2x dx \\ x & -2v dv - y dx \end{vmatrix}}{\begin{vmatrix} 2y & -v \\ x & -2u \end{vmatrix}} = \frac{2(x^2 - y^2)dx - (xu + 4yv)dv}{xv - 4yu}$$

推广形式的隐函数存在定理保证了在 $xv \neq -4yu$ 的点附近, y, u 分别可写成 x, v 的函数 $\begin{cases} y = y(x, v) \\ u = u(x, v) \end{cases}$ (即得到一个映射 $\mathbb{R}^2 \rightarrow \mathbb{R}^2$) 且其微分由上给出, 由此可写出诸偏导数——微分关系中 dx, dv 的系数也.

5. $\frac{\partial(F, G)}{\partial(y, v)} = \begin{vmatrix} F_y & F_v \\ G_y & G_v \end{vmatrix} = \begin{vmatrix} 2y & -u \\ x & 2v \end{vmatrix} = 4yv + xu \neq 0$. 即当 $xu \neq -4yv$ 时, 此时可将微分满足的线性方程组写成

$$\begin{cases} 2y dy - u dv = v du - 2x dx \\ x dy + 2v dv = 2u du - y dx \end{cases}$$

从中可将 dy, dv 解出, 即将 dy, dv 表示为 dx, du 的线性函数. 利用求解线性方程组的克拉默法则 (Cramer's rule), 得

$$dy = \frac{\begin{vmatrix} v du - 2x dx & -u \\ 2u du - y dx & 2v \end{vmatrix}}{\begin{vmatrix} 2y & -u \\ x & 2v \end{vmatrix}} = \frac{(yu + 4xv)dx + 2(u^2 + v^2)du}{4yv + xu}$$

$$dv = \frac{\begin{vmatrix} 2y & v du - 2x dx \\ x & 2u du - y dx \end{vmatrix}}{\begin{vmatrix} 2y & -u \\ x & 2v \end{vmatrix}} = \frac{2(x^2 - y^2)dx + (4yu - xv)du}{4yv + xu}$$

推广形式的隐函数存在定理保证了在 $xu \neq -4yv$ 的点附近, y, v 分别可写成 x, u

的函数 $\begin{cases} y = x(x, u) \\ v = u(x, u) \end{cases}$ (即得到一个映射 $\mathbb{R}^2 \rightarrow \mathbb{R}^2$) 且其微分由上给出, 由此可写出诸偏导数——微分关系中 dx, du 的系数也.

6. $\frac{\partial(F, G)}{\partial(u, v)} = \begin{vmatrix} F_u & F_v \\ G_u & G_v \end{vmatrix} = \begin{vmatrix} -v & -u \\ -2u & 2v \end{vmatrix} = -2(u^2 + v^2) \neq 0$. 即当 $(u, v) \neq (0, 0)$ 时, 此时可将微分满足的线性方程组写成

$$\begin{cases} -vdu - udv = -2xdx + 2ydy \\ -2udu + 2v dv = -ydx - xdy \end{cases}$$

从中可将 dy, dv 解出, 即将 dy, dv 表示为 dx, du 的线性函数. 利用求解线性方程组的克拉默法则 (Cramer's rule), 得

$$du = \frac{\begin{vmatrix} -2xdx + 2ydy & -u \\ -ydx - xdy & 2v \end{vmatrix}}{\begin{vmatrix} -v & -u \\ -2u & 2v \end{vmatrix}} = \frac{-(yu + 4xv)dx - (4yv + xu)dy}{-2(u^2 + v^2)}$$

$$dv = \frac{\begin{vmatrix} -v & -2xdx + 2ydy \\ -2u & -ydx - xdy \end{vmatrix}}{\begin{vmatrix} -v & -u \\ -2u & 2v \end{vmatrix}} = \frac{(yv - 4xu)dx + (xv - 4yu)dy}{-2(u^2 + v^2)}$$

推广形式的隐函数存在定理保证了在 $(u, v) \neq (0, 0)$ 的点附近, u, v 分别可写成 x, y 的函数 $\begin{cases} u = u(x, y) \\ v = v(x, y) \end{cases}$ (即得到一个映射 $\mathbb{R}^2 \rightarrow \mathbb{R}^2$) 且其微分由上给出, 由此可写出诸偏导数——微分关系中 dx, dy 的系数也.

一般地, 给定四个变量 x, y, u, v 间的两个约束

$$\begin{cases} F(x, y, u, v) = 0 \\ G(x, y, u, v) = 0 \end{cases}$$

如果这两个约束是有效的, 即其中两个变量可选为“自由变量”, 而将另两个变量由两自由变量表示, 即可由约束方程“解”出隐函数(向量值)关系. 当然, 首先得确保这在无穷小的(线性化)层面是成立的, 然后根据隐函数存在定理的思路, 反推出变

量间存在反应该线性关系的函数关系. 将关系微分, 得

$$\begin{cases} F_x dx + F_y dy + F_u du + F_v dv = 0 \\ G_x dx + G_y dy + G_u du + G_v dv = 0 \end{cases}$$

其系数矩阵为函数组 F, G 的 *Jacobi* 矩阵, 亦即下映射

$$\varphi_{F,G} : \mathbb{R}^4 \longrightarrow \mathbb{R}^2 \quad (x, y, u, v) \longmapsto (F(x, y, u, v), G(x, y, u, v))$$

的 *Jacobi* 矩阵: $\mathbf{J}_{\varphi_{F,G}} = \mathbf{J}_{F,G} = \begin{bmatrix} F_x & F_y & F_u & F_v \\ G_x & G_y & G_u & G_v \end{bmatrix}$

注记 2.7.3 映射 $\varphi_{F,G}$ 的微分可由上 *Jacobi* 矩阵来表示, 即

$$\begin{aligned} d\varphi_{F,G} : \mathbb{R}^4 \longrightarrow \mathbb{R}^2 \quad \begin{bmatrix} dx \\ dy \\ du \\ dv \end{bmatrix} &\longmapsto \mathbf{J}_{F,G} \begin{bmatrix} dx \\ dy \\ du \\ dv \end{bmatrix} = \begin{bmatrix} F_x & F_y & F_u & F_v \\ G_x & G_y & G_u & G_v \end{bmatrix} \begin{bmatrix} dx \\ dy \\ du \\ dv \end{bmatrix} \\ &= \begin{bmatrix} F_x dx + F_y dy + F_u du + F_v dv \\ G_x dx + G_y dy + G_u du + G_v dv \end{bmatrix} = \begin{bmatrix} dF \\ dG \end{bmatrix} \begin{pmatrix} \text{向量值函数之微分} = \text{分量} \\ \text{函数微分之整全 (矩阵)} \end{pmatrix} \end{aligned}$$

假设约束 $F = 0$ 和 $G = 0$ 都有效, 则在微分层面, *Jacobi* 矩阵对微分 dx, dy, du, dv 的约束是有效的, 即矩阵 $\mathbf{J}_{F,G}$ 满秩 (秩为 2) .

那么, 必有一 2 阶子矩阵的行列式不为零, 不妨设下面的行列式不为零

$$\frac{\partial(F, G)}{\partial(u, v)} = \begin{vmatrix} F_u & F_v \\ G_u & G_v \end{vmatrix} \neq 0$$

则在 $\frac{\partial(F, G)}{\partial(u, v)}$ 的这些点处, 下面的线性方程组关于 du, dv 有**唯一解**.

$$\begin{cases} F_u du + F_v dv = -F_x dx - F_y dy \\ G_u du + G_v dv = -G_x dx - G_y dy \end{cases}$$

利用克拉默法则, 得

$$\begin{aligned}
 du &= \frac{\begin{vmatrix} -F_x dx - F_y dy & F_v \\ -G_x dx - G_y dy & G_v \end{vmatrix}}{\begin{vmatrix} F_u & F_v \\ G_u & G_v \end{vmatrix}} = -\frac{\begin{vmatrix} F_x dx & F_v \\ G_x dx & G_v \end{vmatrix}}{\begin{vmatrix} F_u & F_v \\ G_u & G_v \end{vmatrix}} - \frac{\begin{vmatrix} F_y dy & F_v \\ G_y dy & G_v \end{vmatrix}}{\begin{vmatrix} F_u & F_v \\ G_u & G_v \end{vmatrix}} \\
 &= -\frac{\begin{vmatrix} F_x & F_v \\ G_x & G_v \end{vmatrix}}{\begin{vmatrix} F_u & F_v \\ G_u & G_v \end{vmatrix}} dx - \frac{\begin{vmatrix} F_y & F_v \\ G_y & G_v \end{vmatrix}}{\begin{vmatrix} F_u & F_v \\ G_u & G_v \end{vmatrix}} dy = -\frac{\frac{\partial(F, G)}{\partial(x, v)}}{\frac{\partial(F, G)}{\partial(u, v)}} dx - \frac{\frac{\partial(F, G)}{\partial(y, v)}}{\frac{\partial(F, G)}{\partial(u, v)}} dy \\
 \text{即 } \frac{\partial u}{\partial x} &= -\frac{\frac{\partial(F, G)}{\partial(x, v)}}{\frac{\partial(F, G)}{\partial(u, v)}}; \quad \frac{\partial u}{\partial y} = -\frac{\frac{\partial(F, G)}{\partial(y, v)}}{\frac{\partial(F, G)}{\partial(u, v)}}
 \end{aligned}$$

同理可求得

$$\frac{\partial v}{\partial x} = -\frac{\frac{\partial(F, G)}{\partial(u, x)}}{\frac{\partial(F, G)}{\partial(u, v)}}; \quad \frac{\partial v}{\partial y} = -\frac{\frac{\partial(F, G)}{\partial(u, y)}}{\frac{\partial(F, G)}{\partial(u, v)}}$$

注记 2.7.4 上面这些公式无需特别记忆, 只要明了其背后思想, 并掌握计算要领, 则能“触事即发”, “随心所欲而不逾矩”.

注记 2.7.5 当 $\frac{\partial(F, G)}{\partial(u, v)} \neq 0$, 为计算偏导信息, 可直接对约束 $\begin{cases} F(x, y, u, v) = 0 \\ G(x, y, u, v) = 0 \end{cases}$ 两边同时对 x 求导, 得

$$\begin{cases} F_x + F_u u_x + F_v v_x = 0 \\ G_x + G_u u_x + G_v v_x = 0 \end{cases} \iff \begin{cases} F_u u_x + F_v v_x = -F_x \\ G_u u_x + G_v v_x = -G_x \end{cases}$$

则由克拉默法则, 直接求得

$$u_x = \frac{\begin{vmatrix} -F_x & F_v \\ -G_x & G_v \end{vmatrix}}{\begin{vmatrix} F_u & F_v \\ G_u & G_v \end{vmatrix}} = -\frac{\frac{\partial(F, G)}{\partial(x, v)}}{\frac{\partial(F, G)}{\partial(u, v)}}, \quad v_x = \frac{\begin{vmatrix} F_u & -F_x \\ G_u & -G_x \end{vmatrix}}{\begin{vmatrix} F_u & F_v \\ G_u & G_v \end{vmatrix}} = -\frac{\frac{\partial(F, G)}{\partial(u, x)}}{\frac{\partial(F, G)}{\partial(u, v)}}$$

同理可求出其余.

例 2.7.5 考虑 $\begin{cases} F(x, y, r, \theta) = x - r \cos \theta = 0 \\ G(x, y, r, \theta) = y - r \sin \theta = 0 \end{cases}$ 向量值函数 (F, G) 的 *Jacobi* 矩阵为

$$\mathbf{J}_{F,G} = \begin{bmatrix} F_x & F_y & F_r & F_\theta \\ G_x & G_y & G_r & G_\theta \end{bmatrix} = \begin{bmatrix} 1 & 0 & -\cos \theta & r \sin \theta \\ 0 & 1 & \sin \theta & -r \cos \theta \end{bmatrix}$$

显然 $\frac{\partial(F,G)}{\partial(x,y)} = \begin{vmatrix} 1 & 0 \\ 0 & 1 \end{vmatrix} = 1$, 故 (x, y) 可解为 (u, v) 的函数, 即 $\begin{cases} x = r \cos \theta \\ y = r \sin \theta \end{cases}$.

这是平凡的. 但同时

$$\frac{\partial(F,G)}{\partial(r,\theta)} = \begin{vmatrix} -\cos \theta & r \sin \theta \\ \sin \theta & -r \cos \theta \end{vmatrix} = -r$$

故在非原点处, 该 *Jacobi* 行列式都不为零, 从而可将 (r, θ) 写成 (x, y) 的函数, 即坐标变换 $(r, \theta) \mapsto (x, y)$ 存在逆变换 $(x, y) \mapsto (r, \theta)$.

将坐标变换规则微分, 得到

$$\begin{cases} dx - \cos \theta dr + r \sin \theta d\theta = 0 \\ dy - \sin \theta dr - r \cos \theta d\theta = 0 \end{cases} \Rightarrow \begin{cases} \cos \theta dr - r \sin \theta d\theta = dx \\ \sin \theta dr + r \cos \theta d\theta = dy \end{cases}$$

$$\Rightarrow \begin{bmatrix} dr \\ d\theta \end{bmatrix} = \begin{bmatrix} \cos \theta & -r \sin \theta \\ \sin \theta & r \cos \theta \end{bmatrix}^{-1} \begin{bmatrix} dx \\ dy \end{bmatrix} = \frac{1}{r} \begin{bmatrix} r \cos \theta & r \sin \theta \\ -\sin \theta & \cos \theta \end{bmatrix} \begin{bmatrix} dx \\ dy \end{bmatrix}$$

$$\text{即} \begin{cases} dr = \frac{r \cos \theta dx + r \sin \theta dy}{r} \\ d\theta = \frac{-\sin \theta dx + \cos \theta dy}{r} \end{cases}$$

这里逆变换是可以显式求解出的, 即 $\begin{cases} r = \sqrt{x^2 + y^2} \\ \theta = \arctan \frac{y}{x} \end{cases}$ 由此, 直接微分亦可得

$$\begin{cases} dr = \frac{xdx + ydy}{\sqrt{x^2 + y^2}} = \frac{r \cos \theta + r \sin \theta}{r} \\ d\theta = \frac{\frac{xdy - ydx}{x^2}}{1 + \left(\frac{y}{x}\right)^2} = \frac{xdy - ydx}{x^2 + y^2} = \frac{-\sin \theta dx + \cos \theta dy}{r} \end{cases}$$

现在写出最一般的情形.

定理 2.7.2 考察 $n + m$ 个变量间的 m 个约束关系:
$$\begin{cases} F_1(x_1, \dots, x_n, y_1, \dots, y_m) = 0 \\ F_2(x_1, \dots, x_n, y_1, \dots, y_m) = 0 \\ \dots \\ F_m(x_1, \dots, x_n, y_1, \dots, y_m) = 0 \end{cases}$$

如果下面的行列式在 $(x_1^0, \dots, x_n^0, y_1^0, \dots, y_m^0)$ 处不为零

$$\frac{\partial(F_1, \dots, F_m)}{\partial(y_1, \dots, y_m)} = \begin{vmatrix} \frac{\partial F_1}{\partial y_1} & \dots & \frac{\partial F_1}{\partial y_m} \\ \vdots & & \vdots \\ \frac{\partial F_m}{\partial y_1} & \dots & \frac{\partial F_m}{\partial y_m} \end{vmatrix}$$

且 $F_i(x_1^0, \dots, x_n^0, y_1^0, \dots, y_m^0) = 0 \ \forall i = 1, 2, \dots, m$; 且 F_i 在该点的某个领域内连续并具有连续偏导数, 则

1. 在点 $x_1^0, \dots, x_n^0, y_1^0, \dots, y_m^0$ 的某个领域内, 上面的约束关系可确定唯一的一个向量值隐函数

$$\begin{bmatrix} y_1 \\ \vdots \\ y_m \end{bmatrix} = \begin{bmatrix} f_1(x_1, \dots, x_n) \\ \vdots \\ f_m(x_1, \dots, x_n) \end{bmatrix}$$

即它满足方程 $F(x_1, \dots, x_n, f_1(x_1, \dots, x_n), \dots, f_m(x_1, \dots, x_n)) = 0$ 且 $y_i^0 = f_i(x_i^0, \dots, x_n^0) \ i = 1, 2, \dots, m$.

2. 该向量值隐函数在 $(x_1^0, \dots, x_n^0)$ 点附近连续;
3. 该向量值隐函数在 $(x_1^0, \dots, x_n^0)$ 点附近具有连续的偏导数. 其偏导信息给出如下

$$\begin{bmatrix} \frac{\partial y_1}{\partial x_1} & \dots & \frac{\partial y_1}{\partial x_n} \\ \vdots & & \vdots \\ \frac{\partial y_m}{\partial x_1} & \dots & \frac{\partial y_m}{\partial x_n} \end{bmatrix} = - \begin{bmatrix} \frac{\partial F_1}{\partial y_1} & \dots & \frac{\partial F_1}{\partial y_m} \\ \vdots & & \vdots \\ \frac{\partial F_m}{\partial y_1} & \dots & \frac{\partial F_m}{\partial y_m} \end{bmatrix}^{-1} \begin{bmatrix} \frac{\partial F_1}{\partial x_1} & \dots & \frac{\partial F_1}{\partial x_n} \\ \vdots & & \vdots \\ \frac{\partial F_m}{\partial x_1} & \dots & \frac{\partial F_m}{\partial x_n} \end{bmatrix}$$

注记 2.7.6 在具体计算分量函数的偏导数时, 通常采用的方法是: 先将约束条件对 x_j 分别求导, 得

$$\frac{\partial F_i}{\partial x_j} + \sum_{k=1}^m \frac{\partial F_i}{\partial x_k} \frac{\partial y_k}{\partial x_j} = 0, \quad i = 1, 2, \dots, m.$$

然后对该线性利用克拉默定理求解.

例 2.7.6 给出函数方程组
$$\begin{cases} u + v + w + x + y = a^2 \\ u^2 + v^2 + w^2 + x^2 + y^2 = b^2 \\ u^3 + v^3 + w^3 + x^3 + y^3 = c^2 \end{cases}$$
 问: u, v, w 能否为 x, y 的 (隐) 函数? 如可以, 求 u_x, v_x, w_x .

解: 将方程组写成 F, G, H 对诸变量的约束关系如下

$$\begin{cases} F(x, y, u, v, w) = u + v + w + x + y = a^2 \\ G(x, y, u, v, w) = u^2 + v^2 + w^2 + x^2 + y^2 = b^2 \\ H(x, y, u, v, w) = u^3 + v^3 + w^3 + x^3 + y^3 = c^2 \end{cases}$$

欲判断 (u, v, w) 可否为 (x, y) 的 (向量值) 函数, 即能否确定如下映射使得其每个分量都满足函数对于规则

$$\varphi_{F,G,H} : \mathbb{R}^2 \longrightarrow \mathbb{R}^3 \quad (x, y) \longmapsto (u(x, y), v(x, y), w(x, y))$$

如果可以, 该映射将作为 $\mathbb{R}^3$ 中一张曲面的参数表达 (u, v 为参数, $\varphi_{F,G,H}$ 为曲面参数化). 换言之, 从几何角度来看, 这里的问题是: 5 维欧氏空间 (*Euclidean space*) $\mathbb{R}^5$ 中 (坐标为 (u, v, w, x, y)) 的三张超曲面 (分别有方程 $F = 0, G = 0, H = 0$ 给出) 是否能交出一张二维曲面? 如可交成, 则对其参数化.

注记 2.7.7 在线性化层面, 或考虑交点处诸超曲面的切平面层面, 则对应几何图像为: 三张 $\mathbb{R}^5$ 中的超平面 (即维数为 4 的平面 (线性子空间)), 能否相交成某一 2 维曲面的切平面? 换言之, 5 个自由变量间的三个线性约束方程组的解空间能否是 2 维的? 这当然是有可能的, 因为系数矩阵 (对应 *Jacobi* 矩阵) 的秩的可能值为 0, 1, 2, 3, 只要矩阵是满秩的 (秩为 3), 那么自由变量的个数便是 $5 - 3 = 2$, 即其解的图像是一个 2-维子空间, 即 5 维中的 2 维平面. 而隐函数存在定理保证它就是来自于相交而成的 2-维曲面的切平面, 则相交的 2-维面不是别的, 必也是原函数方程组所确定的唯一隐函数关系的图像, 而该隐函数的功能属性本身就是相交曲面的参数化. 这是非常有意义, 兼具趣味性的几何、代数, 以及函数关系间的综合考量, 请读者仔细琢磨.

回到我们的问题, 如果向量值函数 $\varphi_{F,G,H}$ 是存在的, 相当于 (u, v, w) 可由 (x, y) 表 (解) 出, 则在线性化的微分层面, (du, dv, dw) 也得在局部由 (dx, dy) 解出才行, 而根据隐函数存在定理, 至少得保证下面的 *Jacobi* 行列式 (即线性化后 du, dv, dw 的系数矩阵) 不为零.

$$\frac{\partial(F, G, H)}{\partial(u, v, w)} = \begin{vmatrix} F_u & F_v & F_w \\ G_u & G_v & G_w \\ H_u & H_v & H_w \end{vmatrix} = \begin{vmatrix} 1 & 1 & 1 \\ 2u & 2v & 2w \\ 3u^2 & 3v^2 & 3w^2 \end{vmatrix}$$

$$= 6 \begin{vmatrix} 1 & 1 & 1 \\ u & v & w \\ u^2 & v^2 & w^2 \end{vmatrix} \xrightarrow{\text{利用 Vandermonde 行列式}} 6(v-u)(w-v)(w-u)$$

即在空间 $\mathbb{R}^5$ 中的开区域 $\{(x, y, u, v, w) \in \mathbb{R}^5 \mid u, v, w \text{ 两两不相等}\}$ 中的点的附近,

$$\text{函数关系确定了唯一的向量值隐函数关系} \begin{cases} u = u(x, y) \\ v = v(x, y) \\ w = w(x, y) \end{cases}$$

$$\text{为求其对 } x \text{ 的偏导, 将关系} \begin{cases} F = 0 \\ G = 0 \\ H = 0 \end{cases} \text{ 两边对 } x \text{ 求偏导, 得线性方程组}$$

$$\begin{cases} u_x + v_x + w_x + 1 = 0 \\ 2uu_x + 2vv_x + 2ww_x + 2x = 0 \\ 3u^2u_x + 3v^2v_x + 3w^2w_x + 3x^2 = 0 \end{cases} \iff \begin{cases} u_x + v_x + w_x = -1 \\ uu_x + vv_x + ww_x = -x \\ u^2u_x + v^2v_x + w^2w_x = -x^2 \end{cases}$$

利用克拉默法则求解之, 得

$$\frac{\partial u}{\partial x} = \frac{\begin{vmatrix} -1 & 1 & 1 \\ -x & v & w \\ -x^2 & v^2 & w^2 \end{vmatrix}}{\begin{vmatrix} 1 & 1 & 1 \\ u & v & w \\ u^2 & v^2 & w^2 \end{vmatrix}} = \frac{-(v-x)(w-v)(w-x)}{(v-u)(w-v)(w-u)}$$

$$\frac{\partial u}{\partial y} = \frac{\begin{vmatrix} 1 & -1 & 1 \\ u & -x & w \\ u^2 & -x^2 & w^2 \end{vmatrix}}{\begin{vmatrix} 1 & 1 & 1 \\ u & v & w \\ u^2 & v^2 & w^2 \end{vmatrix}} = \frac{-(x-u)(w-x)(w-u)}{(v-u)(w-v)(w-u)}$$

$$\frac{\partial w}{\partial x} = \frac{\begin{vmatrix} 1 & 1 & -1 \\ u & v & -x \\ u^2 & v^2 & -x^2 \end{vmatrix}}{\begin{vmatrix} 1 & 1 & 1 \\ u & v & w \\ u^2 & v^2 & w^2 \end{vmatrix}} = \frac{-(v-u)(x-v)(x-u)}{(v-u)(w-v)(w-u)}$$

同理可求得对 y 得偏导信息, 当然可以通过对关系式微分, 然后直接求解微分 du, dv, dw , 进而得到全部的偏导信息. 即

$$\begin{cases} F_u du + F_v dv + F_w dw + F_x dx + F_y dy = 0 \\ G_u du + G_v dv + G_w dw + G_x dx + G_y dy = 0 \\ H_u du + H_v dv + H_w dw + H_x dx + H_y dy = 0 \end{cases} \Rightarrow$$

$$\begin{cases} du + dv + dw + dx + dy = 0 \\ udu + vdv + wdw + xdx + ydy = 0 \\ u^2 du + v^2 dv + w^2 dw + x^2 dx + y^2 dy = 0 \end{cases} \Leftrightarrow \begin{cases} du + dv + dw = -dx - dy \\ udu + vdv + wdw = -xdx - ydy \\ u^2 du + v^2 dv + w^2 dw = -x^2 dx - y^2 dy \end{cases}$$

利用克拉默法则, 得到

$$du = \frac{\begin{vmatrix} -dx - dy & 1 & 1 \\ -xdx - ydy & v & w \\ -x^2 dx - y^2 dy & v^2 & w^2 \end{vmatrix}}{\begin{vmatrix} 1 & 1 & 1 \\ u & v & w \\ u^2 & v^2 & w^2 \end{vmatrix}} = -\frac{\begin{vmatrix} 1 & 1 & 1 \\ x & v & w \\ x^2 & v^2 & w^2 \end{vmatrix}}{\begin{vmatrix} 1 & 1 & 1 \\ u & v & w \\ u^2 & v^2 & w^2 \end{vmatrix}} dx - \frac{\begin{vmatrix} 1 & 1 & 1 \\ y & v & w \\ y^2 & v^2 & w^2 \end{vmatrix}}{\begin{vmatrix} 1 & 1 & 1 \\ u & v & w \\ u^2 & v^2 & w^2 \end{vmatrix}} dy$$

$$= -\frac{\frac{\partial(F, G, H)}{\partial(x, v, w)}}{\frac{\partial(F, G, H)}{\partial(u, v, w)}} dx - \frac{\frac{\partial(F, G, H)}{\partial(y, v, w)}}{\frac{\partial(F, G, H)}{\partial(u, v, w)}} dy$$

同理

$$dv = -\frac{\frac{\partial(F, G, H)}{\partial(u, x, w)}}{\frac{\partial(F, G, H)}{\partial(u, v, w)}} dx - \frac{\frac{\partial(F, G, H)}{\partial(u, y, w)}}{\frac{\partial(F, G, H)}{\partial(u, v, w)}} dy; \quad dw = -\frac{\frac{\partial(F, G, H)}{\partial(u, v, x)}}{\frac{\partial(F, G, H)}{\partial(u, v, w)}} dx - \frac{\frac{\partial(F, G, H)}{\partial(u, v, y)}}{\frac{\partial(F, G, H)}{\partial(u, v, w)}} dy$$

例 2.7.7 设 $x = \cos \varphi \cos \psi$, $y = \cos \varphi \sin \psi$, $z = \sin \varphi$, 求 $\frac{\partial^2 z}{\partial x^2}$.

解法一: φ 对于 x 的依赖关系是通过函数关系 $\begin{cases} x = \cos \varphi \cos \psi \\ y = \cos \varphi \sin \psi \end{cases}$ 确定的. 事实上

$$\begin{cases} F(\varphi, \psi, x, y) = \cos \varphi \cos \psi - x = 0 \\ G(\varphi, \psi, x, y) = \cos \varphi \sin \psi - y = 0 \end{cases} \Rightarrow \frac{\partial(F, G)}{\partial(\varphi, \psi)} = \begin{vmatrix} -\sin \varphi \cos \psi & -\cos \varphi \sin \psi \\ -\sin \varphi \sin \psi & \cos \varphi \cos \psi \end{vmatrix}$$

$$= -\cos^2 \psi \sin \varphi \cos \varphi - \sin^2 \psi \sin \varphi \cos \varphi = -\sin \varphi \cos \varphi = -\frac{\sin 2\varphi}{2}$$

当 $\varphi \neq 0$ 时, $\frac{\partial(F, G)}{\partial(\varphi, \psi)} \neq 0$, 此时 (φ, ψ) 是 (x, y) 的函数. 两方程两边对 x 求导, 得

$$\begin{cases} -\sin \varphi \cdot \varphi_x \cos \psi + \cos \varphi (-\sin \psi) \psi_x = 1 \\ -\sin \varphi \cdot \varphi_x \sin \psi + \cos \varphi \cos \psi \cdot \psi_x = 0 \end{cases} \Rightarrow \begin{cases} \varphi_x = -\frac{\cos \psi}{\sin \varphi} \\ \psi_x = -\frac{\sin \psi}{\cos \varphi} \end{cases}$$

从而 $\frac{\partial z}{\partial x} = \frac{\partial z}{\partial \varphi} \frac{\partial \varphi}{\partial x} = \cos \varphi \left(-\frac{\cos \psi}{\sin \varphi} \right) = -\cot \varphi \cos \psi$. 进而

$$\begin{aligned} \frac{\partial^2 z}{\partial x^2} &= \frac{\partial}{\partial x} (-\cot \varphi \cos \psi) = \csc^2 \varphi \cdot \varphi_x \cdot \cos \psi - \cot \varphi \cdot (-\sin \psi) \psi_x \\ &= -\frac{\csc^2 \varphi \cos^3 \psi}{\sin \varphi} + \frac{\cot \varphi \sin^2 \psi}{\cos \varphi} = \frac{\cos \varphi \sin^3 \psi - 1}{\sin^3 \varphi} \end{aligned}$$

解法二: 注意到 x, y, z 之间满足关系 $x^2 + y^2 + z^2 = 1$, 微分后得到

$$x dx + y dy + z dz = 0 \xrightarrow{\text{当 } z \text{ 不为零时}} dz = -\frac{x}{z} dx - \frac{y}{z} dy$$

即 $z = z(x)$, 且 $\frac{dz}{dx} = -\frac{x}{z} = -\cot \varphi \cos \psi$. 又对 $zz_x + x = 0$ 两边对 x 求导, 得

$$\begin{aligned} zz_{xx} + z_x^2 + 1 &= 0 \Rightarrow \frac{\partial^2 z}{\partial x^2} = \frac{-1 - z_x^2}{z} = \frac{-1 - \frac{x^2}{z^2}}{z} = -\frac{z^2 + x^2}{z^3} \\ &= \frac{y^2 - 1}{z^3} = \frac{\cos^3 \varphi \sin^2 \psi - 1}{\sin^3 \varphi} \end{aligned}$$

例 2.7.8 $\begin{cases} x^3 + y^3 + z^3 = 3xyz \\ x + y + z = a \end{cases}$ 何时可确定隐函数组 $\begin{cases} y = y(x) \\ z = z(x) \end{cases}$ 计算 $\frac{dy}{dx}, \frac{dz}{dx}$

解: 线性化, 得 $\begin{cases} 3x^2dx + 3y^2dy + 3z^2dz = 3yzdx + 3xzdy + 3xydz \\ dx + dy + dz = 0 \end{cases} \Rightarrow$

$$\begin{cases} (x^2 - yz)dx + (y^2 - xz)dy + (z^2 - xy)dz = 0 \\ dx + dy + dz = 0 \end{cases} \Rightarrow$$

当 $\begin{vmatrix} y^2 - xz & z^2 - xy \\ 1 & 1 \end{vmatrix} = y^2 - z^2 + x(y - z) = a(y - z) \neq 0$ 时, dy, dz 可由 dx 表示

进而由隐函数存在定理, 知在这些点局部有隐函数组关系 $\begin{cases} y = y(x) \\ z = z(x) \end{cases}$. 为求其导数, 方程组两边对 x 求偏导, 得

$$\begin{cases} 3x^2 + 3y^2y_x + 3z^2z_x = 3yz + 3xzy_x + 3xyz_x \\ 1 + y_x + z_x = 0 \end{cases} \Leftrightarrow$$

$$\begin{cases} (y^2 - xz)y_x + (z^2 - xy)z_x = -x^2 + yz \\ y_x + z_x = -1 \end{cases} \Rightarrow \begin{cases} y_x = \frac{-a(x - z)}{a(y - z)} = \frac{x - z}{z - y} \\ z_x = \frac{-a(y - x)}{a(y - z)} = \frac{x - y}{y - z} \end{cases}$$

例 2.7.9 设 $\begin{cases} x = x(y) \\ z = z(y) \end{cases}$ 由方程组 $\begin{cases} F(y - x, y - z) = 0 \\ G(xy, \frac{z}{y}) = 0 \end{cases}$ 所确定的向量值隐函数, 其中 F, G 都具有连续偏导数, 求 $\frac{dx}{dy}$ 和 $\frac{dz}{dy}$.

解: 方程组两边同时对 y 求偏导, 得

$$\begin{cases} \left(1 - \frac{dx}{dy}\right)F_1 + \left(1 - \frac{dz}{dy}\right)F_2 = 0 \\ \left(x + y\frac{dx}{dy}\right)G_1 + \frac{y\frac{dz}{dy} - z}{y^2}G_2 = 0 \end{cases} \Leftrightarrow \begin{cases} F_1 \cdot \frac{dx}{dy} + F_2 \cdot \frac{dz}{dy} = F_1 + F_2 \\ yG_1 \cdot \frac{dx}{dy} + \frac{G_2}{y} \cdot \frac{dz}{dy} = \frac{zG_2}{y^2} - xG_1 \end{cases}$$

$$\Rightarrow \left\{ \begin{array}{l} \frac{dx}{dy} = \frac{\begin{vmatrix} F_1 + F_2 & F_2 \\ \frac{zG_2}{y^2} - xG_1 & \frac{G_2}{y} \end{vmatrix}}{\begin{vmatrix} F_1 & F_2 \\ yG_1 & \frac{G_2}{y} \end{vmatrix}} = \frac{\frac{F_1G_2 + F_2G_2}{y} - \frac{zF_2G_2}{y^2} + xF_2G_1}{\frac{F_1G_2}{y} - yF_2G_1} \\ \frac{dz}{dy} = \frac{\begin{vmatrix} F_1 & F_1 + F_2 \\ yG_1 & \frac{zG_2}{y^2} - xG_1 \end{vmatrix}}{\begin{vmatrix} F_1 & F_2 \\ yG_1 & \frac{G_2}{y} \end{vmatrix}} = \frac{\frac{zF_1G_2}{y^2} - xF_1G_1 - yG_1(F_1 + F_2)}{\frac{F_1G_2}{y} - yF_2G_1} \end{array} \right.$$

例 2.7.10 利用 $\begin{cases} u = x + y \\ v = \frac{y}{x} \end{cases}$ 及 $w = \frac{z}{x}$ 变换方程 $\frac{\partial^2 z}{\partial x^2} - 2\frac{\partial^2 z}{\partial x \partial y} + \frac{\partial^2 z}{\partial y^2} = 0$

解：我们希望将 (x, y, z) 表为 (u, v, w) 的函数，从而将 $z = z(x, y)$ 看成 (u, v, w) 的函数。题目给出了 x, y, u, v, w 之间的三个函数约束关系

$$\left\{ \begin{array}{l} F(x, y, u, v, w) = x + y - u = 0 \\ G(x, y, u, v, w) = \frac{y}{x} - v = 0 \\ H(x, y, u, v, w) = \frac{z}{x} - w = 0 \end{array} \right. \xRightarrow{\text{线性化}} \left\{ \begin{array}{l} dx + dy = du \\ -\frac{y}{x^2}dx + \frac{x}{x^2}dy = dv \\ -\frac{z}{x^2}dx + \frac{x}{x^2}dz = dw \end{array} \right.$$

$$\Rightarrow \frac{\partial(F, G, H)}{\partial(x, y, z)} = \begin{vmatrix} 1 & 1 & 0 \\ -\frac{y}{x^2} & \frac{x}{x^2} & 0 \\ -\frac{z}{x^2} & 0 & \frac{x}{x^2} \end{vmatrix} = \frac{x}{x^2} \left(\frac{x}{x^2} + \frac{y}{x^2} \right) = \frac{x+y}{x^3}$$

当该行列式不为零时， dx, dy, dz 可由 du, dv, dw 唯一表出，即

$$dx = \frac{\begin{vmatrix} du & 1 & 0 \\ dv & \frac{x}{x^2} & 0 \\ dw & 0 & \frac{x}{x^2} \end{vmatrix}}{\frac{x+y}{x^3}} = \frac{\frac{1}{x^2}du - \frac{x}{x^2}dv}{\frac{x+y}{x^3}} = \frac{x}{x+y}du - \frac{x^2}{x+y}dv$$

$$dy = \frac{\begin{vmatrix} 1 & du & 0 \\ -\frac{y}{x^2} & dv & 0 \\ -\frac{z}{x^2} & dw & \frac{x}{x^2} \end{vmatrix}}{\frac{x+y}{x^3}} = \frac{\frac{xy}{x^4}du + \frac{x}{x^2}dv}{\frac{x+y}{x^3}} = \frac{y}{x+y}du + \frac{x^2}{x+y}dv$$

$$\begin{aligned} dz &= \frac{\begin{vmatrix} 1 & 1 & du \\ -\frac{y}{x^2} & \frac{x}{x^2} & dv \\ -\frac{z}{x^2} & 0 & dw \end{vmatrix}}{\frac{x+y}{x^3}} = \frac{\frac{xz}{x^4}du - \frac{z}{x^2}dv + \left(\frac{x+y}{x^2}\right)dw}{\frac{x+y}{x^3}} \\ &= \frac{z}{x+y}du - \frac{xz}{x+y}dv + xdw \end{aligned}$$

由此也看出 (x, y) 本质上只是 (u, v) 的函数, 而 z 是 (u, v, w) 的函数. 且有

$$\begin{bmatrix} dx \\ dy \end{bmatrix} = \begin{bmatrix} \frac{x}{x+y} & -\frac{x^2}{x+y} \\ \frac{y}{x+y} & \frac{x^2}{x+y} \end{bmatrix} \begin{bmatrix} du \\ dv \end{bmatrix} \Rightarrow$$

$$\begin{bmatrix} du \\ dv \end{bmatrix} = \begin{bmatrix} \frac{x}{x+y} & -\frac{x^2}{x+y} \\ \frac{y}{x+y} & \frac{x^2}{x+y} \end{bmatrix}^{-1} \begin{bmatrix} dx \\ dy \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ -\frac{y}{x^2} & \frac{1}{x} \end{bmatrix} \begin{bmatrix} dx \\ dy \end{bmatrix}$$

$$\Rightarrow u_x = u_y = 1; \quad v_x = -\frac{y}{x^2}, \quad v_y = \frac{1}{x}$$

$$\text{故 } \frac{\partial z}{\partial x} = \frac{\partial z}{\partial u} \frac{\partial u}{\partial x} + \frac{\partial z}{\partial v} \frac{\partial v}{\partial x} + \frac{\partial z}{\partial w} \frac{\partial w}{\partial x}; \quad \frac{\partial z}{\partial y} = \frac{\partial z}{\partial u} \frac{\partial u}{\partial y} + \frac{\partial z}{\partial v} \frac{\partial v}{\partial y} + \frac{\partial z}{\partial w} \frac{\partial w}{\partial y}$$

$$\begin{aligned} \frac{\partial^2 z}{\partial x^2} &= \frac{\partial}{\partial x} \left(\frac{\partial z}{\partial u} \frac{\partial u}{\partial x} + \frac{\partial z}{\partial v} \frac{\partial v}{\partial x} + \frac{\partial z}{\partial w} \frac{\partial w}{\partial x} \right) = \frac{\partial u}{\partial x} \left(\frac{\partial^2 z}{\partial u^2} \frac{\partial u}{\partial x} + \frac{\partial^2 z}{\partial u \partial v} \frac{\partial v}{\partial x} + \frac{\partial^2 z}{\partial u \partial w} \frac{\partial w}{\partial x} \right) + \\ &\quad + \frac{\partial z}{\partial u} \frac{\partial^2 u}{\partial x^2} + \frac{\partial v}{\partial x} \left(\frac{\partial^2 z}{\partial v^2} \frac{\partial v}{\partial x} + \frac{\partial^2 z}{\partial u \partial v} \frac{\partial u}{\partial x} + \frac{\partial^2 z}{\partial v \partial w} \frac{\partial w}{\partial x} \right) + \frac{\partial z}{\partial v} \frac{\partial^2 v}{\partial x^2} \\ &\quad + \frac{\partial w}{\partial x} \left(\frac{\partial^2 z}{\partial w^2} \frac{\partial w}{\partial x} + \frac{\partial^2 z}{\partial w \partial u} \frac{\partial u}{\partial x} + \frac{\partial^2 z}{\partial w \partial v} \frac{\partial v}{\partial x} \right) + \frac{\partial z}{\partial w} \frac{\partial^2 w}{\partial x^2} \end{aligned}$$

$$\begin{aligned} \frac{\partial^2 z}{\partial y^2} &= \frac{\partial}{\partial y} \left(\frac{\partial z}{\partial u} \frac{\partial u}{\partial y} + \frac{\partial z}{\partial v} \frac{\partial v}{\partial y} + \frac{\partial z}{\partial w} \frac{\partial w}{\partial y} \right) = \frac{\partial u}{\partial y} \left(\frac{\partial^2 z}{\partial u^2} \frac{\partial u}{\partial y} + \frac{\partial^2 z}{\partial u \partial v} \frac{\partial v}{\partial y} + \frac{\partial^2 z}{\partial u \partial w} \frac{\partial w}{\partial y} \right) + \\ &\quad + \frac{\partial z}{\partial u} \frac{\partial^2 u}{\partial y^2} + \frac{\partial v}{\partial y} \left(\frac{\partial^2 z}{\partial v^2} \frac{\partial v}{\partial y} + \frac{\partial^2 z}{\partial v \partial u} \frac{\partial u}{\partial y} + \frac{\partial^2 z}{\partial v \partial w} \frac{\partial w}{\partial y} \right) + \frac{\partial z}{\partial v} \frac{\partial^2 v}{\partial y^2} \end{aligned}$$

$$\begin{aligned}
& + \frac{\partial w}{\partial y} \left(\frac{\partial^2 z}{\partial w^2} \frac{\partial w}{\partial y} + \frac{\partial^2 z}{\partial w \partial u} \frac{\partial u}{\partial y} + \frac{\partial^2 z}{\partial w \partial v} \frac{\partial v}{\partial y} \right) + \frac{\partial z}{\partial w} \frac{\partial^2 w}{\partial y^2} \\
\frac{\partial^2 z}{\partial x \partial y} &= \frac{\partial}{\partial x} \left(\frac{\partial z}{\partial u} \frac{\partial u}{\partial y} + \frac{\partial z}{\partial v} \frac{\partial v}{\partial y} + \frac{\partial z}{\partial w} \frac{\partial w}{\partial y} \right) = \frac{\partial u}{\partial y} \left(\frac{\partial^2 z}{\partial u^2} \frac{\partial u}{\partial x} + \frac{\partial^2 z}{\partial u \partial v} \frac{\partial v}{\partial x} + \frac{\partial^2 z}{\partial u \partial w} \frac{\partial w}{\partial x} \right) + \\
& + \frac{\partial z}{\partial u} \frac{\partial^2 u}{\partial y \partial x} + \frac{\partial v}{\partial y} \left(\frac{\partial^2 z}{\partial v^2} \frac{\partial v}{\partial x} + \frac{\partial^2 z}{\partial v \partial u} \frac{\partial u}{\partial x} + \frac{\partial^2 z}{\partial v \partial w} \frac{\partial w}{\partial x} \right) + \frac{\partial z}{\partial v} \frac{\partial^2 v}{\partial y \partial x} \\
& + \frac{\partial w}{\partial y} \left(\frac{\partial^2 z}{\partial w^2} \frac{\partial w}{\partial x} + \frac{\partial^2 z}{\partial w \partial u} \frac{\partial u}{\partial x} + \frac{\partial^2 z}{\partial w \partial v} \frac{\partial v}{\partial x} \right) + \frac{\partial z}{\partial w} \frac{\partial^2 w}{\partial y \partial x} \\
\text{从而 } \frac{\partial^2 z}{\partial x^2} - 2 \frac{\partial^2 z}{\partial x \partial y} + \frac{\partial^2 z}{\partial y^2} &= \frac{\partial^2 z}{\partial u^2} (u_x^2 + u_y^2 - 2u_x u_y) + \frac{\partial^2 z}{\partial v^2} (v_x^2 + v_y^2 - 2v_x v_y) \\
& + \frac{\partial^2 z}{\partial w^2} (w_x^2 + w_y^2 - 2w_x w_y) + 2 \frac{\partial^2 z}{\partial u \partial v} (u_x v_x + u_y v_y - u_x v_y - u_y v_x) + \\
& + 2 \frac{\partial^2 z}{\partial u \partial w} (u_x w_x + u_y w_y - u_y w_x - u_x w_y) + 2 \frac{\partial^2 z}{\partial v \partial w} (v_x w_x + v_y w_y - v_y w_x - v_x w_y) \\
& + \frac{\partial z}{\partial u} (u_{xx} - 2u_{xy} + u_{yy}) + \frac{\partial z}{\partial v} (v_{xx} - 2v_{xy} + v_{yy}) + \frac{\partial z}{\partial w} (w_{xx} - 2w_{xy} + w_{yy}) \\
& = \frac{\partial^2 z}{\partial u^2} (u_x - u_y)^2 + \frac{\partial^2 z}{\partial v^2} (v_x - v_y)^2 + \frac{\partial^2 z}{\partial w^2} (w_x - w_y)^2 + \\
& + 2 \frac{\partial^2 z}{\partial u \partial v} (u_x - u_y)(v_x - v_y) + 2 \frac{\partial^2 z}{\partial u \partial w} (u_x - u_y)(w_x - w_y) + 2 \frac{\partial^2 z}{\partial v \partial w} (v_x - v_y)(w_x - w_y)
\end{aligned}$$

又

$$\begin{aligned}
u_x - u_y &= 0; \quad v_x - v_y = -\frac{x+y}{x^2} \\
dw &= -\frac{z}{x^2} dx + \frac{x}{x^2} dz \implies w_x = -\frac{z}{x^2}, \quad w_y = 0
\end{aligned}$$

从而 $\frac{\partial^2 z}{\partial x^2} - 2 \frac{\partial^2 z}{\partial x \partial y} + \frac{\partial^2 z}{\partial y^2} = 0$ 可写为

$$\frac{\partial^2 z}{\partial v^2} \frac{(x+y)^2}{x^4} + \frac{\partial^2 z}{\partial w^2} \frac{z^2}{x^4} + 2 \frac{\partial^2 z}{\partial v \partial w} \frac{z(x+y)}{x^4} = 0$$

$$\text{即 } (x+y)^2 \frac{\partial^2 z}{\partial v^2} + 2z(x+y) \frac{\partial^2 z}{\partial v \partial w} + z^2 \frac{\partial^2 z}{\partial w^2} = 0$$

又由于 $x+y=u$, 故可将上方程改写为

$$u^2 \frac{\partial^2 z}{\partial v^2} + 2zu \frac{\partial^2 z}{\partial v \partial w} + z^2 \frac{\partial^2 z}{\partial w^2} = 0$$

例 2.7.11 设 $z = z(x, y)$ 由关系 $F\left(\frac{x-x_0}{z-z_0}, \frac{y-y_0}{z-z_0}\right) = 0$ 确定, 证明:

$$(x-x_0)\frac{\partial z}{\partial x} + (y-y_0)\frac{\partial z}{\partial y} = z-z_0$$

分析: 注意到 F 关于 $x-x_0, y-y_0, z-z_0$ 是齐次的, 所以 $F=0$ 描述的是以点 $P_0(x_0, y_0, z_0)$ 为顶点的锥面. 即 $z = z(x, y)$ 的图像是顶点于 P_0 的锥面. 显然, 其上任意一点的切平面都经过 P_0 点, 而这正是所欲证的.

证明: 关系式 $F\left(\frac{x-x_0}{z-z_0}, \frac{y-y_0}{z-z_0}\right) = 0$ 两边微分, 得

$$F_1 d\left(\frac{x-x_0}{z-z_0}\right) + F_2 d\left(\frac{y-y_0}{z-z_0}\right) = 0 \iff$$

$$F_1 \frac{(z-z_0)dx - (x-x_0)dz}{(z-z_0)^2} + F_2 \frac{(z-z_0)dy - (y-y_0)dz}{(z-z_0)^2} = 0 \iff$$

$$F_1 \cdot (z-z_0)dx - F_1 \cdot (x-x_0)dz + F_2 \cdot (z-z_0)dy - F_2 \cdot (y-y_0)dz = 0 \implies$$

$$dz = \frac{F_1 \cdot (z-z_0)}{F_1 \cdot (x-x_0) + F_2 \cdot (y-y_0)} dx + \frac{F_2 \cdot (z-z_0)}{F_1 \cdot (x-x_0) + F_2 \cdot (y-y_0)} dy \implies$$

$$\frac{\partial z}{\partial x} = \frac{F_1 \cdot (z-z_0)}{F_1 \cdot (x-x_0) + F_2 \cdot (y-y_0)}; \quad \frac{\partial z}{\partial y} = \frac{F_2 \cdot (z-z_0)}{F_1 \cdot (x-x_0) + F_2 \cdot (y-y_0)}$$

$$\text{从而 } (x-x_0)\frac{\partial z}{\partial x} + (y-y_0)\frac{\partial z}{\partial y} =$$

$$= \frac{F_1 \cdot (x-x_0) + F_2 \cdot (y-y_0)}{F_1 \cdot (x-x_0) + F_2 \cdot (y-y_0)} (z-z_0) = z-z_0 \quad \square$$

例 2.7.12 设 $u = u(x)$ 由 $\begin{cases} u = f(x, y, z) \\ g(x, y, z) = 0 \\ h(x, y, z) = 0 \end{cases}$ 确定. 求 $\frac{du}{dx}, \frac{d^2u}{dx^2}$.

解: 即给出四个变量 x, y, z, u 间的三个有效约束 $\begin{cases} u - f(x, y, z) = 0 \\ g(x, y, z) = 0 \\ h(x, y, z) = 0 \end{cases}$ 中的后两个约

束 $\begin{cases} g(x, y, z) = 0 \\ h(x, y, z) = 0 \end{cases}$ 给出隐函数关系 $\begin{cases} y = y(x) \\ z = z(x) \end{cases}$, 代入第一个约束后将给出隐函数

$$u = u(x) = f(x, y(x), z(x))$$

故 $\frac{du}{dx} = \frac{\partial f}{\partial x} + \frac{\partial f}{\partial y} \frac{dy}{dx} + \frac{\partial f}{\partial z} \frac{dz}{dx}$, 其中 $\frac{dy}{dx}, \frac{dz}{dx}$ 计算如下

$$\begin{cases} \frac{\partial g}{\partial x} + \frac{\partial g}{\partial y} \frac{dy}{dx} + \frac{\partial g}{\partial z} \frac{dz}{dx} = 0 \\ \frac{\partial h}{\partial x} + \frac{\partial h}{\partial y} \frac{dy}{dx} + \frac{\partial h}{\partial z} \frac{dz}{dx} = 0 \end{cases} \iff \begin{cases} \frac{\partial g}{\partial y} \frac{dy}{dx} + \frac{\partial g}{\partial z} \frac{dz}{dx} = -\frac{\partial g}{\partial x} \\ \frac{\partial h}{\partial y} \frac{dy}{dx} + \frac{\partial h}{\partial z} \frac{dz}{dx} = -\frac{\partial h}{\partial x} \end{cases}$$

约束 g, h 的有效性使得我们可设 $\frac{\partial(g, h)}{\partial(y, z)} = g_y h_z - h_y g_z \neq 0$, 从而可解出

$$\frac{dy}{dx} = \frac{\begin{vmatrix} -g_x & g_z \\ -h_x & h_z \end{vmatrix}}{\begin{vmatrix} g_y & g_z \\ h_y & h_z \end{vmatrix}} = \frac{g_z h_x - h_z g_x}{g_y h_z - h_y g_z}, \quad \frac{dz}{dx} = \frac{\begin{vmatrix} g_y & -g_x \\ h_y & -h_x \end{vmatrix}}{\begin{vmatrix} g_y & g_z \\ h_y & h_z \end{vmatrix}} = \frac{g_x h_y - h_x g_y}{g_y h_z - h_y g_z}$$

$$\text{从而 } \frac{du}{dx} = \frac{\partial f}{\partial x} + \frac{\partial f}{\partial y} \frac{dy}{dx} + \frac{\partial f}{\partial z} \frac{dz}{dx} = f_x + f_y \frac{g_z h_x - h_z g_x}{g_y h_z - h_y g_z} + f_z \frac{g_x h_y - h_x g_y}{g_y h_z - h_y g_z}$$

例 2.7.13 设 $y = f(x, t)$, 而 t 是由方程 $F(x, y, t) = 0$ 所确定的 x, y 的隐函数, 其中 f, F 都具有连续偏导数. 证明:

$$\frac{dy}{dx} = \frac{\frac{\partial f}{\partial x} \frac{\partial F}{\partial t} - \frac{\partial f}{\partial t} \frac{\partial F}{\partial x}}{\frac{\partial f}{\partial t} \frac{\partial F}{\partial y} + \frac{\partial F}{\partial t}}$$

证明: 对方程 $F(x, y, t) = 0$ 微分, 得 $F_x dx + F_y dy + F_t dt = 0$. 又因为 $y = f(x, t)$, 故 $dy = f_x dx + f_t dt$, 代入上式得

$$F_x dx + F_y \cdot (f_x dx + f_t dt) + F_t dt = 0$$

$$\implies dt = -\frac{F_x + F_y \cdot f_x}{F_t + F_y \cdot f_t} dx$$

$$\text{则 } y \text{ 对于 } x \text{ 的全导数 } \frac{dy}{dx} = \frac{\partial f}{\partial x} + \frac{\partial f}{\partial t} \frac{dt}{dx} = \frac{\partial f}{\partial x} - \frac{\partial f}{\partial t} \frac{F_x + F_y \cdot f_x}{F_t + F_y \cdot f_t}$$

$$= \frac{\partial f}{\partial x} - \frac{\frac{\partial F}{\partial x} \frac{\partial f}{\partial t} + \frac{\partial F}{\partial y} \frac{\partial f}{\partial x} \frac{\partial f}{\partial t}}{\frac{\partial F}{\partial t} + \frac{\partial F}{\partial y} \frac{\partial f}{\partial t}} = \frac{\frac{\partial f}{\partial x} \frac{\partial F}{\partial t} - \frac{\partial f}{\partial t} \frac{\partial F}{\partial x}}{\frac{\partial f}{\partial t} \frac{\partial F}{\partial y} + \frac{\partial F}{\partial t}} \quad \square$$

例 2.7.14 映射 $\begin{cases} x = u \cos \frac{v}{u} \\ y = \sin \frac{v}{u} \end{cases}$ 存在逆映射的条件? 并计算逆映射的微分.

解: 将 x, y 微分, 得 (利用一阶微分的形式不变性)

$$\begin{aligned} dx &= \cos \frac{v}{u} du - u \sin \frac{v}{u} d\left(\frac{v}{u}\right) = \cos \frac{v}{u} du - u \sin \frac{v}{u} \frac{v du - u dv}{u^2} \\ &= \frac{u \cos \frac{v}{u} + v \sin \frac{v}{u}}{u} du - \sin \frac{v}{u} dv \end{aligned}$$

$$dy = \cos \frac{v}{u} d\left(\frac{v}{u}\right) = \cos \frac{v}{u} \frac{v du - u dv}{u^2} = -\frac{v}{u^2} \cos \frac{v}{u} du + \frac{\cos \frac{v}{u}}{u} dv$$

故该映射的微分是 $\begin{bmatrix} dx \\ dy \end{bmatrix} = \begin{bmatrix} \frac{1}{u} \left(u \cos \frac{v}{u} + v \sin \frac{v}{u} \right) & -\sin \frac{v}{u} \\ -\frac{v}{u^2} \cos \frac{v}{u} & \frac{\cos \frac{v}{u}}{u} \end{bmatrix} \begin{bmatrix} du \\ dv \end{bmatrix}$. 其 J_{a-}

$cobi$ 行列式为

$$\begin{aligned} \begin{vmatrix} \frac{1}{u} \left(u \cos \frac{v}{u} + v \sin \frac{v}{u} \right) & -\sin \frac{v}{u} \\ -\frac{v}{u^2} \cos \frac{v}{u} & \frac{\cos \frac{v}{u}}{u} \end{vmatrix} &= \frac{1}{u^2} \cos \frac{v}{u} \left(u \cos \frac{v}{u} + v \sin \frac{v}{u} \right) - \frac{v}{u^2} \sin \frac{v}{u} \cos \frac{v}{u} \\ &= \frac{1}{u} \cos^2 \frac{v}{u} \end{aligned}$$

故当 $\frac{1}{u} \cos^2 \frac{v}{u} \neq 0$ 时, 可通过上微分关系反解 du, dv , 而隐函数存在定理保证了局部逆映射的存在性. 且

$$\begin{aligned} \begin{bmatrix} du \\ dv \end{bmatrix} &= \begin{bmatrix} \frac{1}{u} \left(u \cos \frac{v}{u} + v \sin \frac{v}{u} \right) & -\sin \frac{v}{u} \\ -\frac{v}{u^2} \cos \frac{v}{u} & \frac{\cos \frac{v}{u}}{u} \end{bmatrix}^{-1} \begin{bmatrix} dx \\ dy \end{bmatrix} \\ &= \frac{u}{\cos^2 \frac{v}{u}} \begin{bmatrix} \frac{\cos \frac{v}{u}}{u} & \sin \frac{v}{u} \\ \frac{v}{u^2} \cos \frac{v}{u} & \frac{1}{u} \left(u \cos \frac{v}{u} + v \sin \frac{v}{u} \right) \end{bmatrix} \begin{bmatrix} dx \\ dy \end{bmatrix} \end{aligned}$$

即

$$\begin{cases} du = \sec \frac{v}{u} dx + u \tan \frac{v}{u} \sec \frac{v}{u} dy \\ dv = \frac{v}{u} \sec \frac{v}{u} dx + \sec^2 \frac{v}{u} \left(u \cos \frac{v}{u} + v \sin \frac{v}{u} \right) dy \end{cases}$$

3 应用篇

3.1 偏导、微分、梯度及隐函数存在定理在几何上的简单应用

空间曲线的切向量：空间 $\mathbb{R}^3$ 中的一条曲线 Γ 可看成是一个映射（或向量值函数）

$$\mathbf{r}(t) : \mathbb{R} \longrightarrow \mathbb{R}^3 \quad t \longmapsto (x(t), y(t), z(t))$$

$\mathbf{r}(t)$ 称为曲线 Γ 的径矢. 按 1.2. 小节中的解释, 设曲线上点 $P(x, y, z)$ 对应的参数为 t , 则在曲线的分量函数 $x(t), y(t), z(t)$ 可微的假设下, 曲线在 P 处的切向量（即切线的方向向量）为

$$\mathbf{r}'(t) = (x'(t), y'(t), z'(t))$$

处处有切线的曲线称为光滑曲线 (*smooth curve*). 由此, 曲线 Γ 上过 $P_0(x_0, y_0, z_0)$ 的切线方程为 $L_R : \mathbf{r} = \mathbf{r}(t_0) + t\mathbf{r}'(t_0)$, 即

$$\begin{cases} x(t) = x(t_0) + x'(t_0)t \\ y(t) = y(t_0) + y'(t_0)t \\ z(t) = z(t_0) + z'(t_0)t \end{cases} \iff \begin{bmatrix} x(t) \\ y(t) \\ z(t) \end{bmatrix} = \begin{bmatrix} x(t_0) \\ y(t_0) \\ z(t_0) \end{bmatrix} + \begin{bmatrix} x'(t_0) \\ y'(t_0) \\ z'(t_0) \end{bmatrix} t$$

注记 3.1.1 映射 $\mathbf{r}(t)$ 的微分由其 *Jacobi* 矩阵 $\mathbf{J}_{\mathbf{r}} = \begin{bmatrix} x'(t) \\ y'(t) \\ z'(t) \end{bmatrix}$ 给出, 从而 $d\mathbf{r}$ 做为映射,

将 t_0 处的增量 Δt 映射为函数实际增量 $\Delta\mathbf{r}(t) = \mathbf{r}(t_0 + \Delta t) - \mathbf{r}(t_0)$ 的线性主部, 即

$$d\mathbf{r} : \mathbb{R} \longrightarrow \mathbb{R}^3 \quad \Delta t \longmapsto \mathbf{J}_{\mathbf{r}}(t_0)\Delta t = \begin{bmatrix} x'(t_0) \\ y'(t_0) \\ z'(t_0) \end{bmatrix} \Delta t$$


知道了曲线在 t_0 处的切线方程, 则曲线在该点的法平面（即 $\mathbb{R}^3$ 中正交于切线量的（二维）超平面）的一个法向量为 $\mathbf{n} = \mathbf{r}'(t_0)$, 从而有平面方程的点法式得法平面方程为

$$x'(t_0)(x - x(t_0)) + y'(t_0)(y - y(t_0)) + z'(t_0)(z - z(t_0)) = 0$$

若将 $\mathbf{r}(t)$ 解释为一质点的运动轨迹（此时将参数 t 解释为时间, 则切向量 $\mathbf{r}'(t)$ 表示运动质点在时刻 t 时的速度.）

例 3.1.1 一质点在以等角速度 ω 绕 z 轴旋转的同时, 还以匀速 v 沿 z 轴的正向上升. 设在时刻 $t = 0$ 时, 质点位于 $(a, 0, 0)$, 则该质点的运动轨迹是曲线 Γ , 其方程给出如

下：曲线上任一点 (x, y, z) 在时刻 t 时的 z 坐标为 vt ，而其在 x - y 平面上投影做匀速圆周运动，由于角速度为 ω ，故在时刻 t ，质点轨迹相对于 x -轴的转角为 ωt （初始角度为零），从而 $(x(t), y(t)) = (a \cos \omega t, a \sin \omega t)$ 。



由此即知质点的螺旋轨迹 Γ 的参数方程为
$$\begin{cases} x(t) = a \cos \omega t \\ y(t) = a \sin \omega t \\ z(t) = vt \end{cases}$$
 即其径矢量（或位置向量）为 $\mathbf{r}(t) = (a \cos \omega t, a \sin \omega t, vt)$ ，则任意时刻 t 的运动速度

$$\mathbf{v}(t) = \mathbf{r}'(t) = (x'(t), y'(t), z'(t)) = (-a\omega \sin \omega t, a\omega \cos \omega t, v)$$

它也是曲线在 t 对应点出的切向量。

注记 3.1.2 运动的加速度为

$$\mathbf{a}(t) = \frac{d\mathbf{v}(t)}{dt} = (-a\omega^2 \cos \omega t, -a\omega^2 \sin \omega t, 0)$$

则不难看出，其径矢（或位置矢量） $\mathbf{r}(t)$ 满足如下二阶线性常系数微分方程

$$\frac{d^2 \mathbf{v}(t)}{dt^2} = \begin{bmatrix} x''(t) \\ y''(t) \\ z''(t) \end{bmatrix} = \begin{bmatrix} -\omega^2 & 0 & 0 \\ 0 & -\omega^2 & 0 \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} x(t) \\ y(t) \\ z(t) \end{bmatrix}$$

对应系数矩阵是对角矩阵，即三个独立方向的运动可解耦（decouple）。

注记 3.1.3 运动在 x - y 平面上为圆周运动： $\begin{cases} x(t) = a \cos \omega t \\ y(t) = a \sin \omega t \end{cases}$ ，其位置向量为 $\mathbf{r}(t) = (a \cos \omega t, a \sin \omega t)$ ，其速度向量为 $\mathbf{v}(t) = \mathbf{r}'(t) = (-a\omega \sin \omega t, a\omega \cos \omega t)$ 。注意到， $\mathbf{r}(t) \bullet \mathbf{r}'(t) = 0$ ，即速度方向于位置矢量在任意时刻都正交。

事实上，我们可以证明：只要 $|\mathbf{r}(t)| = \sqrt{\mathbf{r}(t) \bullet \mathbf{r}(t)}$ 是恒定的，则必有 $\mathbf{r}(t) \bullet \mathbf{r}'(t) = 0$ 。

这只需注意到, 对两个向量值函数 $\mathbf{u}, \mathbf{v}$, 由求导规则

$$\frac{d\mathbf{u} \bullet \mathbf{v}}{dt} = \mathbf{u} \bullet \frac{d\mathbf{v}}{dt} + \frac{d\mathbf{u}}{dt} \bullet \mathbf{v} \quad (\text{请读者自行证明}).$$

由此公式, 我们有

$$0 = \frac{d(\mathbf{r}(t) \bullet \mathbf{r}(t))}{dt} = \mathbf{r}(t) \bullet \frac{d\mathbf{r}(t)}{dt} + \frac{d\mathbf{r}(t)}{dt} \bullet \mathbf{r}(t) \implies \mathbf{r}(t) \bullet \mathbf{r}'(t) = 0$$

曲面的切平面和法向量: 由微分的几何意义知, 如果 $z = f(x, y)$ 在 $P_0(x_0, y_0)$ 处可微, 则曲面 $z = f(x, y)$ 在 (x_0, y_0, z_0) 处有切平面

$$\pi: \quad z - z_0 = \left. \frac{\partial f}{\partial x} \right|_{P_0} (x - x_0) + \left. \frac{\partial f}{\partial y} \right|_{P_0} (y - y_0)$$

其法向量为 $\mathbf{n} = \left(\left. \frac{\partial f}{\partial x} \right|_{P_0}, \left. \frac{\partial f}{\partial y} \right|_{P_0}, -1 \right)$. 形式上来看, 它是在函数微分

$$dz|_{P_0} = \left. \frac{\partial f}{\partial x} \right|_{P_0} dx + \left. \frac{\partial f}{\partial y} \right|_{P_0} dy$$

中令 $dx = \Delta x = x - x_0$, $dy = \Delta y = y - y_0$, $dz = z - z_0$ 得到的. 即由微分确定的线性函数

$$z = z_0 + f_x(P_0)(x - x_0) + f_y(P_0)(y - y_0)$$

是函数 $f(x, y)$ 在 P_0 处的“最优”线性近似——切平面近似.

一般地, 若曲面 S 由隐函数关系 $F(x, y, z) = 0$ 给出. 将该关系线性化, 即对方程微分, 得

$$dF(x, y, z) = 0 \iff F_x dx + F_y dy + F_z dz = 0$$

若 $F_z(x_0, y_0) \neq 0$, 则在 $P_0(x_0, y_0)$ 附近: $dz = -\left. \frac{F_x}{F_z} \right|_{P_0} dx - \left. \frac{F_y}{F_z} \right|_{P_0} dy$, 它是方程 $F = 0$ 由隐函数定理所确定的函数 $z = f(x, y)$ 的曲面 (当然仍是曲面 S) 在 P_0 处的微分, 按上述说明, 知该点处 S 的切平面方程为

$$z - z_0 = -\left. \frac{F_x}{F_z} \right|_{P_0} (x - x_0) - \left. \frac{F_y}{F_z} \right|_{P_0} (y - y_0)$$

即


$$F_x(P_0)(x - x_0) + F_y(P_0)(y - y_0) + F_z(P_0)(z - z_0) = 0$$

若 $F_x(x_0, y_0) \neq 0$ 或 $F_y(x_0, y_0) \neq 0$, 同样的讨论得到相同的切平面方程. 如在某点 P_0 处 F_x, F_y, F_z 全为零, 则 $F(x, y, z) = 0$ 的图像在该点没有切平面近似 (以锥面 $x^2 + y^2 + z^2 = 0$ 在其顶点 (原点) 处的表现为例) .

即若 $F(x, y, z)$ 在 $M_0(x_0, y_0, z_0)$ 的某领域内可微, 则 $F(x, y, z) = 0$ 定义的曲面在 M_0 处有切平面, 其方程为

$$F_x(P_0)(x - x_0) + F_y(P_0)(y - y_0) + F_z(P_0)(z - z_0) = 0$$

故知切平面的一个法向量为 $\mathbf{n} = \nabla F|_{M_0} = (F_x(P_0), F_y(P_0), F_z(P_0))$. 即函数 $w = F(x, y, z)$ 在 M_0 处的梯度作为法向量.



注记 3.1.4 由于梯度 ∇F 在某点的方向指向函数值变化最快的方向, 且它和该点处的等高面 $F(x, y, z) = C$ 是正交的, 即它正交于等高面在该点处的切平面.

知道了切平面方程, 我们同时也就知到了曲面 $S: F(x, y, z) = 0$ 在点 $M_0(x_0, y_0, z_0)$ 处的法线方程了, 即

$$\frac{x - x_0}{F_x(x_0, y_0, z_0)} = \frac{y - y_0}{F_y(x_0, y_0, z_0)} = \frac{z - z_0}{F_z(x_0, y_0, z_0)}$$

另一种视角: 考察曲面 $S: F(x, y, z) = 0$ 上过 $M_0(x_0, y_0, z_0)$ 的任意一条光滑曲线 $\Gamma: \mathbf{r} = \mathbf{r}(t) = (x(t), y(t), z(t))$, 其中 M_0 点对应于参数 t_0 . 即有 $F(x(t), y(t), z(t)) = 0$. 对方程两边同时对 t 求导, 并令 $t = t_0$, 利用全导数的公式, 得

$$F_x(x_0, y_0, z_0)x'(t_0) + F_y(x_0, y_0, z_0)y'(t_0) + F_z(x_0, y_0, z_0)z'(t_0) = 0$$

即 $\nabla F|_{M_0} \bullet \mathbf{r}'(t_0) = 0$, 即 $\nabla F|_{M_0}$ 与曲线 Γ 在 M_0 处的切向量垂直. 由于光滑曲线 Γ 的选取是任意的, 故知 $\nabla F|_{M_0}$ 与过 M_0 点的任何光滑曲线的切向量都垂直, 即 $\nabla F|_{M_0}$ 与 M_0 点处曲面切平面上的任何向量都垂直, 即 $\nabla F|_{M_0}$ 垂直于 S 在 M_0 点处的切平面, 即它就是曲面 S 在 M_0 点的法向量.

定义 3.1.1 如果曲面 S 的切平面随着点在曲线上的变动而连续变动, 则称该曲面是光滑曲面 (smooth surface) .

等价地, S 光滑当且仅当它的法向量场 $\mathbf{n}(x, y, z)$ (或 F 的梯度场 ∇F) 是光滑的, 即作为映射 $\mathbf{n}: \mathbb{R}^3 \rightarrow \mathbb{R}^3 \quad M \mapsto \nabla F|_M$ 是个连续映射. 亦即, ∇F 的三个分量 F_x, F_y, F_z 皆是连续的.

例 3.1.2 求曲面 $z = x^2 + \frac{1}{4}y^2 - 1$ 上点 $(-1, -2, 1)$ 处的切平面法线方程.

解: 令 $F(x, y, z) = x^2 + \frac{1}{4}y^2 - z - 1$, 则 $\nabla F = (2x, \frac{1}{2}y, -1)$, 故曲面在 $(-1, -2, 1)$ 处的法向量为 $\mathbf{n} = \nabla F(-1, -2, 1) = (-2, -1, -1)$, 故该点处

$$\text{切平面:} \quad -2(x+1) - (y+2) - (z-1) = 0 \quad \Longleftrightarrow \quad 2x + y + z + 3 = 0$$

$$\text{法线:} \quad \frac{x+1}{2} = \frac{y+2}{1} = \frac{z-1}{2}$$

或对 $z = x^2 + \frac{1}{4}y^2 - 1$ 两边微分, 得 $dz = 2xdx + \frac{1}{2}ydy$, 代入 $(x, y, z) = (-1, -2, 1)$, 并将 dx, dy, dz 分别写为 $x+1, y+2, z-1$, 则得切线方程为 $z-1 = -2(x+1) - (y+2) = 0$.

例 3.1.3 证明球面 $x^2 + y^2 + z^2 = 2ax$ 与 $x^2 + y^2 + z^2 = 2by$, ($a, b > 0$) 是相互正交的.

证明: 球面 $x^2 + y^2 + z^2 = 2ax$ 在两球面的任一交点 (x, y, z) 处的法向量为 $\mathbf{n}_1 = (x-a, y, z)$; 球面 $x^2 + y^2 + z^2 = 2by$ 在点 (x, y, z) 处的法向量为 $\mathbf{n}_2 = (x, y-b, z)$. 故在两球面的任一交点 (x, y, z) 处, 有

$$\begin{aligned} \mathbf{n}_1 \bullet \mathbf{n}_2 &= (x-a)x + y(y-b) + zz = x^2 + y^2 + z^2 - ax - by \\ &= \frac{1}{2}(x^2 + y^2 + z^2 - 2ax) + \frac{1}{2}(x^2 + y^2 + z^2 - 2by) = 0 \end{aligned}$$

例 3.1.4 求 $f(x, y, z) = x^2 + y^2 + z^2$ 在椭球面 $\frac{x^2}{a^2} + \frac{y^2}{b^2} + \frac{z^2}{c^2} = 1$ 上的点 $P_0(x_0, y_0, z_0)$ 的外法线方向的导数.

解: 椭球面上点 P_0 处的法向量为 $\mathbf{n} = \left(\frac{2x_0}{a^2}, \frac{2y_0}{b^2}, \frac{2z_0}{c^2}\right)$, 故方向导数为

$$\begin{aligned} \nabla_{\mathbf{n}} f &= \left. \frac{\partial f}{\partial \mathbf{n}} \right|_{P_0} = \nabla f|_{P_0} \bullet \mathbf{n}^0 = (2x_0, 2y_0, 2z_0) \bullet \left(\frac{2x_0}{a^2}, \frac{2y_0}{b^2}, \frac{2z_0}{c^2}\right) \frac{1}{|\mathbf{n}|} = \\ &= \left(\frac{4x_0^2}{a^2} + \frac{4y_0^2}{b^2} + \frac{4z_0^2}{c^2}\right) \frac{1}{2\sqrt{\frac{x_0^2}{a^4} + \frac{y_0^2}{b^4} + \frac{z_0^2}{c^4}}} = 2\sqrt{\frac{x_0^2}{a^4} + \frac{y_0^2}{b^4} + \frac{z_0^2}{c^4}} \end{aligned}$$

例 3.1.5 设 $a > b > c > 0$ 为三个正数. 证明 $\mathbb{R}^3$ 中任意一点 $M(x, y, z)$ 处, 有三个二次曲面

$$\frac{x^2}{a^2 - \lambda_i^2} + \frac{y^2}{b^2 - \lambda_i^2} + \frac{z^2}{c^2 - \lambda_i^2} = -1 \quad (i = 1, 2, 3.)$$

其中 $\lambda_1, \lambda_2, \lambda_3$ 为三个两两不同的实数. 它们通过点 M , 且在 M 处两两正交.

证明: 如果三个二次曲面存在, 则下面下面的函数有三个不同的根.

$$\begin{aligned} F(\lambda^2) &= x^2(b^2 - \lambda^2)(c^2 - \lambda^2) + y^2(a^2 - \lambda^2)(c^2 - \lambda^2) + \\ &+ z^2(a^2 - \lambda^2)(b^2 - \lambda^2) + (a^2 - \lambda^2)(b^2 - \lambda^2)(c^2 - \lambda^2) \end{aligned}$$

对任意 (x, y, z) , $F(\lambda^2)$ 关于 λ^2 是个三次多项式, 故它最多有三个实根. 注意到 $F(c^2) = z^2(a^2 - c^2)(b^2 - c^2) > 0$; $F(b^2) = y^2(a^2 - b^2)(c^2 - b^2) < 0$; $F(a^2) = x^2(b^2 - a^2)(c^2 - a^2) > 0$, 又当 $\lambda^2 \rightarrow +\infty$ 时 $F(\lambda^2) < 0$. 故在区间 (c, b) , (b, a) , $(a, +\infty)$ 上, 方程 $F(\lambda^2) = 0$ 各有一根.

即在 $\mathbb{R}^3$ 中每一点 (x, y, z) , 都有形如上方程描述的三个不同的二次曲面过该点.


在 $M(x, y, z)$ 处, 三曲面的法向量为

$$\mathbf{n}_i = \left(\frac{2x}{a^2 - \lambda_i^2}, \frac{2y}{b^2 - \lambda_i^2}, \frac{2z}{c^2 - \lambda_i^2} \right) \quad i = 1, 2, 3.$$

$$\begin{aligned} \text{则 } \mathbf{n}_i \bullet \mathbf{n}_j &= \frac{4x^2}{(a^2 - \lambda_i^2)(a^2 - \lambda_j^2)} + \frac{4y^2}{(b^2 - \lambda_i^2)(b^2 - \lambda_j^2)} + \frac{4z^2}{(c^2 - \lambda_i^2)(c^2 - \lambda_j^2)} \\ &= \frac{4}{\lambda_i^2 - \lambda_j^2} \left(\frac{x^2}{a^2 - \lambda_i^2} - \frac{x^2}{a^2 - \lambda_j^2} + \frac{y^2}{b^2 - \lambda_i^2} - \frac{y^2}{b^2 - \lambda_j^2} + \frac{z^2}{c^2 - \lambda_i^2} - \frac{z^2}{c^2 - \lambda_j^2} \right) \\ &= \frac{4}{\lambda_i^2 - \lambda_j^2} \left(\left(\frac{x^2}{a^2 - \lambda_i^2} + \frac{y^2}{b^2 - \lambda_i^2} + \frac{z^2}{c^2 - \lambda_i^2} \right) - \left(\frac{x^2}{a^2 - \lambda_j^2} + \frac{y^2}{b^2 - \lambda_j^2} + \frac{z^2}{c^2 - \lambda_j^2} \right) \right) \\ &= \frac{4}{\lambda_i^2 - \lambda_j^2} ((-1) - (-1)) = 0 \end{aligned}$$

由此可知上面三族二次曲面在交点处两两正交. 所以上面三族二次曲面构成了 $\mathbb{R}^3$ 中的一个正交坐标系的坐标曲面, 类比于直角坐标系中的过 $\mathbb{R}^3$ 每一点的分别平行于 x - y , y - z , x - z 的三族坐标面.

一般方程下的曲线之切线方程求解：如果曲线 Γ 由一般方程 $\begin{cases} F(x, y, z) = 0 \\ G(x, y, z) = 0 \end{cases}$ 给出，
即作为曲面 $\Sigma_1 : F = 0$ 和曲面 $\Sigma_2 : G = 0$ 的交 $\Gamma = \Sigma_1 \cap \Sigma_2$.



首先我们要明确一下，如果 Σ_1 和 Σ_2 在 $M_0(x_0, y_0, z_0)$ 附近果能交出一条曲线，则 Σ_i 在 M_0 处的法向量 $\mathbf{n}_i (i = 1, 2)$ **必不共线**，否则由于 $\mathbf{n}_i$ 的连续性， $\mathbf{n}_i$ 将在 M_0 的某个小领域内都共线，导致两曲面在该点附近的小领域内不相交成一维的曲线，而是“黏连”成二维的一小片。由于

$$\mathbf{n}_1 = \nabla F|_{M_0} = (F_x|_{M_0}, F_y|_{M_0}, F_z|_{M_0}); \quad \mathbf{n}_2 = \nabla G|_{M_0} = (G_x|_{M_0}, G_y|_{M_0}, G_z|_{M_0})$$

则 $\mathbf{n}_1$ 和 $\mathbf{n}_2$ 在 M_0 点不共线的条件要求

$$\begin{aligned} \mathbf{n}_1 \times \mathbf{n}_2 &= \nabla F|_{M_0} \times \nabla G|_{M_0} = \begin{vmatrix} \mathbf{i} & \mathbf{j} & \mathbf{k} \\ F_x|_{M_0} & F_y|_{M_0} & F_z|_{M_0} \\ G_x|_{M_0} & G_y|_{M_0} & G_z|_{M_0} \end{vmatrix} = \\ &= \left(\begin{vmatrix} F_y|_{M_0} & F_z|_{M_0} \\ G_y|_{M_0} & G_z|_{M_0} \end{vmatrix}, \begin{vmatrix} F_z|_{M_0} & F_x|_{M_0} \\ G_z|_{M_0} & G_x|_{M_0} \end{vmatrix}, \begin{vmatrix} F_x|_{M_0} & F_y|_{M_0} \\ G_x|_{M_0} & G_y|_{M_0} \end{vmatrix} \right) \\ &= \left(\frac{\partial(F, G)}{\partial(y, z)}(M_0), \frac{\partial(F, G)}{\partial(z, x)}(M_0), \frac{\partial(F, G)}{\partial(x, y)}(M_0) \right) \neq \mathbf{0} \end{aligned}$$

直观上，曲线 $\Gamma = \Sigma_1 \cap \Sigma_2$ 在 M_0 处的切线 L_Γ 是曲面 $\Sigma_i (i = 1, 2)$ 在 M_0 点处切平面 $\pi_i (i = 1, 2)$ 的交线，即 $L_\Gamma = \pi_1 \cap \pi_2$ 。

显然，切线 L_Γ 的一个方向向量就是 $\mathbf{l} := \mathbf{n}_1 \times \mathbf{n}_2 = \nabla F|_{M_0} \times \nabla G|_{M_0}$ ，由此可知曲线 Γ 在 M_0 处的切线 L_Γ 的方程为

$$\frac{x - x_0}{\frac{\partial(F, G)}{\partial(y, z)}(M_0)} = \frac{y - y_0}{\frac{\partial(F, G)}{\partial(z, x)}(M_0)} = \frac{z - z_0}{\frac{\partial(F, G)}{\partial(x, y)}(M_0)}$$

曲线 Γ 在 M_0 处垂直于切线 L_Γ 的平面称为曲线在该点的法平面。由上，法平面方

程为

$$\frac{\partial(F, G)}{\partial(y, z)}(M_0)(x - x_0) + \frac{\partial(F, G)}{\partial(z, x)}(M_0)(y - y_0) + \frac{\partial(F, G)}{\partial(x, y)}(M_0)(z - z_0) = 0$$

即曲线在该点的法平面是由梯度向量 ∇F 和 ∇G 在该点张成的平面.

下面我们用隐函数存在定理严格处理之.

首先 $\mathbf{n}_1 \times \mathbf{n}_2 = \nabla F|_{M_0} \times \nabla G|_{M_0} \neq \mathbf{0}$ 表明: 映射 $\begin{cases} u = F(x, y, z) \\ v = G(x, y, z) \end{cases}$ 的 *Jacobi* 矩阵

$$\mathbf{J} = \begin{bmatrix} F_x & F_y & F_z \\ G_x & G_y & G_z \end{bmatrix}$$

在点 M_0 处是满秩 (*of full rank*) 的, 即 $rk(\mathbf{J}) = 2$, 故必存在具有非零行列式的二阶子方阵, 亦即 $\mathbf{n}_1 \times \mathbf{n}_2 \neq \mathbf{0}$.

$$\text{对关系 } \begin{cases} F(x, y, z) = 0 \\ G(x, y, z) = 0 \end{cases} \text{ 微分, 得到 } \begin{cases} F_x dx + F_y dy + F_z dz = 0 \\ G_x dx + G_y dy + G_z dz = 0 \end{cases}$$

由此即知, 曲面 Σ_i 在 M_0 附近相交情形的线性近似是下面两切平面的相交情形.

$$\begin{cases} F_x(M_0)(x - x_0) + F_y(M_0)(y - y_0) + F_z(M_0)(z - z_0) = 0 \\ G_x(M_0)(x - x_0) + G_y(M_0)(y - y_0) + G_z(M_0)(z - z_0) = 0 \end{cases}$$

显然, 两切平面能交处一条直线 (曲线的切线) 当且仅当其系数矩阵 (即上面的 *Jacobi* 矩阵 $\mathbf{J}$) 是满秩的.

既如此, 不妨假设 $\frac{\partial(F, G)}{\partial(y, z)} = \begin{vmatrix} F_y & F_z \\ G_y & G_z \end{vmatrix}$ 在 M_0 处不为零, 那么, 在上线性方程组的求解过程中 x 可选为自由参数 (想想为什么?). 也就是说, y 和 z 可通过 x 表示, 从而得到解 (直线) 的参数方程 (其中 x 为参数).

既然线性化的图景应当反映原曲面相交时的情形, 则切平面的位置关系表明: 两曲面 Σ_i ($i = 1, 2$) 应于 M_0 处相交于一条曲线 Γ , 且在该点处曲面的切平面 π_i ($i = 1, 2$) 和曲线的切线 L_T 之间的关系由上面的线性方程组给出.

$$\text{从而预期: 在 } M_0 \text{ 点附近, 关系 } \begin{cases} F(x, y, z) = 0 \\ G(x, y, z) = 0 \end{cases} \text{ 唯一确定了满足 } y_0 = f(x_0) \text{ 和 } z_0 = g(x_0) \text{ 的函数 } \begin{cases} y = f(x) \\ z = g(x) \end{cases} \text{ 且有 } f'(x_0) = \frac{\frac{\partial(F, G)}{\partial(z, x)}(M_0)}{\frac{\partial(F, G)}{\partial(y, z)}(M_0)}; \quad g'(x_0) = \frac{\frac{\partial(F, G)}{\partial(x, y)}(M_0)}{\frac{\partial(F, G)}{\partial(y, z)}(M_0)}.$$

注记 3.1.5 这是因为通过微分关系 $\begin{cases} F_x dx + F_y dy + F_z dz = 0 \\ G_x dx + G_y dy + G_z dz = 0 \end{cases}$, 得到 $\begin{cases} F_y \frac{dy}{dx} + F_z \frac{dz}{dx} = -F_x \\ G_y \frac{dy}{dx} + G_z \frac{dz}{dx} = -G_x \end{cases}$

然后利用解线性微分方程组的克拉默法则, 得

$$\frac{dy}{dx} = \frac{df}{dx} = \frac{\begin{vmatrix} -F_x & F_z \\ -G_x & G_z \end{vmatrix}}{\begin{vmatrix} F_y & F_z \\ G_y & G_z \end{vmatrix}} = \frac{\frac{\partial(F, G)}{\partial(z, x)}}{\frac{\partial(F, G)}{\partial(y, z)}}$$

$$\frac{dz}{dx} = \frac{dg}{dx} = \frac{\begin{vmatrix} F_y & -F_x \\ G_y & -G_x \end{vmatrix}}{\begin{vmatrix} F_y & F_z \\ G_y & G_z \end{vmatrix}} = \frac{\frac{\partial(F, G)}{\partial(x, y)}}{\frac{\partial(F, G)}{\partial(y, z)}}$$

故, 此时, 曲线 $\Gamma = \Sigma_1 \cap \Sigma_2$ 在 M_0 附近的参数方程表述为 $\begin{cases} x = x \\ y = f(x) \\ z = g(x) \end{cases}$, 它在


M_0 点处的切向量是 $\mathbf{l} = (1, f'(x_0), g'(x_0))$. 从而所求切线方程是

$$\frac{x - x_0}{1} = \frac{y - y_0}{f'(x_0)} = \frac{z - z_0}{g'(x_0)} \iff \frac{x - x_0}{1} = \frac{y - y_0}{\frac{\frac{\partial(F, G)}{\partial(z, x)}(M_0)}{\frac{\partial(F, G)}{\partial(y, z)}(M_0)}} + \frac{z - z_0}{\frac{\frac{\partial(F, G)}{\partial(x, y)}(M_0)}{\frac{\partial(F, G)}{\partial(y, z)}(M_0)}}$$

$$\iff \frac{\partial(F, G)}{\partial(y, z)}(M_0)(x - x_0) + \frac{\partial(F, G)}{\partial(z, x)}(M_0)(y - y_0) + \frac{\partial(F, G)}{\partial(x, y)}(M_0)(z - z_0) = 0$$

与我们先前通过几何直观求得的切线方程完全一致.

例 3.1.6 求球面 $x^2 + y^2 + z^2 = 4a^2$ 及柱面 $x^2 + y^2 = 2ay$ 的交线 Viviani 曲线在 $M_0(a, a, \sqrt{2}a)$ 的切线及法平面方程.



解 I: 球面和柱面在 M_0 处的法向量分别为

$$\mathbf{n}_1 = 2a(1, 1, \sqrt{2}); \quad \mathbf{n}_2 = 2a(1, 0, 0)$$

故球面和柱面在 M_0 处的切平面分别是

$$\pi_1: (x-a) + (y-a) + \sqrt{2}(z-\sqrt{2}a) = 0; \quad \pi_2: x-a = 0$$

所求交线在 M_0 处的切线就是 $\pi_1 \cap \pi_2$, 即
$$\begin{cases} (x-a) + (y-a) + \sqrt{2}(z-\sqrt{2}a) = 0 \\ x-a = 0 \end{cases}$$

这是切线的一般方程. 或者可求出切线的方向向量为

$$\mathbf{l} = \mathbf{n}_1 \times \mathbf{n}_2 = \begin{vmatrix} \mathbf{i} & \mathbf{j} & \mathbf{k} \\ 2a & 2a & 2a\sqrt{2} \\ 2a & 0 & 0 \end{vmatrix} = (0, 4a^2\sqrt{2}, -4a^2)$$

从而可写出切线的点向式方程为 $\frac{x-a}{0} = \frac{y-a}{\sqrt{2}} = \frac{z-\sqrt{2}a}{-1}$. 而曲线在该点处的法平面是与切线在该点垂直的平面, 其方程是

$$\sqrt{2}(y-a) - (z-\sqrt{2}a) = 0 \quad \Longleftrightarrow \quad \sqrt{2}y - z = 0$$

解 II: 对曲面方程在 M_0 点微分, 得到

$$\begin{cases} dx + dy + \sqrt{2}dz = 0 \\ dx = 0 \end{cases} \quad \Longleftrightarrow \quad \begin{cases} \frac{dy}{\sqrt{2}} = \frac{dz}{-1} \\ dx = 0 \end{cases}$$

$$\Longleftrightarrow \frac{dx}{0} = \frac{dy}{\sqrt{2}} = \frac{dz}{-1} \quad \Longleftrightarrow \quad \frac{x-a}{0} = \frac{y-a}{\sqrt{2}} = \frac{z-\sqrt{2}a}{-1}$$

此即所交曲线在 M_0 点的切线方程.

注记 3.1.6 上面两个曲面上的微分 (线性) 关系联立起来, 即是两曲面的交线上的微分关系, 换言之, 它是标准曲线上的线性近似, 即切线近似的. 从而将其中 dx 赋以 $x-x_0$, dy 赋以 $y-y_0$, dz 赋以 $z-z_0$ 后得到的就是过点 $M_0(x_0, y_0, z_0)$ 的切线方程.

参数形式下的曲面的切平面即法线: 如果曲面 $S \subseteq \mathbb{R}^3$ 由参数形式:
$$\begin{cases} x = x(u, v) \\ y = y(u, v) \\ z = z(u, v) \end{cases} \quad (u, v) \in$$

$D \subseteq \mathbb{R}^2$. 以曲面上点的位置矢量 (径矢) $\mathbf{r}(u, v)$ 来表示, 则该曲面可描述为 $\mathbf{r}(u, v) = (x(u, v), y(u, v), z(u, v))$, 它可以看成如下映射 (向量值函数)

$$\mathbf{r}(u, v) : \mathbb{R}^2 \longrightarrow \mathbb{R}^3 \quad (u, v) \longmapsto (x(u, v), y(u, v), z(u, v))$$


注记 3.1.7 该映射的 *Jacobi* 矩阵 为 $\mathbf{J}_{\mathbf{r}} = \begin{bmatrix} x_u & x_v \\ y_u & y_v \\ z_u & z_v \end{bmatrix}$, 即微分 $d\mathbf{r}|_{P_0}$ 将 P_0 处的增量

$$\begin{bmatrix} \Delta u \\ \Delta v \end{bmatrix} \text{ 映射为函数实际增量的线性主部 } d\mathbf{r}|_{M_0} \left(\begin{bmatrix} \Delta u \\ \Delta v \end{bmatrix} \right) = \mathbf{J}_{\mathbf{r}}(M_0) \begin{bmatrix} \Delta u \\ \Delta v \end{bmatrix}. \text{ 利用}$$

矩阵的乘法写开来, 就是
$$\begin{cases} dx = x_u du + x_v dv \\ dy = y_u du + y_v dv \\ dz = z_u du + z_v dv \end{cases} \quad \text{即其各分量线性主部的合并.}$$

如果曲面 S 在参数 (u_0, v_0) 对应的点 $M_0(x_0, y_0, z_0)$ 处有切平面, 则在直观上, 切平面由过 M_0 的两坐标曲线在该点处的切向量张成, 即由 u -曲线 $\gamma_u : \begin{cases} x = x(u, v_0) \\ y = y(u, v_0) \\ z = z(u, v_0) \end{cases}$

在 M_0 处的切向量 $\gamma'_u(u_0)$ 和 v -曲线 $\gamma_v : \begin{cases} x = x(u_0, v) \\ y = y(u_0, v) \\ z = z(u_0, v) \end{cases}$ 在 M_0 处的切向量 $\gamma'_v(v_0)$ 所张之平面 π .



其中 $\begin{cases} \gamma'_u(u_0) = (x_u(u_0, v_0), y_u(u_0, v_0), z_u(u_0, v_0)) \\ \gamma'_v(v_0) = (x_v(u_0, v_0), y_v(u_0, v_0), z_v(u_0, v_0)) \end{cases}$. 它们能张成平面当且仅当

$$\gamma'_u(u_0) \times \gamma'_v(v_0) \neq \mathbf{0} = \begin{vmatrix} \mathbf{i} & \mathbf{j} & \mathbf{k} \\ x_u(u_0, v_0) & y_u(u_0, v_0) & z_u(u_0, v_0) \\ x_v(u_0, v_0) & y_v(u_0, v_0) & z_v(u_0, v_0) \end{vmatrix} \neq \mathbf{0}$$

即 $\left(\frac{\partial(y, z)}{\partial(u, v)} \Big|_{(u_0, v_0)}, \frac{\partial(z, x)}{\partial(u, v)} \Big|_{(u_0, v_0)}, \frac{\partial(x, y)}{\partial(u, v)} \Big|_{(u_0, v_0)} \right) \neq \mathbf{0}$. 换言之, *Jacobi* 矩阵 $\mathbf{J}_r$ 是满秩的.

此时, 可取切平面 π 的法向量为 $\mathbf{n} = \boldsymbol{\gamma}'_u(u_0) \times \boldsymbol{\gamma}'_v(v_0)$, 由此即知切平面的方程为

$$\frac{\partial(y, z)}{\partial(u, v)} \Big|_{(u_0, v_0)} (x - x_0) + \frac{\partial(z, x)}{\partial(u, v)} \Big|_{(u_0, v_0)} (y - y_0) + \frac{\partial(x, y)}{\partial(u, v)} \Big|_{(u_0, v_0)} (z - z_0) = 0$$

该点处法线的方程为

$$\frac{x - x_0}{\frac{\partial(y, z)}{\partial(u, v)} \Big|_{(u_0, v_0)}} = \frac{y - y_0}{\frac{\partial(z, x)}{\partial(u, v)} \Big|_{(u_0, v_0)}} = \frac{z - z_0}{\frac{\partial(x, y)}{\partial(u, v)} \Big|_{(u_0, v_0)}}$$

下面再用隐函数存在定理对此严格处理. 由于矩阵 $\mathbf{J}_r$ 在点 (u_0, v_0) 处满秩, 不失一般性, 假设 $\frac{\partial(x, y)}{\partial(u, v)} \Big|_{(u_0, v_0)} \neq 0$. 这相当于在 M_0 的一个领域内, 可通过坐标映射的微分关系

$$\begin{cases} dx = x_u du + x_v dv \\ dy = y_u du + y_v dv \\ dz = z_u du + z_v dv \end{cases}$$

中的前两个式子 $\begin{cases} dx = x_u du + x_v dv \\ dy = y_u du + y_v dv \end{cases}$ 解出 du 和 dv , 即利用克拉默法则, 有

$$du = \frac{\begin{vmatrix} dx & x_v \\ dy & y_v \end{vmatrix}_{(u_0, v_0)}}{\begin{vmatrix} x_u & x_v \\ y_u & y_v \end{vmatrix}_{(u_0, v_0)}} = \frac{y_v(u_0, v_0)dx - x_v(u_0, v_0)dy}{\frac{\partial(x, y)}{\partial(u, v)} \Big|_{(u_0, v_0)}}$$

$$dv = \frac{\begin{vmatrix} x_u & dx \\ y_u & dy \end{vmatrix}_{(u_0, v_0)}}{\begin{vmatrix} x_u & x_v \\ y_u & y_v \end{vmatrix}_{(u_0, v_0)}} = \frac{-y_u(u_0, v_0)dx + x_u(u_0, v_0)dy}{\frac{\partial(x, y)}{\partial(u, v)} \Big|_{(u_0, v_0)}}$$

再结合微分关系中的第三个式子, 得

$$dz = z_u(u_0, v_0)du + z_v(u_0, v_0)dv =$$

$$\begin{aligned}
&= \frac{z_u(u_0, v_0)y_v(u_0, v_0) - z_v(u_0, v_0)y_u(u_0, v_0)}{\frac{\partial(x, y)}{\partial(u, v)} \Big|_{(u_0, v_0)}} dx + \\
&+ \frac{z_v(u_0, v_0)x_u(x_0, y_0) - z_u(u_0, v_0)x_v(u_0, v_0)}{\frac{\partial(x, y)}{\partial(u, v)} \Big|_{(u_0, v_0)}} dy = \frac{\frac{\partial(z, y)}{\partial(u, v)} \Big|_{(u_0, v_0)}}{\frac{\partial(x, y)}{\partial(u, v)} \Big|_{(u_0, v_0)}} dx - \frac{\frac{\partial(z, x)}{\partial(u, v)} \Big|_{(u_0, v_0)}}{\frac{\partial(x, y)}{\partial(u, v)} \Big|_{(u_0, v_0)}} dy
\end{aligned}$$

而隐函数存在定理保证了上面微分层面的关系, 在 M_0 点附近对应于函数层面的关系, 即在 M_0 的某个领域内, 存在唯一的逆映射 $\begin{cases} u = u(x, y) \\ v = v(x, y) \end{cases}$. 将其代入 $z = z(u, v)$ 之后就得到了曲面 S 在 M_0 附近的显示表达式

$$z = z(u, v) = z(u(x, y), v(x, y)) = f(x, y)$$

且成立如下偏导关系

$$\frac{\partial u}{\partial x} = \frac{\frac{\partial y}{\partial v}}{\frac{\partial(x, y)}{\partial(u, v)}}; \quad \frac{\partial v}{\partial x} = \frac{-\frac{\partial y}{\partial v}}{\frac{\partial(x, y)}{\partial(u, v)}}; \quad \frac{\partial u}{\partial y} = \frac{-\frac{\partial x}{\partial v}}{\frac{\partial(x, y)}{\partial(u, v)}}; \quad \frac{\partial v}{\partial y} = \frac{\frac{\partial x}{\partial v}}{\frac{\partial(x, y)}{\partial(u, v)}}$$

故由链式法则, 得到

$$\begin{aligned}
\frac{\partial f}{\partial x} &= \frac{\partial z}{\partial u} \frac{\partial u}{\partial x} + \frac{\partial z}{\partial v} \frac{\partial v}{\partial x} = -\frac{\partial(y, z)}{\partial(u, v)} \Big/ \frac{\partial(x, y)}{\partial(u, v)} \\
\frac{\partial f}{\partial y} &= \frac{\partial z}{\partial u} \frac{\partial u}{\partial y} + \frac{\partial z}{\partial v} \frac{\partial v}{\partial y} = -\frac{\partial(x, z)}{\partial(u, v)} \Big/ \frac{\partial(x, y)}{\partial(u, v)}
\end{aligned}$$

与上面直接通过微分关系得到的结论完全一致. 于是 S 在 M_0 点处的切平面方程 $z - z_0 = f_x(M_0)(x - x_0) + f_y(M_0)(y - y_0)$ 可写作

$$\frac{\partial(y, z)}{\partial(u, v)} \Big|_{(u_0, v_0)} (x - x_0) + \frac{\partial(z, x)}{\partial(u, v)} \Big|_{(u_0, v_0)} (y - y_0) + \frac{\partial(x, y)}{\partial(u, v)} \Big|_{(u_0, v_0)} (z - z_0) = 0$$

与通过几何直观计算出的方程是完全一致的, 从而验证了几何直观的合理性.

例 3.1.7 曲面 $\begin{cases} x = u + v \\ y = u^2 + v^2 \\ z = u^3 + v^3 \end{cases}$ 在哪些点有切平面? 并求出切平面方程.

解: 在任意 (u, v) 对应的点处, u -曲线的切向量为 $\mathbf{l}_u = (1, 2u, 3u^2)$; v -曲线的切向量为 $\mathbf{l}_v = (1, 2v, 3v^2)$. 我们计算其外积

$$\begin{aligned}\mathbf{l}_u \times \mathbf{l}_v &= \begin{vmatrix} \mathbf{i} & \mathbf{j} & \mathbf{k} \\ 1 & 2u & 3u^2 \\ 1 & 2v & 3v^2 \end{vmatrix} = \left(\begin{vmatrix} 2u & 3u^2 \\ 2v & 3v^2 \end{vmatrix}, \begin{vmatrix} 3u^2 & 1 \\ 3v^2 & 1 \end{vmatrix}, \begin{vmatrix} 1 & 2u \\ 1 & 2v \end{vmatrix} \right) \\ &= (6uv(v-u), 3u^2-3v^2, 2v-2u) = (v-u)(6uv, -3(u+v), -2)\end{aligned}$$

由此可见, 除 $u = v$ 对应的点外, 切平面是存在的, 且其法向量 $\mathbf{n} = \mathbf{l}_u \times \mathbf{l}_v$ 连续变化. 故当 $u \neq v$ 时, 对应点的切平面方程是

$$\pi_{u,v}: 6uv(x-u-v) - 3(u+v)(y-u^2-v^2) - 2(z-u^3-v^3) = 0$$


下面考察, 当 $(u, v) \rightarrow (k, k)$ 时, 切平面 $\pi_{u,v}$ 及切点的极限位置. 在 $\pi_{u,v}$ 的方程中, 令 $u = v = k$, 得到切平面族的极限状态由下方程描述

$$\pi_{k,k}: 6k^2(x-2k) - 6k(y-2k^2) - 2(z-2k^3) = 0$$

即 $3k^2x - 3ky + z = 2k^2$. 这也是切点满足的方程.

注记 3.1.8 上例中的曲面上过 (u_0, v_0) 对应的点的 u -曲线为 $l_{v_0}: \begin{cases} x = u + v_0 \\ y = u^2 + v_0^2 \\ z = u^3 + v_0^3 \end{cases};$

v -曲线为 $l_{u_0}: \begin{cases} x = v + u_0 \\ y = v^2 + u_0^2 \\ z = v^3 + u_0^3 \end{cases}$ 它们共同构成一族三次绕曲线 (*twisted cubics*). 在该点处的切向量分别为 $(1, 2u_0, 3u_0^2)$ 和 $(1, 2v_0, 3v_0^2)$.



由此看出, 当 $u_0 \neq v_0$ 时, u -曲线和 v -曲线相交于点 $(u_0 + v_0, u_0^2 + v_0^2, u_0^3 + v_0^3)$. 当参数 (u, v) 在平面趋于 $\mathbb{R}^2 \setminus \{u = v\}$ 内连续变动时, 三次绕曲线扫过一个扭面, 即上例中的曲面. 但当 (u, v) 趋于直线 $u = v$ 时, 过曲面点上的 u -曲线和 v -曲线有合一的趋势, 这些点的极限便构成了扭曲面的边界.

3.2 全微分与积分因子

对简单的常微分方程 $\frac{dy}{dx} = -\frac{y}{x}$, 除了分离变量直接积分求解为, 还可按下面的方法求得其解.

$$\frac{dy}{dx} = -\frac{y}{x} \iff ydx + xdy = 0 \iff d(xy) = 0$$

从而直接看出其通解为: $xy = C$. 其实质是微分方程可转化为全微分为零的形式, 即 $d(\cdots) = C$ 的形式. 这样的方程是直接可积的, 称为全微分方程 (*total differential equation*) 或恰当方程 (*exact equation*).

我们探讨在什么条件下, 形如 $P(x, y)dx + Q(x, y)dy = 0$ 的方程是个恰当方程? 或等价地, 可将坐标写成 $dF(x, y)$ 的形式?

首先推导其必要条件. 如果 $\exists F$, 使得 $dF = P(x, y)dx + Q(x, y)dy$, 即

$$\frac{\partial F}{\partial x}dx + \frac{\partial F}{\partial y}dy = P(x, y)dx + Q(x, y)dy$$

即 $P = \frac{\partial F}{\partial x}$, $Q = \frac{\partial F}{\partial y}$, 由此即知 $\frac{\partial P}{\partial y} = \frac{\partial^2 F}{\partial x \partial y} = \frac{\partial^2 F}{\partial y \partial x} = \frac{\partial Q}{\partial x}$, 即如果 P, Q 具有连续偏导, 则必有 $\frac{\partial^2 F}{\partial x \partial y} = \frac{\partial^2 F}{\partial y \partial x}$, 从而知:

$$\text{方程 } Pdx + Qdy = 0 \text{ 恰当 (} P, Q \text{ 具有连续偏导)} \implies \frac{\partial P}{\partial y} = \frac{\partial Q}{\partial x}$$

自然要问: 条件 $\frac{\partial P}{\partial y} = \frac{\partial Q}{\partial x}$ 是否也是方程恰当的充分条件? 答案是肯定的, 即有

定理 3.2.1 若 $\frac{\partial P}{\partial y}, \frac{\partial Q}{\partial x}$ 存在且连续, 则方程 $P(x, y)dx + Q(x, y)dy = 0$ 是全微分 (恰当) 方程的充要条件是 $\frac{\partial P}{\partial y} = \frac{\partial Q}{\partial x}$.

证明: 必要性已证, 下证充分性. 若 $\frac{\partial P}{\partial y} = \frac{\partial Q}{\partial x}$, 需构造函数 F , 使得 $\frac{\partial F}{\partial x} = P, \frac{\partial F}{\partial y} = Q$. 形式上来看, 如这样的 F 存在, 则它似乎可将 $\frac{\partial F}{\partial x} = P$ 两边对 x 积分而得 (比如在开头的例子中, $P = y, \int Pdx = \int ydx \xrightarrow{y \text{ 看成常数}} yx + C$). 受此启发, 令

$F_1(x, y) = \int P(x, y)dx$, 则由不定积分的定义, 有 $\frac{\partial F_1}{\partial x} = P(x, y)$, 且

$$\begin{aligned} \frac{\partial}{\partial x} \left(\frac{\partial F_1}{\partial y} \right) &= \frac{\partial^2 F_1}{\partial y \partial x} = \frac{\partial^2 F_1}{\partial x \partial y} = \frac{\partial P}{\partial y} \stackrel{\text{假设条件}}{=} \frac{\partial Q}{\partial x} \\ \Rightarrow \quad \frac{\partial}{\partial x} \left(\frac{\partial F_1}{\partial y} - Q \right) &\equiv 0 \quad \Rightarrow \quad \frac{\partial F_1}{\partial y} - Q \text{ 只与 } y \text{ 有关} \end{aligned}$$

我们的目标是: 找到 F , 使得它对 x 的偏导是 P , 对 y 的偏导是 Q . 虽然 F_1 满足对 x 偏导为 P 这一条件, 但其 y 偏导不易得.

对称地, 我们可以考虑 $F_2(x, y) = \int Q(x, y)dy$, 它显然满足 $\frac{\partial F_2}{\partial y} = Q(x, y)$, 但其 x 偏导未知. 自然地, 我们希望将两者能够整合为一个满足所需条件的函数 $F(x, y)$.

但如果天真地直接令 $F = F_1 + F_2$, 显然也是不行的, 因为此时 $F_x = P + \frac{\partial F_2}{\partial x}$, 也不易处理. 但如果我们将 F_1 加上一项只依赖于 y 的函数, 且其 y 导数是 Q , 则将消解此处的两难. 事实上, 这是可能的. 注意我们前面说过 $Q(x, y) - \frac{\partial F_1(x, y)}{\partial y}$ 只与 y 有关, 记其为 $\varphi(y)$, 对其积分, 得到只与 y 有关的下函数

$$\int \varphi(y)dy = \underbrace{\int Q(x, y)dy}_{F_2} - \int \frac{\partial F_1(x, y)}{\partial y} dy$$

该函数对 y 的偏导是 $Q - \frac{\partial F_1}{\partial y}$, 它与 $\frac{\partial F_1}{\partial y}$ 相加抵消后正好得到所需的 Q . 故令

$$F(x, y) := F_1(x, y) + \int \varphi(y)dy$$

则

$$\frac{\partial F}{\partial x} = \frac{\partial F_1}{\partial x} = P; \quad \frac{\partial F}{\partial y} = \frac{\partial F_1}{\partial y} + Q - \frac{\partial F_1}{\partial y} = Q$$

从而 $dF = P(x, y)dx + Q(x, y)dy$, 即方程 $P(x, y)dx + Q(x, y)dy$ 是恰当的, 其通解为 $F(x, y) = C$. $\square$

例 3.2.1 考虑方程 $\frac{dy}{dx} = \frac{y}{x}$, 它等价于 $ydx - xdy = 0$, 此时 $P = y$, $Q = -x$, $\frac{\partial P}{\partial y} = 1 \neq -1 = \frac{\partial Q}{\partial x}$. 故该方程不是恰当的. 通过分离变量后直接积分, 我们知道该方程的通

解是 $y = Cx$. 但当 $(x, y) \neq (0, 0)$ 时, 方程两边同乘因子 $\frac{1}{x^2 + y^2}$, 则方程变为

$$\frac{xdy - ydx}{x^2 + y^2} = 0 \iff \underbrace{\frac{-y}{x^2 + y^2}}_P dx + \underbrace{\frac{x}{x^2 + y^2}}_Q dy = 0$$

$$\frac{\partial P}{\partial y} = \frac{-(x^2 + y^2) + 2y^2}{(x^2 + y^2)^2} = \frac{y^2 - x^2}{(x^2 + y^2)^2} = \frac{x^2 + y^2 - 2x^2}{(x^2 + y^2)^2} = \frac{\partial Q}{\partial x}$$

故方程是恰当的, 我们按上定理证明中的思路求出相应的 F .

$$F_1(x, y) = \int P(x, y)dx = \int \frac{-y}{x^2 + y^2} dx = - \int \frac{d\left(\frac{x}{y}\right)}{1 + \left(\frac{x}{y}\right)^2} = -\arctan \frac{y}{x} + C_1$$

$$\varphi(y) = Q - \frac{\partial F_1}{\partial y} = \frac{x}{x^2 + y^2} - \left(-\frac{\frac{1}{x}}{1 + \frac{y^2}{x^2}}\right) \equiv 0$$

故 $F(x, y) = F_1(x, y) = -\arctan \frac{y}{x}$ 即为所求. 从而方程 $Pdx + Qdy = 0$ 的通解为

$$\arctan \frac{y}{x} = C, (x, y) \neq (0, 0) \iff \theta = C$$

上例中, 给方程 $Pdx + Qdy = 0$ 乘上函数因子 μ 后, 方程 $\mu Pdx + \mu Qdy = 0$ 是恰当的. 这样的因子 μ 称为是方程的积分因子 (*integral factor*). μ 满足下方程

$$\begin{aligned} \frac{\partial(\mu P)}{\partial y} = \frac{\partial(\mu Q)}{\partial x} &\iff \mu \frac{\partial P}{\partial y} + P \frac{\partial \mu}{\partial y} = \mu \frac{\partial Q}{\partial x} + P \frac{\partial Q}{\partial x} \iff \\ Q \frac{\partial \mu}{\partial x} - P \frac{\partial \mu}{\partial y} &= \mu \left(\frac{\partial P}{\partial y} - \frac{\partial Q}{\partial x} \right) \xleftrightarrow{\text{两边除 } \mu} Q \frac{\partial \ln \mu}{\partial x} - P \frac{\partial \ln \mu}{\partial y} = \frac{\partial P}{\partial y} - \frac{\partial Q}{\partial x} \end{aligned}$$

求满足上方程的 μ 往往是不易的, 但通常取个只依赖于一个变量的 μ 就行了, 比如, 若 $\frac{\partial \mu}{\partial y} = 0$, 则上方程的解可直接写出

$$\frac{\partial \ln \mu}{\partial x} = \frac{1}{Q} \left(\frac{\partial P}{\partial y} - \frac{\partial Q}{\partial x} \right) \implies \ln \mu = \int \frac{\frac{\partial P}{\partial y} - \frac{\partial Q}{\partial x}}{Q} dx$$

对上例中的方程, $\frac{1}{Q} \left(\frac{\partial P}{\partial y} - \frac{\partial Q}{\partial x} \right) = \frac{2}{-x}$, 故 $\mu = e^{\int \frac{-2dx}{x}} = \frac{1}{x^2}$, 将其乘方程两

边

$$\frac{y}{x^2}dx - \frac{1}{x}dy = 0 \iff d\left(\frac{y}{x}\right) = 0 \iff y = Cx$$

例 3.2.2 求解微分方程 $(3x^2 + y)dx + (2x^2y - x)dy = 0$.

解: 记 $P = 3x^2 + y$, $Q = 2x^2y - x$, 则

$$\frac{\partial P}{\partial y} - \frac{\partial Q}{\partial x} = 1 - (4xy - 1) = 2(1 - 2xy)$$

故方程不恰当, 但 $\frac{1}{Q} \left(\frac{\partial P}{\partial y} - \frac{\partial Q}{\partial x} \right) = \frac{2(1 - 2xy)}{x(2xy - 1)} = -\frac{2}{x}$. 由此可得方程的一个积分因子如下

$$\mu(x) = e^{\int \frac{-2dx}{x}} = \frac{1}{x^2} \quad \text{以此乘方程两边, 得}$$

$$\begin{aligned} 3dx + \frac{y}{x^2}dx + 2ydy - \frac{1}{x}dy &= 0 \iff 3dx + 2ydy + \frac{ydx - xdy}{x^2} = 0 \\ \implies 2x + y^2 + \frac{y}{x} &= C \end{aligned}$$

例 3.2.3 用积分因子法求解齐次方程 $(x + y)dx - (x - y)dy = 0$.

最后我们从积分因子角度来求解一阶线性方程 $y' + P(x)y + Q(x) = 0$. 它的齐次方程 $y' + P(x)y = 0$ 是可分离变量的方程, 有通解 $y = Ce^{-\int P(x)dx}$, 即 $ye^{\int P(x)dx} = C$

$$\implies d\left(ye^{\int P(x)dx}\right) = 0 \iff e^{\int P(x)dx}dy + yP(x)e^{\int P(x)dx} = 0$$

换言之, $e^{\int P(x)dx}$ 即是齐次方程 $y' + P(x)y = 0$ 的一个积分因子. 方程 $y' + P(x)y + Q(x) = 0$ 两边同乘该积分因子, 有

$$\begin{aligned} e^{\int P(x)dx} (dy + P(x)ydx + Q(x)dx) &= 0 \implies \\ d\left(e^{\int P(x)dx}y\right) + e^{\int P(x)dx}Q(x)dx &= 0 \implies \\ e^{\int P(x)dx}y + \int e^{\int P(x)dx}Q(x)dx &= C \\ \implies y = e^{-\int P(x)dx} \left(- \int e^{\int P(x)dx}Q(x)dx + C \right) \end{aligned}$$

即得一阶线性常微分方程的通解公式.

3.3 变量替换和坐标变换问题

本小节是复合函数求导的链式法则的综合运用. 在微积分的实际运用中, 变量替换(或坐标系转变)的操作具有基本的重要性, 它能够化繁为简、归未知为已知, 利解问题. 总之, 它是微积分具体应用的操作基础, 对其掌握务必要灵活熟练.

虽然我们通常习惯于在直角坐标系下处理问题, 但有些问题在其它坐标系下处理起来更加自然简洁, 由此, 我们需知如何将不同坐标系下的微分规则(以后还会探讨积分规则)关联起来.

平面极坐标系下的求导规则: 我们知道, 平面极坐标 (r, θ) 和平面直角坐标 (x, y) 之间的转换关系为 $\begin{cases} x = r \cos \theta \\ y = r \sin \theta \end{cases}$ 设函数 $z = f(x, y)$ 可微, 将 x, y 分别看出 r, θ 的二元函数 $x = x(r, \theta); y = y(r, \theta)$. 则将 z 看成是 r, θ 的函数 $z = f(x(r, \theta), y(r, \theta))$ 时, 由求导的链式法则, 得

$$\begin{aligned}\frac{\partial z}{\partial r} &= \frac{\partial z}{\partial x} \frac{\partial x}{\partial r} + \frac{\partial z}{\partial y} \frac{\partial y}{\partial r} = \cos \theta \frac{\partial z}{\partial x} + \sin \theta \frac{\partial z}{\partial y} \\ \frac{\partial z}{\partial \theta} &= \frac{\partial z}{\partial x} \frac{\partial x}{\partial \theta} + \frac{\partial z}{\partial y} \frac{\partial y}{\partial \theta} = -r \sin \theta \frac{\partial z}{\partial x} + r \cos \theta \frac{\partial z}{\partial y}\end{aligned}$$

将坐标变换公式看成是映射 $\mathbf{r} : \mathbb{R}^2 \rightarrow \mathbb{R}^2 (r, \theta) \mapsto (x, y)$, 则该映射的微分为

$$\begin{bmatrix} dx \\ dy \end{bmatrix} = \underbrace{\begin{bmatrix} \frac{\partial x}{\partial r} & \frac{\partial x}{\partial \theta} \\ \frac{\partial y}{\partial r} & \frac{\partial y}{\partial \theta} \end{bmatrix}}_{\mathbf{J}_r} \begin{bmatrix} dr \\ d\theta \end{bmatrix} = \underbrace{\begin{bmatrix} \cos \theta & -r \sin \theta \\ \sin \theta & r \cos \theta \end{bmatrix}}_{\mathbf{J}_r} \begin{bmatrix} dr \\ d\theta \end{bmatrix}$$

则由一阶微分的形式不变性, 知 dz 的表达不依赖于具体的坐标系, 即有

$$\begin{aligned}dz &= \frac{\partial z}{\partial x} dx + \frac{\partial z}{\partial y} dy = \frac{\partial z}{\partial r} dr + \frac{\partial z}{\partial \theta} d\theta \\ \Leftrightarrow \begin{bmatrix} \frac{\partial z}{\partial x} & \frac{\partial z}{\partial y} \end{bmatrix} \begin{bmatrix} dx \\ dy \end{bmatrix} &= \begin{bmatrix} \frac{\partial z}{\partial r} & \frac{\partial z}{\partial \theta} \end{bmatrix} \begin{bmatrix} dr \\ d\theta \end{bmatrix}\end{aligned}$$

由于 $\begin{bmatrix} dx \\ dy \end{bmatrix} = \mathbf{J}_r \begin{bmatrix} dr \\ d\theta \end{bmatrix}$, 代入上式得

$$\begin{bmatrix} \frac{\partial z}{\partial x} & \frac{\partial z}{\partial y} \end{bmatrix} \mathbf{J}_r \begin{bmatrix} dr \\ d\theta \end{bmatrix} = \begin{bmatrix} \frac{\partial z}{\partial r} & \frac{\partial z}{\partial \theta} \end{bmatrix} \begin{bmatrix} dr \\ d\theta \end{bmatrix}$$

从而得到

$$\begin{bmatrix} \frac{\partial z}{\partial r} & \frac{\partial z}{\partial \theta} \end{bmatrix} = \begin{bmatrix} \frac{\partial z}{\partial x} & \frac{\partial z}{\partial y} \end{bmatrix} \mathbf{J}_{\mathbf{r}} = \begin{bmatrix} \frac{\partial z}{\partial x} & \frac{\partial z}{\partial y} \end{bmatrix} \begin{bmatrix} \cos \theta & -r \sin \theta \\ \sin \theta & r \cos \theta \end{bmatrix}$$

这等同于一开始直接运用链式法则得计算. 如果 *Jacobi* 矩阵 $\mathbf{J}_{\mathbf{r}}$ 是可逆的, 则可从
上式解出

$$\begin{bmatrix} \frac{\partial z}{\partial x} & \frac{\partial z}{\partial y} \end{bmatrix} = \mathbf{J}_{\mathbf{r}}^{-1} \begin{bmatrix} \frac{\partial z}{\partial r} & \frac{\partial z}{\partial \theta} \end{bmatrix}$$

而矩阵可逆当且仅当其行列式不为零, 在我们情形

$$\frac{\partial(x, y)}{\partial(r, \theta)} := \det(\mathbf{J}_{\mathbf{r}}) = \begin{vmatrix} \frac{\partial x}{\partial r} & \frac{\partial x}{\partial \theta} \\ \frac{\partial y}{\partial r} & \frac{\partial y}{\partial \theta} \end{vmatrix} = \begin{vmatrix} \cos \theta & -r \sin \theta \\ \sin \theta & r \cos \theta \end{vmatrix} = r \neq 0$$

该行列式称为变换的行列式 (或 x, y 关于 r, θ 的行列式), 也称为映射 $\mathbf{r}$ 的 *Jacobi*
行列式 (*Jacobian*).

在我们的情形, $\mathbf{J}_{\mathbf{g}}^{-1} = \frac{1}{r} \begin{bmatrix} r \cos \theta & r \sin \theta \\ -\sin \theta & \cos \theta \end{bmatrix}$, 由此直接可得

$$\frac{\partial z}{\partial x} = \cos \theta \frac{\partial z}{\partial r} - \frac{1}{r} \sin \theta \frac{\partial z}{\partial \theta}; \quad \frac{\partial z}{\partial y} = \sin \theta \frac{\partial z}{\partial r} + \frac{1}{r} \cos \theta \frac{\partial z}{\partial \theta}$$

总结: 作为求偏导的微分算子, 直角坐标中下和极坐标中下的微分算子由如下关系:

$$\begin{cases} \frac{\partial}{\partial r} = \cos \theta \frac{\partial}{\partial x} + \sin \theta \frac{\partial}{\partial y} \\ \frac{\partial}{\partial \theta} = -r \sin \theta \frac{\partial}{\partial x} + r \cos \theta \frac{\partial}{\partial y} \end{cases} \quad \begin{cases} \frac{\partial}{\partial x} = \cos \theta \frac{\partial}{\partial r} + \frac{1}{r} \sin \theta \frac{\partial}{\partial \theta} \\ \frac{\partial}{\partial y} = \sin \theta \frac{\partial}{\partial r} + \frac{1}{r} \cos \theta \frac{\partial}{\partial \theta} \end{cases}$$

例 3.3.1 求函数 $u = u(x, y)$ 的梯度的模长 $|\nabla u|$ 在极坐标下的表达式.

解: 由于 $\frac{\partial u}{\partial r} = \cos \theta \frac{\partial u}{\partial x} + \sin \theta \frac{\partial u}{\partial y}$; $\frac{\partial u}{\partial \theta} = -r \sin \theta \frac{\partial u}{\partial x} + r \cos \theta \frac{\partial u}{\partial y}$, 所以

$$\begin{aligned} \left(r \frac{\partial u}{\partial r}\right)^2 + \left(\frac{\partial u}{\partial \theta}\right)^2 &= r^2 \left(\frac{\partial u}{\partial x}\right)^2 + \left(\frac{\partial u}{\partial y}\right)^2 \\ \Rightarrow |\nabla u(x, y)| &= \frac{1}{r} \sqrt{\left(r \frac{\partial u}{\partial r}\right)^2 + \left(\frac{\partial u}{\partial \theta}\right)^2} = \sqrt{\left(\frac{\partial u}{\partial r}\right)^2 + \left(\frac{1}{r} \frac{\partial u}{\partial \theta}\right)^2} \end{aligned}$$

注记 3.3.1 上面的计算结果让我们猜测梯度算子在极坐下的表达应为 $(\frac{\partial}{\partial r}, \frac{1}{r} \frac{\partial}{\partial \theta})$. 我们需溯归源头, 一探究竟.

平面直角坐标系下的梯度算子 $\nabla = (\frac{\partial}{\partial x}, \frac{\partial}{\partial y}) = \frac{\partial}{\partial x} \mathbf{i} + \frac{\partial}{\partial y} \mathbf{j}$, 将它作用于函数 u 上时, 给出了该函数的梯度 (向量) $\nabla u = (\frac{\partial u}{\partial x}, \frac{\partial u}{\partial y})$, 作为向量, 它不依赖于表达它的具体坐标系的选取, 即其坐标分量会随着坐标系的不同而变化, 但分量和基的线性组合是个不变量 (类似在不同变量下, 函数的偏导数会变化, 但其全微分, 作为偏导数与坐标微分的线性组合是不会改变的, 此即一阶微分的形式不变的内蕴解释).


我们自然要问, 直角坐标下的标准基 $\{\mathbf{i}, \mathbf{j}\}$ 在极坐标下的对应为何? 为回答该问题, 我们给予 $\mathbf{i}, \mathbf{j}$ 以新的诠释, 从而将其与坐标系选取的关联以更加实质的形式凸显出来.

平面直角坐标系的坐标曲线族为 $\begin{cases} x = \text{常数} \\ y = \text{常数} \end{cases}$ 即相互正交两族直线. 在每一点, 沿两个独立直线方向的单位向量为 $\mathbf{i} = (1, 0)$, $\mathbf{j} = (0, 1)$, 沿这两个独立方向的无穷小移动 $\begin{cases} (x, y) \rightarrow (x + \Delta x, y) \\ (x, y) \rightarrow (x, y + \Delta y) \end{cases}$ 对函数 $f(x, y)$ 的影响由沿这两个方向的方向导数 (即偏导数) 来衡量, 即

$$\begin{cases} f(x, y) \rightarrow f(x + \Delta x, y) \approx f(x, y) + \frac{\partial f}{\partial x} \Delta x \\ f(x, y) \rightarrow f(x, y + \Delta y) \approx f(x, y) + \frac{\partial f}{\partial y} \Delta y \end{cases}$$

换言之, 可将 $\mathbf{i}$ 看成直线 $y = y_0$ 在任意点 (x_0, y_0) 的切向量; 同理, 可将 $\mathbf{j}$ 看成直线 $x = x_0$ 在任意点 (x_0, y_0) 的切向量.

在该诠释下, 对极坐标 (r, θ) , 其坐标曲线族为 $\begin{cases} r = \text{常数} \\ \theta = \text{常数} \end{cases}$ 这 $\{\mathbf{i}, \mathbf{j}\}$ 在极坐标系下的对应是这两族坐标曲线在每个点处的单位切向量.



过 (r, θ) 点沿着坐标曲线 $\theta = \text{常数}$ 的坐标曲线是圆 $\begin{cases} x = r \cos \theta \\ y = r \sin \theta \end{cases}$, 它在 (r, θ) 处

的切向量为 $\theta = (x'(\theta), y'(\theta)) = (-r \sin \theta, r \cos \theta)$, 故单位切向量为 $\theta^0 = (-\sin \theta, \cos \theta)$; 同理, 过 (r, θ) 点沿着坐标曲线 $r = \text{常数}$ 的坐标曲线是射线 $\begin{cases} x(t) = r \cos \theta + \cos \theta t \\ y(t) = r \sin \theta + \sin \theta t \end{cases}$ 即 $\mathbf{r}(t) = \mathbf{r} + \mathbf{r}^0 t$, 它在 (r, θ) 处的切线为 $\mathbf{r}^0 = (\cos \theta, \sin \theta)$. 特别地, 由于 $\mathbf{r}^0 \bullet \theta^0 = 0$, 故极坐标系也是正交曲线坐标系, 即其坐标曲线在没一点都相互正交.

有了上述准备, 我们可以计算极坐标下梯度的表达式了. 将 ∇u 在平面向量构成的空间的新基 (以极坐标为准的) $\{\mathbf{r}^0, \theta^0\}$ 下做正交分解如下

$$\nabla u = (\nabla u \bullet \mathbf{r}^0) \mathbf{r}^0 + (\nabla u \bullet \theta^0) \theta^0$$

而

$$\begin{aligned} \nabla u \bullet \mathbf{r}^0 &= \cos \theta \frac{\partial u}{\partial x} + \sin \theta \frac{\partial u}{\partial y} \xrightarrow{\text{在极坐标系下表示}} \frac{\partial u}{\partial r} \\ \nabla u \bullet \theta^0 &= -\sin \theta \frac{\partial u}{\partial x} + \cos \theta \frac{\partial u}{\partial y} \xrightarrow{\text{在极坐标系下表示}} \\ &= \frac{1}{r} \left(-r \sin \theta \frac{\partial u}{\partial x} + r \cos \theta \frac{\partial u}{\partial y} \right) = \frac{1}{r} \frac{\partial u}{\partial \theta} \end{aligned}$$

从而得到 $\nabla u = \frac{\partial u}{\partial r} \mathbf{r}^0 + \frac{1}{r} \frac{\partial u}{\partial \theta} \theta^0$, 故梯度算子在极坐标下的表示为

$$\nabla = \left(\frac{\partial}{\partial r}, \frac{1}{r} \frac{\partial}{\partial \theta} \right) = \frac{\partial}{\partial r} \mathbf{r}^0 + \frac{1}{r} \frac{\partial}{\partial \theta} \theta^0$$

例 3.3.2 求平面直角坐标系下拉普拉斯算子 $\Delta = \frac{\partial^2}{\partial x^2} + \frac{\partial^2}{\partial y^2}$ 在极坐标系下的表达.

解: 对任意二阶可导函数 $z = f(x, y)$, 前面, 我们已经计算出

$$\frac{\partial z}{\partial x} = \cos \theta \frac{\partial z}{\partial r} - \frac{1}{r} \sin \theta \frac{\partial z}{\partial \theta}; \quad \frac{\partial z}{\partial y} = \sin \theta \frac{\partial z}{\partial r} + \frac{1}{r} \cos \theta \frac{\partial z}{\partial \theta}$$

继续求导

$$\begin{aligned} \frac{\partial^2 z}{\partial x^2} &= \frac{\partial}{\partial x} \left(\frac{\partial z}{\partial x} \right) = \left(\cos \theta \frac{\partial}{\partial r} - \frac{1}{r} \sin \theta \frac{\partial}{\partial \theta} \right) \frac{\partial z}{\partial x} = \\ &= \cos \theta \frac{\partial}{\partial r} \left(\frac{\partial z}{\partial x} \right) - \frac{1}{r} \sin \theta \frac{\partial}{\partial \theta} \left(\frac{\partial z}{\partial x} \right) = \cos \theta \frac{\partial}{\partial r} \left(\cos \theta \frac{\partial z}{\partial r} - \frac{1}{r} \sin \theta \frac{\partial z}{\partial \theta} \right) - \\ &\quad - \frac{1}{r} \sin \theta \frac{\partial}{\partial \theta} \left(\cos \theta \frac{\partial z}{\partial r} - \frac{1}{r} \sin \theta \frac{\partial z}{\partial \theta} \right) \\ &= \cos^2 \theta \frac{\partial^2 z}{\partial r^2} - \frac{1}{r} \sin \theta \cos \theta \frac{\partial^2 z}{\partial \theta \partial r} + \frac{1}{r^2} \sin \theta \cos \theta \frac{\partial z}{\partial \theta} - \end{aligned}$$

$$- \frac{1}{r} \sin \theta \cos \theta \frac{\partial^2 z}{\partial r \partial \theta} + \frac{1}{r} \sin^2 \theta \frac{\partial z}{\partial r} + \frac{1}{r^2} \sin^2 \theta \frac{\partial^2 z}{\partial \theta^2} + \frac{1}{r^2} \sin \theta \cos \theta \frac{\partial z}{\partial \theta}$$

同理可计算出

$$\begin{aligned} \frac{\partial^2 z}{\partial y^2} &= \sin^2 \theta \frac{\partial^2 z}{\partial r^2} + \frac{1}{r} \sin \theta \cos \theta \frac{\partial^2 z}{\partial \theta \partial r} - \frac{1}{r^2} \sin \theta \cos \theta \frac{\partial z}{\partial \theta} + \\ &+ \frac{1}{r} \cos \theta \sin \theta \frac{\partial^2 z}{\partial r \partial \theta} + \frac{1}{r^2} \cos^2 \theta \frac{\partial z}{\partial r} + \frac{1}{r^2} \cos^2 \theta \frac{\partial^2 z}{\partial \theta^2} - \frac{1}{r^2} \sin \theta \cos \theta \frac{\partial z}{\partial \theta} \end{aligned}$$


从而得到

$$\Delta u = \frac{\partial^2 z}{\partial x^2} + \frac{\partial^2 z}{\partial y^2} = \frac{\partial^2 z}{\partial r^2} + \frac{1}{r} \frac{\partial z}{\partial r} + \frac{1}{r^2} \frac{\partial^2 z}{\partial \theta^2}$$

注意, 在极坐标下, 拉普拉斯方程 $\Delta u = 0$ 的形式结构不同于其在直角坐标下的结构. 我们下面介绍一种平面坐标系, 在其中拉普拉斯方程的形式结果保持不变.

例 3.3.3 考虑平面上的坐标系 (u, v) , 它同 (x, y) 坐标之间的变换关系为
$$\begin{cases} u = x^2 - y^2 \\ v = 2xy \end{cases}$$


其坐标曲线为两族互相正交的双曲线.



坐标变换 $(x, y) \rightarrow (u, v)$ 的 *Jacobi* 矩阵为
$$\begin{bmatrix} u_x & u_y \\ v_x & v_y \end{bmatrix} = \begin{bmatrix} 2x & -2y \\ 2y & 2x \end{bmatrix},$$
 其行列

式为坐标变换的 *Jacobian* 为
$$\frac{\partial(u, v)}{\partial(x, y)} = \begin{vmatrix} 2x & -2y \\ 2y & 2x \end{vmatrix} = 4(x^2 + y^2) \neq 0,$$
 故 *Jacobi* 矩阵可逆, 由隐函数存在定理, 知 x, y 可写成 u, v 的函数, 且其微分由逆矩阵给出.

任给二阶可导函数 $z = f(x, y)$, 由上知, 它也可看成关于变量 u, v 的二阶可导函数, 即有如下变量依赖关系图



由此, 可求微商如下

$$\begin{aligned}\frac{\partial z}{\partial x} &= \frac{\partial z}{\partial u} \frac{\partial u}{\partial x} + \frac{\partial z}{\partial v} \frac{\partial v}{\partial x} = 2x \frac{\partial z}{\partial u} + 2y \frac{\partial z}{\partial v} \\ \frac{\partial z}{\partial y} &= \frac{\partial z}{\partial u} \frac{\partial u}{\partial y} + \frac{\partial z}{\partial v} \frac{\partial v}{\partial y} = -2y \frac{\partial z}{\partial u} + 2x \frac{\partial z}{\partial v} \\ \frac{\partial^2 z}{\partial x^2} &= \frac{\partial}{\partial x} \left(2x \frac{\partial z}{\partial u} + 2y \frac{\partial z}{\partial v} \right) = 2 \frac{\partial z}{\partial u} + 2x \left(\frac{\partial^2 z}{\partial u^2} \frac{\partial u}{\partial x} + \frac{\partial^2 z}{\partial u \partial v} \frac{\partial v}{\partial x} \right) + \\ &+ 2y \left(\frac{\partial^2 z}{\partial v \partial u} \frac{\partial u}{\partial x} + \frac{\partial^2 z}{\partial v^2} \frac{\partial v}{\partial x} \right) = 2 \frac{\partial z}{\partial u} + 4x^2 \frac{\partial^2 z}{\partial u^2} + 4y^2 \frac{\partial^2 z}{\partial v^2} + 4xy \frac{\partial^2 z}{\partial u \partial v} + 4xy \frac{\partial^2 z}{\partial v \partial u}\end{aligned}$$

同理可求得

$$\frac{\partial^2 z}{\partial v^2} = -2 \frac{\partial z}{\partial u} + 4y^2 \frac{\partial^2 z}{\partial u^2} + 4x^2 \frac{\partial^2 z}{\partial v^2} - 4xy \frac{\partial^2 z}{\partial u \partial v} - 4xy \frac{\partial^2 z}{\partial v \partial u}$$

从而

$$\Delta z = \frac{\partial^2 z}{\partial x^2} + \frac{\partial^2 z}{\partial y^2} = 4(x^2 + y^2) \left(\frac{\partial^2 z}{\partial u^2} + \frac{\partial^2 z}{\partial v^2} \right) = 4\sqrt{u^2 + v^2} \left(\frac{\partial^2 z}{\partial u^2} + \frac{\partial^2 z}{\partial v^2} \right)$$

故拉普拉斯方程在 $\Delta z = 0$ 在 $x-y$ 坐标和 $u-v$ 坐标中具有完全相同的形式.

下面是几则平面直角坐标和极坐标之间互动的有趣例子.

例子 3.3.4 我们已经知道 $\begin{cases} \frac{\partial}{\partial r} = \cos \theta \frac{\partial}{\partial x} + \sin \theta \frac{\partial}{\partial y} \\ \frac{\partial}{\partial \theta} = -r \sin \theta \frac{\partial}{\partial x} + r \cos \theta \frac{\partial}{\partial y} \end{cases}$ 设函数 $z = f(x, y)$ 在极坐标下的两族坐标曲线 $\begin{cases} r = \text{常数} \\ \theta = \text{常数} \end{cases}$ 上是恒定的, 则它满足的微分方程为 $\begin{cases} z_r = 0 \\ z_\theta = 0 \end{cases}$ 利用上述两坐标系之间微分的关系, 在 x, y 坐标下 z 满足的方程是

$$x \frac{\partial z}{\partial y} - y \frac{\partial z}{\partial x} = 0; \quad x \frac{\partial z}{\partial x} + y \frac{\partial z}{\partial y} = 0$$

第一个方程两边乘 x , 第二个方程两边乘 y , 然后两方程相加, 得

$$(x^2 + y^2) \frac{\partial z}{\partial y} = 0 \implies \frac{\partial z}{\partial y} = 0 \implies z = z(x)$$

又 $\frac{\partial z}{\partial x} = 0$, 从而 $z = \text{常数}$. 即若函数对两个坐标分量的偏导都为零, 则它本身是常数. 事实上, 可弱化条件, 只要求函数满足上述第二个方程即可推知它为常数, 即有

命题 3.3.1 若 $\mathbb{R}^2$ 上的可微函数 $z = f(x, y)$ 满足 $x \frac{\partial z}{\partial x} + y \frac{\partial z}{\partial y} = 0$, 则 $z \equiv$ 常数.

证明: 设 $x = r \cos \theta, y = r \sin \theta$, 取 $\mathbf{l} = (\cos \theta, \sin \theta)$, 则方向导数

$$\nabla_{\mathbf{l}} z = \frac{\partial z}{\partial \mathbf{l}} = \nabla z \bullet \mathbf{l} = \cos \theta \frac{\partial z}{\partial x} + \sin \theta \frac{\partial z}{\partial y} = 0$$

从而 z 在从原点发出的任意射线上都恒常, 即 $f(x, y) = f(0, 0) \forall (x, y) \in \mathbb{R}^2$ $\square$.

另证一: 由条件知函数 z 是零次齐次函数, 即 $\forall t \in \mathbb{R}$, 有 $f(tx, ty) = t^0 f(x, y) = f(x, y)$. 直接令 $t \rightarrow 0$, 得到 $f(x, y) = f(0, 0) \forall (x, y)$. $\square$

另证二: 令 $\varphi(t) = f(tx, ty)$, $t \geq 0$, 则 $\varphi'(t) = x f_1(tx, ty) + y f_2(tx, ty) =$

$$= \frac{1}{t} (tx f_1(tx, ty) + ty f_2(tx, ty)) = 0$$

从而 $\varphi(t)$ 为常数, 特别地 $\varphi(t) = f(tx, ty) \equiv \varphi(1) = f(x, y)$, 然后令 $t \rightarrow 0$, 则有 $f(x, y) = f(0, 0), \forall (x, y)$. $\square$

注记 3.3.2 事实上, 上命题可推广如下: 设 $\mathbf{l}_1, \mathbf{l}_2, \dots, \mathbf{l}_n$ 是 $\mathbb{R}^n$ 中的 n 个线性无关的单位向量, 若函数 f 在 $\mathbb{R}^n$ 中可微, 且 $\nabla_{\mathbf{l}_i} f = \frac{\partial f}{\partial \mathbf{l}_i} \equiv 0$ ($i = 1, 2, \dots, n$), 则 $f \equiv$ 常数. 其知名留给读者作为练习.

如只要求函数 $z = f(x, y) = f(r \cos \theta, r \sin \theta)$ 满足 $z_\theta = 0$, 即 $x \frac{\partial z}{\partial y} - y \frac{\partial z}{\partial x} = 0$, 则

$$\nabla z \bullet (x, -y) = 0$$

即其积分曲线 $x^2 + y^2 = C$ 上每点处的梯度方向垂直于向量 $(x, -y)$, 而梯度方向和曲线法线方向是共线的, 故向量场 $\mathbf{v} = (x, -y)$ 是积分曲线上的切向量场 (具体讨论见第一节中有关微分方程的向量场中的相关论述), 可看成是在该同心圆族 (极坐标下的一族坐标曲线) 上运动质点的速度场.

由于 $z_\theta = 0$, 故 z 只依赖于径向坐标 $r = \sqrt{x^2 + y^2}$, 即函数具有 $z = h(r)$ 的形式. 事实上, 如果再加一个限制条件: $z = f(x, y)$ 可分离变量, 即它能写成 $z = f(x, y) = \varphi(x)\psi(y)$ 的形式, 则该函数的形式可完全确定下来——概率论中高斯分布 (Gauss distribution) 所具有的形式.

证明: 由于 $\frac{\partial z}{\partial \theta} = -r \sin \theta \frac{\partial z}{\partial x} + r \cos \theta \frac{\partial z}{\partial y} \stackrel{z=\varphi(x)\psi(y)}{=} (-r \sin \theta) \varphi'(x) \psi(y) + r \cos \theta \varphi(x) \psi'(y)$

$$= -y \varphi'(x) \psi(y) + x \varphi(x) \psi'(y) = 0$$

故当 $x \neq 0, y \neq 0$ 时, 成立 $\frac{\varphi'(x)}{x\varphi(x)} = \frac{\psi'(y)}{y\psi(y)} = \lambda$ (其中 λ 为任一常数), 则

$$\frac{\varphi'(x)}{\varphi(x)} = \lambda x \implies \int \frac{d\varphi}{\varphi} = \int \lambda x dx \implies \varphi(x) = C_1 e^{\frac{\lambda x^2}{2}}$$

$$\frac{\psi'(y)}{\psi(y)} = \lambda y \implies \int \frac{d\psi}{\psi} = \int \lambda y dy \implies \psi(y) = C_2 e^{\frac{\lambda y^2}{2}}$$

从而

$$z = f(x, y) = \varphi(x)\psi(y) = C_1 C_2 e^{\frac{\lambda(x^2+y^2)}{2}} \stackrel{C:=C_1 C_2}{=} C e^{\frac{\lambda(x^2+y^2)}{2}} \quad \square$$

上例中的讨论涉及对偏微分方程进行变量替换以探讨其解的可能形式, 下面是这方面的更多例子.

例 3.3.5 考虑一维波动方程: $\frac{\partial^2 u}{\partial t^2} = a^2 \frac{\partial^2 u}{\partial x^2} \quad (x, t) \in \mathbb{R} \times \mathbb{R}_{\geq 0}$. 为看出其解具有的形式, 考虑变量替换 (或坐标系转化): $\begin{cases} \xi = x - at \\ \eta = x + at \end{cases}$ 我们有

$$\frac{\partial u}{\partial t} = \frac{\partial u}{\partial \xi} \frac{\partial \xi}{\partial t} + \frac{\partial u}{\partial \eta} \frac{\partial \eta}{\partial t} = -a \frac{\partial u}{\partial \xi} + a \frac{\partial u}{\partial \eta}$$

$$\frac{\partial u}{\partial x} = \frac{\partial u}{\partial \xi} \frac{\partial \xi}{\partial x} + \frac{\partial u}{\partial \eta} \frac{\partial \eta}{\partial x} = \frac{\partial u}{\partial \xi} + \frac{\partial u}{\partial \eta}$$

$$\frac{\partial^2 u}{\partial t^2} = -a \left(-a \frac{\partial^2 u}{\partial \xi^2} + a \frac{\partial^2 u}{\partial \eta \partial \xi} \right) + a \left(-a \frac{\partial^2 u}{\partial \eta \partial \xi} + a \frac{\partial^2 u}{\partial \eta^2} \right)$$

$$= a^2 \frac{\partial^2 u}{\partial \xi^2} - 2a^2 \frac{\partial^2 u}{\partial \xi \partial \eta} + a^2 \frac{\partial^2 u}{\partial \eta^2}$$

$$\frac{\partial^2 u}{\partial x^2} = \frac{\partial^2 u}{\partial \xi^2} + 2 \frac{\partial^2 u}{\partial \xi \partial \eta} + \frac{\partial^2 u}{\partial \eta^2}$$

故原方程 $\frac{\partial^2 u}{\partial t^2} = a^2 \frac{\partial^2 u}{\partial x^2}$ 在坐标 (ξ, η) 下变为 $\frac{\partial^2 u}{\partial \xi \partial \eta} = 0$, 从而

$$0 = \int \frac{\partial}{\partial \xi} \left(\frac{\partial u}{\partial \eta} \right) d\xi = \int d \left(\frac{\partial u}{\partial \eta} \right) \implies \frac{\partial u}{\partial \eta} = \tilde{f}(\eta)$$

$$\implies u = \int \frac{\partial u}{\partial \eta} d\eta + g(\xi) = \int \tilde{f}(\eta) d\eta + \phi(\xi) = f(\eta) + g(\xi)$$

其中 ϕ, ψ 为任意函数. 故一维波动方程的通解具有形式

$$u(x, t) = f(x + at) + g(x - at)$$

它是直线上两个方向上行波 $f(x + at)$ 和 $g(x - at)$ 的叠加.

注记 3.3.3 若上述波动方程满足初值条件 $\begin{cases} u(x, 0) = \varphi(x) \\ u'_t(x, 0) = \psi(x) \end{cases}$ 的特解求解如下.

首先, 由上面的通解公式, 我们有 $f(x) + g(x) = \varphi(x)$, 然后对 u 求导, 得

$$u'_t(x, t) = af'(x + at) - ag'(x - at) \implies u'_t(x, 0) = a(f'(x) - g'(x)) = \psi(x)$$

$$\implies a \int_0^x df(x) - a \int_0^x dg(x) = \int_0^x \psi(x) dx$$

$$\implies f(x) - f(0) - g(x) + g(0) = \frac{1}{a} \int_0^x \psi(x) dx$$

即 $f(x) - g(x) = \frac{1}{a} \int_0^x \psi(x) dx + C$, 结合 $f(x) + g(x) = \varphi(x)$, 解得

$$2f(x) = \varphi(x) + \frac{1}{a} \int_0^x \psi(x) dx + C; \quad 2g(x) = \varphi(x) - \frac{1}{a} \int_0^x \psi(x) dx - C$$

由此得到波动方程的达朗贝尔 (*D'Alembert*) 公式:

$$u(x, t) = f(x + at) + g(x - at) = \frac{1}{2} \left(\phi(x + at) + \phi(x - at) + \frac{1}{a} \int_{x-at}^{x+at} \psi(s) ds \right)$$

由该公式可知

1. $\forall (x, t) \in \mathbb{R} \times \mathbb{R}_{\geq 0}$, $u(x, t)$ 的值只与 $\phi(x + at), \psi(x - at)$ 和 $\psi(x)$ 在区间 $I = [x - at, x + at]$ 中的值有关. 该区间称为解的依赖区间.
2. 在初始时刻 $t = 0$, 对区间 $[x_1, x_2]$ 中的初始条件给以扰动, 则由上公式可看出, 该扰动能影响到区域 $D = \{(x, t) \mid X_1 - at \leq x \leq X_2 + at\}$ 内函数 $u(x, t)$ 的值, 因此, 该区域称为 $[X_1, X_2]$ 的影响区域.

例 3.3.6 设 $u = u(x, y), v = v(x, y)$ 具有二阶连续导数, 且它满足下面的 *Cauchy-Riemann* 方程

$$\frac{\partial u}{\partial x} = \frac{\partial v}{\partial y}; \quad \frac{\partial u}{\partial y} = -\frac{\partial v}{\partial x}$$

证明：函数 u, v 都满足 $x-y$ 坐标下的 Laplace 方程.

证明：由条件知 $\Delta u = \frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2} = \frac{\partial^2 v}{\partial y \partial x} - \frac{\partial^2 v}{\partial x \partial y} \stackrel{\text{偏导的连续性}}{=} 0$. 同理可证 $\Delta v = 0$ $\square$.

又设函数 $w = w(u, v)$ 满足 Laplace 方程 $\Delta w = \frac{\partial^2 w}{\partial u^2} + \frac{\partial^2 w}{\partial v^2} = 0$, 证明： w 也满足 $x-y$ 坐标系下的拉普拉斯方程.

证明： $\frac{\partial w}{\partial x} = \frac{\partial w}{\partial u} \frac{\partial u}{\partial x} + \frac{\partial w}{\partial v} \frac{\partial v}{\partial x}; \quad \frac{\partial w}{\partial y} = \frac{\partial w}{\partial u} \frac{\partial u}{\partial y} + \frac{\partial w}{\partial v} \frac{\partial v}{\partial y}.$

$$\begin{aligned}
 \frac{\partial^2 w}{\partial x^2} + \frac{\partial^2 w}{\partial y^2} &= \frac{\partial}{\partial x} \left(\frac{\partial w}{\partial u} \frac{\partial u}{\partial x} + \frac{\partial w}{\partial v} \frac{\partial v}{\partial x} \right) + \frac{\partial}{\partial y} \left(\frac{\partial w}{\partial u} \frac{\partial u}{\partial y} + \frac{\partial w}{\partial v} \frac{\partial v}{\partial y} \right) \\
 &= \frac{\partial w}{\partial u} \frac{\partial^2 u}{\partial x^2} + \frac{\partial u}{\partial x} \left(\frac{\partial^2 w}{\partial u^2} \frac{\partial u}{\partial x} + \frac{\partial^2 w}{\partial u \partial v} \frac{\partial v}{\partial x} \right) + \frac{\partial w}{\partial v} \frac{\partial^2 v}{\partial x^2} + \\
 &+ \frac{\partial v}{\partial x} \left(\frac{\partial^2 w}{\partial v \partial u} \frac{\partial u}{\partial x} + \frac{\partial^2 w}{\partial v^2} \frac{\partial v}{\partial x} \right) + \frac{\partial w}{\partial u} \frac{\partial^2 u}{\partial y^2} + \frac{\partial u}{\partial y} \left(\frac{\partial^2 w}{\partial u^2} \frac{\partial u}{\partial y} + \frac{\partial^2 w}{\partial u \partial v} \frac{\partial v}{\partial y} \right) \\
 &+ \frac{\partial w}{\partial v} \frac{\partial^2 v}{\partial y^2} + \frac{\partial v}{\partial y} \left(\frac{\partial^2 w}{\partial v \partial u} \frac{\partial u}{\partial y} + \frac{\partial^2 w}{\partial v^2} \frac{\partial v}{\partial y} \right) \\
 &= \frac{\partial w}{\partial u} \underbrace{\Delta u}_{=0} + \frac{\partial w}{\partial v} \underbrace{\Delta v}_{=0} + \left(\frac{\partial u}{\partial x} \right)^2 \frac{\partial^2 w}{\partial u^2} + \left(\frac{\partial u}{\partial y} \right)^2 \frac{\partial^2 w}{\partial u^2} + \left(\frac{\partial v}{\partial x} \right)^2 \frac{\partial^2 w}{\partial v^2} + \\
 &+ \left(\frac{\partial v}{\partial y} \right)^2 \frac{\partial^2 w}{\partial v^2} + 2 \underbrace{\left(\frac{\partial u}{\partial x} \frac{\partial v}{\partial x} + \frac{\partial u}{\partial y} \frac{\partial v}{\partial y} \right)}_{=0: \text{Cauchy-Riemann}} \frac{\partial^2 w}{\partial u \partial v} = \left(\left(\frac{\partial u}{\partial x} \right)^2 + \left(\frac{\partial u}{\partial y} \right)^2 \right) \frac{\partial^2 w}{\partial u^2} + \\
 &+ \left(\left(\frac{\partial v}{\partial x} \right)^2 + \left(\frac{\partial v}{\partial y} \right)^2 \right) \frac{\partial^2 w}{\partial v^2} \stackrel{\text{Cauchy-Riemann}}{=} \left(\left(\frac{\partial u}{\partial x} \right)^2 + \left(\frac{\partial u}{\partial y} \right)^2 \right) \Delta w = 0 \quad \square
 \end{aligned}$$

注记 3.3.4 由 Cauchy-Riemann 方程可推出

$$\frac{\partial u}{\partial x} \frac{\partial v}{\partial x} + \frac{\partial u}{\partial y} \frac{\partial v}{\partial y} = 0$$

这表明对函数 u, v , 成立 $\nabla u \bullet \nabla v = 0$. 根据梯度的几何意义： ∇u 是等高线族 $u(x, y) = C$ 的法向量； ∇v 是等高线族 $v(x, y) = C$ 的法向量.

由于 $\nabla u \bullet \nabla v = 0$, 即梯度场 ∇u 和 ∇v 在任意点都是相互正交的, 即知对应两族等高线也是相互正交的, 从而它们可被用来作为平面上正交坐标系的坐标曲线. 比如例 3.3.3 中的函数 $u = x^2 - y^2, v = 2xy$ 即满足 Cauchy-Riemann 方程. 以它们为坐标写出来的 Laplace 方程的形式不变性之前已验证过了, 而其一般性由上得证.

例 3.3.7 验证形如 $z = f(\sqrt{x^2 + y^2} e^{\arctan \frac{y}{x}})$ (其中 f 是任意一个连续可微函数) 这样的函数满足如下 (一阶齐次线性) 偏微分方程

$$(x+y)\frac{\partial z}{\partial x} - (x-y)\frac{\partial z}{\partial y} = 0$$

解: 由一阶微分的形式不变性, 有

$$\begin{aligned} dz &= \underbrace{f'(\sqrt{x^2 + y^2} e^{\arctan \frac{y}{x}})}_A d(\sqrt{x^2 + y^2} e^{\arctan \frac{y}{x}}) \\ &= A \left(\sqrt{x^2 + y^2} d e^{\arctan \frac{y}{x}} + e^{\arctan \frac{y}{x}} d \sqrt{x^2 + y^2} \right) = A e^{\arctan \frac{y}{x}} \sqrt{x^2 + y^2} \frac{d(\frac{y}{x})}{1 + (\frac{y}{x})^2} + \\ &\quad + A e^{\arctan \frac{y}{x}} \frac{x dx + y dy}{\sqrt{x^2 + y^2}} = A e^{\arctan \frac{y}{x}} \sqrt{x^2 + y^2} \frac{xdy - ydx}{x^2 + y^2} + A e^{\arctan \frac{y}{x}} \frac{x dx + y dy}{\sqrt{x^2 + y^2}} \\ &= A e^{\arctan \frac{y}{x}} \underbrace{\frac{-y + x}{\sqrt{x^2 + y^2}} dx}_{\frac{\partial z}{\partial x}} + A e^{\arctan \frac{y}{x}} \underbrace{\frac{x + y}{\sqrt{x^2 + y^2}} dy}_{\frac{\partial z}{\partial y}} \\ \Rightarrow (x+y)\frac{\partial z}{\partial x} - (x-y)\frac{\partial z}{\partial y} &= A e^{\arctan \frac{y}{x}} \left(\frac{(x+y)(x-y) - (x+y)(x-y)}{\sqrt{x^2 + y^2}} \right) \equiv 0 \end{aligned}$$

注记 3.3.5 上述方程的通解是空间 $\mathbb{R}^3$ 中的一族曲面, 即方程的积分曲面. 则方程表明: 积分曲面的法向量常 $\mathbf{n} = (z_x, z_y, -1)$ 与向量场 $\mathbf{v} = (x+y, -(x-y), 0)$ 是处处正交的. 注意, 此处向量场 $\mathbf{v}$ 本质上是平面向量场. 那么, 如果在空间任一点 P 处, 我们能求出向量场 $\mathbf{v}$ 所对应的积分曲线 (称为微分方程的特征曲线), 则该曲线在 P 点必于过该点的积分曲面相切, 由于对每一点都又该性质, 则不难想见: 这些特征曲线生成的曲面就是所求特征曲面, 即微分方程通解的等高面. 下就上例来验证

求 $\mathbf{v}$ 的积分曲线即求 $\frac{dy}{dx} = \frac{-(x-y)}{x+y}$ 的通解, 或 $\frac{dx}{x+y} + \frac{-dy}{x-y} = 0$. 称之为微分方程对应的特征方程. 对该齐次线性方程的积出给出其通解


$$\sqrt{x^2 + y^2} e^{\arctan \frac{y}{x}} = C$$

令 $\varphi := \sqrt{x^2 + y^2} e^{\arctan \frac{y}{x}}$, 则在通解两边同时对 x 求导, 得 $\frac{\partial \varphi}{\partial x} + \frac{\partial \varphi}{\partial y} \frac{dy}{dx} = 0$

$$\Leftrightarrow \frac{\partial \varphi}{\partial x} + \frac{\partial \varphi}{\partial y} \left(\frac{-(x-y)}{x+y} \right) = 0 \quad \Leftrightarrow \quad (x+y)\frac{\partial \varphi}{\partial x} - (x-y)\frac{\partial \varphi}{\partial y} = 0$$

即 φ 也满足原偏微分方程, 则特征方程的积分曲线 $\varphi = C$ 生成的光滑曲面是偏微分方程的一个积分曲面, 即对任意连续可微函数 f , $z = f(\varphi)$ 的图像是所有可能的积分曲面. 事实上, 过 (x_0, y_0, z_0) 的特征曲线为 $z_0 = f(\varphi)$, 当 z 连续变动时, 特征曲线也在连续变动. 另一方面, 对方程两边同乘 $\frac{\partial f}{\partial \varphi}$, 则得

$$(x+y)\frac{\partial f(\varphi)}{\partial x} - (x-y)\frac{\partial f(\varphi)}{\partial y} = 0$$



由此也看出 $f(\varphi)$ 满足方程. 上面的考量明显可推广到形如

$$X(x, y, z)\frac{\partial z}{\partial x} + Y(x, y, z)\frac{\partial z}{\partial y} = Z(x, y, z)$$

的方程, 称为一阶拟线性偏微分方程. 其积分曲面 $z = f(x, y)$ 的法向量场为 $\mathbf{n} = (z_x, z_y, -1)$, 它与向量场 $\mathbf{v} = (X(x, y, z), Y(x, y, z), Z(x, y, z))$ 处处正交, 如能求出 $\mathbf{v}$ 的积分曲线, 即下方程 (特征方程) 的通解, 则积分曲线 (特征曲线) 生成积分曲面.

$$\frac{dx}{X(x, y, z)} = \frac{dy}{Y(x, y, z)} = \frac{dz}{Z(x, y, z)}$$

比如, 对方程 $x\frac{\partial z}{\partial x} - y\frac{\partial z}{\partial y} = z$, 其特征方程为 $\frac{dx}{x} = \frac{dy}{-y} = \frac{dz}{z}$, 对其积分得到两族柱

面 $xy = C_1$ 和 $yz = C_2$, 其交线组成特征线族. 给定初始曲线 $\gamma: \begin{cases} x = t \\ y = 3t \\ z = 1 + t^2 \end{cases} \quad t > 0,$

如要求方程的积分曲面通过曲线 γ , 即要求 $3t^2 = C_1$, $3t(1 + t^2) = C_2$, 消去参数, 得到关系: $C_2 = \sqrt{3C_1}\left(1 + \frac{C_1}{3}\right)$. 利用关系: $xy = C_1$, $yz = C_2$, 得到 x, y, z 满足的关系如下, 此即为过曲线 γ 的积分曲面方程.

$$yz = \sqrt{3xy}\left(1 + \frac{1}{3}xy\right)$$

例 3.3.8 设 $z = z(x, y)$ 满足方程 $x^2 \frac{\partial z}{\partial x} + y^2 \frac{\partial z}{\partial y} = z^2$. 按上条注记, 为求其积分曲面, 先解其特征方程 $\frac{dx}{x^2} = \frac{dy}{y^2} = \frac{dz}{z^2}$, 其通解为

$$\begin{cases} \frac{1}{x} = \frac{1}{y} + C_1 \\ \frac{1}{y} = \frac{1}{z} + C_2 \end{cases} \iff \begin{cases} \frac{y-x}{xy} = C_1 \\ \frac{z-y}{yz} = C_2 \end{cases}$$


故知积分曲面的方程为 $f\left(\frac{y-x}{xy}, \frac{z-y}{yz}\right) = 0$, 其中 f 为任意二元连续可微函数.

事实上, 利用隐函数求导法则, 方程两边对 x, y 分别求导, 得

$$\begin{aligned} \frac{\partial}{\partial x}: \quad & f_1 \frac{-(xy) - (y-x)y}{(xy)^2} + f_2 \frac{yz \frac{\partial z}{\partial x} - (z-y)y \frac{\partial z}{\partial x}}{(yz)^2} = 0 \\ \implies \quad & -\frac{f_1}{x^2} + \frac{f_2}{z^2} \frac{\partial z}{\partial x} = 0 \implies x^2 \frac{\partial z}{\partial x} = \frac{f_1}{f_2} z^2 \\ \frac{\partial}{\partial y}: \quad & f_1 \frac{xy - (y-x)x}{(xy)^2} + f_2 \frac{(yz)(\frac{\partial z}{\partial y} - 1) - (z-y)(z + y \frac{\partial z}{\partial y})}{(yz)^2} = 0 \\ \implies \quad & \frac{f_1}{y^2} + \frac{f_2}{(yz)^2} \left(y^2 \frac{\partial z}{\partial y} - z^2 \right) = 0 \implies \frac{f_1}{y^2} - \frac{f_2}{y^2} + \frac{f_2}{z^2} \frac{\partial z}{\partial y} = 0 \\ \implies \quad & y^2 \frac{\partial z}{\partial y} = z^2 - \frac{f_1}{f_2} z^2 \end{aligned}$$

由此即知 $x^2 \frac{\partial z}{\partial x} + y^2 \frac{\partial z}{\partial y} = \frac{f_1}{f_2} z^2 + z^2 - \frac{f_1}{f_2} z^2 = z^2$, 符合预期. 下面我们用巧妙的变量替换将该拟线性一阶偏微分方程化为平凡形式.

设 $x = u, y = \frac{u}{1+uv}, z = \frac{u}{1+uw}$, 现将 $z = z(x, y)$ 满足的方程转化证为 $w = w(u, v)$ 满足的方程.



$$\frac{\partial z}{\partial x} = \frac{\partial}{\partial x} \left(\frac{u}{1+uw} \right) = \frac{(1+uw) - u(w + u(\frac{\partial w}{\partial u} + \frac{\partial w}{\partial v} \frac{\partial v}{\partial x}))}{(1+uw)^2}$$

$$= \frac{1 + uw - uw - u^2 \frac{\partial w}{\partial u} - u^2 \frac{\partial w}{\partial v} \frac{\partial v}{\partial x}}{(1 + uw)^2} \xrightarrow{v = \frac{1}{y} - \frac{1}{x}} \frac{1 - u^2 \frac{\partial w}{\partial u} - u^2 \frac{\partial w}{\partial v} \frac{1}{x^2}}{(1 + uw)^2}$$

$$\xrightarrow{u=x} \frac{1 - x^2 \frac{\partial w}{\partial u} - \frac{\partial w}{\partial v}}{(1 + xw)^2}$$

另一方面 $\frac{\partial z}{\partial y} = \frac{\partial}{\partial y} \left(\frac{u}{1 + uw} \right) = \frac{-u \left(u \frac{\partial w}{\partial y} \right)}{(1 + uw)^2} = \frac{-u^2 \left(\frac{\partial w}{\partial u} \frac{\partial u}{\partial y} + \frac{\partial w}{\partial v} \frac{\partial v}{\partial y} \right)}{(1 + uw)^2}$

$$\xrightarrow{v = \frac{1}{y} - \frac{1}{x}} \frac{-u^2 \frac{\partial w}{\partial v} \left(-\frac{1}{y^2} \right)}{(1 + uw)^2} \xrightarrow{u=x} \frac{\frac{u^2}{y^2} \frac{\partial w}{\partial v}}{(1 + xw)^2} \xrightarrow{y = \frac{u}{1+uv}} \frac{(1 + xv)^2 \frac{\partial w}{\partial v}}{(1 + xw)^2}$$

由此将 $x^2 \frac{\partial z}{\partial x} + y^2 \frac{\partial z}{\partial y} = z^2$ 转化如下

$$\frac{x^2 - x^4 \frac{\partial w}{\partial u} - x^2 \frac{\partial w}{\partial v}}{(1 + xw)^2} + \frac{y^2 (1 + xv)^2 \frac{\partial w}{\partial v}}{(1 + xw)^2} = z^2 = \frac{x^2}{(1 + xw)^2}$$

$$\iff x^2 - x^4 \frac{\partial w}{\partial u} - x^2 \frac{\partial w}{\partial v} + y^2 (1 + xv)^2 \frac{\partial w}{\partial v} = x^2$$

$$\xrightarrow{y = \frac{u}{1+uv}} -x^4 \frac{\partial w}{\partial u} - x^2 \frac{\partial w}{\partial v} + \frac{x^2}{(1 + xv)^2} (1 + xv)^2 \frac{\partial w}{\partial v} = 0$$

即得 $\frac{\partial w}{\partial u} = 0$. 其解显然是 $w = g(v)$, 其中 g 是任意可微函数.

利用关系 $v = \frac{1}{y} - \frac{1}{x}$ 及 $w = \frac{1}{z} - \frac{1}{x}$, 从而解具有形式 $\frac{1}{z} - \frac{1}{x} = g\left(\frac{1}{y} - \frac{1}{x}\right)$. 这相当于在先前得到的解的隐函数形式 $f\left(\frac{1}{x} - \frac{1}{y}, \frac{1}{y} - \frac{1}{z}\right) = 0$ 中分别反解出 $\frac{1}{x} - \frac{1}{y}$ 和 $\frac{1}{y} - \frac{1}{z}$, 然后相加得到 $\frac{1}{z} - \frac{1}{x}$ 的显式表达.

注记 3.3.6 对例 3.3.5 中的一维波动方程: $\frac{\partial^2 u}{\partial t^2} = a^2 \frac{\partial^2 u}{\partial x^2}$ (x, t) $\in \mathbb{R} \times \mathbb{R}_{\geq 0}$. 将其写成

$$\left(\frac{\partial}{\partial t} + a \frac{\partial}{\partial x} \right) \left(\frac{\partial}{\partial t} - a \frac{\partial}{\partial x} \right) u = 0 \quad \text{或} \quad \left(\frac{\partial}{\partial t} - a \frac{\partial}{\partial x} \right) \left(\frac{\partial}{\partial t} + a \frac{\partial}{\partial x} \right) u = 0$$

而 $\left(\frac{\partial}{\partial t} + a \frac{\partial}{\partial x} \right) u = 0$ 的特征方程是 $dt + \frac{dx}{a} = 0 \implies x = -at + C_1$

另 $\left(\frac{\partial}{\partial t} - a \frac{\partial}{\partial x} \right) u = 0$ 的特征方程是 $dt - \frac{dx}{a} = 0 \implies x = at + C_2$

故两个一阶线性偏微分方程的解分别具有 $f(x - at)$ 和 $g(x + at)$ 的形式, 其中 f, g 是任意可微函数. 由线性叠加原理, 原波动方程的解具有如下形式

$$u = f(x - at) + g(x + at)$$

3.4 函数相关及其判定 (*)

首先, 让我们回忆一下线性代数中向量线性相关 (无关) 的概念. 我们说向量 $\mathbf{v}_1, \dots, \mathbf{v}_m$ 是线性相关 (*linear dependent*) 的, 如果它们之间存在非平凡的线性关系, 即存在不全为零的数 $k_1, \dots, k_m$, 使得 $k_1\mathbf{v}_1 + \dots + k_m\mathbf{v}_m = \mathbf{0}$. 反之, 则称向量是线性无关 (*linear independent*) 的.

我们要将向量间的线性相关关系推广到一般函数之间的函数关系 (*functional relation*), 注意: 这不同于将函数看成向量时的线性相关关系. 即考虑函数之间具有的一般函数关系, 而线性关系只是一般函数关系的特殊情形.

定义 3.4.1 给出某区域 $D \subseteq \mathbb{R}^n$ 上的 m 个函数 $f_1(\mathbf{x}), \dots, f_m(\mathbf{x})$, 对 $\mathbf{x}_0 \in D \subseteq$, 我们说 $f_1, \dots, f_m$ 在 $\mathbf{x}_0$ 处函数相关 (*functionally dependent*) 如果存在一个 m -元函数 $F(y_1, \dots, y_m)$, 它在 $\mathbf{y}(\mathbf{x}_0) = (f_1(\mathbf{x}_0), \dots, f_m(\mathbf{x}_0))$ 的任意领域中不恒为零, 且有

$$F(y_1(\mathbf{x}), \dots, y_m(\mathbf{x})) \equiv 0$$

反之, 如不存在这样的非零 (平凡) F 使得在 $\mathbf{x}_0$ 的领域内成立上关系, 则称函数 $f_1, \dots, f_m$ 在 $\mathbf{x}_0$ 处函数无关. 如果在 D 内任意点处函数都是相关 (无关) 的, 则称函数在 D 内是函数相关 (无关) 的.

例 3.4.1 对函数 $u = x + y$, $v = x^2 + y^2$, $w = xy$, 它们在 $\mathbb{R}^2$ 上显然是函数相关的, 因为它们之间有关系 $u^2 = v + 2w$, 即 $F(u, v, w) \equiv 0$, 其中 $F(u, v, w) = u^2 - v - 2w$.

例 3.4.2 函数 $x = \cos \varphi \cos \theta$, $y = \cos \varphi \sin \theta$, $z = \sin \varphi$ 间有关系: $x^2 + y^2 + z^2 = 1$, 故它们在 $[0, \pi] \times [0, 2\pi]$ 上是函数相关的. 即 $F(x, y, z) \equiv 0$, 其中 $F(x, y, z) = x^2 + y^2 + z^2 - 1$.

例 3.4.3 对线性函数组
$$\begin{cases} y_1 = a_{11}x_1 + \dots + a_{1n}x_n \\ \dots \\ y_m = a_{m1}x_1 + \dots + a_{mn}x_n \end{cases}$$
 什么条件下它们是函数相关的?

分析: 如果它们函数相关, 即在 $\mathbb{R}^n$ 中任意点附近, 都存在不恒为零的函数 $F(y_1, \dots, y_m)$ 使得

$$F(a_{11}x_1 + \dots + a_{1n}x_n, \dots, a_{m1}x_1 + \dots + a_{mn}x_n) \equiv 0$$

假设 F 可微且具有连续偏导, 则对上式两边微分 (线性化), 得

$$F_1 d(a_{11}x_1 + \dots + a_{1n}x_n) + \dots + F_m d(a_{m1}x_1 + \dots + a_{mn}x_n) = 0$$

$$\Rightarrow (F_1 a_{11} + \dots + F_m a_{m1}) dx_1 + \dots + (F_1 a_{1n} + \dots + F_m a_{mn}) dx_n = 0$$

$$\begin{aligned} \Leftrightarrow \quad & \begin{bmatrix} F_1 & \cdots & F_m \end{bmatrix} \begin{bmatrix} a_{11} \\ \vdots \\ a_{m1} \end{bmatrix} dx_1 + \cdots + \begin{bmatrix} F_1 & \cdots & F_m \end{bmatrix} \begin{bmatrix} a_{1n} \\ \vdots \\ a_{mn} \end{bmatrix} dx_n = 0 \\ \Leftrightarrow \quad & \begin{bmatrix} F_1 & \cdots & F_m \end{bmatrix} \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & & \vdots \\ a_{m1} & \cdots & a_{mn} \end{bmatrix} \begin{bmatrix} dx_1 \\ \vdots \\ dx_n \end{bmatrix} = 0 \end{aligned}$$

由于 dx_i 的取值任意, 上式等价于 $\begin{bmatrix} F_1 & \cdots & F_m \end{bmatrix} \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & & \vdots \\ a_{m1} & \cdots & a_{mn} \end{bmatrix} = 0$. 故 $y_1, \dots, y_m$ 是否函数相关, 完全取决于矩阵 $A = [a_{ij}]_{m \times n}$ 的转置对应的齐次线性方程组 $A^T \mathbf{x} = \mathbf{0}$ 是否有非平凡解, 由此可知

1. 若矩阵 A 的秩 $r(A) < m$, 则函数组 $y_1, \dots, y_m$ 函数相关;
2. 若矩阵 A 的秩 $r(A) = m$, 则函数组 $y_1, \dots, y_m$ 函数无关.

注记 3.4.1 如果上面的 $y_1, \dots, y_m$ 在某点函数相关, 则由上面的讨论知: 存在不全为零的 m 个数 $F_1, \dots, F_m$, 使得

$$\begin{bmatrix} F_1 & \cdots & F_m \end{bmatrix} \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & & \vdots \\ a_{m1} & \cdots & a_{mn} \end{bmatrix} = 0$$

特别地

$$\begin{bmatrix} F_1 & \cdots & F_m \end{bmatrix} \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & & \vdots \\ a_{m1} & \cdots & a_{mn} \end{bmatrix} \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} = 0 \quad \Leftrightarrow$$

$$F_1(a_{11}x_1 + \cdots + a_{1n}x_n) + \cdots + F_m(a_{m1}x_1 + \cdots + a_{mn}x_n) = 0$$

即 $F_1y_1 + \cdots + F_my_m \equiv 0$. 即 $y_1, \dots, y_m$ 是**线性相关的**. 这同时也说明, 对线性函数组, 它函数相关当且仅当它函数相关. 而且某点处的线性相关性就能推出全局的线性相关性.

上面的例子给了我们很大的启发, 即要判定一组函数是否函数相关, 我们只需判断在线性化层面, 诸微分之间是否有线性相关关系, 然后隐函数存在定理将反推出函数层面的相关性.

定理 3.4.1 给定 m 个 n 元函数 $y_1, \dots, y_m$, 若下面的 *Jacobi* 矩阵在某点 $\mathbf{x}_0$ 处的秩为 m , 则 $y_1, \dots, y_m$ 在 $\mathbf{x}_0$ 处函数无关.

$$\mathbf{J} = \left[\frac{\partial y_i}{\partial x_j} \right]_{1 \leq i \leq m; 1 \leq j \leq n}$$

证明: 因为秩为 $r = m$, 故 *Jacobi* 矩阵 $\mathbf{J}$ 中必有行列式非零的 m -阶子矩阵, 不妨假设下面的行列式非零 (总能通过重新给变量排序而转为该情形)

$$\frac{\partial(y_1, \dots, y_m)}{\partial(x_1, \dots, x_m)} := \begin{vmatrix} \frac{\partial y_1}{\partial x_1} & \dots & \frac{\partial y_1}{\partial x_m} \\ \vdots & & \vdots \\ \frac{\partial y_m}{\partial x_1} & \dots & \frac{\partial y_m}{\partial x_m} \end{vmatrix} \neq 0$$

这表明在 $\mathbf{x}_0$ 点附近, $\begin{cases} y_1 = y_1(x_1, \dots, x_n) \\ \dots \\ y_m = y_m(x_1, \dots, x_n) \end{cases}$ 所确定的 m 个微分关系

$$\begin{cases} dy_1 = \frac{\partial y_1}{\partial x_1} dx_1 + \dots + \frac{\partial y_1}{\partial x_n} dx_n \\ dy_m = \frac{\partial y_m}{\partial x_1} dx_1 + \dots + \frac{\partial y_m}{\partial x_n} dx_n \end{cases} \quad (*)$$

是线性独立的, 但若存在 $\mathbf{y}_0 = \mathbf{y}(\mathbf{x}_0)$ 附近不恒为零的函数 F , 使得 $F(y_1, \dots, y_m) \equiv 0$, 则两边微分知他在 $\mathbf{x}_0$ 附近有非平凡线性关系: $F_1 dy_1 + \dots + F_m dy_m = 0$ $\square$

推论 3.4.1 若 $y_1, \dots, y_m$ 在 $\mathbf{x}_0$ 处函数相关, 则矩阵 $\left[\frac{\partial y_i}{\partial x_j} \right]_{1 \leq i \leq m; 1 \leq j \leq n}$ 在 $\mathbf{x}_0$ 处的秩 $r < m$.

定理 3.4.2 $\mathbf{J}$ 如定理 3.4.1 给出, 若 $r(\mathbf{J}) = r < m$, 不妨设 $\frac{\partial(y_1, \dots, y_r)}{\partial(x_1, \dots, x_r)} \neq 0$, 则在 $\mathbf{x}_0$ 附近, $y_1, \dots, y_r$ 必函数无关, 但 $y_1, \dots, y_m$ 函数相关.

证明: $y_1, \dots, y_r$ 无关性的证明完全雷同于上证明, 下证明 $y_1, \dots, y_m$ 的相关性.

在函数微分关系 (*) 中, 由于 $\frac{\partial(y_1, \dots, y_r)}{\partial(x_1, \dots, x_r)} \neq 0$, 故在 $\mathbf{x}_0$ 附近, 可从中将 $dx_1, \dots, dx_r$ 通过 $dx_{r+1}, \dots, dx_n, dy_1, \dots, dy_r$ 线性表示, 则由隐函数存在定理, 知在 $\mathbf{x}_0$ 点附近, 有

$$\text{唯一确定的函数关系} \begin{cases} x_1 = f_1(x_{r+1}, \dots, x_n, y_1, \dots, y_r) \\ \dots \\ x_r = f_r(x_{r+1}, \dots, x_n, y_1, \dots, y_r) \end{cases} \quad \text{则原函数关系变为}$$

$$\begin{cases} y_1(f_1(x_{r+1}, \dots, x_n, y_1, \dots, y_r), \dots, f_r(x_{r+1}, \dots, x_n, y_1, \dots, y_r), x_{r+1}, \dots, x_n) = \text{常数} \\ \dots \\ y_r(f_1(x_{r+1}, \dots, x_n, y_1, \dots, y_r), \dots, f_r(x_{r+1}, \dots, x_n, y_1, \dots, y_r), x_{r+1}, \dots, x_n) = \text{常数} \\ y_{r+1} = y_{r+1}(f_1(x_{r+1}, \dots, x_n, y_1, \dots, y_r), \dots, f_r(x_{r+1}, \dots, x_n, y_1, \dots, y_r), x_{r+1}, \dots, x_n) \\ \dots \\ y_m = y_m(f_1(x_{r+1}, \dots, x_n, y_1, \dots, y_r), \dots, f_r(x_{r+1}, \dots, x_n, y_1, \dots, y_r), x_{r+1}, \dots, x_n) \end{cases}$$

为证 $y_1, \dots, y_m$ 是函数相关的, 因 $y_1, \dots, y_r$ 函数无关, 故只需证明后面 $m-r$ 个函数 $y_{r+1}, \dots, y_m$ 中的每一个都和前 r 个函数 $y_1, \dots, y_r$ 是函数相关的. 这可以通过表明 $y_{r+1}, \dots, y_m$ 的表达式中其实不真正包含变量 $x_{r+1}, \dots, x_n$ 而获证, 因为一旦表明这点, 那么这些表达式就是 $y_{r+1}, \dots, y_m$ 分别与 $y_1, \dots, y_r$ 相关的函数关系了.

为此, 我们考察 $y_{r+1}, \dots, y_m$ 对 $x_{r+1}, \dots, x_n$ 的偏导数. 首先, 前 r 个函数关系对 x_{r+1} 求偏导, 得

$$\begin{cases} \sum_{i=1}^r \frac{\partial y_1}{\partial x_i} \frac{\partial f_i}{\partial x_{r+1}} + \frac{\partial y_1}{\partial x_{r+1}} = 0 \\ \dots \\ \sum_{i=1}^r \frac{\partial y_r}{\partial x_i} \frac{\partial f_i}{\partial x_{r+1}} + \frac{\partial y_r}{\partial x_{r+1}} = 0 \end{cases} \quad (**)$$

而 $\frac{\partial y_{r+1}}{\partial x_{r+1}} = \sum_{i=1}^r \frac{\partial y_{r+1}}{\partial x_i} \frac{\partial f_i}{\partial x_{r+1}} + \frac{\partial y_{r+1}}{\partial x_{r+1}}$, 但由于 $\mathbf{J} = \left[\frac{\partial y_i}{\partial x_j} \right]_{1 \leq i \leq m; 1 \leq j \leq n}$ 的秩为 r , 故 $\mathbf{J}$ 的第 $r+1$ 行可写成其前 r 行的线性组合, 即 $\exists \lambda_1, \dots, \lambda_r$, 使得

$$\frac{\partial y_{r+1}}{\partial x_i} = \lambda_1 \frac{\partial y_1}{\partial x_i} + \dots + \lambda_r \frac{\partial y_r}{\partial x_i} \quad \forall i$$

$$\begin{aligned} \text{由此可得 } \frac{\partial y_{r+1}}{\partial x_{r+1}} &= \sum_{i=1}^r \frac{\partial y_{r+1}}{\partial x_i} \frac{\partial f_i}{\partial x_{r+1}} + \frac{\partial y_{r+1}}{\partial x_{r+1}} = \sum_{i=1}^r \sum_{j=1}^r \lambda_j \frac{\partial y_j}{\partial x_i} \frac{\partial f_i}{\partial x_{r+1}} + \frac{\partial y_{r+1}}{\partial x_{r+1}} \\ &= \sum_{j=1}^r \lambda_j \left(\sum_{i=1}^r \frac{\partial y_j}{\partial x_i} \frac{\partial f_i}{\partial x_{r+1}} + \frac{\partial y_j}{\partial x_{r+1}} \right) \xrightarrow{\text{根据 } (**)} \sum_{j=1}^r 0 \equiv 0 \end{aligned}$$

同理可证其它偏导数为零, 定理由此得证. $\square$.

$$\text{例 3.4.3 对函数组} \begin{cases} u = \frac{x}{1-x-y-z} \\ v = \frac{y}{1-x-y-z} \\ w = \frac{z}{1-x-y-z} \end{cases} \quad \text{其 } Jacobi \text{ 行列式可计算为 } \frac{\partial(u, v, w)}{\partial(x, y, z)} =$$

$$= \begin{vmatrix} \frac{1-y-z}{(1-x-y-z)^2} & \frac{x}{(1-x-y-z)^2} & \frac{x}{(1-x-y-z)^2} \\ \frac{y}{(1-x-y-z)^2} & \frac{1-x-z}{(1-x-y-z)^2} & \frac{y}{(1-x-y-z)^2} \\ \frac{z}{(1-x-y-z)^2} & \frac{z}{(1-x-y-z)^2} & \frac{1-x-y}{(1-x-y-z)^2} \end{vmatrix}$$

$$= \frac{1}{(1-x-y-z)^6} \begin{vmatrix} 1 & 0 & 0 \\ y & 1-x-y-z & 0 \\ z & 0 & 1-x-y-z \end{vmatrix} = \frac{1}{(1-x-y-z)^4}$$

即 $Jacobi$ 矩阵满秩, 故函数 u, v, w 是函数无关的.

$$\text{例 3.4.4 对} \begin{cases} f(x, y) = \ln y - \ln x \\ g(x, y) = \frac{xy}{x^2 + y^2} \end{cases} \quad \text{其 } Jacobi \text{ 行列式为 } \frac{\partial(f, g)}{\partial(x, y)} =$$

$$\begin{vmatrix} -\frac{1}{x} & \frac{1}{y} \\ y \frac{y^2 - x^2}{(x^2 + y^2)^2} & x \frac{x^2 - y^2}{(x^2 + y^2)^2} \end{vmatrix} = \frac{x^2 - y^2}{(x^2 + y^2)^2} \frac{1}{xy} \begin{vmatrix} -y & x \\ -y & x \end{vmatrix} \equiv 0$$

即秩为 1, 故 f, g 必函数相关. 令

$$\begin{cases} \xi = \ln y - \ln x \\ \eta = y \end{cases}$$

$$\text{则有} \begin{cases} x = \eta e^{-\xi} \\ y = \eta \end{cases} \quad \text{那么 } g(x, y) = \frac{xy}{x^2 + y^2} = \frac{\eta^2 e^{-\xi}}{\eta^2 (1 + e^{-2\xi})} = \frac{1}{e^\xi + e^{-\xi}}$$

$$= \frac{1}{2 \cosh \xi} = \frac{1}{2 \cosh f(x, y)}$$

此即为 f, g 间的一个非平凡函数关系.

3.5 多元泰勒公式及其计算

在介绍多元形式的泰勒公式之前, 让我们先梳理一下一元情形, 以此来洞见推广的关键, 并认识到其背后形式结构之统一.

泰勒定理 (带拉格朗日余项的泰勒公式) 设一元函数 $f(x)$ 在包含点 x_0 的开区间 (a, b) 内具有 $n+1$ 阶导数, 则 $\forall x \in (a, b)$, 存在介于 x_0 与 x 之间的 ξ , 使得

$$f(x) = f(x_0) + f'(x_0)(x - x_0) + \cdots + \frac{f^{(n)}(x_0)}{n!}(x - x_0)^n + \frac{f^{(n+1)}(\xi)}{(n+1)!}(x - x_0)^{n+1}$$

拉格朗日余项也可写成 $\frac{f^{(n+1)}(x_0 + \theta(x - x_0))}{(n+1)!}(x - x_0)^{n+1}$, $\theta \in (0, 1)$ 的形式.

当 $n = 0$ 时, 上定理即为拉格朗日中值定理. 当 $x_0 = 0$ 时, 对于的泰勒公式也称为带拉格朗日余项的马克劳林公式.

我们称下面的 n 此多项式为函数 $f(x)$ 在 $x = x_0$ 处的泰勒多项式

$$P_n(x) = f(x_0) + \frac{f'(x_0)}{1!}(x - x_0) + \frac{f''(x_0)}{2!}(x - x_0)^2 + \cdots + \frac{f^{(n)}(x_0)}{n!}(x - x_0)^n$$

泰勒定理也可写成

$$f(x) = P_n(x) + o((x - x_0)^n)$$

的形式, 称为 $f(x)$ 在 $x = x_0$ 处带皮亚诺余项的 n 级泰勒公式 (展开). 当 $x_0 = 0$ 时, 也叫带皮亚诺余项的 n 级马克劳林公式 (展开).

注记 3.5.1 我们用算符语言重写一元情形时的泰勒公式, 该形式更简洁, 也将有利于多元情形的推广. 记 $\mathbb{I}_{x_0}$ 为将函数 $f(x)$ 变为 $f(x_0)$ 的一个算子, 它实现对函数 $f(x)$ 在 x_0 处取值这一功能. 算子 $\frac{d}{dx}\bigg|_{x_0}$ 将函数 $f(x)$ 变为 $\frac{df(x)}{dx}\bigg|_{x_0}$, 即对函数在 x_0 点处求导

的算子. 类似地, 我们将 $\frac{d^k}{dx^k}\bigg|_{x_0}$ 定义为取函数在 x_0 处的 k -阶导数的算子, 即

$$\frac{d^k}{dx^k}\bigg|_{x=x_0} : C^k(U(x_0, \delta)) \longrightarrow \mathbb{R} \quad f(x) \longmapsto f^{(k)}(x_0)$$

当然, 上算符可加、可减、可数乘, 即可考虑上算符的线性组合. 另外, 一个函数 $g(x)$ 也可看成是算符, 即将任意函数 $f(x)$ 以 $g(x)$ 乘之. 算符之间当然也可以复合.

则在上算符约定下, $f(x)$ 在 x_0 处的泰勒多项式可写为

$$\begin{aligned} P_n(x) &= \mathbb{I}_{x_0} f(x) + (x-x_0) \frac{d}{dx} \Big|_{x_0} f(x) + \frac{(x-x_0)^2}{2!} \frac{d^2}{dx^2} \Big|_{x_0} f(x) + \cdots + \frac{(x-x_0)^n}{n!} \frac{d^n}{dx^n} \Big|_{x_0} f(x) \\ &= \left(\mathbb{I}_{x_0} + (x-x_0) \frac{d}{dx} \Big|_{x_0} + \frac{(x-x_0)^2}{2!} \frac{d^2}{dx^2} \Big|_{x_0} + \cdots + \frac{(x-x_0)^n}{n!} \frac{d^n}{dx^n} \Big|_{x_0} \right) f(x) \\ &\stackrel{\Delta x = x - x_0}{=} \left(\mathbb{I}_{x_0} + \Delta x \frac{d}{dx} \Big|_{x_0} + \frac{1}{2!} \left(\Delta x \frac{d}{dx} \Big|_{x_0} \right)^2 + \cdots + \frac{1}{n!} \left(\Delta x \frac{d}{dx} \Big|_{x_0} \right)^n \right) f(x) \end{aligned}$$

注意, 上面我们将 $\left(\Delta x \frac{d}{dx} \Big|_{x_0} \right)^k$ 等同于 $(\Delta x)^k \frac{d^k}{dx^k} \Big|_{x_0}$. 如想写得更简洁些, 注意到上公式的结构与 e^x 的如下泰勒展开之间的形式相似性

$$e^x = 1 + x + \frac{x^2}{2!} + \cdots + \frac{x^n}{n!} + \cdots$$

而将 $P_n(x)$ 记为 $P_n(x) = (e^{\Delta x \frac{d}{dx} \Big|_{x_0}})_n f(x)$. 这里用了约定: $\left(\Delta x \frac{d}{dx} \Big|_{x_0} \right)^0 \equiv \mathbb{I}_{x_0}$;

而 $(\cdots)_n$ 表示只取展开的前 n 项.

$$\begin{aligned} &\text{由“线性叠加原理”, 则不难推测: 二元情形的展开在形式上应该是将 } \Delta x \frac{d}{dx} \Big|_{x_0} \text{ 替} \\ &\text{换为 } \Delta x \frac{\partial}{\partial x} \Big|_{(x_0, y_0)} + \Delta y \frac{\partial}{\partial y} \Big|_{(x_0, y_0)}, \text{ 即 } f(x, y) = \\ &= (e^{\Delta x \frac{\partial}{\partial x} \Big|_{(x_0, y_0)} + \Delta y \frac{\partial}{\partial y} \Big|_{(x_0, y_0)}})_n f(x, y) = f(x_0, y_0) + \left(\Delta x \frac{\partial}{\partial x} \Big|_{(x_0, y_0)} + \Delta y \frac{\partial}{\partial y} \Big|_{(x_0, y_0)} \right) f(x, y) \\ &+ \frac{1}{2!} \left(\Delta x \frac{\partial}{\partial x} \Big|_{(x_0, y_0)} + \Delta y \frac{\partial}{\partial y} \Big|_{(x_0, y_0)} \right)^2 f(x, y) + \cdots + \frac{1}{n!} \left(\Delta x \frac{\partial}{\partial x} \Big|_{(x_0, y_0)} + \Delta y \frac{\partial}{\partial y} \Big|_{(x_0, y_0)} \right)^n f(x, y) + R_n \\ &= f(x_0, y_0) + \frac{\partial f}{\partial x} \Big|_{(x_0, y_0)} (x - x_0) + \frac{\partial f}{\partial y} \Big|_{(x_0, y_0)} (y - y_0) + \\ &+ \frac{1}{2!} \left(\frac{\partial^2 f}{\partial x^2} \Big|_{(x_0, y_0)} (x - x_0)^2 + 2 \frac{\partial^2 f}{\partial x \partial y} \Big|_{(x_0, y_0)} (x - x_0)(y - y_0) + \frac{\partial^2 f}{\partial y^2} \Big|_{(x_0, y_0)} (y - y_0)^2 \right) \end{aligned}$$

$$\begin{aligned}
& + \cdots + \frac{1}{n!} \left(\frac{\partial^n f}{\partial x^n} \Big|_{(x_0, y_0)} (x-x_0)^n + \binom{n}{1} \frac{\partial^n f}{\partial x^{n-1} \partial y} \Big|_{(x_0, y_0)} (x-x_0)^{n-1} (y-y_0) + \right. \\
& + \binom{n}{2} \frac{\partial^n f}{\partial x^{n-2} \partial y^2} \Big|_{(x_0, y_0)} (x-x_0)^{n-2} (y-y_0)^2 + \cdots + \binom{n}{n-1} \frac{\partial^n f}{\partial x \partial y^{n-1}} \Big|_{(x_0, y_0)} (x-x_0) (y-y_0)^{n-1} + \\
& \left. + \frac{\partial^n f}{\partial y^n} \Big|_{(x_0, y_0)} (y-y_0)^n \right) + R_n
\end{aligned}$$

其中二项系数 $\binom{n}{k} = \frac{n!}{(n-k)!k!}$, 并用到如下符号约定:

$$\begin{aligned}
& \left(\Delta x \frac{\partial}{\partial x} \Big|_{(x_0, y_0)} + \Delta y \frac{\partial}{\partial y} \Big|_{(x_0, y_0)} \right)^k := (\Delta x)^n \frac{\partial^n}{\partial x^n} \Big|_{(x_0, y_0)} + \\
& + \cdots + \binom{n}{k} (\Delta x)^{n-k} (\Delta y)^k \frac{\partial^n}{\partial x^{n-k} \partial y^k} \Big|_{(x_0, y_0)} + \cdots + (\Delta y)^n \frac{\partial^n}{\partial y^n} \Big|_{(x_0, y_0)}
\end{aligned}$$

为验证我们的推测是否正确, 我们先计算一个简单例子.

比如对函数 $f(x, y) = e^{x+y} = e^x e^y$. 因为所谓泰勒展开, 从形式上来讲, 无非是用简单的多项式函数来近似所给函数, 所以我们只需想办法用最自然的方法找到函数的多项式逼近即可.

$$\begin{aligned}
e^{x+y} &= e^x e^y \quad \underline{\underline{\text{考虑 } (0, 0) \text{ 出的多项式逼近}}} \\
&= \left(1 + x + \frac{x^2}{2!} + \cdots + \frac{x^k}{k!} + o(x^k) \right) \left(1 + y + \frac{y^2}{2!} + \cdots + \frac{y^l}{l!} + o(y^l) \right) \quad \underline{\underline{\text{整理出前 } n \text{ 次项}}} \\
&= 1 + x + y + \frac{1}{2!} (x^2 + 2xy + y^2) + \cdots + \left(\frac{1}{n!} x^n + \cdots + \frac{1}{k!l!} x^k y^l + \frac{1}{n!} y^n \right) + o(x^n) + o(y^n) \\
&= 1 + x + y + \frac{1}{2!} (x+y)^2 + \cdots + \frac{1}{n!} (x+y)^n + o(x^n) + o(y^n)
\end{aligned}$$

这与我们的推测完全一致, 而且也可以直接将 $x+y$ 看成一个整体变量 t , 然后利用 e^t 的泰勒展开而得到所需展开!

尚需推测展开后余项的结构. 在上面的例子中, 展开到 x, y 的 n 阶后的余项为 $o(x^n) + o(y^n)$. 按之前的认识: 一元情形下的 Δx 在二元时应推广为距离 $\sqrt{(\Delta x)^2 + (\Delta y)^2}$ 的结构, 则不难推测出 $o(x^n) + o(y^n)$ 的“真实面目”应该是 $o((\sqrt{x^2 + y^2})^n)$. 下证之.

设 $m = s + t = o(x^n) + o(y^n)$, 即 $\lim_{x \rightarrow 0} \frac{s}{x^n} = \lim_{y \rightarrow 0} \frac{t}{y^n} = 0$, 则

$$\begin{aligned} \lim_{(x,y) \rightarrow (0,0)} \frac{m}{(\sqrt{x^2 + y^2})^n} &= \lim_{(x,y) \rightarrow (0,0)} \frac{s}{(\sqrt{x^2 + y^2})^n} + \lim_{(x,y) \rightarrow (0,0)} \frac{t}{(\sqrt{x^2 + y^2})^n} \\ &= \lim_{(x,y) \rightarrow (0,0)} \frac{s/x_n}{\left(\sqrt{1 + \left(\frac{y}{x}\right)^2}\right)^n} + \lim_{(x,y) \rightarrow (0,0)} \frac{t/y_n}{\left(\sqrt{\left(\frac{x}{y}\right)^2 + 1}\right)^n} = 0 \end{aligned}$$

即 $m = o(\sqrt{x^2 + y^2})^n$. 由此, 我们先猜测出二元函数泰勒公式的形式结构.

二元函数的泰勒 (Taylor) 公式: 设 $z = f(x, y)$ 在 $P_0(x_0, y_0)$ 的某领域 $U(P_0)$ 内具有 $n + 1$ 阶连续偏导数, 则

$$f(x_0 + \Delta x, y_0 + \Delta y) = \sum_{k=0}^n \frac{1}{k!} \left(\Delta x \frac{\partial}{\partial x} + \Delta y \frac{\partial}{\partial y} \right)^k \bigg|_{(x_0, y_0)} f + R_n$$

其中余项 $R_n = o(\rho^n)$ ($\rho = \sqrt{(\Delta x)^2 + (\Delta y)^2}$), 称为皮亚诺 (Peano) 型余项. 余项也可写成以下拉格朗日 (Lagrange) 型余项:

$$R_n = \frac{1}{(n+1)!} \left(\Delta x \frac{\partial}{\partial x} + \Delta y \frac{\partial}{\partial y} \right)^{n+1} \bigg|_{(x_0 + \theta \Delta x, y_0 + \theta \Delta y)} f \quad (0 < \theta < 1)$$

若取 $(x_0, y_0) = (0, 0)$, 则对于的泰勒公式称为是马克劳林 (Maclaurin) 公式.

讨论: 通过 e^{x+y} 马克劳林展开的例子, 我们至少获得两点启发: 一, 两变量 x, y “分而治之” 处理得到所需展开; 二, 二元情形的展开可通过一元情形的展开而获得. 下面我们讨论这些启发点的背后是否由一般模式, 从而找到对一般情形处理的方式.

$z = f(x, y)$ 如上假设, 则 $f(x_0 + \Delta x, y_0 + \Delta y) \xrightarrow[\text{由一元函数的泰勒公式, 得}]{\text{只看成 } x \text{ 的函数}}$

$$\begin{aligned} &\xrightarrow{\exists \theta_1 \in (0, 1)} f(x_0, y_0 + \Delta y) + \frac{\partial f}{\partial x} \bigg|_{(x_0, y_0 + \Delta y)} \Delta x + \frac{1}{2!} \frac{\partial^2 f}{\partial x^2} \bigg|_{(x_0, y_0 + \Delta y)} (\Delta x)^2 + \cdots \\ &\quad + \frac{1}{n!} \frac{\partial^n f}{\partial x^n} \bigg|_{(x_0, y_0 + \Delta y)} (\Delta x)^n + \frac{1}{(n+1)!} \frac{\partial^{(n+1)} f}{\partial x^{n+1}} \bigg|_{(x_0 + \theta_1 \Delta x, y_0 + \Delta y)} (\Delta x)^{n+1} \\ &\xrightarrow{\exists \theta_i \in (0, 1)} f(x_0, y_0) + \frac{\partial f}{\partial y} \bigg|_{(x_0, y_0)} \Delta y + \frac{1}{2!} \frac{\partial^2 f}{\partial y^2} \bigg|_{(x_0, y_0)} (\Delta y)^2 + \cdots + \frac{1}{n!} \frac{\partial^n f}{\partial y^n} \bigg|_{(x_0, y_0)} (\Delta y)^n \end{aligned}$$

$$\begin{aligned}
& + \frac{1}{(n+1)!} \frac{\partial^{(n+1)} f}{\partial y^{n+1}} \Big|_{(x_0, y_0 + \theta_2 \Delta y)} (\Delta y)^{n+1} + \frac{\partial f}{\partial x} \Big|_{(x_0, y_0)} \Delta x + \frac{\partial^2 f}{\partial x \partial y} \Big|_{(x_0, y_0)} \Delta x \Delta y + \frac{1}{2!} \frac{\partial^3 f}{\partial x \partial^2 y} \Big|_{(x_0, y_0)} \Delta x (\Delta y)^2 \\
& + \cdots + \frac{1}{(n-1)!} \frac{\partial^n f}{\partial x \partial^{n-1} y} \Big|_{(x_0, y_0)} \Delta x (\Delta y)^{n-1} + \frac{1}{n!} \frac{\partial^{(n+1)} f}{\partial x \partial^n y} \Big|_{(x_0, y_0 + \theta_3 \Delta y)} \Delta x (\Delta y)^n + \\
& + \frac{1}{2!} \frac{\partial^2 f}{\partial x^2} \Big|_{(x_0, y_0)} (\Delta x)^2 + \frac{1}{2!} \frac{\partial^3}{\partial x^2 \partial y} \Big|_{(x_0, y_0)} (\Delta x)^2 \Delta y + \frac{1}{2!2!} \frac{\partial^4 f}{\partial^2 x \partial^2 y} \Big|_{(x_0, y_0)} (\Delta x)^2 (\Delta y)^2 + \cdots \\
& + \frac{1}{2!(n-2)!} \frac{\partial^n f}{\partial^2 x \partial^{(n-2)} y} \Big|_{(x_0, y_0)} (\Delta x)^2 (\Delta y)^{n-2} + \frac{1}{2!(n-1)!} \frac{\partial^{(n+1)} f}{\partial^2 x \partial^{(n-1)} y} \Big|_{(x_0, y_0 + \theta_4 \Delta y)} (\Delta x)^2 (\Delta y)^{n-1} \\
& + \cdots + \frac{1}{n!} \frac{\partial^n f}{\partial x^n} \Big|_{(x_0, y_0)} (\Delta x)^n + \frac{1}{n!} \frac{\partial^{(n+1)} f}{\partial x^n \partial y} \Big|_{(x_0, y_0 + \theta_{n+2} \Delta y)} (\Delta x)^n \Delta y + \frac{1}{(n+1)!} \frac{\partial^{(n+1)} f}{\partial x^{n+1}} \Big|_{(x_0 + \theta_1 \Delta x, y_0 + \Delta y)} (\Delta x)^{n+1} \\
& = \sum_{k=0}^n \frac{1}{k!} \left(\Delta x \frac{\partial}{\partial x} + \Delta y \frac{\partial}{\partial y} \right)^k \Big|_{(x_0, y_0)} f + R_n \\
& \text{其中 } R_n = \frac{\partial^{(n+1)} f}{\partial x^{n+1}} \Big|_{(x_0 + \theta_1 \Delta x, y_0 + \Delta y)} (\Delta x)^{n+1} + \frac{1}{(n+1)!} \frac{\partial^{(n+1)} f}{\partial y^{n+1}} \Big|_{(x_0, y_0 + \theta_2 \Delta y)} (\Delta y)^{n+1} + \\
& + \frac{1}{n!} \frac{\partial^{(n+1)} f}{\partial x \partial^n y} \Big|_{(x_0, y_0 + \theta_3 \Delta y)} \Delta x (\Delta y)^n + \cdots + \frac{1}{n!} \frac{\partial^{(n+1)} f}{\partial x^n \partial y} \Big|_{(x_0, y_0 + \theta_{n+2} \Delta y)} (\Delta x)^n \Delta y = o\left((\sqrt{(\Delta x)^2 + (\Delta y)^2})^n\right)
\end{aligned}$$

虽“分而治之”可方便归纳出泰勒展开的正确形式，并明了其“微观机理”，但如此展开未免太繁琐，且余项不易整理。为避免繁琐，转而考虑上面提到的第二点启发，即我们是通过将 e^{x+y} 看成是 $t = x + y$ 的一元函数，并利用一元函数的泰勒公式而得到正确展开的。这一方面说明，虽展开的最终形式是唯一的（下面将证明这一点），但具体实践中，可灵活选择恰当的展开方法；另一方面也暗示一元和多元或可加以统一处理，只须从源头梳理，将一元和多元的内在一致性探明，然后利用它来做泰勒展开。

引理 3.5.1 (泰勒公式的唯一性) 设 $z = f(x, y)$ 在 $P_0(x_0, y_0)$ 的某领域 $U(P_0)$ 内具有 $n+1$ 阶连续偏导数，若存在多项式 $P_n(x, y) = a_{00}^0 + a_{10}^1(x - x_0) + a_{01}^1(y - y_0) +$

$$+ \cdots + a_{20}^2(x - x_0)^2 + a_{11}^2(x - x_0)(y - y_0) + a_{02}^2(y - y_0)^2 + \cdots + \sum_{k+l=n} a_{kl}^n(x - x_0)^k(y - y_0)^l$$

$$\text{使得 } f(x, y) = P_n(x, y) + o\left((\sqrt{(\Delta x)^2 + (\Delta y)^2})^n\right) \quad (*)$$

则该多项式必是 $f(x, y)$ 在点 $P(x_0, y_0)$ 的 n -次泰勒多项式。即

$$P_n(x, y) = \sum_{k=0}^n \frac{1}{k!} \left(\Delta x \frac{\partial}{\partial x} + \Delta y \frac{\partial}{\partial y} \right)^k \Big|_{(x_0, y_0)} f$$

证明: 令 $(x, y) = (x_0, y_0)$, 代入 (*), 得 $a_{00}^0 = f(x_0, y_0)$. 再 (*) 两边对 x 求偏导, 得

$$\frac{\partial f}{\partial x} = a_{10}^1 + (\dots)$$

又令 $(x, y) = (x_0, y_0)$, 由于括弧里的每项都将为零, 故得到 $a_{10}^1 = f_x(x_0, y_0)$. 按此模式, 逐步求其它偏导及高阶偏导, 可逐渐将多项式中的其它系数确定下来. $\square$

之前将 (全) 微分同方向导数做了对照: $df|_{P_0} \left(\begin{bmatrix} \Delta x \\ \Delta y \end{bmatrix} \right) = f_x(P_0)\Delta x + f_y(P_0)\Delta y$

$$\begin{aligned} &= \left(f_x(P_0) \frac{\Delta x}{\sqrt{(\Delta x)^2 + (\Delta y)^2}} + f_y(P_0) \frac{\Delta y}{\sqrt{(\Delta x)^2 + (\Delta y)^2}} \right) \sqrt{(\Delta x)^2 + (\Delta y)^2} \\ &= (\nabla f|_{P_0} \bullet \mathbf{u}^0) |\mathbf{u}| = \nabla_{\mathbf{u}} f|_{P_0} |\mathbf{u}| = \frac{\partial f}{\partial \mathbf{u}} \Big|_{P_0} |\mathbf{u}| \end{aligned}$$

亦即, 微分 $df|_{P_0} \left(\begin{bmatrix} \Delta x \\ \Delta y \end{bmatrix} \right)$ 计算出函数在 P_0 点处沿方向 $\mathbf{u} = (\Delta x, \Delta y)$ 的方向导数 (即变化率) 和增量向量之长 $|\mathbf{u}|$ 的乘积.

特别地, 对增量 $(\Delta x, 0) = \Delta x \mathbf{i}$, 有 $df_{P_0} \left(\begin{bmatrix} \Delta x \\ 0 \end{bmatrix} \right) = \frac{\partial f}{\partial x}(P_0)\Delta x$, 即函数在 P_0 处沿 x 轴方向的变化速率与 x 增量之积, 给出了 $(x_0, y_0) \rightarrow (x_0 + \Delta x, y_0)$ 时函数增长的线性主部; 同理, 对增量 $(0, \Delta y) = \Delta y \mathbf{j}$, 有 $df_{P_0} \left(\begin{bmatrix} 0 \\ \Delta y \end{bmatrix} \right) = \frac{\partial f}{\partial y}(P_0)\Delta y$, 即函数在 P_0 处沿 y 轴方向的变化速率与 y 增量之积, 给出了 $(x_0, y_0) \rightarrow (x_0, y_0 + \Delta y)$ 时函数增长的线性主部. 一般地, 对增量 $(\Delta x, \Delta y)$, 我们有

$$df|_{P_0} \left(\begin{bmatrix} \Delta x \\ \Delta y \end{bmatrix} \right) = \frac{\partial f}{\partial x}(P_0)\Delta x + \frac{\partial f}{\partial y}(P_0)\Delta y = \frac{\partial f}{\partial \mathbf{u}} \Big|_{P_0} |\mathbf{u}|$$

即函数在 P_0 处沿方向 $\mathbf{u} := \Delta x \mathbf{i} + \Delta y \mathbf{j}$ 的变化率 (方向导数) 与在该方向上自变量增量带来的距离增量 $|\mathbf{u}| = \sqrt{(\Delta x)^2 + (\Delta y)^2}$ 的乘积. 其共同模式为:

函数在某方向上增量的线性主部 = 该方向上函数变化率 (方向导数) $\times$ 该方向的增量向量的长度.

也就是说, 如将增量 $(\Delta x, \Delta y)$ 看成一个方向向量 $\mathbf{u}$, 则一元微分和多元微分在形式上是统一的. 这启发我们, 在处理 $f(x, y)$ 在 $P_0(x_0, y_0)$ 处的泰勒展开时, 也将 $(\Delta x, \Delta y) = (x - x_0, y - y_0)$ 看成一个固定方向, 然后转为一元模式的泰勒展开来处理. 为此, 我们先将一元函数的展开模式按方向导数的形式结构重新表示如下:

$$1. \text{ 原模式: } f(x_0 + \Delta x) = f(x_0) + f'(x_0)(x - x_0) + \frac{1}{2!} \frac{f''(x_0)}{2!} (x - x_0)^2 + \dots$$

$$2. \text{ 方向导数模式: } \frac{f(x_0 + t\Delta x) - f(x_0)}{t} \xrightarrow{t \rightarrow 0} f'(x_0)\Delta x \implies$$

$$f(x_0 + t\Delta x) = f(x_0) + tf'(x_0)\Delta x + o(t) \implies$$

$$\frac{f(x_0 + t\Delta x) - f(x_0) - tf'(x_0)\Delta x}{t^2} \xrightarrow{t \rightarrow 0} \frac{f''(x_0)}{2!} (\Delta x)^2 \implies$$

$$f(x_0 + t\Delta x) = f(x_0) + tf'(x_0)\Delta x + t^2 \frac{f''(x_0)}{2!} (\Delta x)^2 + o(t^2)$$

$$\implies \dots \dots \implies$$

$$f(x_0 + t\Delta x) = f(x_0) + tf'(x_0)\Delta x + t^2 \frac{f''(x_0)}{2!} (\Delta x)^2 + \dots + t^n \frac{f^{(n)}(x_0)}{n!} (\Delta x)^n + o(t^n)$$

$$= (e^{t\Delta x \frac{d}{dx}}|_{x_0})_n f + o(t^{n+1})$$

受此启发, 对二元函数 $f(x, y)$, 考虑其在 $P_0(x_0, y_0)$ 处的增量(向量) $\mathbf{u} := (\Delta x, \Delta y)$, 则函数沿着方向 $(\Delta x, \Delta y)$ 的变化由

$$f(P_0 + t\mathbf{u}) - f(P_0) = f(x_0 + t\Delta x, y_0 + t\Delta y) - f(x_0, y_0)$$

来衡量, 它相对于 t 的“瞬时比值”即给出沿 $\mathbf{u}$ 的方向导数 $\times |\mathbf{u}| = \nabla \bullet \mathbf{u}$, 即

$$f(x_0 + t\Delta x, y_0 + t\Delta y) - f(x_0, y_0) = t \left(\Delta x \frac{\partial}{\partial x} + \Delta y \frac{\partial}{\partial y} \right) \Big|_{(x_0, y_0)} f + o(t)$$

如需考虑 f 沿方向 $\mathbf{u}$ 的变化的二阶信息, 则考虑

$$\lim_{t \rightarrow 0} \frac{f(x_0 + t\Delta x, y_0 + t\Delta y) - f(x_0, y_0) - t \left(\Delta x \frac{\partial}{\partial x} + \Delta y \frac{\partial}{\partial y} \right) \Big|_{(x_0, y_0)} f}{t^2} \xrightarrow{\text{洛必达法则}}$$

$$\xrightarrow{\text{链式法则}} \lim_{t \rightarrow 0} \frac{\Delta x \frac{\partial f}{\partial(x_0 + t\Delta x)} + \Delta y \frac{\partial f}{\partial(y_0 + t\Delta y)} - \left(\Delta x \frac{\partial}{\partial x} + \Delta y \frac{\partial}{\partial y} \right) \Big|_{(x_0, y_0)} f}{2t}$$

$$\frac{\text{洛必达法则}}{\text{链式法则}} \frac{1}{2!} \left((\Delta x)^2 \frac{\partial^2 f}{\partial x^2} \Big|_{(x_0, y_0)} + \Delta x \Delta y \frac{\partial^2 f}{\partial x \partial y} \Big|_{(x_0, y_0)} + \Delta y \Delta x \frac{\partial^2 f}{\partial y \partial x} \Big|_{(x_0, y_0)} + (\Delta y)^2 \frac{\partial^2 f}{\partial y^2} \Big|_{(x_0, y_0)} \right) = \frac{1}{2!} \left(\Delta x \frac{\partial}{\partial x} + \Delta y \frac{\partial}{\partial y} \right)^2 \Big|_{(x_0, y_0)} f$$

故得二阶近似如下

$$f(x_0 + t\Delta x, y_0 + t\Delta y) - f(x_0, y_0) = t \left(\Delta x \frac{\partial}{\partial x} + \Delta y \frac{\partial}{\partial y} \right) \Big|_{(x_0, y_0)} f + \frac{t^2}{2!} \left(\Delta x \frac{\partial}{\partial x} + \Delta y \frac{\partial}{\partial y} \right)^2 \Big|_{(x_0, y_0)} f + o(t^2)$$

如此, 通过逐步添加高阶“微扰项”, 可得到越来越精确的近似, 此即为泰勒展开的微观机制. 值得强调的是, 借助“方向导数”背后的“意向”, 得以将一元和二元加以统一处理. 这直接启发泰勒公式的如下简洁证明.

二元泰勒公式的证明: 记 $F(t) := f(x_0 + t\Delta x, y_0 + t\Delta y)$, $t \in [0, 1]$, 则 $F(t)$ 具有 $n+1$ 阶连续导数, 故它有 n -阶 (级) 泰勒展开如下

$$F(t) = F(0) + tF'(0) + \frac{t^2}{2!!} F''(0) + \cdots + \frac{t^n}{n!} F^{(n)}(0) + \frac{t^{n+1}}{(n+1)!} F^{(n+1)}(\theta t), \quad \theta \in (0, 1)$$

下面用复合函数求导的链式法则来计算上式中的诸导数.

$$F'(t) = \Delta x \frac{\partial f}{\partial(x_0 + t\Delta x)} + \Delta y \frac{\partial f}{\partial(y_0 + t\Delta y)} = \left(\Delta x \frac{\partial}{\partial x} + \Delta y \frac{\partial}{\partial y} \right) \Big|_{(x_0 + t\Delta x, y_0 + t\Delta y)} f$$

同理 (或按上面的计算), 可得 $F''(t) = \left(\Delta x \frac{\partial}{\partial x} + \Delta y \frac{\partial}{\partial y} \right)^2 \Big|_{(x_0 + t\Delta x, y_0 + t\Delta y)} f$, 更一般地, 有

$$F^{(k)}(t) = \left(\Delta x \frac{\partial}{\partial x} + \Delta y \frac{\partial}{\partial y} \right)^k \Big|_{(x_0 + t\Delta x, y_0 + t\Delta y)} f$$

令 $t = 0$, 得到 $F^{(k)}(0) = \left(\Delta x \frac{\partial}{\partial x} + \Delta y \frac{\partial}{\partial y} \right)^k \Big|_{(x_0, y_0)} f$, $k = 0, 1, \dots, n$. 特别地, 有

$$F^{(n+1)}(\theta) = \left(\Delta x \frac{\partial}{\partial x} + \Delta y \frac{\partial}{\partial y} \right)^{n+1} \Big|_{(x_0 + \theta\Delta x, y_0 + \theta\Delta y)} f$$

将这些“数据信息”代入 $F(t)$ 的泰勒公式里头，便得到

$$F(t) = F(0) + tF'(0) + \frac{t^2}{2!!}F''(0) + \cdots + \frac{t^n}{n!}F^{(n)}(0) + \frac{t^{n+1}}{(n+1)!}F^{(n+1)}(\theta t) =$$

$$= \sum_{k=0}^n \frac{t^k}{k!} \left(\Delta x \frac{\partial}{\partial x} + \Delta y \frac{\partial}{\partial y} \right)^k \Big|_{(x_0, y_0)} f + \frac{t^{n+1}}{(n+1)!} \left(\Delta x \frac{\partial}{\partial x} + \Delta y \frac{\partial}{\partial y} \right)^{n+1} \Big|_{(x_0 + t\theta\Delta x, y_0 + t\theta\Delta y)} f$$

最后，在上式中令 $t = 1$ ，得到 $F(1) =$

$$f(x_0 + \Delta x, y_0 + \Delta y) = \sum_{k=0}^n \frac{1}{k!} \left(\Delta x \frac{\partial}{\partial x} + \Delta y \frac{\partial}{\partial y} \right)^k \Big|_{(x_0, y_0)} f + R_n$$

$$\text{其中 } R_n = \frac{1}{(n+1)!} \left(\Delta x \frac{\partial}{\partial x} + \Delta y \frac{\partial}{\partial y} \right)^{n+1} \Big|_{(x_0 + \theta\Delta x, y_0 + \theta\Delta y)} f, \quad 0 < \theta < 1. \quad \square$$

换言之，我们证明了

$$f(x, y) = \sum_{k+l=0}^n A_{kl}(x-x_0)^k(y-y_0)^l + o(\rho^n)$$

$$\text{其中 } A_{kl} = \frac{1}{k!l!} \frac{\partial^{k+l}}{\partial x^k \partial y^l} f(x_0, y_0) \quad \rho = \sqrt{(\Delta x)^2 + (\Delta y)^2}$$

特别地，一阶泰勒展开即拉格朗日中值定理，简称中值定理。二元情形时

$$f(x_0 + \Delta x, y_0 + \Delta y) - f(x_0, y_0) \stackrel{\exists \theta \in (0,1)}{=} \\ = f_x(x_0 + \theta\Delta x, y_0 + \theta\Delta y)\Delta x + f_y(x_0 + \theta\Delta x, y_0 + \theta\Delta y)\Delta y$$

上面的公式通常也称为有限增量公式。它具有重要的应用，比如，若在某平面区域 $D \subseteq \mathbb{R}^2$ 内 f 的偏导恒为零，则由上公式，任意两点处（只要任意两点的连线尚在 D 内部）的值都是相同的。这是因为在这样的平面区域内，任意两点都可以通过无穷小的折线段联结起来，在每条折线段的两端应用上面的有限增量公式（即沿着折线方向的函数改变量），可知两端点处的函数值相同。

上论述说明：要使泰勒公式成立，则所考虑区域须是满足如下被称为凸性的区域。

定义 3.5.1 设 $D \subseteq \mathbb{R}^n$ 是区域，若联结 D 内任意两点的线段都完全属于 D ，即 $\forall \mathbf{x}_0, \mathbf{x}_1 \in D, \forall t \in [0, 1]$ ，有 $\mathbf{x}_0 + t(\mathbf{x}_1 - \mathbf{x}_0) \in D$ ，那么我们称 D 为凸区域（convex domain）。

显然我们通常考虑的一个点的 δ -领域 $U(\delta)$ 是凸集。下面是泰勒展开的例子。

例 3.5.1 设 $z = f(x, y) = x^2 + y^2$, 它在 $(0, 0)$ 点的一阶泰勒展开是 0, 在 $(0, 0)$ 处的二阶泰勒展开 $P_2 = x^2 + y^2$; 在 $(0, 0)$ 处它没有更高阶的泰勒展开. 为得到它在 $(1, 1)$ 处的展开信息, 根据泰勒公式的唯一性, 对所考虑函数, 无须计算其偏导数, 而只需想法将其写成有关 $x - 1$ 和 $y - 1$ 的多项式.

$$\begin{aligned} x^2 + y^2 &= (x - 1 + 1)^2 + (y - 1 + 1)^2 = (x - 1)^2 + 2(x - 1) + 1 + (y - 1)^2 + 2(y - 1) + 1 \\ &= 2 + 2(x - 1) + 2(y - 1) + (x - 1)^2 + (y - 1)^2 \end{aligned}$$

故 f 在 $(1, 1)$ 处的一阶展开为 $P_1 = 2 + 2(x - 1) + 2(y - 1)$, 即 $f_x(1, 1) = f_y(1, 1) = 2$; 而自身乃其二阶展开, 只按中心 $(1, 1)$ 改写罢了, 即 $f_{xx}(1, 1) = f_{yy}(1, 1) = 2$.

例 3.5.2 对函数 $z = f(x, y) = (x + y)^n$, 它在 $(0, 0)$ 处的泰勒展开就是我们熟悉的二项式展开 (*binomial expansion*): $(x + y)^n = \sum_{k=0}^n \binom{n}{k} x^k y^{n-k}$, 而我们知道, 它其实等于

$$\sum_{k=0}^n \frac{1}{k!} \left(x \frac{\partial}{\partial x} + y \frac{\partial}{\partial y} \right)^k \Big|_{(0,0)} f = \sum_{i+j=0}^n A_{ij} x^i y^j$$

其中 $A_{ij} = \frac{1}{i!j!} \frac{\partial^{i+j}}{\partial x^i \partial y^j} f(0, 0)$. 故 $f(x, y) = (x + y)^n$ 在 $(0, 0)$ 处的非零导数只有:

$$\frac{\partial^n f}{\partial x^k \partial y^{n-k}} \Big|_{(0,0)} = k!(n-k)! \binom{n}{k} = k!(n-k)! \frac{n!}{k!(n-k)!} = n!, \quad k = 0, 1, \dots, n.$$

更一般地, 对 n 元对称多项式函数 $z = f(x_1, \dots, x_n) = (x_1 + \dots + x_n)^m$, 其多项展开 (*multinomial expansion*) 为

$$(x_1 + \dots + x_n)^m = \sum_{i_1 + \dots + i_n = m} \frac{m!}{i_1! \dots i_n!} x_1^{i_1} \dots x_n^{i_n}$$

与上面二元情形的模式类比, 可知对一般 n 元函数 $z = f(x_1, \dots, x_n)$, 若其可 m -阶泰勒展开, 则其形式为 $f(x_1, \dots, x_n) =$

$$= \sum_{k=0}^m \frac{1}{k!} \left(x_1 \frac{\partial}{\partial x_1} + \dots + x_n \frac{\partial}{\partial x_n} \right)^k \Big|_{(x_1^0, \dots, x_n^0)} f = \sum_{i_1 + \dots + i_n = 0}^m A_{i_1 \dots i_n} x_1^{i_1} \dots x_n^{i_n}$$

其中

$$A_{i_1 \dots i_n} = \frac{1}{i_1! \dots i_n!} \frac{\partial^{i_1 + \dots + i_n} f}{\partial x_1^{i_1} \dots \partial x_n^{i_n}} \Big|_{(x_1^0, \dots, x_n^0)}$$

由此知, 对函数 $z = (x_1 + \cdots + x_n)^m$, 其在原点处的非零导数是 m 阶的, 即

$$\left. \frac{\partial^m (x_1 + \cdots + x_n)^m}{\partial x_1^{i_1} \cdots \partial x_n^{i_n}} \right|_{(0, \dots, 0)} = m! \quad i_1 + \cdots + i_n = m.$$

例 3.5.3 对函数 $z = f(x, y) = x^y = e^{y \ln x}$, 计算其于 $(1, 4)$ 处直到 3 阶的泰勒展开.

$$e^{y \ln x} = e^{(y-4+4) \ln(1+(x-1))} = e^{4 \ln(1+(x-1))} e^{(y-4) \ln(1+(x-1))}$$

然后利用 $e^x = 1 + x + \frac{x^2}{2!} + \cdots + \frac{x^n}{n!} + o(x^n)$ 及展开

$$\ln(1+x) = x - \frac{x^2}{2} + \frac{x^3}{3} - \cdots + (-1)^{n+1} \frac{x^n}{n} + o(x^n)$$

得到 $e^{y \ln x} = e^{4 \ln(1+(x-1))} e^{(y-4) \ln(1+(x-1))} =$

$$= e^4 \left((x-1) - \frac{(x-1)^2}{2} + \frac{(x-1)^3}{3} - \cdots + (-1)^{n+1} \frac{(x-1)^n}{n} + o((x-1)^n) \right)$$

$$\times e^{(y-4) \left((x-1) - \frac{(x-1)^2}{2} + \frac{(x-1)^3}{3} - \cdots + (-1)^{n+1} \frac{(x-1)^n}{n} + o((x-1)^n) \right)} \quad \text{利用 } e^x \text{ 的展开}$$

$$= \left(1 + 4(x-1) - 2(x-1)^2 + \frac{4}{3}(x-1)^3 + \cdots + \frac{1}{2} (4(x-1) - 2(x-1)^2 + \cdots)^2 + \cdots \right)$$

$$\times \left(1 + (y-4) \left((x-1) - \frac{(x-1)^2}{2} + \cdots \right) + \frac{1}{2} (y-4)^2 \left((x-1) - \frac{(x-1)^2}{2} + \cdots \right)^2 \right.$$

$$\left. + \frac{1}{3!} (y-4)^3 ((x-1) - \cdots)^3 + \cdots \right) \quad \text{整理出关于 } (x-1) \text{ 和 } (y-4) \text{ 直到 3 阶的项}$$

$$= 1 + 4(x-1) - 2(x-1)^2 + (x-1)(y-4) + \frac{1}{2} \times 16(x-1)^2 + \frac{4}{3}(x-1)^3 - \frac{1}{2} \times 16(x-1)^3 +$$

$$+ \frac{4^3}{3!}(x-1)^3 + 4(x-1)^2(y-4) - \frac{1}{2}(x-1)^2(y-4) + \frac{1}{2}(x-1)(y-4)^2 + o(\rho^3)$$

$$\stackrel{\Delta x=x-1, \Delta y=y-4}{=} 1 + 4\Delta x + 6(\Delta x)^2 + \Delta x \Delta y + 4(\Delta x)^3 + \frac{7}{2}(\Delta x)^2 \Delta y + \frac{1}{2} \Delta x (\Delta y)^2 + o(\rho^3)$$

由泰勒展开的唯一性, 可知 $f_x(1, 4) = 4$, $f_y(1, 4) = 0$, $f_{xx}(1, 4) = 12$, $f_{yy}(1, 4) = 0$, $f_{xy}(1, 4) = f_{yx}(1, 4) = 1$, $f_{xxx}(1, 4) = 24$, $f_{xxy}(1, 4) = 7$, $f_{xyy}(1, 4) = 1$, $f_{yyy}(1, 4) = 0$.

当微分近似计算的精度不够时, 可考虑用泰勒展开给出的更高阶信息来提升精度.

比如对 $1.08^{3.96}$ 的估计, 可利用上面 $f(x, y) = x^y$ 在 $(1, 4)$ 处的泰勒展开加以近似. 令 $\Delta x = 0.08$, $\Delta y = -0.04$, 则有

1. 一阶近似: $1.08^{3.96} \approx 1 + 4\Delta x = 1 + 4 \times 0.08 = 1.32$.
2. 二阶近似: $1.08^{3.96} \approx 1 + 4\Delta x + \Delta x \Delta y = 1 + 4 \times 0.08 + 6 \times (-0.08)^2 = 1.3552$.
3. 三阶近似: $1.08^{3.96} \approx 1 + 4\Delta x + \Delta x \Delta y + 4(\Delta x)^3 + \frac{7}{2}(\Delta x)^2 \Delta y + \frac{1}{2}\Delta x (\Delta y)^2$

$$= 1 + 4 \times 0.08 + 6 \times (-0.08)^2 + 4 \times (0.08)^3 + \frac{7}{2}(0.08)^2 \times (-0.04) + \frac{1}{2}(0.08) \times (-0.04)^2$$

$$= 1.3552 + 0.002048 - 0.000896 + 0.000064 = 1.3564$$

$1.08^{3.96}$ 的精确值是 1.35630721... 我们看到精度随展开项的增多而逐渐增大.

例 3.5.4 对 $f(x, y) = \frac{\cos x}{\cos y}$, 考察其于 $(0, 0)$ 处的泰勒展开.

$$\begin{aligned} \frac{\cos x}{\cos y} &= \left(1 - \frac{x^2}{2} + \frac{x^4}{4!} - \frac{x^6}{6!} + o(x^7)\right) \left(1 - \frac{y^2}{2} + \frac{y^4}{4!} - \frac{y^6}{6!} + o(y^7)\right)^{-1} \stackrel{\frac{1}{1-t}=1+t+t^2+\dots}{=} \\ &= \left(1 - \frac{x^2}{2} + \frac{x^4}{4!} - \frac{x^6}{6!} + o(x^7)\right) \left(1 + \left(\frac{y^2}{2!} - \frac{y^4}{4!} + \frac{y^6}{6!} + o(y^7)\right) + \left(\frac{y^2}{2!} - \frac{y^4}{4!} + \frac{y^6}{6!} + o(y^7)\right)^2 \right. \\ &\quad \left. + \left(\frac{y^2}{2!} - \frac{y^4}{4!} + \frac{y^6}{6!} + o(y^7)\right)^3 + o(\rho^7)\right) \quad (\rho = \sqrt{x^2 + y^2}) \\ &\stackrel{\text{整理出前 7 阶项}}{=} 1 + \left(-\frac{x^2}{2} + \frac{y^2}{2}\right) + \left(\frac{x^4}{4!} - \frac{x^2 y^2}{(2!)^2} - \frac{y^4}{4!} + \frac{y^4}{(2!)^2}\right) + \\ &\quad + \left(-\frac{x^6}{6!} + \frac{x^4 y^2}{4!2!} + \frac{x^2 y^4}{2!4!} + \frac{y^6}{6!} - \frac{x^2 y^4}{2!(2!)^2} - \frac{2y^6}{2!4!} + \frac{y^6}{(2!)^3}\right) + o(\rho^7) \end{aligned}$$

由上可反推出偏导数信息:


1. 一阶: $f_x(0, 0) = f_y(0, 0) = 0$;
2. 二阶: $\frac{1}{2!}f_{xx}(0, 0) = -\frac{1}{2}, \frac{1}{2}f_{yy}(0, 0) = \frac{1}{2}, f_{xy}(0, 0) = 0$;
3. 三阶: 全为零;
4. 四阶: $\frac{1}{4!}f_{xxxx}(0, 0) = \frac{1}{4!}, \frac{1}{4!}f_{yyyy}(0, 0) = -\frac{1}{4!} + \frac{1}{(2!)^2}, \frac{1}{4!}\binom{4}{2}f_{xxyy}(0, 0) = -\frac{1}{(2!)^2}$;
5. 五阶: 全为零;
6. 六阶: $\frac{1}{6!}f_{xxxxxx}(0, 0) = -\frac{1}{6!}, \frac{1}{6!}f_{yyyyyy}(0, 0) = \frac{1}{6!} - \frac{1}{4!} + \frac{1}{8},$

$$\frac{1}{6!}\binom{6}{4}f_{xxxxyy}(0, 0) = \frac{1}{4!2!}, \frac{1}{6!}\binom{6}{2}f_{xxyyyy}(0, 0) = \frac{1}{2!4!} - \frac{1}{2!(2!)^2}.$$

特别地，若只考虑二阶近似，则有

$$\frac{\cos x}{\cos y} \approx 1 - \frac{1}{2}x^2 + \frac{1}{2}y^2$$

即在二阶近似下， $\frac{\cos x}{\cos y}$ 在 $(0,0)$ 处的局部图像具有“马鞍面”的形态.




例 3.5.5 为计算 $f(x,y) = \sqrt{1-x^2-y^2}$ 在 $(0,0)$ 处的泰勒展开，令 $z = -x^2 - y^2$ ，先在 $z=0$ 处展开 $\sqrt{1+z}$ ，然后代入后整理.

$$\begin{aligned} (1+z)^{-1/2} &= 1 - \frac{1}{2}z + \left(\frac{-\frac{1}{2}}{2}\right)z^2 + \left(\frac{-\frac{1}{2}}{3}\right)z^3 + \left(\frac{-\frac{1}{2}}{4}\right)z^4 + o(z^4) \implies \\ \sqrt{1-x^2-y^2} &= 1 - \frac{1}{2}(-x^2-y^2) + \left(\frac{-\frac{1}{2}}{2}\right)(-x^2-y^2)^2 + \left(\frac{-\frac{1}{2}}{3}\right)(-x^2-y^2)^3 \\ &\quad + \left(\frac{-\frac{1}{2}}{4}\right)(-x^2-y^2)^4 + o((x^2+y^2)^4) \xrightarrow{\text{按次数整理}} \\ &= 1 + \frac{1}{2}(x^2+y^2) + \left(\frac{-\frac{1}{2}}{2}\right)(x^4+2x^2y^2+y^4) + \left(\frac{-\frac{1}{2}}{3}\right)(x^6+y^6+3x^4y^2+3x^2y^4) + o(\rho^7) \end{aligned}$$

特别地，若只考虑二阶近似，则有

$$\sqrt{1-x^2-y^2} \approx 1 + \frac{1}{2}(x^2+y^2)$$

即在二阶近似下，函数 $\sqrt{1-x^2-y^2}$ 在 $(0,0)$ 处的局部图像似若圆锥在其顶点附近的形态.



在实践中，泰勒展开的前两阶信息比较重要，我们将会看到，它包含了函数在某点附近性态的重要信息，所以这里单独将其写下，并用矩阵的语言重新表达，便于使用.

$$\begin{aligned}
f(x, y) &= f(x_0, y_0) + \underbrace{\left. \frac{\partial f}{\partial x} \right|_{(x_0, y_0)} \Delta x + \left. \frac{\partial f}{\partial y} \right|_{(x_0, y_0)} \Delta y}_{\text{一阶信息}} + \\
&+ \underbrace{\frac{1}{2!} \left(\left. \frac{\partial^2 f}{\partial x^2} \right|_{(x_0, y_0)} (\Delta x)^2 + 2 \left. \frac{\partial^2 f}{\partial x \partial y} \right|_{(x_0, y_0)} \Delta x \Delta y + \left. \frac{\partial^2 f}{\partial y^2} \right|_{(x_0, y_0)} (\Delta y)^2 \right)}_{\text{二阶信息}} + o(\rho^2) \\
\Delta \mathbf{x} &:= \begin{bmatrix} \Delta x & \Delta y \end{bmatrix}^T \\
&\xlongequal{\quad} f(x_0, y_0) + \nabla f(x_0, y_0) \bullet \Delta \mathbf{x} + \\
&+ \frac{1}{2!} \Delta \mathbf{x}^T \underbrace{\begin{bmatrix} f_{xx}(x_0, y_0) & f_{xy}(x_0, y_0) \\ f_{yx}(x_0, y_0) & f_{yy}(x_0, y_0) \end{bmatrix}}_{\mathbf{Q}_f(x_0, y_0)} \Delta \mathbf{x} + o(\rho^2) \quad \text{其中 } \rho = \sqrt{(\Delta x)^2 + (\Delta y)^2}
\end{aligned}$$

假设 $f_{xy} = f_{yx}$, 故 $\mathbf{Q}_f$ 是个实对称矩阵, 从而函数展开的二阶信息是包含在与 $\mathbf{Q}_f$ 相伴的二次型 $\frac{1}{2!} \Delta \mathbf{x}^T \mathbf{Q}_f \Delta \mathbf{x}$ 里头的. 矩阵 $\mathbf{Q}_f$ 称为 f 的赫塞 (Hessian) 矩阵.

一般地, 对凸区域 $D \subseteq \mathbb{R}^n$ 上的 n 元函数 $f(x_1, \dots, x_n)$, 设它在 $\mathbf{x}_0 = (x_1^0, \dots, x_n^0)$ 处有定义, 且具二阶连续偏导数, 则对 $\mathbf{x}_0$ 附近的增量 $\Delta \mathbf{x} = \begin{bmatrix} \Delta x_1 & \cdots & \Delta x_n \end{bmatrix}^T$, 有

$$f(\mathbf{x}_0 + \Delta \mathbf{x}) = f(\mathbf{x}_0) + \nabla f(\mathbf{x}_0) \bullet \Delta \mathbf{x} + \frac{1}{2!} \Delta \mathbf{x}^T \mathbf{Q}_f(\mathbf{x}_0) \Delta \mathbf{x} + o(\rho^2)$$

其中 $\mathbf{Q}_f(\mathbf{x}_0) = \left[\frac{\partial^2 f}{\partial x_i \partial x_j} \bigg|_{\mathbf{x}_0} \right]_{1 \leq i, j \leq n}$ 为 Hessian 矩阵; $\rho = \sqrt{(\Delta x_1)^2 + \dots + (\Delta x_n)^2}$.

定义 3.6.1 设 $f(\mathbf{x})$ 是定义在开区域 $D \subseteq \mathbb{R}^n$ 上的 n 元函数, 对 $\mathbf{x}_0 = (x_1^0, \dots, x_n^0) \in D$, 若存在 $\mathbf{x}_0$ 的某个邻域 $U(\mathbf{x}_0, \delta)$, 且 $\forall \mathbf{x} \in U(\mathbf{x}_0, \delta)$, 有

$$f(\mathbf{x}) \geq f(\mathbf{x}_0) \quad \text{或} \quad f(\mathbf{x}) \leq f(\mathbf{x}_0)$$

则称 $\mathbf{x}_0$ 为 f 的极小值点 (或极大值点); 并称 $f(\mathbf{x}_0)$ 为函数的一个极小值 (或极大值). 极大值点和极小值点通常为极值点, 极大值与极小值统称为函数的极值.

如同一元情形，一函数在其定义域内可有多极值点，诸极大（或极小）值中最大

(或最小)的极值对应函数的最大(或最小)值点,且对应函数值称为函数的最大(或最小)值,统称为函数的最值.类似一元情形可证明:闭区域上的连续函数必能取到最值.最值点可能在定义区域内部,也可能在区域边界上,故探寻函数最值时切不可忽略函数在边界上的取值情况.


定义 3.6.2 若在 $\mathbf{x}_0 = (x_1^0, \dots, x_n^0)$ 处,函数 $f(x)$ 的各一阶偏导数都为 0,则称 $\mathbf{x}_0$ 是函数的驻点 (stationary point). 驻点也称为临界点 (critical point). 换言之,驻点 $\mathbf{x}_0$ 是函数的梯度 ∇f 为零的点. 即

$$\mathbf{x}_0 \text{ 是驻点: } \nabla f(\mathbf{x}_0) = \mathbf{0} \iff \left. \frac{\partial f}{\partial x_i} \right|_{\mathbf{x}_0} = 0, \quad \forall i = 1, 2, \dots, n.$$


定理 3.6.1 (极值的必要条件) 若 $\mathbf{x}_0$ 是函数 f 的极值点,且 f 在 $\mathbf{x}_0$ 点可偏导,则 f 在 $\mathbf{x}_0$ 点处梯度 ∇f 为零,即其各一阶偏导为零.

证明: 将 $f(x_1, \dots, x_n)$ 只看成 x_1 的函数,则 f 在 $\mathbf{x}_0$ 取得极值同时也意味着该一元函数在 x_1^0 处取得极值,根据费马引理,此时必有 $f_{x_1}(\mathbf{x}_0) = 0$, 同理可证其余. $\square$.

需要特别强调的是,梯度为零只是可偏导函数取极值的必要条件,所以驻点未必是极值点,比如马鞍面 (saddle surface) 对应的函数 $f(x, y) = x^2 - y^2$, 显然鞍点 (saddle point) $(0, 0)$ 乃其驻点,但不是极值点. 这是因为沿直线 $y = kx$ 接近鞍点时,函数的变化 $\Delta f = f(x, y) - f(0, 0) = (1 - k^2)x^2$ 随着 k 的变化而可正可负. 当然,这可从鞍点附近函数的图像直观可见.



另外,偏导数不存在的点也可能是极值点. 比如函数 $f(x, y) = |x|$, 其图像为下面的柱面,则显然, y -轴上的每个点都是 f 的极小值点,但函数在这些点处都不可偏导.



注记 3.6.1 同一元情形类似,极值的存在表明函数在对应极值点附近的取值趋于“稳定”状态,否则在其变化的趋势下将会变得更大或更小,从而难以达到极值状态. 而我们知道,某点的梯度向量是函数在该点变化最快的方向,且在该点沿任何方向的变化速率(方向导数)由(单位)方向向量同该点梯度向量内积(即内积在单位方向向量上的正交投影)而成. 由此,极值点处梯度须消失确实是个很直观的要求.

回忆在一元情形, 如果 $y = f(x)$ 在其驻点 x_0 附近具有连续的二阶导数, 则可通过 $y''(x_0)$ 的符号来判定极值点类型.

1. 若 $f''(x_0) < 0$, 则 $f(x)$ 在 x_0 取得极大值;
2. 若 $f''(x_0) > 0$, 则 $f(x)$ 在 x_0 取得极小值;
3. 若 $f''(x_0) = 0$, 未定 (可为极值点也可能不是, 须借助它法判断).

为将其推广到多元情形, 让我们再来回忆一元时获得以上结论的思路. 关键就是利用 $f(x)$ 在 x_0 处的二阶泰勒展开

$$f(x) = f(x_0) + \frac{1}{2!}f''(x_0)(x - x_0)^2 + o((x - x_0)^2) \implies$$

$$\Delta f := f(x) - f(x_0) = \frac{1}{2!}f''(x_0)(x - x_0)^2 + o((x - x_0)^2)$$

则当 $x \rightarrow x_0$ 时, Δf 的符号由 $f''(x_0)$ 的符号决定, 故有上结论.

在多元的情形, 若函数 f 具有二阶连续偏导数, 则在驻点 $\mathbf{x}_0$ 处 (即 $\nabla f(\mathbf{x}_0) = \mathbf{0}$), 有如下二阶泰勒展开

$$\Delta f := f(\mathbf{x}_0 + \Delta \mathbf{x}) - f(\mathbf{x}_0) = \frac{1}{2!}\Delta \mathbf{x}^T \mathbf{Q}_f(\mathbf{x}_0)\Delta \mathbf{x} + o(\rho^2)$$

则 $\mathbf{x}_0$ 是否是函数 f 的极值点的问题转变为判断二次型 $\Delta \mathbf{x}^T \mathbf{Q}_f(\mathbf{x}_0)\Delta \mathbf{x}$ 是否当 $\Delta \mathbf{x} \rightarrow 0$ 时恒正、恒负或不确定? 三种情形分别对应着函数 f 在 $\mathbf{x}_0$ 处取极小值、极大值或不取极值. 根据线性代数的知识, 这又转化为判定赫塞 (Hessian) 矩阵 $\mathbf{Q}_f(\mathbf{x}_0)$ 是否为正定、负定或不定的问题.

定理 3.6.2 (利用二阶信息判定极值类型) 设 n 元函数在 $f(\mathbf{x})$ 在 $\mathbf{x}_0 = (x_1^0, \dots, x_n^0)$ 附近具有二阶连续偏导数, 且 $\mathbf{x}_0$ 是 f 的驻点, 即 $\nabla f(\mathbf{x}_0) = \mathbf{0}$, 则当其 Hessian 矩阵

$$\mathbf{Q}_f(\mathbf{x}_0) = \left[\frac{\partial^2 f}{\partial x_i \partial x_j} \Big|_{\mathbf{x}_0} \right]_{1 \leq i, j \leq n}$$

正定, $f(\mathbf{x}_0)$ 为极小值; 负定, $f(\mathbf{x}_0)$ 为极大值; 不定, $f(\mathbf{x}_0)$ 不是极值.

注记 3.6.2 实对称矩阵 A 是正定 (或负定) 的当且仅当其特征根全为正 (或全为负); 如其特征值有正有负, 则 A 是不定的. 等价地, 记 A_k 为 A 的 k -阶顺序主子式, 则当 $\det(A_k) > 0$ ($k = 1, 2, \dots, n$) 时, A 是正定的; 若 $(-1)^k \det(A_k) > 0$ ($k = 1, 2, \dots, n$), 则 A 为负定. 特别地, 对二阶实对称矩阵 $A = \begin{bmatrix} a & b \\ b & c \end{bmatrix}$, 其特征值 λ_1, λ_2 满足特征

方程 $\lambda^2 - \text{tr}(A)\lambda + \det(A) = 0$, 故 $\lambda_1 + \lambda_2 = \text{tr}(A) = a + c$, $\lambda_1\lambda_2 = \det(A) = ac - b^2$. 由此推断出, 若 $\det(A) > 0$, 且 $\lambda_1 > 0$ 时, A 必正定; 若 $\det(A) > 0$, 且 $\lambda_1 < 0$ 时, A 必负定; 若 $\det(A) < 0$, 则 A 是不定的.

利用上注记中关于二阶实对称矩阵的讨论, 可得下定理——定理 3.6.2 的特殊情形.

定理 3.6.2' (二元函数极值判定) 设 $z = f(x, y)$ 在 $P_0(x_0, y_0)$ 的某领域 $U(P_0)$ 内有连续的二阶偏导数, P_0 是驻点, 即 $f_x(x_0, y_0) = f_y(x_0, y_0) = 0$. 记 $A = f_{xx}(x_0, y_0)$, $B = f_{xy}(x_0, y_0) = f_{yx}(x_0, y_0)$, $C = f_{yy}(x_0, y_0)$, $H = \det(\mathbf{Q}_f(P_0)) = AC - B^2$, 那么

1. 当 $H > 0$ 时, $f(x_0, y_0)$ 是函数 f 的极值, 此时又有

(a) 若 $A > 0$, 则 $f(x_0, y_0)$ 是极小值;

(b) 若 $A < 0$, 则 $f(x_0, y_0)$ 是极大值;

2. 当 $H < 0$ 时, $f(x_0, y_0)$ 不是函数 f 的极值.

注记 3.6.3 $H = 0$ 时无确切结论, 各种可能性都存在, 比如对 $f(x, y) = x^4 + y^4$, $g(x, y) = -(x^4 + y^4)$, $h(x, y) = x^2y$, 原点都是它们的驻点, 在驻点处 H 都为 0, 但 $f(0, 0)$ 是极小值, $g(0, 0)$ 是极大值; $h(0, 0)$ 即不是极大也不是极小.


注记 3.6.4 上定理中情形 1.a) 的典例为 $f(x, y) = \frac{x^2 + y^2}{2}$, 原点 $(0, 0)$ 乃其驻点, 该点处的 Hessian 矩阵为 $\begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$; 情形 1.b) 的典例是 $f(x, y) = -\frac{x^2 + y^2}{2}$, 原点处的 Hessian 矩阵为 $\begin{bmatrix} -1 & 0 \\ 0 & -1 \end{bmatrix}$; 情形 2 的典例是 $f(x, y) = \frac{x^2 - y^2}{2}$, 其在 $(0, 0)$ 处的 Hessian 矩阵为 $\begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}$. 根据二次型理论, 对二元函数 $f(x, y)$, 只要 Hessian 矩阵 $\mathbf{Q}_f(\mathbf{x}_0)$

1. 正定, 则可通过坐标的线性变化将 $\mathbf{Q}_f(\mathbf{x}_0)$ 写成 $\begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$, 故在二阶近似下, f 在极小值点附近的图像类似于圆锥的顶点附近;

2. 负定, 则可通过坐标 (线性) 变化将 $\mathbf{Q}_f(\mathbf{x}_0)$ 化为 $\begin{bmatrix} -1 & 0 \\ 0 & -1 \end{bmatrix}$, 故在二阶近似下, f 在极大值点附近的图像类似于倒圆锥 (相对于 1 中的圆锥) 的顶点附近;

3. 不定, 则可通过坐标的线性变化将 $\mathbf{Q}_f(\mathbf{x}_0)$ 写成 $\begin{bmatrix} -1 & 0 \\ 0 & -1 \end{bmatrix}$, 故在二阶近似下, f 在既非极大又非极小点附近的图像类似于鞍点附近.

上面三种情形中，函数在对应驻点（临界点）附近的等高线如下图所示。



对上定理 3.6.2' 的证明，除诉诸线性代数外，亦可直接证明如下。

定理 3.6.2' 的证明：驻点 $P_0(x_0, y_0)$ 处给 x, y 以微增量，则函数的增量 Δf 有二阶泰勒展开如下

$$\begin{aligned}
 \Delta f &= f(x_0 + \Delta x, y_0 + \Delta y) - f(x_0, y_0) \stackrel{\exists \theta \in (0,1)}{=} \\
 &= \frac{1}{2} (f_{xx}(x_0 + \theta \Delta x, y_0 + \theta \Delta y)(\Delta x)^2 + 2f_{xy}(x_0 + \theta \Delta x, y_0 + \theta \Delta y)\Delta x \Delta y + \\
 &\quad + f_{yy}(x_0 + \theta \Delta x, y_0 + \theta \Delta y)(\Delta y)^2) \\
 &= \frac{1}{2} (\tilde{A}(\Delta x)^2 + 2\tilde{B}\Delta x \Delta y + \tilde{C}(\Delta y)^2) \stackrel{\substack{\text{不妨设 } \Delta x, \Delta y \rightarrow 0 \\ \Delta y \neq 0}}{=} \\
 &= \frac{(\Delta y)^2}{2} \left(\tilde{A} \left(\frac{\Delta x}{\Delta y} \right)^2 + 2\tilde{B} \frac{\Delta x}{\Delta y} + \tilde{C} \right) \stackrel{\mu := \frac{\Delta x}{\Delta y}}{=} \frac{(\Delta y)^2}{2} \underbrace{(\tilde{A}\mu^2 + 2\tilde{B}\mu + \tilde{C})}_{g(\mu)}
 \end{aligned}$$

取足够小的领域 $U(P_0, \delta)$ ，使得当 $(\Delta x, \Delta y)$ 在该领域内 $\rightarrow (0, 0)$ 时， $\tilde{A}, \tilde{B}, \tilde{C}$ 的符号与 A, B, C 的符号相同，且 $\tilde{A}\tilde{C} - \tilde{B}^2$ 的符号亦与 $AC - B^2$ 的符号相同，这都可由连续函数的局部保号性来加以确保。

而 Δf 在 $P \rightarrow P_0$ 时的符号是否会“稳定”下来，这完全取决于 $g(\mu)$ 的符号当 $(\Delta x, \Delta y) \rightarrow (0, 0)$ 时是否能“稳定”下来。由于 $\mu = \frac{\Delta x}{\Delta y}$ 可取到任意值，故 $g(\mu) = \tilde{A}\mu^2 + 2\tilde{B}\mu + \tilde{C}$ 可稳定下来的条件是：

1. 判别式 $\Delta = 4\tilde{B}^2 - 4\tilde{A}\tilde{C} < 0$ ，且 $\tilde{A} < 0$ ，此时 Δy 的符号可在 P_0 附近“稳定”为“+”，故此时 P_0 为极小值点；
2. 判别式 $\Delta = 4\tilde{B}^2 - 4\tilde{A}\tilde{C} < 0$ ，且 $\tilde{A} > 0$ ，此时 Δy 的符号可在 P_0 附近“稳定”为“-”，故此时 P_0 为极大值点；

而若判别式 $\Delta = 4\tilde{B}^2 - 4\tilde{A}\tilde{C} > 0$ 时，则抛物线 $g(\mu)$ 与 μ -轴有交点，故 $g(\mu)$ 的值时正时负，导致 Δy 的符号在 P_0 点的任意领域内无法“稳定”下来。从而 P_0 不是极值点。结合上述“保号性”的说明，即知定理成立。□

例 3.6.1 概率论中二元正态分布 (*standard bi-normal distribution*) 的密度函数的一般形式为

$$f(x, y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} e^{-\frac{1}{2(1-\rho^2)}\left(\frac{(x-\mu_1)^2}{\sigma_1^2} - 2\rho\frac{(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} + \frac{(y-\mu_2)^2}{\sigma_2^2}\right)}$$

其中 $\mu_1, \mu_2, \sigma_1, \sigma_2, \rho$ 都是常数, 取值范围分别为: $-\infty < \mu_1, \mu_2 < +\infty, \sigma_1, \sigma_2 > 0, -1 < \rho < 1$. 函数 f 的图像形如一个“钟”倒扣在 x, y -平面上, 其中心为 (μ_1, μ_2) .

为方便讨论, 做(线性)变量替换
$$\begin{cases} u = \frac{x - \mu_1}{\sigma_1\sqrt{1-\rho^2}} \\ v = \frac{y - \mu_2}{\sigma_2\sqrt{1-\rho^2}} \end{cases} \quad (\text{在概率论中对应着将二元}$$


正态分布标准化), 则函数可写为

$$\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} e^{-\frac{1}{2}(u^2-2\rho uv+v^2)} \xrightarrow[t_2=\sqrt{1-\rho^2}v]{t_1=u-\rho v} \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} e^{-\frac{1}{2}(t_1^2+t_2^2)}$$

当 $(x, y) \rightarrow (\mu_1, \mu_2)$ 时, $(u, v) \rightarrow (0, 0)$, 继而 $(t_1, t_2) \rightarrow (0, 0)$, 而

$$e^{-\frac{1}{2}(t_1^2+t_2^2)} = 1 - \frac{1}{2}(t_1^2+t_2^2) + o\left(\sqrt{t_1^2+t_2^2}\right)$$

即知函数在 $(t_1, t_2) = (0, 0)$ 处取到极大值, 由此可推出 $f(x, y)$ 在 $(x, y) = (\mu_1, \mu_2)$ 处取到极大值, 且由于 (μ_1, μ_2) 是函数的唯一极大值点, 故函数在该点处取得其最大值.



更一般地, 对函数 $f(x_1, \dots, x_n) = e^{-\frac{x_1^2 + \dots + x_n^2}{2}}$, 其在 $\mathbf{0}$ 处的赫塞 (Hessian) 矩阵为

$$\mathbf{Q}_f(\mathbf{0}) = \begin{bmatrix} -1 & 0 & \dots & 0 \\ 0 & -1 & \dots & 0 \\ \vdots & \vdots & & \vdots \\ 0 & 0 & \dots & -1 \end{bmatrix}_{n \times n}$$

由于 $(-1)^k \det(\mathbf{Q}_f(\mathbf{0})) = 1 > 0$ ($k = 1, 2, \dots, n$), 故 $\mathbf{Q}_f(\mathbf{0})$ 是负定的, 从而 $\mathbf{0}$ 是函数 f 的极大值点.

例 3.6.2 考虑函数 $z = f(x, y) = y^2 - y^4 - x^2$. 其驻点是方程 $\nabla f = \mathbf{0}$ 的解, 即求解

$$\begin{cases} z_x = -2x = 0 \\ z_y = 2y - 4y^3 = 0 \end{cases}$$


解得驻点为 $p_1(0, 0)$, $p_2 = (0, 1/\sqrt{2})$, $p_3 = (0, -1/\sqrt{2})$. 由于 $z_{xx} = -2$, $z_{xy} = z_{yx} = 0$, $z_{yy} = 2 - 12y^2$, 故 f 在三个临界点处的赫塞矩阵分别为

$$\mathbf{Q}_f(p_1) = \begin{bmatrix} -2 & 0 \\ 0 & 2 \end{bmatrix}; \quad \mathbf{Q}_f(p_2) = \mathbf{Q}_f(p_3) = \begin{bmatrix} -2 & 0 \\ 0 & -4 \end{bmatrix}$$

对应着函数在 p_i ($i = 1, 2, 3$) 处的二阶近似

1. p_0 处: $f(x, y) \approx -x^2 + y^2$;
2. p_1 处: $f(x, y) \approx \frac{1}{4} - x^2 - 2\left(y - \frac{1}{\sqrt{2}}\right)^2$;
3. p_2 处: $f(x, y) \approx \frac{1}{4} - x^2 - 2\left(y + \frac{1}{\sqrt{2}}\right)^2$.

故知 $p_0 = (0, 0)$ 是函数的鞍点, 它不是函数的极值点; 而 p_1 和 p_2 皆是函数的极大值点, 且两点处的极大值同为 $1/4$.



下面论述 $1/4$ 是函数的最大值, 且该函数无最小值. 将函数限制在变动圆族 $x^2 + y^2 = C^2$ 上, 然后探讨函数在圆周上的值当 C 变动时的变化情况.

在圆周 $x^2 + y^2 = C^2$ 上, $f(x, y) = y^2 - y^4 - x^2 = y^2(2 - y^2) - C^2$, $0 \leq y^2 \leq C^2$

令 $g(t) = t(2-t) - C^2$, $0 \leq t \leq C^2$. 则当 C 足够大时, $g(t) = -t^2 + 2t - C^2 \rightarrow -\infty$, 故 f 无最小值. 另一方面, 当 $g(t)$ 的判别式 $\Delta = 4(1 - C^2) \leq 0$, 即 $C^2 \geq 1$ 时, $\max_{0 \leq t \leq C^2} g(t) = 1 - C^2 \leq 0$, 显然不是函数的最大值; 当 $\Delta > 0$, 即 $C^2 < 1$ 时, $g(t)$ 的最大值取于 $t = C^2$ 时, 此时 $\max_{0 \leq t \leq C^2} g(t) = g(C^2) = -C^4 + C^2 = C^2(1 - C^2) \leq \frac{1}{4}$, 故知 $g(t)$ 当 $C^2 = 1 - C^2$, 即 $t = C^2 = 1/2$ 时取到最大值 $1/4$, 亦即函数 $f(x, y)$ 当 $y^2 = t = 1/2$ 时取到最大值 $1/4$, 此时 $x^2 = C^2 - y^2 = 0$.

例 3.6.3 计算 $f(x, y) = \sin x + \sin y - \sin(x + y)$ 在闭区域 $D = \{(x, y) \mid x, y \geq 0; x + y \leq 2\pi\}$ 内的最大值和最小值.

解: 由于 $\nabla f = (\cos x - \cos(x + y), \cos y - \cos(x + y)) = \mathbf{0}$, 故临界点满足下方程

$$\begin{cases} \cos x = \cos(x + y) \\ \cos y = \cos(x + y) \end{cases} \implies \begin{cases} \cos x = \cos y \\ \cos x = \cos(x + y) \end{cases} \implies \begin{cases} x - y = 2k\pi, k \in \mathbb{Z} \\ \cos x = \cos(x + y) \end{cases}$$

但考虑到区域 D 的约束, 故满足 $x - y \in 2\pi\mathbb{Z}$ 的点只有: $(0, 2\pi)$, $(2\pi, 0)$ 及 D 中位于直线 $y = x$ 上的所有点. 显然边界点 $(0, 2\pi)$, $(2\pi, 0)$ 也满足 $\cos x = \cos(x + y)$, 故这两个点是临界点. 此外, 当 $y = x$ 时, 上面第二个方程可写为 $2\cos^2 x - \cos x - 1 = 0$. 其解为 $\cos x = 1$ 或 $\cos x = -\frac{1}{2}$, 在 $[0, 2\pi]$ 内的解为: $x = 0$, $x = 2\pi/3$, $x = 5\pi/3$, $x = 2\pi$. 从而求得函数的全部临界点为

$$(0, 2\pi); \left(\frac{2\pi}{3}, \frac{2\pi}{3}\right); \left(\frac{5\pi}{3}, \frac{5\pi}{3}\right); (2\pi, 0)$$

由于 $f_{xx} = -\sin x + \sin(x + y)$; $f_{xy} = \sin(x + y)$; $f_{yy} = -\sin y + \sin(x + y)$, 故在位于边界 ∂D 的临界点 $(0, 2\pi)$, $(2\pi, 0)$ 处, $f_{xx} = f_{xy} = f_{yy} = 0$, 判别法在此失效, 但无所谓, 只需判断函数在区域 D 内部的临界点处的极值情况. 当 $y = x$ 时, 有

$$H = f_{xx}f_{yy} - f_{xy}^2 = (2\sin x \cos x - \sin x)^2 - 4\sin^2 x \cos^2 x = \sin^2 x (1 - 4\cos x)$$

故在临界点 $\left(\frac{2\pi}{3}, \frac{2\pi}{3}\right)$ 及 $\left(\frac{5\pi}{3}, \frac{5\pi}{3}\right)$ 处, $H = \frac{9}{4}$; 又在 $\left(\frac{2\pi}{3}, \frac{2\pi}{3}\right)$ 处, $A = f_{xx} = -\sqrt{3}$, 但在 $\left(\frac{5\pi}{3}, \frac{5\pi}{3}\right)$ 处, $A = f_{xx} = \sqrt{3}$. 故由定理 3.6.2', 知 $\left(\frac{2\pi}{3}, \frac{2\pi}{3}\right)$ 是函数的极大值点; 而 $\left(\frac{5\pi}{3}, \frac{5\pi}{3}\right)$ 是函数的极小值点, 且对应的极大值和极小值分别为

$$f\left(\frac{2\pi}{3}, \frac{2\pi}{3}\right) = \frac{3\sqrt{3}}{2}; \quad f\left(\frac{5\pi}{3}, \frac{5\pi}{3}\right) = \frac{3\sqrt{3}}{2} = -\frac{3\sqrt{3}}{2}$$


再考察函数在边界

$$\partial D = [0, 2\pi] \times \{0\} \cup \{0\} \times [0, 2\pi] \cup \{(x, y) \in [0, 2\pi] \times [0, 2\pi] \mid x + y = 2\pi\}$$

上的取值情况.

1. 在 $[0, 2\pi] \times \{0\}$ 上, 函数 $f(x, y) = f(x, 0) = \sin x - \sin x \equiv 0$;
2. 在 $\{0\} \times [0, 2\pi]$ 上, 函数 $f(x, y) = f(0, y) = \sin y - \sin y \equiv 0$;

3. 在 $\{(x, y) \in [0, 2\pi] \times [0, 2\pi] \mid x + y = 2\pi\}$ 上, 函数 $f(x, y) = f(x, 2\pi - x) = \sin x - \sin x \equiv 0$.



故在 ∂D 上, $f(x, y) \equiv 0$. 从而知在区域 D 上, 函数 f 在 $\left(\frac{2\pi}{3}, \frac{2\pi}{3}\right)$ 取最大值 $\frac{3\sqrt{3}}{2}$; 在 $\left(\frac{5\pi}{3}, \frac{5\pi}{3}\right)$ 取最小值 $-\frac{3\sqrt{3}}{2}$.

例 3.6.4 证明不等式: $xy \leq x \ln x - x + e^y$, $x \geq 1, y \geq 0$.

证明: 考察函数 $f(x, y) = x \ln x - x + e^y - xy$ 在区域 $D = \{(x, y) \mid x \geq 1, y \geq 0\}$ 上的取值情况. 首先求驻点

$$\begin{cases} f_x = \ln x - y = 0 \\ f_y = e^y - x = 0 \end{cases} \implies (x, y) \in \{(x, y) \mid y = \ln x, x \geq 1\}$$

在此例中函数的临界点不是离散的, 而是整条连续曲线 $y = \ln x, x \geq 1$, 可称之为临界曲线. 又因为 $f_{xx} = 1/x$, $f_{xy} = -1$, $f_{yy} = e^y$, 故在临界曲线上

$$H = f_{xx}f_{yy} - f_{xy}^2 = \frac{e^y}{x} - 1 \stackrel[\text{成立 } x=e^y]{\text{临界曲线上}} 1 - 1 \equiv 0$$

即其赫塞矩阵为 $\mathbf{Q}_f = \begin{bmatrix} 1/x & -1 \\ -1 & x \end{bmatrix}$ 的行或列成比例 (矩阵不满秩), 故我们之前的判别方法于此失效. 设 $x_0 \geq 1$, 则函数在任意临界点 $(x_0, \ln x_0)$ 处的泰勒展开为

$$\begin{aligned} f(x, y) &= \underbrace{x_0 \ln x_0 - x_0 + e^{\ln x_0} - x_0 \ln x_0}_0 + \\ &+ \frac{1}{2x_0}(x - x_0)^2 - (x - x_0)(y - \ln x_0) + \frac{x_0}{2}(y - \ln x_0)^2 + o(\rho^2) \\ &= \frac{1}{2x_0}(\Delta x)^2 - \Delta x \Delta y + \frac{x_0}{2}(\Delta y)^2 + o(\rho^2) \end{aligned}$$

$$\geq 2\sqrt{\frac{1}{2x_0}(\Delta x)^2 \cdot \frac{x_0}{2}(\Delta y)^2 - \Delta x \Delta y + o(\rho^2)} = o(\rho^2) \geq 0$$

故 $(x_0, \ln x_0)$ 是极小值点, 从而在其定义区域 D 的**内部**, f 有最小值 $f(x_0, \ln x_0) = 0$ ($\forall x_0 > 1$). 下面再考察函数在区域边界上的取值.

1. 在射线 $\{(x, y) \in \mathbb{R}^2 \mid x \geq 1, y = 1\}$ 上, $f(x, y) = f(x, 0) = x \ln x - x + 1$, 从而 $f_x(x, 0) = \ln x > 0$ ($x \geq 1$), 故 $f(x, 0) \geq f(1, 0) = 0$, 最小值仍是 0;
2. 在射线 $\{(x, y) \in \mathbb{R}^2 \mid y \geq 0; x \equiv 1\}$, $f(x, y) = f(1, y) = 1 + e^y - y$, 从而 $f_y(1, y) = e^y - 1 \geq 0$, 故 $f(1, y) \geq f(1, 0) = 2$, 故在这条直线上 f 的最小值是 2.

综上, f 在 D 上的最小值为 0, 即 $\forall x \geq 1, y \geq 0$, 成立 $f(x, y) \geq 0$, 亦即

$$x \ln x - x + e^y - xy \geq 0 \iff xy \leq x \ln x - x + e^y \quad \square$$

注记 3.6.5 上面的计算表明当函数 f 在其临界点处的赫塞矩阵是**半正定**的 (即所有特征值非负) 时, 临界点为局部极小值点; 同理**半负定**的临界点对应局部极大状态.

例 3.6.5 求由 $2x^2 + 2y^2 + z^2 + 8yz - z + 8 = 0$ 所确定的隐函数 $z = f(x, y)$ 的极值.

解: 方程两边同时微分, 得 $4xdx + 4ydy + 2zdz + 8ydz + 8zdy - dz = 0$, 整理可得

$$dz = \frac{4x}{1-8y-2z}dx + \frac{4y+8z}{1-8y-2z}$$

从而 $\frac{\partial z}{\partial x} = \frac{4x}{1-8y-2z}$; $\frac{\partial z}{\partial y} = \frac{4y+8z}{1-8y-2z}$. 由此求得驻点所满足的方程为

$$\begin{aligned} \begin{cases} x = 0 \\ y + 2z = 0 \end{cases} & \xrightarrow{2x^2+2y^2+z^2+8yz-z+8=0} \begin{cases} x = 0 \\ y + 2z = 0 \\ 2y^2 + z^2 + 8yz - z + 8 = 0 \end{cases} \\ \Rightarrow \begin{cases} x = 0 \\ y + 2z = 0 \\ 7z^2 + z - 8 = 0 \end{cases} & \Rightarrow \begin{cases} x = 0 \\ y + 2z = 0 \\ z = 1 \text{ 或 } z = -8/7 \end{cases} \end{aligned}$$

由此得知函数的驻点为 $(0, -2)$ 和 $(0, 16/7)$. 未确定其类型, 我们计算二阶偏导信息, 为此, 先将方程两边同时对 x 求导, 得 $4x + 2zz_x + 8yz_x - z_x = 0$, 然后两边再对 x 求导一次, 得

$$4 + 2zz_{xx} + 2z_x^2 + 8yz_{xx} - z_{xx} = 0 \implies z_{xx} = \frac{4 + 2z_x^2}{1 - 8y - 2z}$$

方程 $4x + 2zz_x + 8yz_x - z_x = 0$ 两边对 y 求导, 得 $2z_y z_x + 2zz_{xy} + 8z_x + 8yz_{xy} - z_{xy} = 0$, 解得

$$z_{xy} = \frac{2z_x z_y + 8z_x}{1 - 8y - 2z}$$

又原方程 $2x^2 + 2y^2 + z^2 + 8yz - z + 8 = 0$ 两边对 y 求导, 得

$$4y + 2zz_y + 8z + 8yz_y - z_y = 0 \implies z_y = \frac{4y + 8z}{1 - 8y - 2z}$$


然后方程 $4y + 2zz_y + 8z + 8yz_y - z_y = 0$ 两边对 y 再求导一次, 得

$$4 + 2z_y^2 + 2zz_{yy} + 8z_y + 8z_y + 8yz_{yy} - z_{yy} = 0 \implies z_{yy} = \frac{4 + 2z_y^2 + 16z_y}{1 - 8y - 2z}$$

利用上面求得的二阶导数公式, 可得驻点处的二阶信息如下

1. 在 $(0, -2)$ 处, $z_{xx} = 4/15$, $z_{xy} = 0$, $z_{yy} = 4/15$. 此时, 函数取极小值 $f(0, -2) = 1$;
2. 在 $(0, 16/7)$ 处, $z_{xx} = -4/15$, $z_{xy} = 0$, $z_{yy} = -4/15$. 此时, 函数取极大值 $f(0, -2) = -8/7$.

虽然这两个点是函数的唯一极大值点和极小值点, 但对于极大值却必极小值小, 由此我们推测它们只是局部极大和局部极小值点, 而并非全局的最值点, 也就是说, 函数是无界的. 事实上, 函数的图像是如下的双叶双曲面.



这可通过对方程变形看出: $2x^2 + 2y^2 + z^2 + 8yz - z + 8 = 2x^2 + 2(y^2 + 4yz + 4z^2) - 7z^2 - z + 8 = 2x^2 + 2(y + 2z)^2 - 7(z^2 + z/7 - 8/7) = 2x^2 + 2(y + 2z)^2 - 7(z + 1/14)^2 + 7/14^2 + 8$.

令 $\tilde{z} = z + 1/14$, 则方程变为 $2x^2 + 2((y - 1/7) + 2\tilde{z})^2 - 7\tilde{z}^2 + 784/98 = 0$.

再令 $\tilde{y} = y - 1/7$, 则方程变为 $2x^2 + 2(\tilde{y} + 2\tilde{z})^2 - 7\tilde{z}^2 + 784/98 = 0$.

最后再令 $\begin{cases} \tilde{\tilde{y}} = \tilde{y} + 2\tilde{z} \\ \tilde{\tilde{z}} = \tilde{z} \end{cases}$, 则方程化为 $2x^2 + 2\tilde{\tilde{y}}^2 - 7\tilde{\tilde{z}}^2 + 784/98 = 0$, 显然为双叶

双曲曲的方程. 所做坐标变换为两次中心平移 “剪切 (shear)” 的复合, 它不改变曲面的型态特征.

例 3.6.6 (最小二乘法) 给出一组数据 $(x_i, y_i) \ i = 1, 2, \dots, n$.

x	x_1	x_2	x_3	$\cdots$	x_n
y	y_1	y_2	y_3	$\cdots$	y_n

如这些数据大致依某条直线而分布, 则需找到一条能“最契合 (*best fit*)”这些数据的直线. 首先, 我们得明确这里“最契合”的含义.

假设最契合于数据的直线方程为: $y = ax + b$, 则要求: $\forall i \in \{1, 2, \dots, n\}$ 通过直线方程算出来的与 x_i 所对应的 y 值: $ax_i + b$, 同真实观测值 y_i 的差的平方和最小化.

$$\min_{a,b} Q(a,b), \text{ 其中 } Q(a,b) := \sum_{i=1}^n (y_i - ax_i - b)^2$$

这样求得的直线方程称为是最小二乘直线, 求解它的方法称为最小二乘法 (*method of least squares*) .

$$\begin{cases} \frac{\partial Q}{\partial x} = -2 \sum_{i=1}^n (y_i - ax_i - b)x_i = 2a \sum_{i=1}^n x_i^2 - 2 \sum_{i=1}^n x_i y_i + 2b \sum_{i=1}^n x_i = 0 \\ \frac{\partial Q}{\partial b} = -2 \sum_{i=1}^n (y_i - ax_i - b) = 2a \sum_{i=1}^n x_i - 2 \sum_{i=1}^n y_i + 2nb = 0 \end{cases}$$

即 a, b 满足线性方程组 $\begin{bmatrix} \sum_{i=1}^n x_i^2 & \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i & n \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^n x_i y_i \\ \sum_{i=1}^n y_i \end{bmatrix}$, 利用克拉默法

则求解, 得

$$a = \frac{n \sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i \sum_{i=1}^n y_i}{n \sum_{i=1}^n x_i^2 - \left(\sum_{i=1}^n x_i \right)^2}; \quad b = \frac{\sum_{i=1}^n x_i^2 \sum_{i=1}^n y_i - \sum_{i=1}^n x_i \sum_{i=1}^n x_i y_i}{n \sum_{i=1}^n x_i^2 - \left(\sum_{i=1}^n x_i \right)^2}$$

当然我们得确保分母 $n \sum_{i=1}^n x_i^2 - \left(\sum_{i=1}^n x_i \right)^2 \neq 0$ 才行. 事实上, 该式可做如下化简


$$n \sum_{i=1}^n x_i^2 - \left(\sum_{i=1}^n x_i \right)^2 \stackrel{\substack{\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \\ \text{数据平均}}}{=} n \sum_{i=1}^n x_i^2 - n^2 \bar{x}^2 = n \sum_{i=1}^n (x_i - \bar{x} + \bar{x})^2 - n^2 \bar{x}^2$$

$$\begin{aligned}
&= n \sum_{i=1}^n (x_i - \bar{x})^2 + 2n \sum_{i=1}^n \bar{x}(x_i - \bar{x})n + n \sum_{i=1}^n \bar{x}^2 - n^2 \bar{x}^2 \\
&= n^2 \sum_{i=1}^n \frac{(x_i - \bar{x})^2}{n} = n^2 \sigma^2 \quad \begin{array}{l} \text{只要数据方差 } \sigma^2 \neq 0, \\ \text{则方程有唯一解} \end{array}
\end{aligned}$$

对如下数据

x	3	6	9	12	15	18	21	24
y	57.6	41.5	31.2	22.9	15.4	12.1	8.9	6.4

通过绘制如下的数据分布图，可看出它们不是依据某条直线分布的。



但其分布趋势接近于指数曲线上点分布的模式，故可设数据是 x, y 间指数关系 $y = \beta e^{\alpha x}$ 的观测结果. 为利用最小二乘法“预测”参数 α, β 的值，将方程两边取对数，得到 $\ln y = \ln \beta + \alpha x$ ，并令 $z = \ln y$ ， $a = \alpha, b = \ln \beta$ ，则 x, y 间的指数相关转化为 x, z 之间的线性相关 $z = ax + b$ ，我们将上面的数据按 x, z 转化，得

x	3	6	9	12	15	18	21	24
$z = \ln y$	4.054	3.726	3.440	3.131	2.734	2.493	2.186	1.856

然后计算相关统计量

$$\sum_i x_i = 108; \quad \sum_i z_i = 23.62; \quad \sum_i x_i z_i = 279.204$$

$$\sum_i x_i^2 = 1836; \quad \sum_i z_i^2 = 73.868$$

$$a = \frac{8 \times 279.204 - 108 \times 23.62}{8 \times 1836 - 108^2} = -0.1049; \quad b = \frac{1836 \times 23.63 - 108 \times 269.204}{8 \times 1836 - 108^2} = 4.7324$$

从而 $\alpha = a = -0.1049$ ， $\beta = e^b \approx 113.57$ ，从而 x, y 之间的由最小二乘法预测的函数关系为

$$y = 113.57e^{-0.1049x}$$

3.7 条件极值与拉格朗日乘子法

相比上节中求极值和最值的问题——也称优化问题 (*optimization problem*), 更一般的极值问题是所谓带约束的条件极值 (*conditional extremum*) 问题. 其模型如下

$$\min / \max \{f(x_1, \dots, x_n)\} \quad s.t. \quad \begin{cases} g_1(x_1, \dots, x_n) = 0 \\ \dots \\ g_m(x_1, \dots, x_n) = 0 \end{cases} \quad (\Delta)$$

其中 f 称为待优化的目标函数 (*objective function*), 诸 g_i 称为约束条件 (*constraints*). 上问题即是寻求 f 在约束 $g_i = 0, i = 1, \dots, m$ 下的最值问题.

先分析一个例子, 比如求 $z = f(x, y) = xy$ 在约束条件 $x + y = 1$ 下的极值问题.

这个问题虽然是条件极值的问题, 但由于可从条件 $x + y = 1$ 解出一个变量, 比如 $y = 1 - x$, 从而将原问题变为非条件极值问题, 即求 $z = f(x, y(x)) = x(1 - x)$ 的极值问题. 显然当 $x = \frac{1}{2}$ 时它取到最大值 $\frac{1}{4}$. 换言之, 原条件极值有唯一解 $(x_*, y_*) = \left(\frac{1}{2}, \frac{1}{2}\right)$, 该点对应函数的极大值 $\frac{1}{4}$, 这显然也是目标函数的最大值.

但如果不能直接从条件中解出显示函数关系, 从而将问题划归为自由极值问题, 上面的方法就不能使用了. 为了探寻一般条件极值问题的求解思路, 我们重新审视上例.

受启发于对隐函数存在性及其求导问题的处理, 我们知道: 虽然通常不易 (或不能) 从变量的约束条件中确定出显式的函数关系, 但在变量的微分 (线性化) 层面, 则一切转化为诸微分间的线性约束了, 从而可从中直接读出诸微分间的 (线性) 函数关系, 而隐函数存在定理确保可将其 “提升” 为变量间的局部函数关系.

将上面的原理应用到此处, 可对上面条件极值问题进行如下 “微观分析”.

函数 $z = xy$ 的微小变动 (或变动的线性近似) 由微分 $dz = ydx + xdy$ 描述, 也就是说: x, y 的独立 “无穷小变动” dx, dy 通过线性 (函数) 关系 $dz = ydx + xdy$ 给出 z 的 “无穷小变动”.


1. 如不考虑任何约束, 则 z 变动的 “相对稳态” 必发生在 $dz = 0$, 或 $\nabla z = \mathbf{0}$ 的点处, 即在函数的 “驻点 (*stationary point*)” 或 “临界点 (*critical point*)” 处. 这是因为, 在这些点近旁, z 增量的线性近似 dz 对 dx 和 dy 的变化不再 “敏感”, 故其值似局部 “驻留”, 而这通常发生在局部极值点或鞍点附近——即函数变动的瞬时速度为零的点附近. 否则, 在 $\nabla f \neq \mathbf{0}$ 的点附近, dz 会随 dx 和 dy 的无穷小变动而有继续增大或减少的趋势, 从而导致相对稳定的态势无法取得.
2. 但在约束条件 $x + y = 1$ 之下, dx 和 dy 尚受 $dx + dy = 0$ 的约束, 从而 z -增量

Δz 的线性近似 dz 对 dx 和 dy 的线性依赖可约化为 (即消去一个变量的微分)

$$dz = ydx + xdy \stackrel{dx+dy=0}{=} ydx - xdx = (y-x)dx$$

则由此显见, 当 dx 前的系数 $y-x=0$, 即当 $y=x=1/2$ 时, dz 不再对 dx 的变动敏感, 从而可知点 $(x_*, y_*) = \left(\frac{1}{2}, \frac{1}{2}\right)$ 是 $z=xy$ 在约束 $x+y=1$ 下的一个极值点或相对稳态点.

下面, 让我们再探寻其背后的几何直观. 几何上来看, 我们要考察函数 $z=xy$ 的等值线 (level curve) 图 $xy=C$ 与约束条件 $x+y=1$ 的图像的相交情况, 从找找寻使得 C 取最值的交点.



这里值得注意的是, 在临界点 $(x_*, y_*) = (1/2, 1/2)$ 处, 梯度方向 $\nabla f|_{(x_*, y_*)}$ 与约束直线 $x+y=1$ 是正交的. 这并非偶然, 而是有其深刻原因.

首先, 以代数角度看, 约束直线 $x+y=1$ 上有微分关系 $dx+dy=0$, 即其上任一点 (x, y) 处的法方向为 $(1, 1)$, 或切方向为 $(1, -1)$; 而等值线 $xy=C$ 上有微分关系 $ydx+xdy=0$, 即其上任一点 (x, y) 处的法方向为 $\nabla f = (y, x)$. 故在约束直线上, 为使 $dz=0$, 或等价地, 为使函数 $z=xy$ 沿直线方向的变化率, 即方向导数为 0, 需满足

$$\nabla f \cdot \left(\frac{1}{\sqrt{2}}, -\frac{1}{\sqrt{2}}\right) = (y, x) \cdot \left(\frac{1}{\sqrt{2}}, -\frac{1}{\sqrt{2}}\right) = \frac{y-x}{\sqrt{2}} = 0$$

即条件极值问题的临界点 (x_*, y_*) 满足 $y_* = x_*$, 再结合约束 $x_* + y_* = 1$, 便得到唯一临界点 $(x_*, y_*) = (1/2, 1/2)$.

再从直观上看, 等值线的法向量就是函数的梯度方向, 而梯度方向又是函数值 (即等值线方程 $xy=C$ 中的 C -值) 变动最快的方向, 它与其它方向 (以单位向量表示) 的点乘——即梯度在其它方向上的投影长度, 则给出了函数沿该方向的变化速率 (方向导数). 当函数限制于约束直线, 其取极值的必要条件是其沿约束直线的 (方向) 导数为零——此即为函数在约束直线上取得驻点的条件. 换言之, 在驻点处, 梯度方向必与约

束直线的方向正交, 即梯度在约束直线上的投影为零, 表明在该点函数的取值相对稳定下来了, 否则若投影长度 (方向导数) 非零, 则函数有继续增大或减少的趋势.

注记 3.7.1 对无约束的自由极值问题 $z = f(x, y)$, 即不对 x, y 给约束条件, 但这也可视作是将 x, y 约束于整个平面之内, 则某点是极值点的必要条件 $\nabla f = (f_x, f_y) = \mathbf{0}$ 也可解释称在该点处, 函数在平面内任何方向的变化率都为零. 这与上例中将函数限定于约束直线上的讨论是完全一致的.

接下来将对上例的讨论进行“形式化”处理, 以此来总结处理该类问题的一般模式.

先将上例一般化, 即考虑下条件极值问题:

$$\min / \max \{z = f(x, y)\} \quad s.t. \quad g(x, y) = 0$$

1. 代数推导

$$(a) \text{ 微分角度: 线性化后: } \begin{cases} dz = f_x dx + f_y dy = 0 \\ g_x dx + g_y dy = 0 \end{cases} \xrightarrow{\text{不妨设 } g_y \neq 0}$$

$$dz = f_x dx - f_y \frac{g_x}{g_y} dx = 0 \xrightarrow{dx \text{ 任意}} f_x - f_y \frac{g_x}{g_y} = 0 \implies$$

$$\text{故约束下的驻点条件: } f_x g_y = g_x f_y \iff (f_x, f_y) // (g_x, g_y) \iff$$

$$\exists \lambda, \text{ 使得 } \begin{cases} f_x + \lambda g_x = 0 \\ f_y + \lambda g_y = 0 \end{cases} \iff \nabla f + \lambda \nabla g = \mathbf{0}, \text{ 即 } \nabla f, \nabla g \text{ 共线 (或线性相关)}$$

(b) 偏导角度: 不妨设 $g_y \neq 0$, 则由隐函数存在定理, 可从约束 $g(x, y) = 0$ 中解出函数关系 $y = y(x)$. 将其代入目标函数 $z = f(x, y)$, 则问题转化为求解函数 $z = f(x, y(x)) = z(x)$ 的自由极值问题, 它对应的驻点由 $z'(x) = 0$ 给出. 根据隐函数求导法则, 得 $y'(x) = -\frac{g_x}{g_y}$, 然后利用链式法则 (此时表现为为全导数公式), 知约束下的驻点条件为


$$z'(x) = f_x + f_y \frac{dy}{dx} = f_x - f_y \frac{g_x}{g_y} = 0 \quad \text{同 (a) 中所得.}$$

2. 几何解释 函数 z 在约束下的极值点若存在, 则它必位于等值线 $f(x, y) = C$ 同约束曲线 $\mathcal{C}: g(x, y) = 0$ 的交点上, 那么哪些交点是约束下的极值点呢? 为回答此问题, 现将函数 $z = f(x, y)$ 限制于曲线 $\mathcal{C}$, 当点沿着曲线变动时, $z = f(x, y)$ 的变化速率即为沿曲线 $\mathcal{C}$ 上的切线方向的方向导数.

将约束曲线 $\mathcal{C}$ 的方程微分, 得 $g_x dx + g_y dy = 0$, 知其上任意点 (x, y) 处的切线方程为 $g_x(X - x) + g_y(Y - y) = 0$, 即点 (x, y) 处的法方向为 (g_x, g_y) , 从而切方向为 $\boldsymbol{l} = (g_y, -g_x)$, 故单位切向量是 $\boldsymbol{l}^0 = \frac{1}{\sqrt{g_x^2 + g_y^2}}(g_y, -g_x)$. 由此, 知函数 z 沿着约束曲线 $\mathcal{C}$ 的变化速率为方向导数

$$\nabla_{\boldsymbol{l}} = \nabla f \bullet \boldsymbol{l}^0 = \frac{1}{\sqrt{g_x^2 + g_y^2}}(f_x, f_y) \bullet (g_y, -g_x) = f_x g_y - g_x f_y$$

则函数 $z|_{\mathcal{C}}$ 取极值的条件是 $\nabla_{\boldsymbol{l}} = f_x g_y - g_x f_y = 0$, 换言之 $\exists \lambda$, 使得 $\nabla f + \lambda \nabla g = 0$, 即极值点处函数等值曲线的法向量与约束曲线在该点的法向量是共线的.



注意条件 $\nabla f + \lambda \nabla g = \mathbf{0}$ 等价于 $\nabla(f + \lambda g) = \mathbf{0}$. 即求解条件极值问题:

$$\min / \max \{z = f(x, y)\} \quad s.t. \quad g(x, y) = 0$$

等价于求解函数 $f + \lambda g$ 的自由 (无条件) 极值问题.

令 $\mathcal{L}(x, y, \lambda) = f(x, y) + \lambda g(x, y)$, 称做条件极值问题的拉格朗日函数, 其中的 λ 称为拉格朗日乘子 (Lagrange multiplier), 则上面的讨论说明: $z = f(x, y)$ 在约束 $g(x, y) = 0$ 下的极值点是其拉格朗日函数 $\mathcal{L}$ 的极值点, 即约束条件下的可能极值点需满足如下拉格朗日方程

$$\nabla \mathcal{L} = \nabla f + \lambda \nabla g = \mathbf{0} \iff \begin{cases} \frac{\partial \mathcal{L}}{\partial x} = \frac{\partial f}{\partial x} + \lambda \frac{\partial g}{\partial x} = 0; & \frac{\partial \mathcal{L}}{\partial y} = \frac{\partial f}{\partial y} + \lambda \frac{\partial g}{\partial y} = 0 \\ \frac{\partial \mathcal{L}}{\partial \lambda} = g(x, y) = 0 & (\text{约束条件本身}) \end{cases}$$

上面的求解方法通常称为拉格朗日乘子法. 将其推广到三元及一般 n 元函数在一

个约束条件下的极值问题是毫无困难的，我们不再写推导过程，而将其平行结论写出：


$$\min / \max \{u = f(x, y, z)\} \quad s.t. \quad g(x, y, z) = 0 \quad \Longleftrightarrow$$

$$\min / \max \{\mathcal{L}(x, y, z, \lambda) := f(x, y, z) + \lambda g(x, y, z)\}$$

问题由此转化为求解拉格朗日方程： $\nabla \mathcal{L} = \mathbf{0} \Longleftrightarrow \exists \lambda$, 使得 $\nabla f + \lambda \nabla g = \mathbf{0}$, 即

$$\begin{cases} \frac{\partial \mathcal{L}}{\partial x} = \frac{\partial f}{\partial x} + \lambda \frac{\partial g}{\partial x} = 0; & \frac{\partial \mathcal{L}}{\partial x} = \frac{\partial f}{\partial x} + \lambda \frac{\partial g}{\partial y} = 0; & \frac{\partial \mathcal{L}}{\partial x} = \frac{\partial f}{\partial z} + \lambda \frac{\partial g}{\partial z} = 0 \\ \frac{\partial \mathcal{L}}{\partial \lambda} = g(x, y, z) = 0 & (\text{约束条件本身}) \end{cases}$$

其几何含义见下图.



例 3.7.1 作为上面模式的应用，我们重新考察 3.6 节中的例 3.65：求由 $2x^2 + 2y^2 + z^2 + 8yz - z + 8 = 0$ 所确定的隐函数 $z = f(x, y)$ 的极值. 首先，将其转为以下条件极值问题：

$$\min / \max \{z\} \quad s.t. \quad 2x^2 + 2y^2 + z^2 + 8yz - z + 8 = 0$$

解：构造拉格朗日函数 $\mathcal{L} = z + \lambda(2x^2 + 2y^2 + z^2 + 8yz - z + 8)$ ，然后求解驻点（临界点）方程 $\nabla \mathcal{L} = \mathbf{0}$ ，即 $\frac{\partial \mathcal{L}}{\partial \lambda} = 2x^2 + 2y^2 + z^2 + 8yz - z + 8 = 0$ ，且

$$\frac{\partial \mathcal{L}}{\partial x} = 4x\lambda = 0; \quad \frac{\partial \mathcal{L}}{\partial y} = (4y + 8z)\lambda = 0; \quad \frac{\partial \mathcal{L}}{\partial z} = 1 + (2z + 8y - 1)\lambda = 0$$

$$\text{故 } x = 0, \text{ 且 } \begin{cases} y + 2z = 0 \\ 2y^2 + z^2 + 8yz - z + 8 = 0 \end{cases} \quad \text{解得极值点为}$$

$$\mathbf{p}_1 = (0, -2, 1, 1/15) \quad \mathbf{p}_2 = (0, 16/7, -8/7, -1/15)$$

由于

$$\begin{aligned}\mathcal{L}_{xy} &= 4\lambda, & \mathcal{L}_{xy} &= 0, & \mathcal{L}_{xz} &= 0, & \mathcal{L}_{x\lambda} &= 4x \\ \mathcal{L}_{yx} &= 0, & \mathcal{L}_{yy} &= 4\lambda, & \mathcal{L}_{yz} &= 8\lambda, & \mathcal{L}_{y\lambda} &= 4y + 8z \\ \mathcal{L}_{zx} &= 0, & \mathcal{L}_{zy} &= 8\lambda, & \mathcal{L}_{zz} &= 2\lambda, & \mathcal{L}_{z\lambda} &= 2z + 8y - 1 \\ \mathcal{L}_{\lambda x} &= 4x, & \mathcal{L}_{\lambda y} &= 4y + 8z, & \mathcal{L}_{\lambda z} &= 2z + 8y - 1, & \mathcal{L}_{\lambda\lambda} &= 0\end{aligned}$$

故 $\mathcal{L}(x, y, z, \lambda)$ 的赫塞矩阵为

$$\mathbf{Q}_{\mathcal{L}} = \begin{bmatrix} 4\lambda & 0 & 0 & 4x \\ 0 & 4\lambda & 8\lambda & 4y + 8z \\ 0 & 8\lambda & 2\lambda & 2z + 8y - 1 \\ 4x & 4y + 8z & 2z + 8y - 1 & 0 \end{bmatrix}$$

在极值点处

$$\mathbf{Q}_{\mathcal{L}}|_{\mathbf{p}_1} = \begin{bmatrix} 4/15 & 0 & 0 & 0 \\ 0 & 4/15 & 8/15 & 0 \\ 0 & 8/15 & 2/15 & -15 \\ 0 & 0 & -15 & 0 \end{bmatrix}; \quad \mathbf{Q}_{\mathcal{L}}|_{\mathbf{p}_2} = \begin{bmatrix} -4/15 & 0 & 0 & 0 \\ 0 & -4/15 & -8/15 & 0 \\ 0 & -8/15 & -2/15 & 15 \\ 0 & 0 & 15 & 0 \end{bmatrix}$$

故 $\mathbf{Q}_{\mathcal{L}}|_{\mathbf{p}_1}$ 正定, 而 $\mathbf{Q}_{\mathcal{L}}|_{\mathbf{p}_2}$ 负定, 从而 $\mathbf{p}_1$ 对应 $\mathcal{L}$ 的极小值点; $\mathbf{p}_2$ 对应 $\mathcal{L}$ 的极大值点. 但在这些极值点处, $\mathcal{L} = z$, 故知 $(0, -2)$ 是 z 的极小值点, $(0, 16/7)$ 是 z 的极大值点.

例 3.7.2 求函数 $f(x, y) = 2x^2 + 6xy + y^2$ 在闭区域 $x^2 + 2y^2 \leq 3$ 上的最大值和最小值.

解: 求解 $\nabla f = (4x + 6y, 2y + 6x) = 0$, 得 $(x, y) = (0, 0)$ 是位于区域内部 $x^2 + 2y^2 < 3$ 的唯一驻点. 由于 $\mathbf{Q}_f(0, 0) = \begin{bmatrix} 4 & 6 \\ 6 & 2 \end{bmatrix}$ 是正定的, 故 $(0, 0)$ 是函数在所在区域内的极小值点. 下面考察它在区域边界曲线 $x^2 + 2y^2 = 3$ 上的取值情况, 而这相当于下面的条件极值问题

$$\max / \min \{z = 2x^2 + 6xy + y^2\} \quad s.t. \quad x^2 + 2y^2 = 3$$

构造拉格朗日函数 $\mathcal{L}(x, y, \lambda) = 2x^2 + 6xy + y^2 + \lambda(x^2 + 2y^2 - 3)$, 求解拉格朗日方程 $\nabla \mathcal{L} = \mathbf{0}$

$$\mathcal{L}_x = 4x + 6y + 2\lambda x = 0; \quad \mathcal{L}_y = 6x + 2y + 4\lambda y = 0$$

且 $\mathcal{L}_\lambda = x^2 + 2y^2 - 3 = 0$, 解得 $\lambda = 1$ 或 $\lambda = -\frac{7}{2}$.

1. $\lambda = 1$ 时, 解得可能极值点为 $(1, -1)$ 和 $(-1, 1)$, 此时 $f(1, -1) = f(-1, 1) = -3$.

2. $\lambda = -\frac{7}{2}$ 时, 解得可能的极值点为 $(\sqrt{2}, \frac{\sqrt{2}}{2})$ 和 $(-\sqrt{2}, -\frac{\sqrt{2}}{2})$, 此时 $f(\sqrt{2}, \frac{\sqrt{2}}{2}) = f(-\sqrt{2}, -\frac{\sqrt{2}}{2}) = \frac{21}{2}$.

比较可知 $f(x, y)$ 在区域 $x^2 + 2y^2 \leq 3$ 上的最大值和最小值分别为 $\frac{21}{2}$ 和 -3 .

更一般地, 条件极值问题: $\max / \min \{y = f(x_1, \dots, x_n)\} \quad s.t. \quad g(x_1, \dots, x_n) = 0$ 可转化为无约束极值问题 $\max / \min \{\mathcal{L}\}$, 其中拉格朗日函数为

$$\mathcal{L}(x_1, \dots, x_n, \lambda) = f(x_1, \dots, x_n) + \lambda g(x_1, \dots, x_n)$$

则它取得极值的必要条件是 $\nabla \mathcal{L} = \mathbf{0}$, 由此解出驻点, 从而知可能的极值点.

例 3.7.3 设 $a > 0, a_i > 0 (i = 1, 2, \dots, n)$, 求 n 元函数 $f(x_1, \dots, x_n) = x_1^{a_1} x_2^{a_2} \dots x_n^{a_n}$ 在约束 $x_1 + \dots + x_n = a (x_i > 0, i = 1, 2, \dots, n)$ 下的最大值.

解: 直接求 f 的极值在形式上不便利, 但 f 取到最值当且仅当 $\ln f = \sum_{i=1}^n a_i \ln x_i$ 取到最值. 为此构造函数 $\mathcal{L}(x_1, \dots, x_n, \lambda) = \ln f(x_1, \dots, x_n) + \lambda(x_1 + \dots + x_n - a)$, 则 $\nabla \mathcal{L} = \mathbf{0}$ 等价于

$$\mathcal{L}_{x_i} = \frac{a_i}{x_i} - \lambda = 0, \quad i = 1, 2, \dots, n; \quad x_1 + \dots + x_n = a \quad \Rightarrow \quad \lambda = \frac{\sum_{i=1}^n a_i}{a}$$

$$\Rightarrow \quad x_{i*} = \frac{aa_i}{\sum_{i=1}^n a_i} \quad i = 1, 2, \dots, n.$$

这是 $\mathcal{L}$ 的唯一可能极值点, 下面验证它是极大值点, 由于它的唯一性, 故它是最大值点. 注意到, 当 $\mathcal{L}_\lambda = 0$ 成立, 即约束条件成立时, $\mathcal{L} = \ln f$, 故此时 $\mathcal{L}$ 的极值即 $\ln f$ 的极值, 亦即 f 的极值. 故在判断极值点的属性时, 只需考察 $\mathcal{L}$ 对 x_i 的二阶导数信息, 即

$$\left[\frac{\partial^2 \mathcal{L}}{\partial x_i \partial x_j} \right]_{1 \leq i, j \leq n} = \begin{bmatrix} -\frac{a_1}{x_1^2} & \dots & 0 & 0 \\ \vdots & -\frac{a_2}{x_2^2} & & \vdots \\ 0 & & \ddots & 0 \\ 0 & \dots & 0 & -\frac{a_n}{x_n^2} \end{bmatrix}$$

它显然是负定的, 从而 $(x_{1*}, \dots, x_{n*})$ 是 $\ln f$ (即 f) 的极大值点. 此时, f 取到其

在约束下的最大值

$$\prod_{i=1}^n \left(\frac{aa_i}{a_1 + \cdots + a_n} \right)^{a_i} = a_1^{a_1} \cdots a_n^{a_n} \left(\frac{a}{a_1 + \cdots + a_n} \right)^{a_1 + \cdots + a_n}$$

注记 3.7.2 特别地, 取 $a_1 = \cdots = a_n = 1, a = 1$, 则 $\max\{f\} = 1/n^n$, 亦即, 当 $x_1 + \cdots + x_n = 1, x_i > 0 (i = 1, \cdots, n)$ 时, 成立不等式 $x_1 \cdots x_n \leq 1/n^n$. 由此, 对任意整数 $y_1, \cdots, y_n$, 令 $x_i := \frac{y_i}{y_1 + \cdots + y_n}, i = 1, \cdots, n$, 则 x_i 满足上条件, 故得

$$\prod_{i=1}^n \frac{y_i}{y_1 + \cdots + y_n} \leq \left(\frac{1}{n} \right)^n \iff \sqrt[n]{y_1 \cdots y_n} \leq \frac{y_1 + \cdots + y_n}{n}$$

此即著名的平均值不等式. 很多著名的不等式也可通过此法证明. 比如通过考虑在条件 $\sum_{i=1}^n x_i y_i = A (x_i, y_i \geq 0)$ 之下求下面函数的最小值

$$f(y_1, \cdots, y_n) = \left(\sum_{i=1}^n x_i^p \right)^{\frac{1}{p}} \left(\sum_{i=1}^n y_i^q \right)^{\frac{1}{q}} \quad \text{其中 } p > 1, \text{ 且 } \frac{1}{p} + \frac{1}{q} = 1$$

$$\text{可证明著名的 Hölder 不等式: } \sum_{i=1}^n x_i y_i \leq \left(\sum_{i=1}^n x_i^p \right)^{\frac{1}{p}} \left(\sum_{i=1}^n y_i^q \right)^{\frac{1}{q}}$$

我们不应止步于此, 而应在数学形式自发完善的结构牵引之下, 将条件极值的更一般模式写下来, 便于应用的同时, 也得以将微分学中一以贯之的核心理念加以凸显, 从而体会繁杂多样背后的简易之道.

让我们回到本小节开始提及的最一般的条件极值模型 (Δ)

$$\min / \max \{f(x_1, \cdots, x_n)\} \quad s.t. \quad \begin{cases} g_1(x_1, \cdots, x_n) = 0 \\ \cdots \\ g_m(x_1, \cdots, x_n) = 0 \end{cases}$$

通过对只有一个约束条件的极值问题的多角度探讨, 我们大体能猜出有多个约束条件的求解思路及其求解格式.

首先, 我们假定上面 m 个约束条件 $g_i = 0$ 是独立的 (即没有冗余), 其判定可通过先在无穷小层面保证它们的独立性, 然后隐函数存在定理将保证它们的独立性. 为此,

对上面的约束条件微分, 得到

$$\begin{cases} \frac{\partial g_1}{\partial x_1} dx_1 + \cdots + \frac{\partial g_1}{\partial x_n} dx_n = 0 \\ \vdots \\ \frac{\partial g_m}{\partial x_1} dx_1 + \cdots + \frac{\partial g_m}{\partial x_n} dx_n = 0 \end{cases} \iff \underbrace{\begin{bmatrix} \frac{\partial g_1}{\partial x_1} & \cdots & \frac{\partial g_1}{\partial x_n} \\ \vdots & & \vdots \\ \frac{\partial g_m}{\partial x_1} & \cdots & \frac{\partial g_m}{\partial x_n} \end{bmatrix}}_{\mathbf{J}} \begin{bmatrix} dx_1 \\ \vdots \\ dx_n \end{bmatrix} = \begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix}$$

约束条件的诸微分是层度的当且仅当其所满足的线性方程组中诸方程是独立的, 当且仅当雅克比矩阵 $\mathbf{J}$ 是满秩的.

注记 3.7.3 如果 $\mathbf{J}$ 不是满秩的, 则诸微分 dg_i 不是独立的, 可将其中某些用另一些加以线性表示, 从而由隐函数存在定理知诸约束函数有冗余, 可将冗余消去后再考虑问题.

一般拉格朗日乘数法

对模型 (Δ) , 若点 $\mathbf{x}_* = (x_{1*}, \cdots, x_{n*})$ 为函数 $f(\mathbf{x})$ 在约束条件下的极值点的**必要条件**是 $\exists$ 常数 $\lambda_1, \cdots, \lambda_m$, 使得在 $\mathbf{x}_0$ 点处, 成立

$$\nabla f + \lambda_1 \nabla g_1 + \cdots + \lambda_m \nabla g_m = \mathbf{0}$$

故求解可能极值点的方法是先构造如下拉格朗日函数

$$\mathcal{L}(x_1, \cdots, x_n, \lambda_1, \cdots, \lambda_m) = f(x_1, \cdots, x_n) + \lambda_1 g_1(x_1, \cdots, x_n) + \cdots + \lambda_m g_m(x_1, \cdots, x_n)$$

则条件极值点满足拉格朗日方程 $\nabla \mathcal{L} = \mathbf{0}$, 即

$$\frac{\partial \mathcal{L}}{\partial x_i} = \frac{\partial f}{\partial x_i} + \sum_{k=1}^m \lambda_k \frac{\partial g_k}{\partial x_i} = 0, \quad i = 1, \cdots, n; \quad g_j = 0, \quad j = 1, \cdots, m.$$

另外, 若在满足上方程的极值点 $\mathbf{x}_*$ 处, 方阵 $\left[\frac{\partial^2 \mathcal{L}}{\partial x_i \partial x_j}(\mathbf{x}_*) \right]_{1 \leq i, j \leq n}$ 是正定 (负定) 的, 则 $\mathbf{x}_*$ 是满足约束条件的极小 (极大) 值点.

注记 3.7.4 注意, 一般形式的拉格朗日乘数法也遵循一般的“线性叠加”原理, 即独立约束条件 g_i 是以线性组合 $\sum_i \lambda_i g_i$ 的形式进入拉格朗日函数 $\mathcal{L}$ 里头的, 而系数 λ_i 为对应约束函数 g_i 的拉格朗日乘数. 如此, 则原 f 的条件极值问题转化为拉格朗日函数 $\mathcal{L}$ 的自由极值问题了.

下面以三元函数 $w = f(x, y, z)$ 在约束条件 $\begin{cases} G(x, y, z) = 0 \\ H(x, y, z) = 0 \end{cases}$ 下的条件极值问题

为例加以详细论述，并勾勒处其背后的直观几何图景，一般情形亦将由此自明.

1. 代数推导

(a) 微分角度：假设约束条件独立，即 $\mathbf{J} = \begin{bmatrix} G_x & G_y & G_z \\ H_x & H_y & H_z \end{bmatrix}$ 的秩为 2. 不妨设

$$\frac{\partial(G, H)}{\partial(x, y)} = \begin{vmatrix} G_x & G_y \\ H_x & H_y \end{vmatrix} \neq 0, \text{ 则可从微分约束关系中解出 } dx, dy$$

$$\text{即 } \begin{cases} G_x dx + G_y dy + G_z dz = 0 \\ H_x dx + H_y dy + H_z dz = 0 \end{cases} \Rightarrow \begin{cases} dx = -\frac{\frac{\partial(G, H)}{\partial(z, y)}}{\frac{\partial(G, H)}{\partial(x, y)}} dz \\ dy = -\frac{\frac{\partial(G, H)}{\partial(x, z)}}{\frac{\partial(G, H)}{\partial(x, y)}} dz \end{cases}$$

将 dx, dy 的如上表达式代入目标函数的微分 $dw = f_x dx + f_y dy + f_z dz$, 得到 dw 同 dz 之间的如下线性关系

$$dw = -f_x \frac{\frac{\partial(G, H)}{\partial(z, y)}}{\frac{\partial(G, H)}{\partial(x, y)}} dz - f_y \frac{\frac{\partial(G, H)}{\partial(x, z)}}{\frac{\partial(G, H)}{\partial(x, y)}} dz + f_z dz$$

则函数变动的相对稳定点位于微分 dw 为零处，故可能的极值点需满足条件

$$f_x \frac{\partial(G, H)}{\partial(y, z)} + f_y \frac{\partial(G, H)}{\partial(z, x)} + f_z \frac{\partial(G, H)}{\partial(x, y)} = 0$$

$$\text{因 } \nabla G \times \nabla H = \begin{vmatrix} \mathbf{i} & \mathbf{j} & \mathbf{k} \\ G_x & G_y & G_z \\ H_x & H_y & H_z \end{vmatrix} = \left(\frac{\partial(G, H)}{\partial(y, z)}, \frac{\partial(G, H)}{\partial(z, x)}, \frac{\partial(G, H)}{\partial(x, y)} \right)$$

故上式等价于

$$\nabla f \bullet (\nabla G \times \nabla H) = 0 \iff \nabla f \in \text{span} \{ \nabla G, \nabla H \}$$

即可能极值点条件等价于 $\exists \lambda, \mu \in \mathbb{R}$, 使得 $\nabla f + \lambda \nabla G + \mu \nabla H = 0$.

(b) 偏导角度：不妨设 $\frac{\partial(G, H)}{\partial(x, y)} = \begin{vmatrix} G_x & G_y \\ H_x & H_y \end{vmatrix} \neq 0$ ，则由隐函数存在定理知 x, y 可表示为 z 的函数，即有 $x = x(z)$, $y = y(z)$ ，且其对 z 的导数由下给出

$$\frac{dx}{dz} = -\frac{\frac{\partial(G, H)}{\partial(z, y)}}{\frac{\partial(G, H)}{\partial(x, y)}}; \quad \frac{dy}{dz} = -\frac{\frac{\partial(G, H)}{\partial(x, z)}}{\frac{\partial(G, H)}{\partial(x, y)}}$$

如此， $w = f(x, y, z)$ 就变成 z 的一元函数 $w = f(x(z), y(z), z)$ 了，则由全导数公式，及上面的导数公式，可得

$$\frac{dw}{dz} = \frac{\partial f}{\partial x} \frac{dx}{dz} + \frac{\partial f}{\partial y} \frac{dy}{dz} + \frac{\partial f}{\partial z} = -f_x \frac{\frac{\partial(G, H)}{\partial(z, y)}}{\frac{\partial(G, H)}{\partial(x, y)}} - f_y \frac{\frac{\partial(G, H)}{\partial(x, z)}}{\frac{\partial(G, H)}{\partial(x, y)}} + f_z$$


从而约束极值问题的驻点由方程 $\frac{dw}{dz} = 0$ 给出，故可能极值点满足条件

$$f_x \frac{\partial(G, H)}{\partial(y, z)} + f_y \frac{\partial(G, H)}{\partial(z, x)} + f_z \frac{\partial(G, H)}{\partial(x, y)} = 0 \quad \text{同 (a) 中所得.}$$

2. **几何解释** 两个独立约束 $G(x, y, z) = 0$ 和 $H(x, y, z) = 0$ 分别表示了 $\mathbb{R}^3$ 中的两张（约束）曲面，由独立性，它们有交线 $\mathcal{C} : \begin{cases} G(x, y, z) = 0 \\ H(x, y, z) = 0 \end{cases}$ 作为该条件极值问题的约束曲线。

则优化 $w = f(x, y, z)$ 的问题转为求 f 限制于约束曲线 $\mathcal{C}$ 上的优化问题。需计算 w 沿着 $\mathcal{C}$ 的切向量的方向导数，因方向导数为零的点是可能的条件极值点。

而曲线在其上任何点的切线方向正交于过该点的两曲面的方向量方向——分别由 ∇G 和 ∇H 给出，从而切线方向由 $\mathbf{n} = \nabla G \times \nabla H$ 给出。




故当点在约束曲线 $\mathcal{C}$ 上变动时, 目标函数 $w = f(x, y, z)$ 的变化率由方向导数 $\nabla_{\mathbf{n}}f$ 给出, 故条件极值点需满足如下方程


$$\begin{aligned}\nabla_{\mathbf{n}}f &= \nabla f \cdot \frac{\mathbf{n}}{|\mathbf{n}|} = 0 \iff \nabla f \cdot \mathbf{n} = 0 \\ \iff \nabla f \cdot (\nabla G \times \nabla H) &= 0 \iff \nabla f \in \text{span}\{\nabla G, \nabla H\}\end{aligned}$$

即 $\exists \lambda, \mu \in \mathbb{R}$, 使得 $\nabla f + \lambda \nabla G + \mu \nabla H = 0$.

几何上来说, 只有当函数 $w = f(x, y, z)$ 的梯度向量 (函数变化最快的方向) 在约束曲线 $\mathcal{C}$ 上某点 $\mathbf{x}_*$ 处的切向量上的投影长度为零, 即 $\nabla f \cdot \mathbf{n} = 0$ 时, 函数在约束下的取值才有可能相对稳定下来, 否则有继续增大或减少的趋势.



例 3.7.4 求平面 $\alpha x + \beta y + \gamma z = 0$ 与圆柱 $\frac{x^2}{A^2} + \frac{y^2}{B^2} = 1$ ($A, B > 0$) 交成的椭圆面积.



解: 知道所截椭圆的半轴 a, b , 则其面积为 πab . 注意到, a, b 为椭圆中心 $O(0, 0)$ 到椭圆上点的距离的最大和最小值. 故问题转化为求 $x^2 + y^2 + z^2$ 在约束 $\alpha x + \beta y + \gamma z = 0$ 和 $\frac{x^2}{A^2} + \frac{y^2}{B^2} = 1$ 下的最值. 为此构造拉格朗日函数

$$\mathcal{L}(x, y, z, \lambda, \mu) = x^2 + y^2 + z^2 + \lambda(\alpha x + \beta y + \gamma z) + \mu\left(\frac{x^2}{A^2} + \frac{y^2}{B^2} - 1\right)$$

则极值点需满足 $\nabla \mathcal{L} = \mathbf{0}$, 即

$$\begin{cases} \mathcal{L}_x = 2x + \frac{2\mu}{A^2}\mu x + \lambda\alpha = 0 & \textcircled{1} \\ \mathcal{L}_y = 2y + \frac{2\mu}{B^2}\mu y + \lambda\beta = 0 & \textcircled{2} \\ \mathcal{L}_z = 2z + \lambda\gamma = 0 & \textcircled{3} \end{cases} \quad \begin{cases} \alpha x + \beta y + \gamma z = 0 & (C_1) \\ \frac{x^2}{A^2} + \frac{y^2}{B^2} = 1 & (C_2) \end{cases}$$

先从①, ②, ③中解出

$$x = -\frac{\lambda\alpha}{2} \frac{A^2}{\mu + A^2}; \quad y = -\frac{\lambda\beta}{2} \frac{B^2}{\mu + B^2}; \quad z = -\frac{\lambda\gamma}{2}$$

代入约束条件 (C_1) 后整理得到参数 μ 所满足的(二次)方程

$$\mu^2 + \left(A^2 + B^2 + \frac{\alpha^2 A^2 + \beta^2 B^2}{\gamma^2} \right) \mu + \frac{A^2 B^2}{\gamma^2} (\alpha^2 + \beta^2 + \gamma^2) = 0 \quad (*)$$

但求解 μ , 然后解 x, y, z 会非常繁琐, 为简化处理, 我们先通过方程直接 ① - ③ 写出 $x^2 + y^2 + z^2$ 的表达式, 即考虑 ① $\times x$ + ② $\times y$ + ③ $\times z$, 得到

$$2x^2 + 2y^2 + 2z^2 + \frac{2\mu}{A^2}\mu x^2 + \frac{2\mu}{B^2}\mu y^2 + \lambda(\alpha x + \beta y + \gamma z) = 0$$

结合条件 (C_1) 和 (C_2) , 上式即为 $x^2 + y^2 + z^2 = -\mu$.

所截椭圆的半轴 a, b 为 $\sqrt{x^2 + y^2 + z^2}$ 在约束 $(C_1), (C_2)$ 下的最大值和最小值

$$\text{长半轴: } a = \sqrt{(-\mu)_{\max}} \quad \text{短半轴: } b = \sqrt{(-\mu)_{\min}}$$

故所截椭圆的面积为

$$S = \pi ab = \pi \sqrt{(-\mu)_{\max}(-\mu)_{\min}} = \pi \sqrt{\mu_{\max} \mu_{\min}}$$

而 $\mu_{\max}$ 和 $\mu_{\min}$ 即为上二次方程 $(*)$ 的两个根, 由韦达定理知

$$\mu_{\max} \mu_{\min} = \frac{A^2 B^2}{\gamma^2} (\alpha^2 + \beta^2 + \gamma^2) \quad \text{故} \quad S = \pi \frac{AB}{|\gamma|} \sqrt{\alpha^2 + \beta^2 + \gamma^2}$$


注记 3.7.5 截椭圆是 xy 平面上椭圆 $\frac{x^2}{A^2} + \frac{y^2}{B^2} = 1$ 在平面 $\alpha x + \beta y + \gamma z = 0$ 上的投影,

故两椭圆的面积之比 $\frac{\pi AB}{S}$ 为平面法向量相对于 z -轴方向的方向余弦 $\frac{|\gamma|}{\sqrt{\alpha^2 + \beta^2 + \gamma^2}}$.

例 3.7.5 求椭圆 $x^2 + 2y^2 = 1$ 和直线 $x + y = 4$ 之间的距离.

解: 椭圆和直线间的距离即为椭圆上的点 (x_1, y_1) 和直线上的点 (x_2, y_2) 之间距离的最小值, 故问题转化为如下条件极值问题

$$\min \left\{ \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2} \right\} \quad s.t. \quad \begin{cases} x_1^2 + 2y_1^2 = 1 \\ x_2 + y_2 = 4 \end{cases}$$



为求解它, 构造拉格朗日函数 $\mathcal{L}(x_1, y_1, x_2, y_2, \lambda, \mu) =$

$$= (x_1 - x_2)^2 + (y_1 - y_2)^2 + \lambda(x_1^2 + 2y_1^2 - 1) + \mu(x_2 + y_2 - 4)$$

然后令 $\nabla \mathcal{L} = \mathbf{0}$, 得 $\mathcal{L}_\lambda = x_1^2 + 2y_1^2 - 1 = 0$; $\mathcal{L}_\mu = x_2 + y_2 - 4 = 0$, 且

$$\mathcal{L}_{x_1} = 2(x_1 - x_2) + 2\lambda x_1 = 0; \quad \mathcal{L}_{y_1} = 2(y_1 - y_2) + 4\lambda y_1 = 0$$

$$\mathcal{L}_{x_2} = -2(x_1 - x_2) + \mu = 0; \quad \mathcal{L}_{y_2} = -2(y_1 - y_2) + \mu = 0$$

$$\text{得} \begin{cases} x_1 - x_2 = -\lambda x_1 \\ y_1 - y_2 = -2\lambda y_1 \\ x_1 - x_2 = \mu/2 \\ y_1 - y_2 = \mu/2 \end{cases} \Rightarrow \begin{cases} x_1 = -\mu/2\lambda \\ y_1 = -\mu/4\lambda \end{cases} \Rightarrow \begin{cases} x_1 = 2y_1 \\ x_1^2 + 2y_1^2 = 1 \end{cases} \Rightarrow$$

$$\begin{cases} x_1 = \pm \frac{2}{\sqrt{6}} \\ y_1 = \pm \frac{1}{\sqrt{6}} \end{cases} \Rightarrow \begin{cases} x_2 = (1 + \lambda)x_1 = \pm \frac{2}{\sqrt{6}}(1 + \lambda) \\ y_2 = (1 + 2\lambda)y_1 = \pm \frac{1}{\sqrt{6}}(1 + 2\lambda) \end{cases} \Rightarrow$$

$$x_2 - y_2 = \pm \frac{1}{\sqrt{6}}, \quad \text{又因 } x_2 + y_2 = 4 \quad \text{故} \quad \begin{cases} x_2 = 2 \pm \frac{1}{2\sqrt{6}} \\ y_2 = 2 \mp \frac{1}{2\sqrt{6}} \end{cases}$$

这是唯一临界点, 从而由题意知所求距离为 $\sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2} =$

$$\sqrt{\left(\pm \frac{2}{\sqrt{6}} - \left(2 \pm \frac{1}{2\sqrt{6}}\right)^2 + \left(\pm \frac{1}{\sqrt{6}} - \left(2 \mp \frac{1}{2\sqrt{6}}\right)^2\right)\right)} = \sqrt{2} \left(2 - \frac{3}{2\sqrt{6}}\right).$$

例 3.7.6 求函数 $f(x, y) = ax^2 + 2bxy + cy^2$ ($b \neq 0$) 限制在单位圆 $S^1: x^2 + y^2 = 1$ 上的极值.

解: 该问题可通过替换 $\begin{cases} x = \cos \theta \\ y = \sin \theta \end{cases}$ 转化为一元函数极值问题求解. 这里用更自然的拉格朗日乘子法. 构造

$$\mathcal{L}(x, y, \lambda) = ax^2 + 2bxy + cy^2 - \lambda(x^2 + y^2 - 1)$$

$$\text{然后令 } \nabla \mathcal{L} = \mathbf{0} \text{ 得 } \begin{cases} \mathcal{L}_x = 2ax + 2by - 2\lambda x = 0 \\ \mathcal{L}_y = 2bx + 2cy - 2\lambda y = 0 \\ \mathcal{L}_\lambda = x^2 + y^2 - 1 = 0 \end{cases} \quad \text{前两式可整理为如下线性方程组}$$

组

$$\begin{cases} (a - \lambda)x + by = 0 \\ bx + (c - \lambda)y = 0 \end{cases} \iff \underbrace{\begin{bmatrix} a - \lambda & b \\ b & c - \lambda \end{bmatrix}}_A \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

约束条件表明 x, y 不能同时为零, 故若问题有解, 则上方程组须有非平凡解才行! 而这要求上面的系数矩阵 A 的行列式为零 (即系数矩阵不可逆), 即

$$\det(A) = \begin{vmatrix} a - \lambda & b \\ b & c - \lambda \end{vmatrix} = \lambda^2 - (a + c)\lambda + ac - b^2 = 0$$

为使它有实根, 须判别式 $\Delta = (a + c)^2 - 4(ac - b^2) = (a - c)^2 + 4b^2 > 0$, 此时, 方程有两个相异实根

$$\lambda_{\pm} = \frac{(a + c) \pm \sqrt{(a - c)^2 + 4b^2}}{2}$$

$$\text{为简化求解过程, 利用 } \begin{cases} (a - \lambda)x + by = 0 \\ bx + (c - \lambda)y = 0 \\ x^2 + y^2 = 1 \end{cases}, \text{ 第一式, 第二式分别乘 } x, y, \text{ 再结}$$

合第三式, 得

$$f(x, y) = ax^2 + 2bxy + cy^2 = \lambda(x^2 + y^2) = \lambda$$

故 f 在单位圆上的限制 $f|_{S^1}$ 的最大值和最小值分别是 λ 的最大值和最小值, 即

$$\begin{cases} \max_{(x,y) \in S^1} \{f(x,y)\} = \lambda_+ = \frac{a+c+\sqrt{(a-c)^2+4b^2}}{2} \\ \min_{(x,y) \in S^1} \{f(x,y)\} = \lambda_- = \frac{a+c-\sqrt{(a-c)^2+4b^2}}{2} \end{cases}$$

注记 3.7.6 $f(x, y)$ 是一个二次型, 而系数矩阵 A 即为二次型的矩阵, 即

$$f(x, y) = x^2 + 2bxy + cy^2 = \begin{bmatrix} x & y \end{bmatrix} \begin{bmatrix} a & b \\ b & c \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix}$$

而 $\lambda_{\pm}$ 即为矩阵 A 的特征值, 即其特征多项式 $\det(\lambda I - A) = 0$ 的根. 故 $f|_{S^1}$ 的最值即为二次型 f 对应矩阵特征根的最值. 该结论的代数本质就在于“二次型的主轴定理”, 即通过正交坐标变化变消去二次型的交叉项, 则二次型可化简为 $\lambda_+ u^2 + \lambda_- v^2$, 由于坐标变换是正交的, 故 $x^2 + y^2 = 1$ 等价于新坐标下的 $u^2 + v^2 = 1$, 由此可直接看出最大值和最小值. 当然, 新坐标 (u, v) 对应的方向即两特征根对应特征向量的方向.

例 3.7.7 上例中的结论可进一步推广为求 n 元二次型 $Q(\mathbf{x}) = \sum_{i,j=1}^n a_{ij}x_i x_j$ (其中 $a_{ij} = a_{ji}$) 在 n 维单位球面 $S^n = \{\mathbf{x} \in \mathbb{R}^n \mid \|\mathbf{x}\| = \sqrt{x_1^2 + \cdots + x_n^2} = 1\}$ 上的最值问题. 令 $A = [a_{ij}]_{n \times n}$ 为二次型的相伴 (实对称) 矩阵. 构造拉格朗日函数

$$\mathcal{L}(\mathbf{x}, \lambda) = Q(\mathbf{x}) - \lambda \left(\sum_{i=1}^n x_i^2 - 1 \right) = \sum_{i,j=1}^n a_{ij}x_i x_j - \lambda \left(\sum_{i=1}^n x_i^2 - 1 \right)$$

令 $\nabla \mathcal{L} = \mathbf{0}$, 解得 $\forall i$, 有 $\mathcal{L}_{x_i} = 2 \sum_{j=1}^n a_{ij}x_j - 2\lambda x_i = 0$, 即 $\sum_{j=1}^n a_{ij}x_j = \lambda x_i$, 但这就是矩阵 A 的特征方程 $A\mathbf{x} = \lambda\mathbf{x}$. 故二次型在单位球面上的约束极值问题的临界点 $\mathbf{x}_*$ 满足其矩阵的特征方程, 而此时又有

$$Q(\mathbf{x}_*) = \mathbf{x}_*^T A \mathbf{x}_* = \lambda \mathbf{x}_*^T \mathbf{x}_* = \lambda \|\mathbf{x}_*\|^2 = \lambda$$

故知 $\max_{\mathbf{x} \in S^n} \{Q(\mathbf{x})\} = \lambda_{\max}$; $\min_{\mathbf{x} \in S^n} \{Q(\mathbf{x})\} = \lambda_{\min}$, 由此推广了例 3.7.6 中的结论.

3.8 多元凸函数及其刻画、凸规划 (*)

先回忆有关一元函数凸性的定义及其刻画.

一元凸函数: 设 $f(x)$ 在区间 I 上连续, 若 $\forall x_1, x_2 \in I$ 以及 $\forall \alpha \in (0, 1)$, 都成立

$$f(\alpha x_1 + (1 - \alpha)x_2) \leq \alpha f(x_1) + (1 - \alpha)f(x_2)$$

则称 f 在区间 I 上是下凸的. 若上面不等式严格成立 (即将 " $\leq$ " 改为 " $<$ " ($x_1 \neq x_2$)), 则称 f 在区间 I 上是严格下凸的; 又若 $\forall x_1, x_2 \in I$ 以及 $\forall \alpha \in (0, 1)$, 都成立


$$f(\alpha x_1 + (1 - \alpha)x_2) \geq \alpha f(x_1) + (1 - \alpha)f(x_2)$$

则称 f 在区间 I 上是上凸的. 若上面不等式严格成立 (即将 " $\geq$ " 改为 " $>$ " ($x_1 \neq x_2$)), 则称 f 在区间 I 上是严格上凸的.

特别地, 当 $\alpha = \frac{1}{2}$ 时, 有

$$\text{下凸: } f\left(\frac{x_1 + x_2}{2}\right) \leq \frac{f(x_1) + f(x_2)}{2}; \quad \text{上凸: } f\left(\frac{x_1 + x_2}{2}\right) \geq \frac{f(x_1) + f(x_2)}{2}$$

一般地 $\forall \alpha \in (0, 1)$, $\alpha x_1 + (1 - \alpha)x_2$ 是 x_1, x_2 之间的所有点, 而 $\alpha f(x_1) + (1 - \alpha)f(x_2)$ 是连接 $(x_1, f(x_1))$ 和 $(x_2, f(x_2))$ 的弦上所有点的纵坐标. 则下凸表示: 用垂直于 x 轴的直线扫描曲线, 则直线与弦线交点的纵坐标不小于直线与曲线交点的纵坐标, 即曲线在弦线之下; 同理, 上凸表示: 用垂直于 x 轴的直线扫描曲线, 则直线与弦线交点的纵坐标不大于直线与曲线交点的纵坐标, 即曲线在弦线之上.




一元凸函数判定法则:

1. (凸性的第一判别法) 设函数 $f(x)$ 在 $[a, b]$ 连续, 在 (a, b) 可导, 则 $f(x)$ 在 (a, b) 内是上凸(下凸)的充分必要条件是 $f'(x)$ 在区间 (a, b) 内单调减少(增加). 严格上(下)凸对应 $f'(x)$ 的严格减少(增加).
2. (凸性的第二判别法) 设函数 $f(x)$ 在 (a, b) 内二阶可导, 则 $f(x)$ 在 (a, b) 内下(上)凸当且仅当 $f''(x) > (<) 0$.

判定法则背后的直观就在下图及其解释之中: 若 $f(x)$ 在 (a, b) 内下凸, 那么 $\forall x \in (a, b)$ 及 $\Delta x > 0$, 若 $x + \Delta x$ 和 $x - \Delta x$ 都属于 (a, b) , 则有

$$f(x + \Delta x) - f(x) \geq f(x) - f(x - \Delta x)$$



$\forall x_1, x_2 \in (a, b)$, 不妨设 $x_1 < x_2$, 令 $\Delta x_n = \frac{x_2 - x_1}{n}$, 反复利用上式, 可得

$$\begin{aligned}
 f(x_2) - f(x_2 - \Delta x_n) &\geq f(x_2 - \Delta x_n) - f(x_2 - 2\Delta x_n) \\
 &\geq f(x_2 - 2\Delta x_n) - f(x_2 - 3\Delta x_n) \geq \dots \\
 \dots &\geq f(x_2 - (n-1)\Delta x_n) - f(x_2 - n\Delta x_n) = f(x_1 + \Delta x_n) - f(x_1) \\
 \Rightarrow \frac{f(x_2 + (-\Delta x_n)) - f(x_2)}{(-\Delta x_n)} &\geq \frac{f(x_1 + \Delta x_n) - f(x_1)}{\Delta x_n}
 \end{aligned}$$

令 $n \rightarrow \infty$ ($\Delta x_n \rightarrow 0$), 则上不等式变为 $f'(x_2) \geq f'(x_1)$, 即 $f'(x)$ 在 (a, b) 上单调增加. 若函数二阶可导, 则 $f''(x) > 0$. 下将凸函数的概念推广到多元情形.

定义 3.8.1 给出凸区域 $D \subseteq \mathbb{R}^n$, 即 $\forall \mathbf{x}, \mathbf{y} \in D, \forall \lambda \in [0, 1]$, 都有 $\lambda \mathbf{x} + (1 - \lambda) \mathbf{y} \in D$. 则定义在凸区域 D 上的 n 元函数 $y = f(\mathbf{x})$ 称为是凸函数 (convex function) 如果 $\forall \mathbf{x}, \mathbf{y} \in D, \forall \lambda \in [0, 1]$, 都有

$$f(\lambda \mathbf{x} + (1 - \lambda) \mathbf{y}) \leq \lambda f(\mathbf{x}) + (1 - \lambda) f(\mathbf{y})$$

若将 " $\leq$ " 换成 " $<$ ", 则称函数是严格凸 (*strictly convex*) 的.


注记 3.8.1 多元函数的凸性定义在形式上与一元情形是完全相同的, 只是为了简单起见, 我们没有单独定义上凸和下凸的概念, 读者可自行区分定义. 注意, 有些书籍论文中, 也把上面的 (下) 凸叫做凸, 而把上凸称作是凹. 虽然多元凸函数的定义结构同一元的一致, 只是为了 $\lambda \mathbf{x} + (1 - \lambda) \mathbf{y}$ 这样的式子有意义, 所考虑的定义区域必须是凸的才行 (一元情形的开闭区间是天然凸的, 故无需特别强调).

一元凸函数的判定法则只关心一阶导 f' 的单调性及二阶导 f'' 的正负性, 这是简洁的, 在实际应用中也是极方便的, 但对多元函数, 由于一元情形下的一阶导数和二阶导数的概念在多元情况下的自然推广是梯度向量和赫塞矩阵, 而向量函数没有单调一说, 而赫塞矩阵也无大于或小于零的概念, 故为了推广一元凸函数的判定法则, 需重审判定法则中所用到的核心结构特征, 以便将其转化或改写为可直接推广到多元的形式.

首先, 一元函数 $y = f(x)$ 在区间 I 上是 (下) 凸的, 等价于 $f'(x)$ 在区间内是单调增加的. 这是以区间 I 内每点附近为视角对凸性做出的判断, 见上页的对判定法则背后直观的说明. 但如以区间 I 整体为视角对凸性做出判断, 则有

定理 3.8.1 区间 I 上的可微函数 f 是下凸, 当且仅当过其上任意点 $(x_0, f(x_0)) (x_0 \in I)$ 的切线一定在曲线 $y = f(x)$ 的下方, 即

$$f(x) \geq f(x_0) + f'(x_0)(x - x_0) \quad \forall x \in I$$



证明: 必要性: 由中值定理, 知 $\exists \xi \in (x_0, x)$, 使得 $f(x) - f(x_0) = f'(\xi)(x - x_0)$, 故

$$f(x) - f(x_0) - f'(x_0)(x - x_0) = (f'(\xi) - f'(x_0))(x - x_0) \geq 0$$

充分性: $\forall x, y \in I, \forall \alpha \in [0, 1]$, 记 $z = \alpha x + (1 - \alpha)y$, 则由条件知

$$f(x) \geq f(z) + f'(z)(x - z); \quad f(y) \geq f(z) + f'(z)(y - z) \implies$$

$$\begin{aligned}\alpha f(x) + (1-\alpha)f(y) &\geq \alpha f(z) + (1-\alpha)f(z) + (\alpha(x-z) + (1-\alpha)(y-z))f'(z) \\ &= f(z) + \underbrace{(\alpha x + (1-\alpha)y - z)}_z f'(z) = f(z) = f(\alpha x + (1-\alpha)y)\end{aligned}$$

故 $\forall x, y \in I$, 有 $f(\alpha x + (1-\alpha)y) \leq \alpha f(x) + (1-\alpha)f(y)$. $\square$

由上定理, 一元函数 $y = f(x)$ 在区间 I 上下凸, 当且仅当 $\forall x, y \in I$, 有

$$f(y) \geq f(x) + f'(x)(y-x)$$

这种形式自然是便于推广到多元函数 $y = f(\mathbf{x})$, $\mathbf{x} \in D \subseteq \mathbb{R}^n$ (其中 D 是凸区域).

定理 3.8.1' (凸性的第一判别法) 凸区域 $D \subseteq \mathbb{R}^n$ 上的具有连续一阶偏导的函数 f 是凸的, 当且仅当: $\forall \mathbf{x}, \mathbf{y} \in D$, 有 $f(\mathbf{y}) \geq f(\mathbf{x}) + \nabla f(\mathbf{x}) \bullet (\mathbf{y} - \mathbf{x})$, 或以矩阵记 (向量写成列矩阵), 则为

$$f(\mathbf{y}) \geq f(\mathbf{x}) + (\mathbf{y} - \mathbf{x})^T \cdot \nabla f(\mathbf{x})$$

设 $\mathbf{x} = (x_1, \dots, x_n)$, $\mathbf{y} = (y_1, \dots, y_n)$, 则 $\nabla f = \left(\frac{\partial f}{\partial x_1}, \dots, \frac{\partial f}{\partial x_n} \right)$. 上式写开来就是

$$f(y_1, \dots, y_n) \geq f(x_1, \dots, x_n) + \sum_{i=1}^n \frac{\partial f}{\partial x_i} \Big|_{\mathbf{x}} (y_i - x_i)$$

上定理的证明模式完全同于一元情形, 只需将一元情形证明中的相关符号做对应的改写即可, 请读着自己完成.

其次, 在处理多元函数极值问题时已明了: 一元函数的二阶导数 $f''(x)$ 为正这一概念在多元时的相应推广是函数 $y = f(\mathbf{x})$ 的赫塞矩阵 (Hessian) 为正定, 即其对应二次型为恒正函数. 由此, 可将一元凸函数的第二判别准则推广到多元情形.

定理 3.8.2 (凸性的第二判别法) 凸域 $D \subseteq \mathbb{R}^n$ 上的具有连续二阶偏导的函数 f 是凸的, 当且仅当其 Hessian 矩阵

$$Q_{\mathbf{f}} = \left[\frac{\partial^2 f}{\partial x_i \partial x_j} \right]_{1 \leq i, j \leq n}$$

在 D 上半正定 (semi-positive definite). 即它在 D 上的每个点处都是半正定的.

注记 3.8.2 半正定赫塞矩阵的情形我们在上节中的例 3.5.4 中已接触过了, 见注记 3.6.5 中的说明. 一般地, 一个 n 阶实对称矩阵 A 是半正定的, 如果 $\forall \mathbf{x} \in \mathbb{R}^n$, $\mathbf{x} \neq \mathbf{0}$, 有 $\mathbf{x}^T A \mathbf{x} \geq 0$ (其中向量以列矩阵书写). 其等价刻画是, A 的所有 n 个特征根 (重数算入) 全部非负. 同理可定义半负定的概念.

定理 3.8.2 之证明 (充分性): $\forall \mathbf{x}, \mathbf{y} \in D$, 由多元泰勒展开, 知 $\exists \theta \in (0, 1)$, 使得

$$\begin{aligned} f(\mathbf{y}) &= f(\mathbf{x}) + (\mathbf{y} - \mathbf{x}) \cdot \nabla f(\mathbf{x}) + (\mathbf{y} - \mathbf{x})^T \cdot \mathbf{Q}_f|_{\mathbf{x}+\theta(\mathbf{y}-\mathbf{x})} \cdot (\mathbf{y} - \mathbf{x}) \\ &= f(\mathbf{x}) + \sum_{i=1}^n \frac{\partial f}{\partial x_i} \Big|_{\mathbf{x}} (y_i - x_i) + \frac{1}{2!} \sum_{1 \leq i, j \leq n} \frac{\partial^2 f}{\partial x_i \partial x_j} \Big|_{\mathbf{x}+\theta(\mathbf{y}-\mathbf{x})} (y_i - x_i)(y_j - x_j) \end{aligned}$$

若赫塞矩阵 $\mathbf{Q}_f = \left[\frac{\partial^2 f}{\partial x_i \partial x_j} \right]$ 半正定, 则对任意的 $\mathbf{x}, \mathbf{y} \in D$, 上式最后一项非负, 从而 $\forall \mathbf{x}, \mathbf{y} \in D$, 有

$$f(\mathbf{y}) - f(\mathbf{x}) + (\mathbf{y} - \mathbf{x})^T \cdot \nabla f(\mathbf{x}) \geq 0 \iff f(\mathbf{y}) \geq f(\mathbf{x}) + (\mathbf{y} - \mathbf{x})^T \cdot \nabla f(\mathbf{x})$$

则由定理 3.8.1' 知函数 f 是 D 上的凸函数.

(必要性): 用反证法, 若赫塞矩阵 $\mathbf{Q}_f$ 在 D 上不是半正定的, 即 $\exists \mathbf{x} \in D$, 及向量 $\mathbf{h} = [h_1 \ h_2 \ \cdots \ h_n]^T$ 使得 $\mathbf{h}^T \cdot \mathbf{Q}_f(\mathbf{x}) \cdot \mathbf{h} < 0$, 即

$$\begin{aligned} [h_1 \ h_2 \ \cdots \ h_n] &\begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2}(\mathbf{x}) & \frac{\partial^2 f}{\partial x_1 \partial x_2}(\mathbf{x}) & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n}(\mathbf{x}) \\ \frac{\partial^2 f}{\partial x_2 \partial x_1}(\mathbf{x}) & \frac{\partial^2 f}{\partial x_2^2}(\mathbf{x}) & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n}(\mathbf{x}) \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n^1}(\mathbf{x}) & \frac{\partial^2 f}{\partial x_n \partial x_2}(\mathbf{x}) & \cdots & \frac{\partial^2 f}{\partial x_n^2}(\mathbf{x}) \end{bmatrix} \begin{bmatrix} h_1 \\ h_2 \\ \vdots \\ h_n \end{bmatrix} \\ &= \sum_{1 \leq i, j \leq n} \frac{\partial^2 f}{\partial x_i \partial x_j}(\mathbf{x}) h_i h_j < 0 \end{aligned}$$

但另一方面, 由泰勒展开知, $\forall t > 0$, 当 $t \rightarrow 0$ 时, 有

$$\begin{aligned} f(\mathbf{x} + t\mathbf{h}) &= f(\mathbf{x}) + t\mathbf{h}^T \cdot \nabla f(\mathbf{x}) + \frac{1}{2!} (t\mathbf{h})^T \cdot \mathbf{Q}_f(\mathbf{x}) \cdot (t\mathbf{h}) + o(|t\mathbf{h}|^2) \\ &= f(\mathbf{x}) + t\mathbf{h}^T \cdot \nabla f(\mathbf{x}) + \frac{t^2}{2!} \underbrace{\mathbf{h}^T \cdot \mathbf{Q}_f(\mathbf{x}) \cdot \mathbf{h}}_{<0} + o(t^2) \end{aligned}$$

t 足够小时, $f(\mathbf{x} + t\mathbf{h}) - f(\mathbf{x}) - t\mathbf{h}^T \cdot \nabla f(\mathbf{x}) = \frac{t^2}{2!} \underbrace{\mathbf{h}^T \cdot \mathbf{Q}_f(\mathbf{x}) \cdot \mathbf{h}}_{<0} + o(t^2) < 0$, 从而

得到

$$f(\mathbf{x} + t\mathbf{h}) < f(\mathbf{x}) + t\mathbf{h}^T \cdot \nabla f(\mathbf{x}) \quad \text{而这与 } f \text{ 的凸性是矛盾的. } \square$$

我们知道, 函数的极小值点是局部的, 一般不是全局极小值点 (即最小值点). 故在求解优化问题时, 除了确定考察区域内部的所有极小值点外, 还要考察函数在区域边界上的取值情况, 然后与区域内的极小值相比较, 这通常是比较繁琐的. 但下面将表明, 如果考察的是凸区域上的凸函数, 则不用这么麻烦, 因为其极小值点就是最小值点.

设 $f(\mathbf{x})$ 是定义在凸区域 $D \subseteq \mathbb{R}^n$ 上的可微凸函数, 设 $\mathbf{x}_* \in D$ 是区域内函数的一个极小值点, 即 $\nabla f(\mathbf{x}_*) = \mathbf{0}$, 但由于 f 是凸函数, 故 $\forall \mathbf{x} \in D$ (包括 $\mathbf{x}_* \in \partial D$), 成立

$$f(\mathbf{x}) \geq f(\mathbf{x}_*) + (\mathbf{x} - \mathbf{x}_*)^T \cdot \nabla f(\mathbf{x}_*) = f(\mathbf{x}_*)$$

故对凸域上的凸函数来说: 局部极小值 = 全局极小值 = 最小值.

事实上, 对凸域 D 上的凸函数 f 来说, 只要点 $\mathbf{x}_* \in D$ 满足下条件, 那么它就是 f 在 D 上的最小值点

$$(\mathbf{x} - \mathbf{x}_*)^T \cdot \nabla f(\mathbf{x}_*) \geq 0 \quad \forall \mathbf{x} \in D$$

当然, 如果 $\mathbf{x}_*$ 属于区域 D 的内部, 则向量 $\mathbf{x} - \mathbf{x}_*$ 可取到 $\mathbb{R}^n$ 中的所有方向, 故此时, 上条件“退化”为通常的临界点 (驻点) 条件 $\nabla f(\mathbf{x}_*) = \mathbf{0}$.

故而, 对凸域 D 上的可微凸函数 f 来说, 其内点 $\mathbf{x}_*$ 是最小值点当且仅当 $\mathbf{x}_*$ 是临界点, 即 $\nabla f(\mathbf{x}_*) = \mathbf{0}$. 但对非凸函数, 条件 $\nabla f(\mathbf{x}_*) = \mathbf{0}$ 只是内点 $\mathbf{x}_*$ 为极值点的必要条件. 由此看出“凸”是比较强的限制条件, 它能简化优化问题的处理.

命题 3.8.1 凸域 D 上的有限个凸函数 $f_i, i = 1, \dots, n$ 的非负线性组合 $\beta_1 f_1 + \dots + \beta_n f_n$ ($\beta_i \geq 0$) 仍是凸函数.

证明: $\forall \mathbf{x}, \mathbf{y} \in D, \forall \lambda \in \mathbb{R}$, 因 f_i 为凸, 故 $(\beta_1 f_1 + \dots + \beta_n f_n)(\lambda \mathbf{x} + (1 - \lambda)\mathbf{y}) =$

$$= \beta_1 f_1(\lambda \mathbf{x} + (1 - \lambda)\mathbf{y}) + \dots + \beta_n f_n(\lambda \mathbf{x} + (1 - \lambda)\mathbf{y})$$

$$\leq \beta_1 (\lambda f_1(\mathbf{x}) + (1 - \lambda)f_1(\mathbf{y})) + \dots + \beta_n (\lambda f_n(\mathbf{x}) + (1 - \lambda)f_n(\mathbf{y}))$$

$$= \lambda(\beta_1 f_1 + \dots + \beta_n f_n)(\mathbf{x}) + (1 - \lambda)(\beta_1 f_1 + \dots + \beta_n f_n)(\mathbf{y}) \quad \square$$

命题 3.8.2 f 是凸域 D 上的凸函数, 则 $\forall \beta \in \mathbb{R}$, 其 β -水平集: $S_\beta = \{\mathbf{x} \mid \mathbf{x} \in D, f(\mathbf{x}) \leq \beta\}$ 是凸的.

证明: $\forall \mathbf{x}, \mathbf{y} \in S_\beta, \forall \lambda \in \mathbb{R}$, 由于 f 是凸的, 故

$$f(\lambda \mathbf{x} + (1 - \lambda)\mathbf{y}) \leq \lambda f(\mathbf{x}) + (1 - \lambda)f(\mathbf{y}) \leq \lambda \beta + (1 - \lambda)\beta = \beta$$

从而 $\lambda \mathbf{x} + (1 - \lambda)\mathbf{y} \in S_\beta$, 由此知 S_β 是凸域. $\square$

非线性规划 (*nonlinear programming*) 是应用中比较重要的一类优化模型 (*optimization model*), 它推广了上节讨论的条件极值模型, 其数学模型可写成

$$\min f(\mathbf{x}), \mathbf{x} \in \mathbb{R}^n \quad \text{s.t.} \quad \begin{cases} h_i(\mathbf{x}) = 0 & (i = 1, 2, \dots, m) \\ g_j(\mathbf{x}) \geq 0 & (j = 1, 2, \dots, n) \end{cases}$$

其中 $f(\mathbf{x})$ 称为要优化的目标函数, 约束条件由约束函数 $h_i(\mathbf{x})$ 及 $g_j(\mathbf{x})$ 给出.

如果某个约束是 " $\leq$ " 的形式, 则两边乘 " $-$ " 便将该约束写为 " $\geq$ " 的形式. 又因为 $\max f(\mathbf{x}) = -\min(-f(\mathbf{x}))$, 故上表述能处理最一般的模式.

另外, 注意到等式约束条件 $h_i(\mathbf{x}) = 0$ 等价于 $\begin{cases} h_i(\mathbf{x}) \geq 0 \\ -h_i(\mathbf{x}) \geq 0 \end{cases}$ 故上模型也可写为

$$\min f(\mathbf{x}), \mathbf{x} \in \mathbb{R}^n \quad \text{s.t.} \quad g_i(\mathbf{x}) \geq 0 \quad (i = 1, \dots, l)$$


$$\Leftrightarrow \min f(\mathbf{x}), \mathbf{x} \in R \subseteq \mathbb{R}^n, \quad R := \{\mathbf{x} \mid g_i(\mathbf{x}) \geq 0, i = 1, \dots, l\}$$

其中 R 称为优化或规划问题的可行域.

例 3.8.1 考虑非线性规划 $\min f(\mathbf{x}) = x_1^2 + x_2^2 - 4x_1 + 4$, s.t. $\begin{cases} g_1(\mathbf{x}) = x_1 - x_2 + 2 \geq 0 \\ g_2(\mathbf{x}) = -x_1^2 + x_2 - 1 \geq 0 \\ g_3(\mathbf{x}) = x_1 \geq 0 \\ g_4(\mathbf{x}) = x_2 \geq 0 \end{cases}$

解: 该问题的每个约束函数 g_i 都是凹函数 (即 $-g_i$ 为凸), 故约束条件界定的可行域, 由命题 3.8.2, 可知是凸的; 而目标函数 f 显然也是凸的. 故我们的问题是凸函数在凸 (可行) 域上的最值问题.

由于是二维问题, 故求解思路可遵从图解线性规划的模式, 先画出可行区域, 然后考虑目标函数的登高线图, 观察其与可行域的相交情况, 由此定出所求解.



可知, $f(\mathbf{x}) = C$ 与可行域 R 的边界上由 $g_2(\mathbf{x}) \geq 0$ 给出的部分交于唯一一点 $\mathbf{x}_* = (0.58, 1.34)$, 它对于 f 的最小值 $f(\mathbf{x}_*) = 3.8$. 故该问题有唯一解 $\mathbf{x}_*$.

对上例中的目标函数 f ，其梯度 $\nabla f = (2x_1 - 4, 2x_2)$ ，从而在 $\mathbf{x}_*$ 处

$$\nabla f(\mathbf{x}_*) = (2 \times 0.58 - 4, 2 \times 1.34) = (-2.84, 2.68)$$

由此，可直接验证极小点条件如下： $\forall \mathbf{x} \in R$ ，有

$$\begin{aligned} (\mathbf{x} - \mathbf{x}_*)^T \cdot \nabla f(\mathbf{x}_*) &= -2.84(x_1 - 0.58) + 2.68(x_2 - 1.34) = \\ &= 2.68x_2 - 2.84x_1 - 1.944 \geq 2.68(1 + x_1^2) - 2.84x_1 - 1.944 \\ &= 2.68x_1^2 - 2.84x_1 + 0.736 \geq \frac{4 \times 2.68 \times 0.736 - 2.84^2}{4 \times 2.68} \approx -0.016 \end{aligned}$$

故在误差容许的范围内， $\mathbf{x}_*$ 满足凸域上凸函数的局部极小点的条件，上面的求解表明它也是全局最优解，这当然符合我们先前的推断。下面将看到，它作为唯一最优解这一特性也并非偶然，而是有其根本原因的。

定义 3.8.2 非线性规划称为凸规划若目标函数 $f(\mathbf{x})$ 为凸函数，且约束函数 $g_j(\mathbf{x})$ 皆是凹函数（即 $-g_j(\mathbf{x})$ 皆为凸）。

由命题 3.8.2，凸规划的可行域为凸，故局部最优解也是全局最优解。但对凸规划，不仅有此便利，还有更好的性质，即

定理 3.8.3 凸优化中，如目标函数 f 严格凸，则其最优解若存在则必唯一。

证明：假设最优解不唯一，则不妨假设有不互相同的两个最优解 $\mathbf{x}_1, \mathbf{x}_2 \in R$ ，满足 $f(\mathbf{x}_1) = f(\mathbf{x}_2)$ ，且 $\forall \mathbf{x} \in R$ ， $\mathbf{x} \neq \mathbf{x}_i, i = 1, 2$ ，都有 $f(\mathbf{x}) \geq f(\mathbf{x}_1) = f(\mathbf{x}_2)$ 。

由于可行域 R 是凸的，故 $\forall \lambda \in (0, 1)$ ，成立

$$\lambda \mathbf{x}_1 + (1 - \lambda) \mathbf{x}_2 \in R$$

又由于目标函数 f 是严格凸的，故

$$f(\lambda \mathbf{x}_1 + (1 - \lambda) \mathbf{x}_2) < \lambda f(\mathbf{x}_1) + (1 - \lambda) f(\mathbf{x}_2) = f(\mathbf{x}_1)$$

但这与我们的假设 $f(\mathbf{x}_1) = f(\mathbf{x}_2)$ 相矛盾了。从而说明凸规划若有最优解，则其必是唯一的。□

3.9 梯度下降法、库恩-塔克条件与广义拉格朗日乘子 (*)

处理极值问题时, 理论上先得确定目标函数的所有临界点, 即梯度为零的点 (约束极值情形时拉格朗日函数 $\mathcal{L}$ 的临界点). 但如果目标函数的解析表达式相当繁复, 或根本写不出具体的解析表达式时, 这种方法就不方便了. 此时, 宜采用迭代 (iteration) 法, 以逐步逼近为目标, 后一步经由前一步反馈而生成迭代的下一步, 且迭代过程只用到函数值, 而不要求函数的解析性质.

考虑问题 $\arg \min_{\mathbf{x} \in \mathbb{R}^n} \{f(\mathbf{x})\}$, 即求极小值点 $\mathbf{x}_*$. 设 $\mathbf{x}_k$ 是 $\mathbf{x}_*$ 的第 k 次近似.

为得到第 $k+1$ 次近似 $\mathbf{x}_{k+1}$, 假设它位于从 $\mathbf{x}_k$ 出发, 沿 $\mathbf{v}_k$ 方向的如下射线上

$$l_k : \mathbf{x} = \mathbf{x}_k + t\mathbf{v}_k, \quad t \geq 0$$

为确定 $\mathbf{x}_{k+1}$, 现将 f 限制于 l_k 上, 便得到函数 $f|_{l_k}(t)$, 然后将其在 $t=0$ 泰勒展开 (注意, 这相当于原函数 $f(\mathbf{x})$ 沿 l_k 变动时在 $\mathbf{x}_k$ 处的泰勒展开), 得到

$$f(\mathbf{x}) = f(\mathbf{x}_k + t\mathbf{v}_k) = f(\mathbf{x}_k) + t\nabla f(\mathbf{x}_k)^T \mathbf{v}_k + o(t)$$

显然, 这里 $\nabla f(\mathbf{x}_k) \neq \mathbf{0}$, 否则 $\mathbf{x}_k$ 已经是所需临界点了. 故只要选择 $\mathbf{x} \in l_k$, 使得 $f(\mathbf{x}) < f(\mathbf{x}_k)$, 则 $\mathbf{x}$ 便可作为 $\mathbf{x}_{k+1}$ 的“候选”. 当然, 我们要尽可能选出最优的 $\mathbf{x}_{k+1}$ 的“候选”值. 由于在射线 l_k 上,

$$f(\mathbf{x}) - f(\mathbf{x}_k) = t\nabla f(\mathbf{x}_k)^T \mathbf{v}_k + o(t) = t\|\nabla f(\mathbf{x}_k)\| \cdot \|\mathbf{v}_k\| \cos \theta + o(t)$$

其中 θ 为 $\mathbf{x}_k$ 处的梯度方向和射线方向之间的夹角, 为使函数值 f 沿 l_k 的减少速度最快, 显然 l_k 的方向 $\mathbf{v}_k$ 须选为与 $\nabla f(\mathbf{x}_k)$ 反向 (即 $\theta = \pi$).

故取 $\mathbf{v}_k = -\nabla f(\mathbf{x}_k)$, 尚需选择合适的“步长” t , 使得 $f(\mathbf{x}_k - t\nabla f(\mathbf{x}_k))$ 的值最小, 即最佳步长由下定义

$$t_k := \arg \min_{t \geq 0} \{f(\mathbf{x}_k - t\nabla f(\mathbf{x}_k))\}$$

由此, 得到 $\mathbf{x}_*$ 的第 $k+1$ 次迭代为 $\mathbf{x}_{k+1} = \mathbf{x}_k - t_k \nabla f(\mathbf{x}_k)$. 事实上, 若 f 具有二阶连续偏导数, 则最佳步长可确定如下: 将 $f(\mathbf{x}_k - t\nabla f(\mathbf{x}_k))$ 在 $\mathbf{x}_k$ 处二阶泰勒展开

$$\begin{aligned} f(\mathbf{x}_k - t\nabla f(\mathbf{x}_k)) &= f(\mathbf{x}_k) - t\nabla f(\mathbf{x}_k)^T \cdot \nabla f(\mathbf{x}_k) + \\ &+ \frac{1}{2}t^2 \nabla f(\mathbf{x}_k)^T \mathbf{Q}_f(\mathbf{x}_k) \nabla f(\mathbf{x}_k) + o(t^2) \end{aligned}$$

其中 $\mathbf{Q}_f(\mathbf{x}_k) := \left[\frac{\partial^2 f}{\partial x_i \partial x_j} \bigg|_{\mathbf{x}_k} \right]_{1 \leq i, j \leq n}$ 为 $f(\mathbf{x})$ 在 $\mathbf{x}_k$ 处的赫塞矩阵 (Hessian matrix)

令


$$\frac{df(\mathbf{x}_k - t\nabla f(\mathbf{x}_k))}{dt} \approx \nabla f(\mathbf{x}_k)^T \cdot \nabla f(\mathbf{x}_k) + t \nabla f(\mathbf{x}_k)^T \mathbf{Q}_f(\mathbf{x}_k) \nabla f(\mathbf{x}_k) = 0$$

从中解出 t , 即得最优步长的二阶近似为

$$t_k = \frac{\nabla f(\mathbf{x}_k)^T \cdot \nabla f(\mathbf{x}_k)}{\nabla f(\mathbf{x}_k)^T \cdot \mathbf{Q}_f(\mathbf{x}_k) \cdot \nabla f(\mathbf{x}_k)} \quad (*)$$

上面的迭代算法通常成为梯度下降法 (gradient decent), 也称为最速下降法 (steepest decent), 其算法流程给出如下

1. 给定初始点 $\mathbf{x}_k$ 和容许误差 ϵ , 令 $k := 0$;
2. 计算 $f(\mathbf{x}_k)$ 和 $\nabla f(\mathbf{x}_k)$, 若 $\|\nabla f(\mathbf{x}_k)\|^2 \leq \epsilon$, 则停止迭代, 得到近似极小值点 $\mathbf{x}_k$ 和近似极小值 $f(\mathbf{x}_k)$, 否则转到下一步
3. 利用上公式 (*) 求出近似最优步长 t_k , 并计算 $\mathbf{x}_{k+1} = \mathbf{x}_k - t_k \nabla f(\mathbf{x}_k)$, 然后令 $k := k + 1$, 转回到第 2 步.



实际中常需处理带约束的优化问题, 其一般形式为

$$\min\{f(\mathbf{x})\}, \mathbf{x} \in R \subseteq \mathbb{R}^n, \quad R := \{\mathbf{x} \mid g_i(\mathbf{x}) \geq 0, i = 1, \dots, l.\}$$

为将梯度下降法推广到这一情景之中，即需考虑约束条件带来的限制，但此时由于约束条件通常是**不等式约束**，故先前通过引入拉格朗日乘子构造拉格朗日函数的方法在此不能直接试用。须推广拉格朗日乘子法。

先回忆拉格朗日乘子法的由来。以二元函数 $f(x, y)$ 在一个约束条件 $g(x, y) = 0$ 下的极值问题为例来说明，拉格朗日乘子法的本质在于：考察 $df = f_x dx + f_y dy$ 在微分约束 $g_x dx + g_y dy = 0$ 下为零的条件——驻点条件。但如果约束是不等式 $g(x, y) \geq 0$ ，那就无法对 g 微分而获得 dx 和 dy 之间的关系，从而代入 $df = 0$ 加以求解了。

破此限制的策略：在区域 $g(x, y) \geq 0$ 中搜寻点列 (x_k, y_k) （即 $g(x_k, y_k) \geq 0$ ），使得 $f(x_k, y_k) \geq f(x_{k+1}, y_{k+1})$ 。问题的关键在于：

在满足约束条件的每一点 (x_k, y_k) 处，确定一个**下降方向** $\mathbf{v}_k$ ，使得沿该方向的射线上存在满足约束条件的点 (x_{k+1}, y_{k+1}) 。

首先，任取满足约束的点 (x_0, y_0) ，即 $g(x_0, y_0) \geq 0$ ，有两种可能

1. 如果 $g(x_0, y_0) = 0$ ，此时可确定一个方向 $\mathbf{v} = (v_x, v_y)$ 且 $\exists t_0 > 0$ ，使得 $\forall t \in [0, t_0]$ ，都有

$$g(x_0 + tv_x, y_0 + tv_y) \geq g(x_0, y_0) = 0$$

而这条件又等价于

$$\left. \frac{d}{dt} \right|_{t=0} g(x_0 + tv_x, y_0 + tv_y) = \nabla g|_{(x_0, y_0)} \bullet \mathbf{v} \geq 0$$

即在 (x_0, y_0) 点处的**可行方向**（作为下降方向的可能候选） $\mathbf{v}$ 需满足的条件是：它与约束函数 g 在这点的梯度方向成锐角，即

$$\nabla g(x_0, y_0) \bullet \mathbf{v} = \nabla g(x_0, y_0)^T \cdot \mathbf{v} \geq 0 \quad (C_1)$$

2. 如果 $g(x_0, y_0) > 0$ ，此时由于约束函数 g 的连续性，可知对 1. 中的可行方向 $\mathbf{v} = (v_x, v_y)$ 及足够小的 t ，都成立 $g(x_0 + tv_x, y_0 + tv_y) \geq 0$ 。

综上，只要 $\mathbf{v}$ 满足条件 (C_1) ，它就是 (x_0, y_0) 点处的一个**可行方向**。接着，需在全体可行方向中选择适合的下降方向，称为**可行下降方向**。

对可行方向 $\mathbf{v}$ ，如果它同时是目标函数 $f(x, y)$ 在 (x_0, y_0) 点处的一个下降方向，那么存在 t'_0 ，使得 $\forall t \in [0, t'_0]$ ，都有

$$f(x_0 + tv_1, y_0 + tv_y) < f(x_0, y_0)$$

由泰勒展开

$$f(x_0 + tv_1, y_0 + tv_y) = f(x_0, y_0) + t \nabla f(x_0, y_0) \bullet \mathbf{v} + o(t)$$

故当 t 足够小时, 只要满足**下降条件**

$$\nabla f(x_0, y_0) \bullet \mathbf{v} = \nabla f(x_0, y_0)^T \cdot \mathbf{v} < 0 \quad (C_2)$$


则必有 $f(x_0 + tv_x, y_0 + tv_y) < f(x_0, y_0)$. 上述讨论可总结为:

只要在某可行点 $p_0(x_0, y_0)$ 处, 存在方向 $\mathbf{v}$, 使得条件 $(C_1), (C_2)$ 同时满足, 则 $\mathbf{v}$ 就是该点处的一个可行下降方向, 即在以 p_0 为端点, 以 $\mathbf{v}$ 为方向的射线上能选到点 p , 使得 p 仍是满足约束条件的可行点, 且 $f(p) < f(p_0)$.

换言之, 若 $p_*(x_*, y_*)$ 是 f 在约束 $g \geq 0$ 下的一个局部极小值点, 且 f 和 g 在 p_* 处都可微, 则 p_* 处不存在可行下降方向, 即不存在方向 $\mathbf{v}$, 使得下两条件同时成立

$$\nabla g(p_*) \bullet \mathbf{v} > 0 \quad (C_1); \quad \nabla f(p_*) \bullet \mathbf{v} < 0 \quad (C_2)$$

即在 p_* 处, **不存在**如下图所示的与 ∇g 和 $-\nabla f$ 都构成锐角的方向 $\mathbf{v}$.



试问: 如上图中的情形不可能, 则 $\nabla f(p_*)$ 和 $\nabla g(p_*)$ 之间本身应满足什么条件呢?

不难看出, 当且仅当 ∇f 和 ∇g 在点 p_* 是同方向时, 才能避免上图情形发生, 即

$$\exists \lambda < 0, \quad \text{使得} \quad \nabla f(p_*) + \lambda \nabla g(p_*) = \mathbf{0}$$

但如 $g(p_*) > 0$, 则 p_* 附近的微小“扰动” $p_* + \delta p$ 仍可行, 即 $g(p_* + \delta p) \geq 0$ 这相当于在 g 在 p_* 附近对 f 没有起到有效的约束, 从而 p_* 处的极小值条件只是 $\nabla f(p_*) = \mathbf{0}$ 本身, 可将其视作 $\lambda = 0$ 的情形. 该情形也纳入考量, 可以得到如下判定条件:

设 p_* 是 $f(x, y)$ 在约束 $g(x, y) \geq 0$ 下的极小值点, 则该点须满足下条件

$$\exists \lambda \leq 0, \quad \text{使得} \quad \begin{cases} \nabla f(p_*) + \lambda \nabla g(p_*) = \mathbf{0} \\ \lambda g(p_*) = 0 \end{cases}$$

也就是说, 当 $g(p_*) = 0$ 时, g 在 p_* 近旁对 f 的约束是有效的, 是实质得, 故此
 时 $\lambda \neq 0$; 而当 $g(p_*) > 0$ 时, g 在 p_* 近旁对 f 的约束是无效的, 此时 $\lambda = 0$, 上条件
 退化为 $\nabla f(p_*) = \mathbf{0}$.

由此看出, 所得到的结论仍符合拉格朗日乘子法的模式, 只是将其推广到纳入不
 等式约束的更一般情形. 故上面的 λ 可称为广义拉格朗日乘子 (*generalized Lagrange multiplier*). 而上面的极值点条件即为著名的库恩-塔克 (*Kuhn-Tucker*) 条件 (只有一个
 约束的特殊情形). 库恩-塔克 (*Kuhn-Tucker*) 条件简称为 *K-T* 条件.

例 3.9.1 求解 $\max\{f(x) = (x-3)^2\}$, *s.t.* $x \leq 5$. 它等价于 $\min\{-f(x)\}$, *s.t.* $g(x) = -x + 5 \geq 0$. 此时极值点 x_* 的 *K-T* 条件为: $\exists \lambda \leq 0$, 使得

$$(-f)'(x_*) + \lambda g'(x_*) = 0; \quad \lambda g(x_*) = 0 \quad \Longleftrightarrow \quad \begin{cases} -2(x_* - 3) - \lambda = 0 \\ \lambda(5 - x_*) = 0 \end{cases}$$

当 $\lambda \neq 0$ 时, 由第二个方程知 $x_* = 5$, 但这与第一个方程矛盾 (因 $\lambda \leq 0$), 故
 $\lambda = 0$, 此时只有 $x_* = 3$ 可行, 但它是无约束下函数的一个极值点, 不是我们需要的极
 大值点, 故该问题无解, 这当然是符合题意的.

我们稍将问题改变一下, 即 $\min\{f(x) = (x-3)^2\}$, *s.t.*, $g(x) = 5 - x \geq 0$. 此时极
 值点 x_* 的 *K-T* 条件为: $\exists \lambda \leq 0$, 使得

$$f'(x_*) + \lambda g'(x_*) = 0; \quad \lambda g(x_*) = 0 \quad \Longleftrightarrow \quad \begin{cases} 2(x_* - 3) - \lambda = 0 \\ \lambda(5 - x_*) = 0 \end{cases}$$

此时出了无约束时的极值点 $x_* = 3$ 之外, 还有解 $x_* = 5$ (对应 $\lambda = 0$), 它显然是
 在约束条件下的一个局部极大值点. 该问题的解为 $x_* = 3$.

我们不加证明地给出如下一般约束极值问题的 *K-T* 条件

$$\min\{f(\mathbf{x})\}, \quad \mathbf{x} \in R \subseteq \mathbb{R}^n, \quad R := \{\mathbf{x} \mid g_i(\mathbf{x}) \geq 0, i = 1, \dots, l\}$$

从形式上来讲, 如果有多个条件 $g_i \geq 0$, 则应给每个约束条件配给一个广义拉格朗
 日乘子 λ_i , 然后按一个约束时的模式将它们共线线性叠加即可.

K-T 条件: $\mathbf{x}_*$ 是上优化问题的极小值点的必要条件是 $\exists \lambda_i \leq 0, i = 1, \dots, l$, 使得

$$\nabla f(\mathbf{x}_*) + \sum_{i=1}^l \lambda_i \nabla g_i(\mathbf{x}_*) = \mathbf{0}; \quad \lambda_i g_i(\mathbf{x}_*) \geq 0, \quad 1 \leq i \leq l.$$

例 3.9.2 求解 $\max\{f(x) = (x-3)^2\}$, $s.t. 1 \leq x \leq 5$, 它等价于

$$\min\{-f(x)\}, \quad s.t. \quad \begin{cases} g_1(x) = x-1 \geq 0; \\ g_2(x) = 5-x \geq 0 \end{cases}$$

则极值点 x_* 的 $K-T$ 条件为 $\exists \lambda_1, \lambda_2 \leq 0$, 使得

$$\begin{cases} -f'(x_*) + \lambda_1 g'_1(x_*) + \lambda_2 g'_2(x_*) = 0 \\ \lambda_1 g_1(x_*) = 0; \quad \lambda_2 g_2(x_*) \geq 0 \end{cases} \iff \begin{cases} 2(3-x_*) + \lambda_1 - \lambda_2 = 0 \\ \lambda_1(x_*-1) = 0; \quad \lambda_2(5-x_*) = 0 \end{cases}$$

当 $\lambda_1 = \lambda_2 = 0$ (即两约束条件对极值点无效) 时, 解得 $x_* = 3$; 下面考察有效约束条件下的极值点

1. 当 λ_1 和 λ_2 都非零, 方程无解;
2. 当 $\lambda_1 = 0, \lambda_2 < 0$ 时, $x_* = 5, f(x_*) = 4$;
3. 当 $\lambda_2 = 0$, 此时 $\lambda_1 < 0$ 时, $x_* = 1$, 此时 $f(x_*) = 4$.

故 $x_* = 5, x_* = 1$ 是有效约束下的极值点, 它们都是最值点.

例 3.9.3 求解 $\max\{f(x, y) = -(x-5)^2 - (y-5)^2\}$, $s.t. x^2 + y \leq 9; x, y \geq 0$.

解: 将问题写为标准形式如下

$$\min\{-f(x, y)\}, \quad s.t. \quad \begin{cases} g_1(x, y) = 9 - x^2 - y \geq 0; \\ g_2(x, y) = x \geq 0; \\ g_3(x, y) = y \geq 0. \end{cases}$$

极值点 $\mathbf{p}_*(x_*, y_*)$ 应满足的 $K-T$ 条件为: $\exists \lambda_1, \lambda_2, \lambda_3 \leq 0$, 使得

$$\begin{cases} -\nabla f(\mathbf{p}_*) + \lambda_1 \nabla g_1(\mathbf{p}_*) + \lambda_2 \nabla g_2(\mathbf{p}_*) + \lambda_3 \nabla g_3(\mathbf{p}_*) = \mathbf{0}; \\ \lambda_1 g_1(\mathbf{p}_*) = 0; \quad \lambda_2 g_2(\mathbf{p}_*) = 0; \quad \lambda_3 g_3(\mathbf{p}_*) = 0; \end{cases} \implies$$

$$\begin{cases} (5(x_* - 5), 5(y_* - 5)) + \lambda_1(-2x_*, -1) + \lambda_2(1, 0) + \lambda_3(0, 1) = (0, 0) \\ \lambda_1(9 - x_*^2 - y_*) = 0; \quad \lambda_2 x_* = 0; \quad \lambda_3 y_* = 0. \end{cases}$$

1. $\lambda_1 = \lambda_2 = \lambda_3 = 0$ (约束全无效) 时, $(x_*, y_*) = (5, 5)$, 此即无约束下的极值点;
2. $\lambda_1, \lambda_2, \lambda_3$ 全不为零, 即约束不可能同时有效, 此时无解.

下面是只有两个约束同时有效的情形:


3. $\lambda_1 = 0, \lambda_2 < 0, \lambda_3 < 0$, 此时无解;
4. $\lambda_2 = 0, \lambda_1 < 0, \lambda_3 < 0$, 此时无解;
5. $\lambda_3 = 0, \lambda_1 < 0, \lambda_2 < 0$, 此时无解.

下面是只有一个约束有效的情形:

6. $\lambda_1 = \lambda_2 = 0, \lambda_3 < 0$, 解得 $(x_*, y_*) = (5, 0)$;
7. $\lambda_1 = \lambda_3 = 0, \lambda_2 < 0$, 解得 $(x_*, y_*) = (0, 5)$;
8. $\lambda_2 = \lambda_3 = 0, \lambda_1 < 0$ 时, 此时

$$\begin{cases} x_*^2 + y_* = 9 \\ (5 - 2\lambda_1)x_* = 25; \quad 5y_* - \lambda_1 = 25. \end{cases}$$

解得 $(x_*, y_*) \approx (2.2, 4.3)$. 显然 $(2.2, 4.3)$ 是约束下的最大值点; $(5, 0)$ 和 $(0, 5)$ 是约束下的最小值点. 当然, 该问题也可直接图解如下



4 附录篇


4.1 附录一：从边界无边界谈起：一般流形概念简介

在第 2.1 小节对欧几里得空间 $\mathbb{R}^n$ 中的点集 E 定义了内点、外点及边界点的概念. 并说明了这些概念是与考虑点列的极限及如何衡量点之间的“接近”程度等拓扑概念是息息相关的.

对 $E \subseteq \mathbb{R}^n$, 只要在其中有开集的概念, 则就有了一个点的(开)邻域(*neighbourhood*)的概念, 从而也就有了点的“近旁”, 及“接近”一个点的衡量方式了. 当然, 在 $\mathbb{R}^n$ 中, 我们通常给出标准的欧几里得距离的概念, 然后利用该距离定义的开球作为基本开集及基本 δ -邻域, 由此得到了 $\mathbb{R}^n$ 中的标准拓扑, 但读者应该意识到, 这只是其上众多可能拓扑的一种——最直观、自然、也最常用的一种.

另外需要澄清的一点是: 当 $E \subseteq \mathbb{R}^n$ 做为子集时, 它上面的拓扑(即其上的开集等概念)往往是“承袭”自 $\mathbb{R}^n$ 上由距离函数所界定的标准拓扑, 故称之为诱导拓扑(*induced topology*). 但也可以将 E 本身看做一个空间实体——即暂时“忘记”其所从属的背景空间 $\mathbb{R}^n$, 此时, 可独立规定 E 上的开集类型等, 从而界定其拓扑类型, 而这不一定要和其背景空间的拓扑有直接关系. 这一点的重要性体现在下面对一个图形(点集)的边界的边界的考量之中.

先考虑一个例子, $\mathbb{R}^2$ 中的单位圆盘(*unit disk*) $\mathbb{D}^2 = \{(x, y) \mid x^2 + y^2 \leq 1\}$, 我们赋予它以从 $\mathbb{R}^2$ 中的标准拓扑(即由欧几里得距离所规定的开集概念)所诱导出的拓扑. 由于 $\mathbb{D}^2$ 的边界点定义为其任何开邻域 U 中既有 $\mathbb{D}^2$ 中的点又有不在 $\mathbb{D}^2$ 的点, 故单位圆盘的边界即单位圆, 即 $\partial\mathbb{D}^2 = S^1 := \{(x, y) \mid x^2 + y^2 = 1\}$.



自然要问, 如果把 $\mathbb{D}^2$ 看成是一个独立空间(忘掉其背景), 此时如何定义其上的拓扑, 即如何利用它来界定其边界呢? 得到的结果是否与上面将其作为 $\mathbb{R}^2$ 的部分所得出的结论相同?

这种考量是很有意思的, 因为它将直接导致对空间概念的拓广, 即不必在熟悉的 $\mathbb{R}^3$ 及其推广 $\mathbb{R}^n$ 的限制下就能思考可能的图形和空间概念了, 而且我们理应有一种可直接描述(包括 $\mathbb{R}^n$ 在内的)空间的方式, 也就是说, 空间概念是能够独立于 $\mathbb{R}^n$ 这一

熟悉的空间（先验（*a priori*）？）模型而存在的. 狭义相对论和广义相对论的成功又表明这种考虑是有其现实意义的.


直观起见, 假设你是圆盘上的生命, 即你的世界是 $\mathbb{D}^2$, 而不知其它 (当然也不知道 $\mathbb{R}^n$ 的存在), 又该如何认识你所处的空间, 并赋以其类似于 $\mathbb{R}^n$ 中我们已有的几何概念?

好吧, 当在圆盘内部观察某个点的近旁, 会感觉到它和我们熟悉的 $\mathbb{R}^2$ 内某点附近的结构非常相似, 即圆盘内部某点的局部和 $\mathbb{R}^2$ 内某点的局部是一样的! 注意, 这并不是圆盘内部的生命先有了对 $\mathbb{R}^2$ 的知识后所作出的判断, 而是指这两种对“点的近旁”的认知, 虽来自于不同空间的生命的独立意识活动, 但如果按我们人类的意识加以统摄和再“表象 (*represent*)”的话, 则会认为两者是近乎一致的.


基于此, 对圆盘内部的点 $p \in \mathbb{D}^2$, 可按如下方式赋予其领域概念, 即将 $\mathbb{R}^2$ 中任一点 (不妨设为原点 $O(0,0)$) 的标准开领域 U (即一个小圆盘) 用连续映射映到 $\mathbb{D}^2$ 中的 p 附近, 作为 p 点的开领域, 或作为这一概念的“原型” (因为这是按人类意识对两者领域概念比对后的比附, 圆盘上的生命会给出和这个映射所给处的结构一致的开领域概念, 但先天并不会将其理解为某连续映射的象——所谓“天外飞盘”), 即存在连续映射

$$\varphi: U \subseteq \mathbb{R}^2 \longrightarrow \varphi(U) \subseteq \mathbb{D}^2$$

使得 $\varphi(U)$ 包含 p , 则将 $\varphi(U)$ 认作 p (在 $\mathbb{D}^2$ 中) 的一个开领域. 当然, 不同的 U 及不同的连续映射 φ 将给出 p 的不同的开领域. 可形象地将 $\varphi(U)$ 看成是通过 φ 将 U “贴”在 $\mathbb{D}^2$ 上的 p 近旁, 特别地, 如果 U 是一个半径 < 1 的圆盘, φ 是恒等映射, 则 $\varphi(U)$ 即按 U 的原样将其“贴”在 $\mathbb{D}^2$ 的 p 点处.



好, 接下来, 如果圆盘上的生命趋向其边界 S^1 , 它会发现自己“碰壁”了, 不能继续走下去, 好像来到了其所在世界的“边界”. 以领域概念作衡量的话, 它会惊奇地发现在边界点处, 没有像在圆盘内部存在的那种 (在我们来看) 形如 $\varphi(U)$ 的领域了——它的世界的“边界”阻碍它连续地绕边界点走动一圈! 如下图所示




即 p 点的邻域只能是 $\mathbb{R}^2$ 中的某缺角邻域 $U = \{(x, y) \mid x^2 + y^2 < 1, x, y \geq 0\}$ 的映象. 这一特征才是区分边界点和内点的核心依据.

接下来, 我们考察圆盘边界的边界, 即 $\partial^2 \mathbb{D} := \partial(\partial \mathbb{D}) = \partial S^1 = ?$


须强调, 既然考察的是 $\mathbb{D}^2$ 的边界 S^1 之边界, 我们必须想象生活在 S^1 上的生命会如何探寻其所处空间的边界? 基本模式是一致的, 即当点在 S^1 上连续变动时, 其是否会触碰到某些障碍? 显然不能, 圆周上的生命会延圆周永远顺时或逆时旋转下去, 对它来说它的世界是没有界限的, 虽然它会发现它每过一段时间总会回到原出发点. 由此直观, 我们自然认为 $\partial S^1 = \emptyset$, 即它无边. 下面依据边界的定义对其加以严格说明.

首先得明确 S^1 上的邻域概念, 如上段所言, 不能借用其背景 $\mathbb{D}^2$ 中的邻域作为 S^1 上点的邻域, 原因就在于, 探测 S^1 的边界即探测 S^1 内部点的运动趋势, 如果选择超出其外的邻域的话, 相当于容许 S^1 中的点“越界”而出, 与需求不符. 那么, 该如何描述 S^1 上某点 p 的邻域呢? 直观上来看, S^1 上 p 点近旁应由过该点的邻近 (两个方向都考虑) 小开弧来衡量. 依照上面对 $\mathbb{D}^2$ 中开邻域的刻画, 可将其看成是 $\mathbb{R}$ 中过原点的开区间 $(-\epsilon, \epsilon)$ 的在 S^1 上的连续映射象 $\varphi((-\epsilon, \epsilon))$, 使得 $p \in \varphi((-\epsilon, \epsilon))$. 即下图所示



以此为邻域, 则圆周上每一点的任何邻域都是能够一致地加以界定的——即都可看成是 $\mathbb{R}$ 中每个开邻域的连续映射象, 从而知其上所有点都是内点, 故无边界.

但有意思的是, ∂S^1 上点 p 的如上小开弧邻域总可以实现为其在 $\mathbb{D}^2$ 中的某“缺角”邻域在 $\partial \mathbb{D}^2$ 中的部分边界. 这说明, 边界点 p 在 S^1 中的任意邻域同时也是其在 $\mathbb{D}^2$ 中的“缺角”邻域在 $\partial \mathbb{D}^2$ 的边界上的部分, 那么, 其中的点也属于 $\partial \mathbb{D}^2$ 就是不言而喻了!



最后，让我们对以上分析中体现出的数学观念做些总结性说明。

1. 首先，欧几里得空间 $\mathbb{R}^n$ 及其子空间（作为其内部的子集存在）的传统空间理解应该推广为一般流形（*manifold*）概念，它一方面是可独立于 $\mathbb{R}^n$ 存在的，另一方面，它在局部又很象 $\mathbb{R}^n$ 中开领域的连续映射象，也就是说，流形是 $\mathbb{R}^n$ 中的开集（象）通过一定的方式“黏连”成的空间构型。
2. 在确定流形的边界时，选取的领域一定是相对于该流形本身而确定的领域，切不可将其混同为（维度更高的）背景空间中的领域。

对概念做如此拓广和澄清之后，可证明任意流形 M 的边界之边界为空，即边界本身没有边界，或曰：其边无边 —— $\partial^2 M = \partial(\partial M) = \emptyset$ 。

将会看到，这是隐藏在微积分形式框架背后的核心线性枢纽之一，当遇到与之对偶的另一线性枢纽，即微分不再微分 $d^2 = 0$ ，或曰：不微其微，并通过积分“配对”（“相反相成，阴阳比参”）作用后，便成各类“变奏”的共同主题，遂可将“微积分基本定理”推广至无远弗界。

$\partial^2 M = \emptyset$ 的说明： 设 $m \in \partial M$ ，此时，由于 M 可独立于任何 $\mathbb{R}^n$ 而存在，故不能想当然地将边界点用“它在 M 中的任一开领域 $U_m \ni m$ 中有在 M 中的点，同时也存在不在 M 中的点”来界定，因为这时“不属于 M 的点”这个说法本身无意义！

通过上例不难领会一般情形。边界点 m 的特征是：它附近的领域不能是由某 $\mathbb{R}^n$ 中的标准领域 U 的映射象，只能是 $\mathbb{R}^n$ 中的“缺角领域”的映射象；而 m 在 ∂M 中的任意领域 U 总能看成是它在 M 中某“缺角领域” V 在 ∂M 中的部分 $V \cap \partial M$ ，由此即知 U 中点都是 ∂M 中的点，即任意 $m \in \partial M$ 都是 ∂M 的内点，故 $\partial(\partial M) = \emptyset$ 。


你看，只要营造出数学概念栖息的自然“场域”，深刻的数学结论往往就生发于不经意间。最后以一段文字游戏结束：

一图形之有边，乃其上有非边界点，否则，谈何其边？而图形之为一边界也，盖其上皆为边界点，而无非边界点，如是，则谈其边何？

4.2 附录二：从方向导数谈起：一般流形上如何定义切向量？

方向导数的定义背后其实隐藏着一个基本事实 (c.f. 2.3): 将函数 f 限制于其定义域 D 内的一条光滑曲线 c 上时, 即考虑限制函数 $f|_c$, 则它沿 c 在 $p \in c$ 点的瞬时变化率即为 f 沿 c 在 p 处的单位切方向 v 的方向导数, 且计算结果并不依赖于过 p 点的具体光滑曲线的选择, 而只依赖于曲线在 p 处的切向量.


也就是说, 任意两条过 p 的光滑曲线, 只要它们在 p 处具有相同的切向量, 那么沿它们计算出的函数在 p 点的变化速率将是相同的.




$$\begin{aligned} \left. \frac{d}{dt} \right|_{t=0} f_{c_1}(t) &= \left. \frac{d}{dt} \right|_{t=0} f_{c_2}(t) = \\ &= \left. \frac{\partial f}{\partial v} \right|_p = \nabla f(p) \cdot \frac{v}{\|v\|} \end{aligned}$$

这一基本事实, 不仅是方向导数这一概念的隐性基石, 更是有其深层意涵的, 即它可用来“转释”切向量 (*tangent vector*) 这一概念, 使我们能摆脱通常在 $\mathbb{R}^n$ 中的图形某点标记一个“箭头”作为切向量这一桎梏.

比如对下面的二维球面 S^2 , 如将其看成 $\mathbb{R}^3$ 中的图形, 那么它在其上某点的切向量这一概念的含义是熟知的, 即 (在 $\mathbb{R}^3$ 中) 做该点的切平面, 则切平面上的任意方向都是 S^2 在该点的切向量.



S^2 作为 $\mathbb{R}^3$ 中的图形



S^2 作为独立存在的流形

但若将 S^2 视作独立存在的流形 (见附录一), 此时无背景空间这一意象, 自然也就没有可视觉化的**实体**切平面这一意象了, 那该如何定义 p 点处的切向量?

为此, 我们得重头梳理方向导数的定义, 以便将隐藏于其背后的“切向量”身影给彰显出来, 以此揭示“切向量”在微分学中的功能属性, 进而可将其功能属性抽象出来, 作为一般切向量的定义, 从而可考虑一般流形上的“切向量”.

我们以 $z = f(x, y)$ 在 $p(x_0, y_0)$ 点沿 $l = (\cos \theta, \sin \theta)$ 的方向导数为例来说明. 先

回忆其定义

$$\begin{aligned}\nabla_l|_p f &= \left. \frac{\partial f}{\partial l} \right|_p = \lim_{t \rightarrow 0} \frac{f(x_0 + t \cos \theta, y_0 + t \sin \theta) - f(x_0, y_0)}{t} \\ &= \cos \theta \left. \frac{\partial f}{\partial x} \right|_{(x_0, y_0)} + \sin \theta \left. \frac{\partial f}{\partial y} \right|_{(x_0, y_0)} = \nabla f|_p \bullet l\end{aligned}$$

其背后的隐藏线索是，对任意过 p 点的曲线 $\gamma(t) = (x(t), y(t))$ (设 $\gamma(0) = p$)，只要它在 p 点处的切向量 $\gamma'(0) = (x'(0), y'(0))$ 与 l 同方向，即 $\gamma'(0) = \|\gamma'(0)\|l$ ，则

$$\nabla_{\gamma'(0)} f = \nabla f|_p \bullet \frac{\gamma'(0)}{\|\gamma'(0)\|} = \nabla f|_p \bullet l = \nabla_l|_p f$$

即 $\forall \gamma(t): \gamma(0) = p$, 且 $\gamma'(0) = l$, 都有

$$\left. \frac{d}{dt} \right|_{t=0} f(\gamma(t)) = \left. \frac{d}{dt} \right|_{t=0} f(x(t), y(t)) = \nabla f|_p \bullet \gamma'(0) = \nabla_l|_p f \cdot \|\gamma'(0)\|$$

这里需要强调的是，虽然方向导数 $\nabla_l f(p)$ 的计算结果虽然只依赖于点 p 及方向向量 l ，但将 l 看成某一曲线 $\gamma(t)$ 在 p 处的切向量 $\gamma'(t)$ 不仅是有其现实需要的（将函数限制于曲线上是种很自然的操作，比如在考察函数在曲线约束下的极值问题时），而且从认知完备的角度来说，也是必须的。

这是因为：利用方向导数定义作计算的本质就在于考察函数在无穷小移动

$$(x_0, y_0) \rightarrow (x_0 + \cos \theta \Delta t, y_0 + \sin \theta \Delta t)$$

下的 ($\Delta t \rightarrow 0$) 无穷小变化，那么，自然要问：这一无穷小移动该如何具体实现？

自然，该无穷小移动可看成是沿着过 p 点的某曲线 $\gamma(t) = (x(t), y(t))$ 上点的无穷小运动，即瞬时速度 $\gamma'(0) \times$ 时间 Δt 。所以，曲线“意象”是自然隐于考量背景里头的，需将其显明化，以便理解它的深层内涵，并静观其如何将我们引入新的概念天地。

关键视角： l 自然可看成平面 $\mathbb{R}^2$ 本身在 p 点处的一个切向量（或切方向）——虽然这时考察切向量似是平凡的（因平面上任一点的切平面乃其自身），而且，可将其实现为某条曲线在 p 处的切向量。这里的要点是，将其实现为曲线在该点的切向量（即考虑运动例子在该点的速度）的方式是多样的——有无穷多条曲线在该点给出同一切向量。

所以，如果不想用平面上通常的“箭头”来定义切向量（很多时候这种意象是不存在的，比如在抽象流形上，所以我们必须要从箭头的直观里走出来才行），则可采用下面的概念途径。

可将 $\mathbb{R}^2$ 中 p 点的任一“切向量”（在这里就是 p 点处的向量） $\mathbf{v}$ 定义为所有过 p 点局部（指定义在 p 点附近）光滑曲线的等价类（*equivalent class*），即所有在 p 点有切向量 $\mathbf{v}$ 的局部光滑曲线全体形成的类（*class*）看成是 $\mathbf{v}$ 。即可将 $\mathbf{v}$ 看成下面的局部光滑曲线的几何

$$\{\gamma(t) \subseteq U(p, \delta) : \gamma(0) = p; \gamma'(0) = \mathbf{v}\}$$

但这样定义有点别扭？我们换一种更合理的叙述方式。

设 $\gamma_1(t)$ 和 $\gamma_2(t)$ 都是过 p 点的局部曲线，即 $\gamma_1(0) = \gamma_2(0) = p$ ，则称它们是等价的如果 $\gamma_1'(0) = \gamma_2'(0)$ ，记为 $\gamma_1(t) \sim \gamma_2(t)$ 。该关系是等价关系，因为下面几条是显然成立的

1. $\gamma(t) \sim \gamma(t)$ （自反性）
2. $\gamma_1(t) \sim \gamma_2(t) \implies \gamma_2(t) \sim \gamma_1(t)$ （对称性）
3. $\gamma_1(t) \sim \gamma_2(t)$ 且 $\gamma_2(t) \sim \gamma_3(t)$ ，则 $\gamma_1(t) \sim \gamma_3(t)$ （传递性）

将与 $\gamma(t)$ 等价的所有局部曲线看成是一类，并记之为 $[\gamma(t)]$ ，由于它里面的所有曲线在 $t = 0$ 处的切向量都是相同的，且这是该等价类中所有曲线所具有的共同属性，故该等价类就是刻画该共同属性的，而该共同属性可用切向量 $\mathbf{v}$ 命名之。即 $\mathbf{v}$ 是该等价类中所有曲线在 p 点的共同切向量的一个符号表示。

等价类中的曲线有无穷多个，其中任何一条都可作为在 p 的切向量都是 $\mathbf{v}$ 的代表（*representative*）。可通过上等价关系对过 p 点的局部光滑曲线进行分类，即相互等价的曲线并为一类，且每条曲线都可被归入唯一一个等价类里头。这些等价类的全体即可定义为 $\mathbb{R}^2$ 在 p 点的切空间（*tangent space*），常记做 $T_p\mathbb{R}^2$ ，即有

$$T_p\mathbb{R}^2 := \{[\gamma(t)] : \forall \text{ 局部光滑曲线 } \gamma \subseteq U(p, \delta), \gamma(0) = p\}$$

总算从“箭头”的世界中暂时抽离出了，在概念层面已算是跨了一大步，但这只是对切向量这一概念抽象的第一步。为什么说是第一步呢？因为毕竟我们是在 $\mathbb{R}^2$ 中考虑，对其中曲线 γ 的切向量有直观认识，并将其等同于 γ' ，之所以这样等同，也是因为将 $\gamma'(t) = (x'(t), y'(t))$ 不假思索地等同为 $\mathbb{R}^2$ 中的一个向量（二元数组）了。

也就是说，这一切看似顺理成章的操作背后都有很多直观预设，这些直观预设对空间 $\mathbb{R}^2$ 是天然的，那自然要问，如果不是这么熟悉的 $\mathbb{R}^2$ ，而是抽象的流形，那这些直观预设还能否成立？如不能，可否在概念上对其超越呢？

稍微转思，便可进行对切向量的第二步抽象，而抽象的关键不是别的，正是方向导数的定义（只是需将切线向量这一意象考虑在内）！即 $\mathbb{R}^2$ 上某点 p 的切向量（此处按曲线等价类理解） $\mathbf{v}$ 的功能属性是：

利用它可定义在 p 点附近的可导函数 f 沿其的方向导数, 即对 $\mathbf{v} = [\gamma(t)]$ 中的任意一条曲线 $\gamma(t)$, 将 f 限制于其上 $f|_{\gamma(t)}$ 得到 t 的函数, 则函数沿着曲线在 p 点的变化速率是不依赖于代表曲线 $\gamma(t)$ 的选择的, 即

$$\left. \frac{d}{dt} \right|_{t=0} f_{\gamma(t)} = \nabla f|_p \bullet \mathbf{v} = \|\mathbf{v}\| \cdot \nabla_{\mathbf{v}}|_p f \quad \forall \gamma(t) \in [\gamma(t)] =: \mathbf{v}$$

下面, 我们将此功能属性抽象为切向量的定义. 即将 $\mathbf{v}$ 理解为对 p 点附近全体可微函数构成的空间 $C_p^\infty(\mathbb{R}^2)$ 上的沿曲线的导数这一算子

$$\mathbf{v} : C_p^\infty(\mathbb{R}^2) \longrightarrow \mathbb{R} \quad f \mapsto \left. \frac{d}{dt} \right|_{t=0} f_{\gamma(t)}(t), \quad \forall \gamma(t) \in [\gamma(t)] =: \mathbf{v}$$

该映射是 $\|\mathbf{v}\| \nabla_{\mathbf{v}}|_p$, 本质是求方向导数算子. 为方便起见, 我们将其称为 p 处的导算子 (derivation), 记之为 $D_{\mathbf{v}}$, 则 $\mathbf{v}$ 的功能属性体现在导算子中

$$D_{\mathbf{v}} : C_p^\infty(\mathbb{R}^2) \longrightarrow \mathbb{R} \quad f \mapsto D_{\mathbf{v}} f = \nabla f|_p \bullet \mathbf{v} = f'|_{\gamma(t)}(0) \quad (\forall \gamma(t) \in [\gamma(t)] =: \mathbf{v})$$

导算子由以下性质刻画

1. 线性性: $D_{\mathbf{v}}(kf + lg) = kD_{\mathbf{v}}f + lD_{\mathbf{v}}g, \forall f, g \in C_p^\infty(\mathbb{R}^2), \forall k, l \in \mathbb{R};$
2. 莱布尼茨法则: $D_{\mathbf{v}}(fg) = D_{\mathbf{v}}f \cdot g + f \cdot D_{\mathbf{v}}g.$

可证明, 如一线性算子 D 满足如上性质, 则它必形如 $D_{\mathbf{v}}$. 另外, p 处所有满足上面性质的导算子的全体构成一个线性空间, 由于它里面的向量和 $D_{\mathbf{v}}$ 一一对应, 而 $\mathbf{v}$ 作为曲线等价类, 其全体就是上面定义的切空间 $T_p\mathbb{R}^2$, 从而在功能属性上来讲, 切空间 $T_p\mathbb{R}^2$ 可等价地定义为 p 处所有导算子全体构成的线性空间.

如此, 便完成了对切向量这一概念 (按其功能属性) 的抽象刻画, 这不仅使我们摆脱“箭头”描述的桎梏, 同时也能将其推广到一般流行上.

回到我们一开始的问题, 即将 S^2 看做抽象流形, 又该如何描述其上 p 点的切平面呢? 首先切平面 $T_p S^2$ 是 p 点处切向量构成的线性空间, 而切向量, 按上面的理解, 可定义为过 p 点的所有光滑曲线的等价类, 即定义关系: $\gamma_1 \sim \gamma_2$ 当且仅当

$$\forall f \in C_p^\infty(S^2) \quad \text{都有} \quad \left. \frac{d}{dt} \right|_{t=0} f|_{\gamma_1(t)} = \left. \frac{d}{dt} \right|_{t=0} f|_{\gamma_2(t)}$$

这是一个等价关系, 其等价类全体和之前曲线的等价类全体是相同的, 只是这里没直接引入曲线切向量这一意向, 而是将其用它的功能属性给转释了一番. $T_p S^2$ 就是曲线等价类之全体了. 由此, 更一般流形上如何定义切向量及切空间的手法亦将自明.

4.3 附录三：对行列式求导

我们想知道，行列式 $\det$ 作为矩阵空间 $\mathbb{M}_n(\mathbb{R})$ 上的函数，是如何依赖于矩阵的无穷小移动的. 即我们想推导行列式函数的微分公式.

$$\det: \mathbb{M}_n(\mathbb{R}) \longrightarrow \mathbb{R} \quad A \longmapsto \det A$$

定理 4.3.1 雅可比 (Jacobi) 公式: 我们有如下微分公式

$$\boxed{d(\det A) = \operatorname{tr}(\operatorname{adj}(A) dA)}$$

证明: 设 $A = [a_{ij}]_{n \times n}$. 所以 $\det A = \det(a_{i1}, \dots, a_{ij}, \dots, a_{in})$. 则

$$d(\det A) = \sum_{i=1}^n \sum_{j=1}^n \frac{\partial \det A}{\partial a_{ij}} da_{ij}$$

由拉普拉斯定理, 按第 i 行展开, 得

$$\det A = \sum_{k=1}^n a_{ik} \operatorname{adj}^T(A)_{ik}$$

所以

$$\begin{aligned} \frac{\partial \det A}{\partial a_{ij}} &= \frac{\partial (\sum_{k=1}^n a_{ik} \operatorname{adj}^T(A)_{ik})}{\partial a_{ij}} = \sum_{k=1}^n \frac{\partial (a_{ik} \operatorname{adj}^T(A)_{ik})}{\partial a_{ij}} \\ &= \sum_{k=1}^n \operatorname{adj}^T(A)_{ik} \frac{\partial a_{ik}}{\partial a_{ij}} + \sum_{k=1}^n a_{ik} \underbrace{\frac{\partial \operatorname{adj}^T(A)_{ik}}{\partial a_{ij}}}_0 \\ &= \sum_{k=1}^n \operatorname{adj}^T(A)_{ik} \delta_{jk} = \operatorname{adj}^T(A)_{ij} \end{aligned}$$

从而

$$d(\det A) = \sum_{i=1}^n \sum_{j=1}^n \operatorname{adj}^T(A)_{ij} da_{ij} = \operatorname{tr}(\operatorname{adj}(A) dA) \quad \square$$

由上面证明过程, 我们得到

推论 4.3.1 $\det A$ 对 a_{ij} 的微分关系由下给出

$$\boxed{\frac{\partial \det A}{\partial a_{ij}} = \operatorname{adj}(A)_{ji}}$$

推论 4.3.2 给定 $A(t) = [a_{ij}(t)]_{1 \leq i, j \leq n}$ 可逆, 且 $a_{ij}(t)$ 对 t 的依赖可微, 则有

$$\boxed{\frac{d}{dt} \det A(t) = \det A(t) \cdot \operatorname{tr} \left(A(t)^{-1} \cdot \frac{dA(t)}{dt} \right)}$$

证明:

$$\begin{aligned} \frac{d}{dt} \det A(t) &= \operatorname{tr} \left(\operatorname{adj}(A(t)) \frac{dA(t)}{dt} \right) \stackrel{A^{-1} = \frac{\operatorname{adj} A}{\det A}}{=} \\ &= \det A(t) \operatorname{tr} \left(A(t)^{-1} \cdot \frac{dA(t)}{dt} \right) \quad \square \end{aligned}$$

例 4.3.1 在上公式中令 $A(t) = e^{tB}$ 则有

$$\frac{d}{dt} \det e^{tB} = \det e^{tB} \operatorname{tr} (e^{-tB} \cdot e^{tB} \cdot B) = \det e^{tB} \operatorname{tr} B$$


也即, 函数 $f(t) := \det e^{tB}$ 满足如下微分方程

$$\frac{df}{dt} = (\operatorname{tr} B) f \implies f(t) = C e^{(\operatorname{tr} B)t}$$

常数 C 由 $f(0) = \det e^0 = \det I = 1$. 即 $C = 1$. 从而得到公式

$$\det e^{tB} = e^{t \operatorname{tr} B} \stackrel{\text{令 } t=1}{\implies} \det e^B = e^{\operatorname{tr} B}$$

迹作为梯度算子: 我们接着计算 $\det$ 在矩阵空间上的方向导数. 先计算 $\det$ 在单位矩阵 $I \in \mathbb{M}_n(\mathbb{R})$ 处沿方向 $T \in \mathbb{M}_n(\mathbb{R})$ 的方向导数 (即变化率).



$$\det'(I)(T) := \nabla_T \det(I) = \lim_{\epsilon \rightarrow 0} \frac{\det(I + \epsilon T) - \det(I)}{\epsilon}$$

$$\begin{aligned}
&= \lim_{\epsilon \rightarrow 0} \frac{\epsilon^n \det(\epsilon^{-1}I + T) - 1}{\epsilon} = \lim_{\epsilon \rightarrow 0} \frac{\epsilon^n \left[\frac{1}{\epsilon^n} + \operatorname{tr}(T) \frac{1}{\epsilon^{n-1}} + \dots \right] - 1}{\epsilon} \\
&= \lim_{\epsilon \rightarrow 0} \frac{1 + \epsilon \operatorname{tr}(T) + o(\epsilon^2) - 1}{\epsilon} = \operatorname{tr} T
\end{aligned}$$

即迹作为单位矩阵附近的梯度算子

$$\boxed{\operatorname{Tr} = \det'(I) = \nabla \det(I)}$$

注记 4.3.1 若 A 可逆, 我们计算在 $\det$ 在 A 点处沿 T 的方向导数, 即有

$$\begin{aligned}
\nabla_T \det A &= \lim_{\epsilon \rightarrow 0} \frac{\det(A + \epsilon T) - \det A}{\epsilon} = \\
\lim_{\epsilon \rightarrow 0} \frac{\det[AA^{-1}(A + \epsilon T)] - \det A}{\epsilon} &= \lim_{\epsilon \rightarrow 0} \frac{\det A [\det(A^{-1}(A + \epsilon T)) - \det I]}{\epsilon} \\
&= \lim_{\epsilon \rightarrow 0} \frac{\det A [\det(I + \epsilon A^{-1}T) - \det I]}{\epsilon} \\
&= \det A \nabla_{A^{-1}T} \det I = \det A \operatorname{tr}(A^{-1}T).
\end{aligned}$$

即得

$$\boxed{\nabla_T \det A = (\det A) \operatorname{tr}(A^{-1}T)}$$

4.4 附录四：拉格朗日乘子的分析力学起源